

册05 · 多元微积分与凸优化

《数学基础》· 创世游戏系列丛书基础卷

高维怎么找最优

7 册 · 53 章 · 苏格拉底对话体自学教材

造物主（读者） $\rightleftharpoons$ 老谟（毒舌导师）—— 知识是推导出来的，不是背出来的

开源教材 · CC BY 4.0 · 在线版: lwq200.github.io/math-foundation

目录

1. 第 01 章 · 多元函数与偏导——山有千万面，先看哪边
2. 第 02 章 · 多元链式法则与多元泰勒——让梯度学会"拐弯"
3. 第 03 章 · 多元积分——高维"面积"怎么加出来
4. 第 04 章 · 凸集与凸函数——什么形状的"碗"敢保证一滑到底
5. 第 05 章 · 凸性判定与二次型——怎么用二阶导判定"这碗有没有歪坑"
6. 第 06 章 · 无约束优化与梯度下降——闭着眼睛下山，凭什么能到谷底
7. 第 07 章 · 高维景观鞍点与局部最优——深度学习为什么怕"马鞍"不怕"小坑"
8. 第 08 章 · 约束优化——拉格朗日乘子与 KKT：戴上锁链找谷底
9. 《多元微积分与凸优化》· 计算答案速查页

第 01 章 · 多元函数与偏导——山有千万面，先看哪边

本章从哪个问题出发：一元函数 $y=f(x)$ ，你要么往左、要么往右，只有两个方向。可当你真的站在一座山的山坡上——面前是 360° 无数个方向，你要往哪边迈脚才能最快上山？"这一面"有多陡，还能用"一个数"说清楚吗？推导到哪个结论：只固定一个方向看（偏导）不够——它只告诉你"东西向"和"南北向"各自多陡。把所有方向的陡峭程度合成一个**向量**（梯度），你会惊异地发现：**任意方向的坡度，不过是"梯度"在这个方向上的投影；而上山最快的方向，正是梯度自己指向的方向。**

核心认知：**多元函数的"陡峭程度"不是一个数，而是一个向量（梯度）。** 梯度同时回答两个问题：朝哪个方向变化最快（方向），最快的变化率有多大（长度）。这一章是你走进"高维求最优"的第一级台阶——后面所有章节（梯度下降、鞍点、KKT）都踩在这块"梯度"上。

引子

老谟的客厅里摊着一张等高线地形图，图上弯弯曲曲的红线一圈套一圈，中间用铅笔重重标了个圈。

"我明天要陪人去爬山，"我盯着那张图，"可是老谟，我看了半天这图，有一个问题憋住了——图里只标了'等高线'，也就是高度相同的地方连起来的线。可我站在坡上的时候，想知道的是**我该往哪边走才最陡**。你给我讲讲，这跟一元函数可不一样：一元函数 $y=f(x)$ ，我想往哪边看就看哪边，左边右边两条路。可这是座山，我面前有 360° 的方向，我这脚，往哪迈？"

老谟把铅笔往图上一戳："你说得对，这确实不一样。那我们先从一个更笨的问题开始——**你说'山的陡峭'，它到底该用几个数来描述？**"

我愣了一下："几个数？.....一个数不就够了？坡度嘛， 45° 、 60° ，一个角度。"

"一元函数用一个导数就能描述陡峭，是因为你只能往一个方向走。现在你面前有**无穷多个**方向——你拿一个数，怎么装得下无穷多个方向各自的陡峭程度？"

".....装不下。可我总不能数出 360 个坡度来吧？"

"那你就想吧。"老谟把笔往桌上一放，"这一章，就是让你亲手把'一个数'长成'一个向量'。别急，先从最省事的那一步走起。"

对话引擎

第 1 轮：一座山有无数个方向——"陡峭"需要一个"数"还是"一个向量"

老谟："你站在这张图的 A 点上。我现在让你回答：'A 点有多陡？'你张口就来，报一个数给我。你打算怎么报？"

造物主：".....我先朝东走一步试试？感觉一下东边是上坡还是下坡，陡不陡。"

老谟："好，你朝东试了，报了个数。那我再问你：'A 点有多陡？' 你这回朝**北**走一步再试试——报出来的，还是刚才那个数吗？"

造物主：".....不一定。山是歪的，朝东可能平缓、朝北可能陡峭。朝东报一个数，朝北又是另一个数。"

老谟："那你刚才那句'一个数就够了'，还作数吗？"

造物主："不作数了。A 点'有多陡'，不是一个数能装完的——每个方向都有自己的坡度。"

老谟："所以你被逼到一个选择面前：要么老老实实把无穷多个方向全都试一遍——你试得完吗？要么，**找个更聪明的法子，用有限的几个数，把'所有方向有多陡'这件事全都包进去。**数学家当年也是被同一个问题卡住的。我们先看他们最省事的那个办法——先不贪心，只挑两个方向看。"

知识锚点：多元函数——"输入"不止一个数

【概念深挖】这一章我们要处理的函数长这样： $f(x, y)$ ——输入是两个数，输出是一个数。比如你站的山：输入是"平面坐标 (x, y) "，输出是"该点的高度 $f(x, y)$ "。更一般地， $f(x_1, x_2, \dots, x_n)$ 输入 n 个数，输出 1 个数，叫 **n 元函数 (function of several variables)**。

注意它和一元函数的关键差别：一元函数的图像是**一条曲线**，你站在上面只有左右两个方向；二元函数 $f(x, y)$ 的图像是**一张曲面**（在三维空间里），你站在曲面上，面前是**一整圈的切线方向**。**"输入多了一个维度"这件事，直接导致"陡峭"从一个数膨胀成一个向量。**这就是本章全部故事的起点。

【历史溯源】多变量微积分的真正奠基要等到 18 世纪。**克莱罗 (Clairaut, 1713–1765)** 在研究曲面几何时较早系统处理"同时对两个变量求导"的问题，他在 1740 年左右给出了后来以他命名的定理——**混合偏导数相等的条件 (克莱罗定理)**。之后欧拉、拉格朗日把多变量求导的算法补全。至于那个扭来扭去的偏导符号 ∂ ，则是**雅可比 (Jacobi, 1804–1851)** 在 1841 年前后推广使用的——他用 ∂ 强调"这是偏导数，不是对唯一变量的全导数"，这个约定沿用至今。**数学家花了一个多世纪才搞定"一个数装不下多方向陡峭"这件事，所以你一时绕不出来，不丢人。**

第 2 轮：先只挑两个方向看——"把 y 冻住，只让 x 动"

老谟："现在你站 A 点。你答应我不贪心，只挑两个方向看。你说，挑哪两个？"

造物主：".....朝东 (x 方向) 和朝北 (y 方向) 吧？这俩横平竖直，好认。"

老谟："行。那我问你：朝东这个方向，你怎么测量它的坡度？"

造物主："朝东走一小步 Δx ，看高度变了多少 Δf ，比值就是平均坡度……这跟一元函数求导不是一样吗？"

老谟："一样，也不一样。一元函数里， x 一动， f 跟着动，就完了。可你现在是二元函数 $f(x,y)$ ——你朝东走， x 在变， y 呢？"

造物主："…… y 不变。我是正东走的， y 一直没动。"

老谟："这就对了。朝东走 = 把 y 冻住当常数，只把 f 看成 x 的一元函数来求导。这个操作，数学家给它起了个名字叫**偏导**——'偏'就偏在：我只动一个变量，其他全都按住不动。你先按这个思路，说说朝北该怎么做？"

造物主："朝北走 = 把 x 冻住当常数，只把 f 看成 y 的一元函数来求导。……这样每个方向我都只剩一个变量在动，跟一元函数一模一样了！"

老谟："你摸到偏导的精髓了：**多元函数求导的'笨办法'，就是把其他变量全冻住，退回一元函数**。可你自己也承认过——朝东的坡度和朝北的坡度是两回事，是两个数。那我只给你这两个数，你站 A 点朝**东北**（45°）走，坡度是多少？用这两个数，能算出来吗？"

知识锚点：偏导数——"按住其他变量，只动一个"

【概念深挖】**偏导数 (partial derivative)** 的定义：设 $f(x, y)$ ，把 y 当作常数，对 x 求导，得到

$$f_x(x, y) = \partial f / \partial x = \lim_{h \rightarrow 0} [f(x+h, y) - f(x, y)] / h$$

把 x 当作常数，对 y 求导，得到 $f_y(x, y) = \partial f / \partial y$ 。记号里那个 ∂ 就是偏导号，读作"偏"——它提醒你：**这个导数是在"按住其他变量"的前提下算的，不是全导数**。计算上，它和一元求导完全一样，只是每动一个变量前，要把其余变量当"带字母的常数"处理。

例： $f(x, y) = x^2y + \sin y$ 。

- 对 x 求偏导：把 y 当常数， x^2 的导数是 $2x$ ， x^2y 对 x 的偏导是 $2xy$ ； $\sin y$ 与 x 无关，当常数，导数为 0。得 **$f_x = 2xy$** 。
- 对 y 求偏导：把 x 当常数， x^2y 对 y 的偏导是 x^2 ； $\sin y$ 对 y 的导数是 $\cos y$ 。得 **$f_y = x^2 + \cos y$** 。

【工程实践】为什么工程师必须先练"偏导"这一手？因为**几乎所有"调参"场景都是多元的**。你在训练一个模型，参数是 $w_1, w_2, \dots, w_n$ ——你手里只有一个损失函数 $L(w_1, \dots, w_n)$ 要往下压。**你不可能同时乱动所有参数，只能"按住其他参数，单独试这一个怎么变"——这恰恰就是偏导**。后面第 6 章你会看到，整个梯度下降就是在反复做这件事：算所有偏导、打包成向量、朝那个方向迈一步。**偏导是"多元微积分"和"机器学习"之间的第一块接头**。

第 3 轮：两个方向不够——方向导数登场

老谟："回到刚才的问题。你手里有两个数：朝东的坡度、朝北的坡度。现在我问你朝**东北**（45°）的坡度——你答得上来吗？"

造物主：".....答不上来。东北既不是正东也不是正北，感觉是'两个都有点'。可'有点'是多少？总不能拿朝东的坡度和朝北的坡度加起来除以二吧？"

老谟："那我们先不急着算。先把这个新问题**立起来**：你现在需要的是一个新概念——**朝任意给定方向的坡度**。它得比偏导更'全能'：偏导只会东西向和南北向，而你要的是 360° 任何一个方向都能回答。数学家管这个叫**方向导数**。它长什么样？你自己说：朝单位方向 u 走，坡度怎么定义？"

造物主：".....跟偏导一个思路？朝 u 方向走一小步，高度变化量除以步长。只不过步长不是一个单纯的 Δx 了，得同时动 x 和 y 。"

老谟："你定义得对。方向 $u = (u_1, u_2)$ 是**单位长度**的方向，朝它走 t 步，坐标变成 $(x + tu_1, y + tu_2)$ ，高度从 $f(x,y)$ 变到 $f(x+tu_1, y+tu_2)$ ，那么

$$D_u f(x,y) = \lim_{t \rightarrow 0} [f(x+tu_1, y+tu_2) - f(x,y)] / t$$

就是朝 u 方向的方向导数。**注意偏导就是它的特例**： $u = (1,0)$ 时就是 f_x ， $u = (0,1)$ 时就是 f_y 。定义立起来了——可你自己马上会发现一个麻烦：这定义要对**每一个方向**单独算一次极限，360° 就要算 360 个极限。**这条路走得通，但你愿意这么干吗？**"

知识锚点：方向导数——朝任意方向的"坡度"

【概念深挖】**方向导数 (directional derivative)**：设 $u = (u_1, u_2)$ 为单位向量 ($u_1^2 + u_2^2 = 1$)， f 在点 (x,y) 朝 u 方向的方向导数为

$$D_u f(x,y) = \lim_{t \rightarrow 0} [f(x + t \cdot u_1, y + t \cdot u_2) - f(x,y)] / t$$

直觉：从点 (x,y) 出发，沿着 u 方向迈一小步 t ，测高度变化率。**它回答的问题比偏导更完整**："这座山上，我朝这个方向走，坡有多陡？" 偏导只是它取 $u=(1,0)$ 和 $u=(0,1)$ 的两个特例。

【概念深挖】方向导数有两个必须钉死的细节：

1. **u 必须是单位向量**（长度 1）。如果 u 长度不是 1，你迈的那"一小步 t "就不是"一步"而是"0.7 步"——测出来的就不是"每步变化率"，数值会失真。**先把方向归一化（除以自己的长度），再算方向导数。**

2. **极限的存在性**：方向导数是一个极限，极限可能不存在（比如曲面在该方向上有棱）。后面反例里你会亲眼看到一个“朝所有轴方向都有偏导、却几乎任何别的方向都没有方向导数”的病态函数。

【工程实践】方向导数的工程直觉：“沿着这个策略方向改，指标会涨还是会跌？涨多少？”比如你调参时想同时微调多个超参数——“把学习率 $\times 1.1$ 、批大小 $\times 0.9$ ”这个组合方向，损失函数朝这个方向走是升是降，就是方向导数。它把“一个方向”翻译成“一个变化率”，是所有“往哪儿走”类问题的统一度量。

第 4 轮：无穷多个方向，难道要算无穷多个极限？

老谟：“方向导数定义好了。可你自己数数——一个点有 360° 无限多个方向，每个方向都要单独算一个极限。这要是真这么干，工程师早累死了。你回头看看你手里那点家当：朝东的偏导 f_x 、朝北的偏导 f_y 。就这两个数，你觉得够不够拼出任意方向的方向导数？”

造物主：“……拼出来？可是东北方向的坡度和 f_x 、 f_y 什么关系？我不是说不能简单平均嘛……”

老谟：“别猜平均值。我们一步一步来：你朝东北走，等于**同时**往东走一点、往北走一点。假设曲面在这一点是**平滑**的（没有棱、没有台阶），那你迈这一小步，高度变化能不能看成‘往东那部分贡献的 + 往北那部分贡献的’？”

造物主：“能……吧？往东走贡献 $f_x \times$ 东向位移，往北走贡献 $f_y \times$ 北向位移，加起来就是总高度变化。东向位移是 $t \cdot u_1$ ，北向位移是 $t \cdot u_2$ ，所以总变化 $\approx f_x \cdot (t \cdot u_1) + f_y \cdot (t \cdot u_2)$ 。”

老谟：“你刚刚干了一件大事，自己可能还没发现。把 t 除下去，你得到的是

$$D_u f \approx f_x \cdot u_1 + f_y \cdot u_2$$

你看清楚这个式子的结构：左边是‘朝任意方向 u 的坡度’，右边是两个已知数 f_x 、 f_y 分别乘上 u 的两个分量再相加。你有没有觉得，这个式子眼熟？”

造物主：“……乘起来再相加？这不就是**点积**的样子吗？把 (f_x, f_y) 和 (u_1, u_2) 这两个向量做点积，就是这个式子！”

老谟：“抓住它了。**方向导数 = 一个由偏导组成的向量，和方向向量做点积**。那个“由偏导组成的向量”，数学家给它起名叫**梯度**。这一下，无穷多个方向的坡度，全都被这两个数（ f_x 和 f_y ）装进去了——你不需要算 360 个极限，你只需要算 2 个偏导，然后任意方向一问，做个点积就出答案。”

▮ 知识锚点：梯度——把“所有方向的陡峭”装进一个向量

【概念深挖】**梯度 (gradient)**：把 f 对每个变量的偏导打包成一个向量：

$$\nabla f(x,y) = (f_x(x,y), f_y(x,y)) \quad (\text{三元: } \nabla f = (f_x, f_y, f_z))$$

∇ 读作"nabla", 是倒置的三角形符号。**梯度把"一个点所有方向的陡峭信息"压缩进了"一个向量"**——这一压缩, 就是本章的核心魔法: 你不再需要 360 个数, 只需要 n 个 (n 个输入变量就有 n 个偏导)。

为什么方向导数 = 梯度·方向 (点积): 在 f 平滑 (可微) 的前提下, 朝单位方向 u 的方向导数正是

$$D_u f = \nabla f \cdot u = f_x \cdot u_1 + f_y \cdot u_2$$

(严格证明见严格化走廊定理 1。) **这个公式是本章的"总钥匙"**: 以后你要问"朝任意方向走多陡", 一律先算梯度, 再和方向做点积, 永远不用回到定义去算极限。

【历史溯源】"梯度"这个术语出自麦克斯韦 (James Clerk Maxwell) 在 1873 年的《论电与磁》。他在研究电磁场时需要一个词描述"场的强度朝哪个方向增长最快", 于是借了气象学里"gradient" (气压梯度) 的说法。注意一件耐人寻味的事: **梯度这个工具是被物理逼出来的——工程师/物理学家先需要"往哪儿走最陡", 数学家才回头把它的理论钉牢。** 你现在学的顺序 (先偏导、再梯度), 和人类当年被问题追着跑的路径, 方向一致。

【工程实践】**梯度是"下山算法"的罗盘**: 训练模型要找损失函数的谷底, 办法就是"算梯度, 朝负梯度方向走" (第 6 章梯度下降)。你不需要知道损失面长什么样 (几百个参数根本画不出来), 只需要**在每个点算出梯度这个向量, 它永远指着"上坡最陡"的方向, 朝反方向走就是"下坡最陡"**。这就是为什么"自动求梯度"是每个深度学习框架的标配功能——**梯度, 是多元微积分写给工程的通行证。**

【实现思考】如果让你写一个函数「输入任意方向、输出该方向坡度」, 你会怎么实现? **最笨的写法**: 对每个方向单独算一次"差商极限"——每问一个方向就要一次极限, 慢且不稳, 方向无穷多, 根本写不完。**聪明的写法**: 先算一次梯度向量存下来, 之后任何方向只需一个点积 $D_u f = \nabla f \cdot u$ ——**把"每问一次都要算极限"降级成"算一次梯度、之后每次只做点积"**。深度学习框架的自动求梯度 (autograd) 正是这个思路: **先反向传播把梯度算好存下, 之后任何方向的查询都是点积。** 这就是"打包成向量"的真正价值——**它不只是记法漂亮, 它把计算的复杂度从"每问一次重算一遍"降到"算一次、随便查"**。

第 5 轮: 梯度告诉我们什么——它指着上坡最陡的方向

老谏: "公式 $D_u f = \nabla f \cdot u$ 到手了。现在我问你一个尖锐的问题: **既然任意方向的坡度都是梯度·方向, 那你站在这点上, 朝哪个方向走坡度最大? 最大能到多少?** 别急, 先看看你手里有什么工具——点积的几何意义, 你还记得吗?"

造物主："点积的几何意义..... $a \cdot b = |a||b|\cos\theta$ ， θ 是两个向量的夹角。.....啊，我明白了： $D_u f = \nabla f \cdot u = |\nabla f| \cdot |u| \cdot \cos\theta = |\nabla f| \cdot \cos\theta$ (u 是单位向量， $|u|=1$)。 $\cos\theta$ 最大是 1，当 $\theta=0$ ，也就是 u 和 ∇f 同一个方向时，坡度最大，等于 $|\nabla f|$ ！"


老谏："一字不差。**梯度的方向，就是上坡最陡的方向；梯度的长度，就是最陡的坡度。** 这就是梯度的全部意义——它不只是一个"打包好的偏导向量"，它直接回答了你最初那个问题：'我该往哪边迈脚？'"

造物主："那我要是朝**垂直于**梯度的方向走呢？ $\cos 90^\circ = 0$ ，坡度是 0——**就是说，沿着和梯度垂直的方向走，高度一点不变！** 这不就是.....等高线吗？！"

老谏："你自己把第二个几何结论也摸出来了：**等高线在每一点都和梯度垂直。** 你看那张地形图——等高线是"高度相同"的线，沿着它走当然高度不变，所以它的切线方向必然和"上坡最陡方向"（梯度）垂直。这张图你研究了半天没看懂的线条，现在能看懂了。"

知识锚点：梯度的两个几何结论

【概念深挖】**结论一（方向）：** 梯度 ∇f 指向 f 增长最快的方向；沿梯度方向的方向导数最大，为 $|\nabla f|$ 。**结论二（正交）：** 过点 (x,y) 的等高线（方程 $f(x,y)=c$ 确定的曲线）在该点的切线方向，与梯度 $\nabla f(x,y)$ 垂直——因为沿等高线走 f 不变，方向导数为 0，由 $D_u f = \nabla f \cdot u = 0$ 即得 $\nabla f \perp u$ 。



读图说明： 这张图是本章的"出口导航"。中间是梯度这个核心对象，它同时携带三份信息——方向（上坡最陡）、大小（最陡坡度）、几何关系（垂直等高线）。最下面那条箭头最要紧：**把梯度反过来，就是下山最陡的方向——第 6 章整章就是沿着这个箭头走出来的。** 你现在看到的"梯度"，是后面所有优化算法的地基。

【工程实践】等高线垂直梯度的工程版："最陡下降方向"和"等损失面"永远垂直。你在调参时，损失函数等高线（等损失曲线）在参数空间里画出来，梯度总是垂直于等高线——这意味着**"最陡的改进方向"从不和"损失不变的方向"重合**"。这个几何直觉后面理解梯度下降的"之字形"路径时还会用上。

第 6 轮：偏导存在，就万事大吉了吗？——“可微”的门槛

老谟：“梯度这么好用，公式 $D_u f = \nabla f \cdot u$ 也漂亮。可我问你：**这个公式，是白捡的吗？** 我们推导它的时候，偷偷做了一个假设——你还记得是什么吗？”

造物主：“.....我说‘假设曲面是平滑的，没有棱、没有台阶’，然后才敢把高度变化拆成‘东向贡献 + 北向贡献’。”

老谟：“对。‘平滑’就是‘可微’ (differentiable) 的白话版。可问题来了：一元函数里，‘可导’几乎总是成立，例外极少。多元函数这里，‘偏导存在’比你想象的脆弱得多——我给你一个函数，它的两个偏导在原点都存在，但它连**连续**都不连续，更别说‘平滑’。你觉得可能吗？”

造物主：“.....偏导都存在，居然可以不连续？一元函数里，可导必连续，这可是铁律啊！”

老谟：“一元函数的铁律，在多元这里**不搬了**。原因就在偏导的定义里： f_x 是‘把 y 冻住’求的导， f_y 是‘把 x 冻住’求的导——**两条轴方向各看一次，只保证了‘沿这两条轴’行为正常，可没保证‘斜着穿过来’的方向正常**。一个函数可以只在十字架上光滑，四个象限之间却是撕裂的。这个反例，放到严格化走廊里你会亲手看到它长什么样——它是本章最重要的‘边界’，比梯度公式本身更能防止你拿公式到处乱用。”

知识锚点：偏导存在 $\neq$ 连续——多元世界的第一记“耳光”

【概念深挖】**多元“可微”的完整定义**（严格版见走廊）： f 在点 a 可微，是指存在一个线性函数能“贴住”曲面——即全增量可以写成

$$f(a+h) - f(a) = \nabla f(a) \cdot h + \varepsilon(h) \cdot |h|, \text{ 其中 } \varepsilon(h) \rightarrow 0 \text{ (当 } h \rightarrow 0\text{)}$$

意思是：**高度变化 $\approx$ 梯度与位移的点积（线性主部）+ 一个比位移还小的尾巴**。可微 $\Rightarrow$ 连续；可微 $\Rightarrow$ 方向导数全都存在且 $= \nabla f \cdot u$ 。但**偏导存在只是一条弱得多的条件**——它只保证“沿坐标轴方向”正常。

【概念深挖】经典反例 (f 在原点偏导存在、方向导数（斜向）不存在、甚至不连续)：

$$f(x, y) = xy / (x^2 + y^2), \text{ 当 } (x, y) \neq (0, 0); f(0, 0) = 0$$

- 沿 x 轴 ($y=0, x \neq 0$)： $f = 0/x^2 = 0$ ，故 $f_x(0,0) = \lim_{h \rightarrow 0} [f(h,0) - f(0,0)]/h = 0$ 。同理 $f_y(0,0) = 0$ 。**两个偏导都存在，都是 0。**
- 但沿直线 $y = kx$ 靠近原点 ($k \neq 0$)： $f(x, kx) = kx^2/(x^2 + k^2x^2) = k/(1+k^2)$ ，随 k 不同而不同！**沿不同斜线逼近，极限值不同——所以 f 在原点极限不存在，更不连续。**

- 甚至斜向方向导数也不存在：朝 $u=(1,1)/\sqrt{2}$ 走， $f(t/\sqrt{2}, t/\sqrt{2}) = (t^2/2)/(t^2) = 1/2 \neq 0$ ，而 $f(0,0)=0$ ，比值 $(1/2)/t \rightarrow \infty$ （或说极限不存在）。

这一记“耳光”打醒什么：多元世界里，“每个坐标轴方向都正常”远不等于“所有方向都正常”。梯度公式 $D_u f = \nabla f \cdot u$ 能成立，前提是 f 可微——所以在用梯度之前，你得先确认“这块曲面是平滑的”，而不是只看偏导存在。

【工程实践】这个反例在工程里对应**“病态损失面”：有些表面看似各方向都有定义，实则在某条斜线上藏着“断崖”或“刀刃”。神经网络的大多数损失函数是光滑的（可微），但ReLU 这类带折角的激活函数让损失面出现“棱”——在棱上梯度不存在（或不可微），优化器就得用次梯度等变通手段。知道“偏导存在≠可微”，你就知道为什么工程里要格外小心“折角”和“棱”。

第 7 轮：落点——“一个数”长成了“一个向量”

老谟：“把地图收起来。你现在回答我最初的问题：‘一座山的陡峭，该用几个数描述？’”

造物主：“不是一个数，是一个向量——**梯度**。它的方向指着上坡最陡的方向，它的长度就是最陡的坡度；任意方向的坡度，都是梯度往那个方向上的投影（点积）。而且我还知道了：偏导存在不等于曲面平滑，要用梯度公式，得先确认可微。”

老谟：“你手里现在有三样东西：偏导（按住其他变量只动一个）、方向导数（任意方向的坡度）、梯度（把所有方向打包成一个向量）。这三样是什么关系，你自己理一遍。”

造物主：“偏导是‘只沿坐标轴看’的特例；方向导数是‘任意方向都能看’的完整版；梯度是把所有偏导打包，然后‘任意方向 = 梯度·方向’这个点积公式，让我不用真的去算每个方向的极限。”

老谟：“理得很顺。可是你有没有发现——我们这一章，从头到尾都在问‘这一个点，往哪个方向最陡’。这只是站在山坡上找方向。下一章，你手里这个梯度还要再长本事：当 x 和 y 自己不老实、互相牵着手变的时候（比如 x 和 y 都是中间变量的函数），梯度该怎么跟着变？那叫链式法则。你先把这个‘向量’踩实，明天我们让它学会‘拐弯’。”

严格化走廊

位置说明：本章对话负责“直觉”——为什么“一个数”不够用、梯度为什么是向量。本走廊负责“严谨”——把偏导、方向导数、梯度写成精确的定义，把“方向导数 = 梯度·方向”推成可复写的证明。

下面每一行，读者都能对着空白纸重写一遍。

定义 1: 偏导数 (partial derivative)

设 $f: D \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$, 点 (a, b) 在 D 内。 **f 对 x 的偏导数**定义为

$$f_x(a, b) = \partial f / \partial x (a, b) = \lim_{h \rightarrow 0} [f(a+h, b) - f(a, b)] / h \quad (\text{若极限存在})$$

f 对 y 的偏导数同理: $f_y(a, b) = \lim_{h \rightarrow 0} [f(a, b+h) - f(a, b)] / h$ 。 n 元函数 $f(x_1, \dots, x_n)$ 同理, 每次只让一个变量变、其余全固定。

严格注记: 偏导数是"沿坐标轴方向"的极限, 它只探测曲面沿坐标轴方向的行为。它甚至不需要函数在点附近"长得像平面"——这是后面定义 4 (可微) 要补的约束。

定义 2: 方向导数 (directional derivative)

设 $u = (u_1, u_2)$ 为单位向量 ($u_1^2 + u_2^2 = 1$)。 **f 在 (a, b) 沿方向 u 的方向导数**定义为

$$D_u f(a, b) = \lim_{t \rightarrow 0} [f(a + t \cdot u_1, b + t \cdot u_2) - f(a, b)] / t \quad (\text{若极限存在})$$

当 $u = (1, 0)$ 时 $D_u f = f_x$; 当 $u = (0, 1)$ 时 $D_u f = f_y$ 。**偏导是方向导数的特例。**

定义 3: 梯度 (gradient)

设 $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ 在点 a 处所有偏导存在。**梯度**为行向量/列向量

$$\nabla f(a) = (\partial f / \partial x_1 (a), \partial f / \partial x_2 (a), \dots, \partial f / \partial x_n (a))$$

定义 4: 可微 (differentiable)

$f: D \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$ 在点 a 处**可微**, 是指存在向量 $v = (v_1, v_2)$ (只依赖 a , 不依赖 h), 使得对 a 附近的所有 $h = (h_1, h_2)$:

$$f(a+h) - f(a) = v_1 \cdot h_1 + v_2 \cdot h_2 + \varepsilon(h) \cdot |h|, \text{ 其中 } \varepsilon(h) \rightarrow 0 \text{ (当 } h \rightarrow 0 \text{)}$$

严格注记: 若 f 可微, 则 v 必为 $\nabla f(a)$ 。可微的含义是: 曲面在该点被一个"倾斜平面" (线性函数) 牢牢顶住, 误差比位移还小一个量级。可微 $\Rightarrow$ 连续 (因为 $f(a+h) - f(a) \rightarrow 0$) ; 可微 $\Rightarrow$ 沿任意方向的方向导数存在。

定理 1 (方向导数 = 梯度·方向) : 若 f 在点 a 可微, 则对任意单位向量 u ,

$$D_u f(a) = \nabla f(a) \cdot u$$

证明 (可复写) :

- 由定义 4 (可微), $f(a + t \cdot u) - f(a) = \nabla f(a) \cdot (t \cdot u) + \varepsilon(t \cdot u) \cdot |t \cdot u| = t \cdot [\nabla f(a) \cdot u] + |t| \cdot \varepsilon(t \cdot u)$ 。
- 两边除以 t (沿 $t \rightarrow 0$ 取极限; 注意 t 可正可负, 用 $|t|$ 记号统一): $[f(a + t \cdot u) - f(a)] / t = \nabla f(a) \cdot u + \varepsilon(t \cdot u) \cdot (|t|/t)$ 。
- 因 $\varepsilon(t \cdot u) \rightarrow 0$ (当 $t \rightarrow 0$), 且 $|t|/t$ 有界 (恒为 ± 1), 故最后一项 $\rightarrow 0$ 。
- 于是极限 $D_u f(a) = \lim_{t \rightarrow 0} [f(a + t \cdot u) - f(a)] / t = \nabla f(a) \cdot u$ 。■

证明要点标注: 第 1 步用了**定义 4 (可微的线性主部分解)**; 第 2 步是**代数整理 + 有界量乘无穷小仍为无穷小** ($\varepsilon(t \cdot u) \cdot (|t|/t) \rightarrow 0$); 第 3 步直接套**定义 2 (方向导数的极限式)**。

定理 2 (梯度的最陡方向) : 设 f 在点 a 可微且 $\nabla f(a) \neq 0$, 则

- 所有单位方向 u 中, $D_u f(a)$ 在 $u = \nabla f(a) / |\nabla f(a)|$ 时取到最大值, 最大值为 $|\nabla f(a)|$;
- 在 u 与 $\nabla f(a)$ 垂直 ($u \cdot \nabla f(a) = 0$) 的方向上, $D_u f(a) = 0$ 。

证明 (可复写) :

- 由定理 1: $D_u f(a) = \nabla f(a) \cdot u$ 。对单位向量 u , 由**向量点积的定义** $\nabla f(a) \cdot u = |\nabla f(a)| \cdot |u| \cdot \cos \theta = |\nabla f(a)| \cdot \cos \theta$ (其中 θ 是 $\nabla f(a)$ 与 u 的夹角, $|u| = 1$)。
- 因 $-1 \leq \cos \theta \leq 1$, 故 $-|\nabla f(a)| \leq D_u f(a) \leq |\nabla f(a)|$ 。
- 等号 u 同向 ($\cos \theta = 1$) 时取到上界 $|\nabla f(a)|$; u 反向 ($\cos \theta = -1$) 时取到下界 $-|\nabla f(a)|$ 。■

证明要点标注: 第 1 步用了**定理 1 (方向导数的点积公式)**; 第 2 步用了**点积的几何定义 (夹角余弦)**与**单位向量的长度条件 $|u|=1$** ; 第 3 步是**余弦的有界性**。

定理 3 (克莱罗定理, 叙述) : 设 f 在点 (a,b) 附近二阶混合偏导存在且连续, 则

$$f_{xy}(a,b) = f_{yx}(a,b) \quad (\text{即 } \partial^2 f / \partial x \partial y = \partial^2 f / \partial y \partial x, \text{ 求导次序可交换})$$

严格注记: "二阶混合偏导连续"是充分条件 (不是必要条件)。若混合偏导不连续, 交换次序可能出问题——**克莱罗定理是有前提的**, 不是永远成立。第 2 章讲多元泰勒时会用到它。

反例/边界：偏导存在 $\neq$ 连续 $\neq$ 可微

考虑 $f(x,y) = xy/(x^2+y^2)$ ($(x,y) \neq (0,0)$) , $f(0,0) = 0$:

- **偏导存在**： $f_x(0,0) = \lim_{h \rightarrow 0} [f(h,0) - f(0,0)]/h = \lim 0/h = 0$; $f_y(0,0) = 0$ 。两个偏导都是 0。
- **不连续**：沿 $y = kx$ ($k \neq 0$) 逼近原点, $f(x, kx) = kx^2/(x^2+k^2x^2) = k/(1+k^2)$ 。 $k = 0$ 时极限 0, $k = 1$ 时极限 $1/2$ ——**不同路径极限不同，原点极限不存在，故不连续**。既然不连续，就谈不上可微（可微 $\Rightarrow$ 连续）。
- **斜向方向导数不存在**： $u = (1/\sqrt{2}, 1/\sqrt{2})$, $[f(t/\sqrt{2}, t/\sqrt{2}) - 0]/t = [(t^2/2)/(t^2/2 + t^2/2)]/t = (1/2)/t$, $t \rightarrow 0$ 时发散。

结论：这个函数是“偏导存在但方向导数（斜向）不存在、且不连续”的活标本。**它钉死了本章最要紧的边界——看到 f_x 、 f_y 都存在，不要立刻写 $D_u f = \nabla f \cdot u$ ；先确认 f 可微。**可微是梯度公式的“许可证”。

知识点总结

知识点（本章推出的核心概念）

- **多元函数**： $f(x_1, \dots, x_n)$ ，输入 n 个数输出 1 个数；图像在 $n=2$ 时是一张曲面，点上有无穷多个切线方向——所以“陡峭”装不进一个数。
- **偏导数 f_x 、 f_y** ：按住其他变量当常数，只对其中一个求导；记号 ∂ （雅可比推广，1841 前后）。偏导只探测“沿坐标轴方向”的行为。
- **方向导数 $D_u f$** ：朝任意单位方向 u 的坡度；定义是 f 沿 u 方向位移的变化率极限；**偏导是它取 $u=(1,0)/(0,1)$ 的特例**。
- **梯度 $\nabla f = (f_x, f_y, \dots)$** ：把所有偏导打包成一个向量；“所有方向的陡峭”被压缩进一个向量。术语出自麦克斯韦《论电与磁》（1873）。
- **总钥匙公式**： f 可微时， $D_u f = \nabla f \cdot u$ ——任意方向的坡度 = 梯度在 u 上的投影，不用每个方向都算极限。
- **梯度的几何**：方向 = 上坡最陡；长度 $|\nabla f|$ = 最陡坡度；**与等高线垂直**（沿等高线方向导数 = 0）。
- **可微 vs 偏导存在**：可微 = 曲面被线性平面“顶住”（全增量 = 线性主部 + 高阶小）；**可微 $\Rightarrow$ 连续，可微 $\Rightarrow$ 偏导存在**（但两个方向的反向均不成立）；特别地**偏导存在不蕴含连续**（反例 $xy/(x^2+y^2)$ ）。
- **克莱罗定理**：二阶混合偏导连续时， $f_{xy} = f_{yx}$ （求导次序可交换）。

历史结论（本章涉及的史料）

- **克莱罗（18 世纪）**：系统处理多变量求导，给出混合偏导相等的定理（克莱罗定理）。
- **雅可比（1841 前后）**：推广偏导记号 ∂ ，区分"偏导"与"全导数"。
- **麦克斯韦（1873）**：《论电与磁》引入"gradient（梯度）"一词描述"场向哪个方向增长最快"——工具先被物理逼出来，理论再钉牢。
- **一个共性**：多元微积分不是被数学家关起门造出来的，是被"曲面的几何问题"和"场的物理问题"一步步逼出来的。

工程实践结论（本章知识在真实工程里怎么用）

- **调参 = 多元求偏导**：模型参数 $w_1, \dots, w_n$ ，损失 $L(w_1, \dots, w_n)$ ，一次只能"按住别的、单独动一个"看效果——这就是偏导。
- **梯度是下山罗盘**：朝 $-\nabla f$ 走是下降最陡的方向，深度学习框架标配"自动求梯度"。
- **方向导数 = "往这个策略方向改，指标怎么变"**：同时微调多个超参数的组合方向，用方向导数度量升降。
- **棱和折角要小心**：ReLU 激活函数让损失面带棱（不可微点），偏导存在 $\neq$ 可微的反例就是它的数学根源；工程上要用次梯度等变通手段。

计算训练场

位置说明：本章对话负责"为什么"，这里负责"怎么算"。下面每题请动笔 10 分钟以上，先自己写，再对照完整解答。禁止边算边翻答案。

题 1（易→中）：求偏导、梯度、方向导数——公式法与定义法互证

题干：设 $f(x, y) = x^2y + \sin y$ 。(a) 求 f_x 与 f_y （偏导的完整计算过程）。(b) 求梯度 ∇f 在点 $(1, 0)$ 处的值。(c) 求 f 在点 $(1, 0)$ 沿单位方向 $u = (1/\sqrt{2}, 1/\sqrt{2})$ 的方向导数。要求**先用公式 $D_u f = \nabla f \cdot u$ 算一遍，再用方向导数的极限定义直接验算一遍**，两法结果应一致。

完整分步解答：

(a) 求偏导：第 1 步 (f_x)：把 y 当常数。 x^2y 是"常数 $y \times x^2$ "，对 x 求导得 $2xy$ ； $\sin y$ 与 x 无关，当常数，导数为 0。故 $f_x = 2xy$ 。第 2 步 (f_y)：把 x 当常数。 x^2y 是"常数 $x^2 \times y$ "，对 y 求导得 x^2 ； $\sin y$ 对 y 求导得 $\cos y$ 。故 $f_y = x^2 + \cos y$ 。

(b) 梯度在 $(1, 0)$ ：第 3 步：代入点 $(1, 0)$ ： $f_x(1, 0) = 2 \cdot 1 \cdot 0 = 0$ ； $f_y(1, 0) = 1^2 + \cos 0 = 1 + 1 = 2$ 。第 4 步： $\nabla f(1, 0) = (0, 2)$ 。

(c) 方向导数——公式法：第 5 步： $D_u f(1,0) = \nabla f(1,0) \cdot u = 0 \cdot (1/\sqrt{2}) + 2 \cdot (1/\sqrt{2}) = 2/\sqrt{2} = \sqrt{2} \approx 1.4142$ 。

(c) 方向导数——定义法验算：第 6 步：点 $(1,0)$ 沿 u 走 t 步到达 $(1 + t/\sqrt{2}, t/\sqrt{2})$ 。先算 f 在该点： $f(1 + t/\sqrt{2}, t/\sqrt{2}) = (1 + t/\sqrt{2})^2 \cdot (t/\sqrt{2}) + \sin(t/\sqrt{2}) = (1 + 2t/\sqrt{2} + t^2/2) \cdot (t/\sqrt{2}) + \sin(t/\sqrt{2}) = t/\sqrt{2} + t^2 \cdot (2/2) + t^3/(2\sqrt{2}) + \sin(t/\sqrt{2}) = t/\sqrt{2} + t^2 + t^3/(2\sqrt{2}) + \sin(t/\sqrt{2})$ 。第 7 步： $f(1,0) = 1^2 \cdot 0 + \sin 0 = 0$ 。第 8 步：差商 $= [f(1+t/\sqrt{2}, t/\sqrt{2}) - f(1,0)] / t = 1/\sqrt{2} + t + t^2/(2\sqrt{2}) + \sin(t/\sqrt{2})/t$ 。第 9 步：取极限 $t \rightarrow 0$ ： $1/\sqrt{2} + 0 + 0 + (1/\sqrt{2}) \cdot 1 = 2/\sqrt{2} = \sqrt{2}$ 。（这里用了 $\sin z / z \rightarrow 1, z = t/\sqrt{2} \rightarrow 0$ 。）第 10 步： $\sqrt{2} = \sqrt{2} \checkmark$ ，公式法与定义法一致。

答：(a) $f_x = 2xy$, $f_y = x^2 + \cos y$; (b) $\nabla f(1,0) = (0, 2)$; (c) $D_u f(1,0) = \sqrt{2} \approx 1.414$ 。

常见错误：① 求 f_x 时把 $\sin y$ 误当常数算成 0——没错，但有人会把“ $\sin y$ 对 x 求导”误写成 $\cos y$ ， **$\sin y$ 里没有 x ，对 x 的偏导就是 0**；② 定义法验算时忘了 $(1 + t/\sqrt{2})^2$ 展开要算三项，导致 t 的一次项系数算错；③ 方向 u 忘记归一化—— **u 必须是单位向量，先算 $|u|$ 再除以它**。

题 2 (中)：三元函数——梯度、指定方向、最陡方向与最大变化率

题干：设 $f(x, y, z) = x^2y^3 + xz^2$ 。(a) 求 f_x 、 f_y 、 f_z 。(b) 求梯度 ∇f 在点 $(1, 1, 2)$ 的值及其长度 $|\nabla f|$ 。(c) 求 f 在点 $(1, 1, 2)$ 沿单位方向 $v = (1/\sqrt{3}, 1/\sqrt{3}, 1/\sqrt{3})$ 的方向导数。(d) 在点 $(1, 1, 2)$ ， f 增长最快的方向是什么？最快的变化率是多少？

完整分步解答：

(a) 三个偏导：第 1 步： f_x ： y 、 z 都当常数。 x^2y^3 对 x 求导得 $2xy^3$ ； xz^2 对 x 求导得 z^2 。故 $f_x = 2xy^3 + z^2$ 。第 2 步： f_y ： x 、 z 都当常数。 x^2y^3 对 y 求导得 $3x^2y^2$ ； xz^2 与 y 无关，为 0。故 $f_y = 3x^2y^2$ 。第 3 步： f_z ： x 、 y 都当常数。 x^2y^3 与 z 无关，为 0； xz^2 对 z 求导得 $2xz$ 。故 $f_z = 2xz$ 。

(b) 梯度及其长度：第 4 步：代入 $(1, 1, 2)$ ： $f_x = 2 \cdot 1 \cdot 1^3 + 2^2 = 2 + 4 = 6$ ； $f_y = 3 \cdot 1^2 \cdot 1^2 = 3$ ； $f_z = 2 \cdot 1 \cdot 2 = 4$ 。第 5 步： $\nabla f(1,1,2) = (6, 3, 4)$ 。第 6 步： $|\nabla f| = \sqrt{6^2 + 3^2 + 4^2} = \sqrt{36 + 9 + 16} = \sqrt{61} \approx 7.8102$ 。

(c) 指定方向的方向导数：第 7 步： $D_v f = \nabla f \cdot v = 6 \cdot (1/\sqrt{3}) + 3 \cdot (1/\sqrt{3}) + 4 \cdot (1/\sqrt{3}) = 13/\sqrt{3} = 13\sqrt{3}/3 \approx 7.5056$ 。

(d) 最陡方向与最大变化率：第 8 步：增长最快方向 = 梯度的单位化： $u = (6, 3, 4)/\sqrt{61}^*$ 。第 9 步：最快变化率 $= |\nabla f| = \sqrt{61} \approx 7.8102$ （沿 u^* 时 $D_{u^*} f = |\nabla f| \cdot \cos 0 = |\nabla f|$ ）。

答：(a) $f_x = 2xy^3 + z^2$, $f_y = 3x^2y^2$, $f_z = 2xz$; (b) $\nabla f = (6, 3, 4)$, $|\nabla f| = \sqrt{61} \approx 7.810$; (c) $D_v f = 13/\sqrt{3} \approx 7.506$; (d) 方向 $(6, 3, 4)/\sqrt{61}$ ，最大变化率 $\sqrt{61}$ 。

常见错误：① f_x 里丢了 z^2 这一项——因为 xz^2 对 x 求导是 z^2 （不是 $2xz$ ，那是 f_z ）；② 算长度时 $\sqrt{36+9+16}$ 算成 $\sqrt{61}$ 时有人误加成 61 的平方根形式没问题，但有人把 $36+9+16$ 算成 51；③ 方

向导数只除一次 $\sqrt{3}$ ——因为 v 已是单位向量，不要再额外除。

题 3 (中→难)：梯度与等高线正交的数值验证 + 偏导存在却不连续的检验

题干：设 $f(x, y) = x^2 + y^2$ 。(a) 求 ∇f 在点 $(1, 1)$ 的值。过 $(1, 1)$ 的等高线是 $f(x, y) = 2$ ，即圆 $x^2 + y^2 = 2$ 。用隐函数求导（或圆的几何）求出该等高线在 $(1, 1)$ 处的切线方向，并验证它与梯度垂直。(b) 把本章反例 $f(x, y) = xy/(x^2 + y^2)$ （原点取 0）在原点处的两个偏导算出来；再沿 $y = 2x$ 逼近原点计算极限，验证“偏导存在但不连续”。

完整分步解答：

(a) 梯度 $\perp$ 等高线：第 1 步： $f_x = 2x$, $f_y = 2y$ 。代入 $(1, 1)$ ： $\nabla f(1, 1) = (2, 2)$ 。第 2 步：等高线 $x^2 + y^2 = 2$ 。隐函数求导：对 x 求导， $2x + 2y \cdot y' = 0$ ，故 $y' = -x/y = -1/1 = -1$ 。第 3 步：切线方向取 $(1, y') = (1, -1)$ （或它的相反方向）。与梯度做点积： $(2, 2) \cdot (1, -1) = 2 \cdot 1 + 2 \cdot (-1) = 0$ 。**点积为 0，故梯度 $\perp$ 切线方向 $\checkmark$** （这也说明沿等高线走 f 不变： $D_u f = \nabla f \cdot u = 0$ ）。

(b) 偏导存在但不连续：第 4 步： $f_x(0, 0) = \lim_{h \rightarrow 0} [f(h, 0) - f(0, 0)]/h = \lim_{h \rightarrow 0} [0 - 0]/h = 0$ （沿 $y=0$, $f(h, 0) = h \cdot 0/(h^2 + 0) = 0$ ）。同理 $f_y(0, 0) = 0$ 。第 5 步：沿 $y = 2x$ 逼近原点 ($x \rightarrow 0$, $x \neq 0$)： $f(x, 2x) = x \cdot (2x)/(x^2 + (2x)^2) = 2x^2/(x^2 + 4x^2) = 2/5$ 。第 6 步：沿 $y = 0$ （即 $k=0$ ）逼近，极限 = 0；沿 $y = 2x$ 逼近，极限 = $2/5$ 。**两条路径极限不同 ($0 \neq 2/5$)，故原点极限不存在， f 在原点不连续。**但两个偏导却都是 0——“偏导存在”和“连续”在这里脱钩了。

答：(a) $\nabla f(1, 1) = (2, 2)$ ，等高线切线方向 $(1, -1)$ ，点积 0，垂直成立；(b) $f_x = f_y = 0$ 但沿 $y=2x$ 极限 $2/5 \neq 0$ ，故不连续——反例坐实。

常见错误：① 隐函数求导忘了 y 是 x 的函数，把 $x^2 + y^2$ 对 x 求导写成 $2x + 2y$ （漏了 y' ）；② 验证不连续时只沿一条路径逼近——**不连续要用“两条路径极限不同”来证明，一条路径算不出“极限不存在”**；③ 把“偏导存在”直接当成“可微”用梯度公式——这正是本章反例要钉死的误区。

向导便签

这一章咱们干了什么：从“山上有 360° 方向，往哪边走最陡”这个登山地图前的傻问题出发，发现“陡峭”装不进一个数；先学最省事的偏导（按住其他变量只动一个），发现它只能回答东西南北四个方向；于是定义方向导数（任意方向的坡度），最后用梯度把所有方向打包成一个向量——**任意方向的坡度 = 梯度·方向（点积）**。

钉死一句话：**梯度同时回答两件事——朝哪个方向上坡最陡（方向），最陡有多陡（长度 $|\nabla f|$ ）；而且它和等高线垂直**。反过来说：**朝 $-\nabla f$ 走，就是下坡最陡的方向**——这句话是第 6 章梯度下降的全部起点。

记住一个边界：**偏导存在 $\neq$ 连续 $\neq$ 可微**。那记“耳光”函数 $xy/(x^2+y^2)$ 让你亲眼看到，只在十字架上光滑、斜着穿过来就撕裂的曲面是真实存在的。用梯度公式之前，先确认 f 可微。

造物主手记

我曾踩的坑：

我一开始坚持“山的陡峭一个数就够了”，被老谟一句“朝东报一个数、朝北报另一个数，还作数吗”噎住。接着我差点说出“东北的坡度 = 朝东坡度加朝北坡度除以二”——这是把方向导数当平均值的典型错误，幸好老谟拦住我没让我算。最丢人的是：我算出两个偏导 $f_x = f_y = 0$ 之后，差点就拿着梯度公式到处用了——反例函数让我看见偏导为 0 的原点居然不连续。“沿坐标轴正常”和“整体平滑”是两回事，这个教训我记一辈子。

顿悟时刻：

真正开窍是在第 5 轮——当我把 $D_u f = \nabla f \cdot u$ 和点积的几何意义一接，突然看见：“任意方向的坡度”原来只是“梯度”这个向量在各方位的投影，而投影最大的方向就是梯度自己。无穷多个方向，被两个数全部装下。那一瞬间我明白了一件事：**多元微积分不是“变难了”，而是“把‘一个数’换成了‘一个向量’”——只要你肯换，所有东西还是整整齐齐的**。

自测题

计算题须动笔完成，附完整解答自核；概念题用于检查理解。

题 A（计算，易→中）：偏导基本功

设 $f(x, y) = e^{(xy)} + x/y$ ($y \neq 0$)。(a) 求 f_x 与 f_y 。(b) 求 ∇f 在点 $(1, 1)$ 的值。(c) 求 f 在点 $(1, 1)$ 沿单位方向 $u = (0, 1)$ 的方向导数，并指出它与哪个偏导一致、为什么。

完整解答： (a) f_x : 把 y 当常数。 $e^{(xy)}$ 对 x 求导 $= y \cdot e^{(xy)}$; x/y 对 x 求导 $= 1/y$ 。故 $f_x = y \cdot e^{(xy)} + 1/y$ 。 f_y : 把 x 当常数。 $e^{(xy)}$ 对 y 求导 $= x \cdot e^{(xy)}$; $x/y = x \cdot (1/y)$ 对 y 求导 $= -x/y^2$ 。故 $f_y = x \cdot e^{(xy)} - x/y^2$ 。(b) 代入 $(1,1)$: $f_x = 1 \cdot e^1 + 1 = e + 1 \approx 3.718$; $f_y = 1 \cdot e^1 - 1/1 = e - 1 \approx 1.718$ 。 $\nabla f(1,1) = (e+1, e-1)$ 。(c) $u = (0,1)$: $D_u f = \nabla f \cdot u = (e+1) \cdot 0 + (e-1) \cdot 1 = e - 1 \approx 1.718$ 。这正是 $f_y(1,1)$ ——因为 $u = (0,1)$ 就是 y 轴方向，方向导数退化为对 y 的偏导。 $\checkmark$ 与 (b) 的 f_y 一致。

题 B (计算, 中一难) : 方向导数全流程

设 $f(x, y) = x^2y - y^3$ 。(a) 求 ∇f 在点 $(2, 1)$ 。(b) 求 f 在 $(2, 1)$ 沿单位方向 $u = (3/5, 4/5)$ 的方向导数。(c) 求 f 在 $(2, 1)$ 的最陡上升方向与最大变化率。(d) 用定义法验算 (b): 沿 u 走 t 步写出 $f(2 + 3t/5, 1 + 4t/5)$, 展开并取极限。

完整解答： (a) $f_x = 2xy$, $f_y = x^2 - 3y^2$ 。代入 $(2,1)$: $f_x = 4$, $f_y = 4 - 3 = 1$ 。 $\nabla f(2,1) = (4, 1)$ 。(b) $D_u f = 4 \cdot (3/5) + 1 \cdot (4/5) = 12/5 + 4/5 = 16/5 = 3.2$ 。(c) 最陡上升方向 $= (4,1)/\sqrt{17}$ (单位化), 最大变化率 $= |\nabla f| = \sqrt{17} \approx 4.123$ 。(d) 验算: $f(2 + 3t/5, 1 + 4t/5) = (2 + 3t/5)^2(1 + 4t/5) - (1 + 4t/5)^3$ 。 $f(2,1) = 4 \cdot 1 - 1 = 3$ 。差商 $[f(\dots) - 3]/t$, 展开取 $t \rightarrow 0$ 的一次项系数: x 方向贡献 $f_x \cdot (3/5) = 4 \cdot (3/5) = 12/5$, y 方向贡献 $f_y \cdot (4/5) = 1 \cdot (4/5) = 4/5$, 合计 $16/5 = 3.2 \checkmark$ 与 (b) 一致。(完整展开: $(2+3t/5)^2 = 4 + 12t/5 + 9t^2/25$; $(1+4t/5)^3 = 1 + 12t/5 + 48t^2/25 + 64t^3/125$; 代入化简后 t 的一次项系数恰为 $16/5$ 。)

题 C (概念, 检查理解) : 偏导、可微、连续

老谟给造物主一个函数 g , 已知 g 在原点两个偏导都存在, 但 g 在原点不连续。(1) 这违反一元函数的哪条"铁律"? 为什么多元世界会这样?(2) 在这种情况下, g 在原点能用梯度公式 $D_u g = \nabla g \cdot u$ 吗? 为什么?

完整解答： (1) 一元函数里"可导 $\Rightarrow$ 连续"是铁律; 多元世界里偏导只在坐标轴方向探测, 只保证"十字架"上正常, 不保证"斜着穿过来"正常, 所以偏导存在不蕴含连续。**违反的不是数学, 是把一元直觉硬搬到多元。** (2) 不能直接套。梯度公式的前提是**可微**; 不连续 $\Rightarrow$ 不可微 $\Rightarrow$ 公式的许可证没拿到。要先用可微定义 (全增量 = 线性主部 + 高阶小) 确认 g 可微, 才能用 $D_u g = \nabla g \cdot u$ 。

预告

你手里现在有一把"罗盘": 梯度。它告诉你站在山坡上往哪儿迈脚最陡, 也告诉你任意方向的坡度只要做一个点积。

可这一章有个隐藏前提: **我们一直在问"站在某个固定点上, 往哪个方向最陡"**。但现实里更常见的情形是—— **x 和 y 自己不听你指挥, 它们都是中间变量的函数**。比如温度 T 是位置 (x, y) 的函数, 而位置又随时间 t 变化: 你想知道"温度随时间怎么变", 就得让梯度跟着 t "拐弯"。这中间那个"让梯度学会

拐弯"的规则，叫**链式法则**；拐弯拐得好，我们还能把一元函数的泰勒展开搬过来，变成"用一张抛物面近似一块曲面"的**多元泰勒公式**——那是第 4、5 章判定"碗"的形状（凸性）要用到的重武器。

下一章，让梯度先学会拐弯。

第 02 章 · 多元链式法则与多元泰勒——让梯度学会"拐弯"

本章从哪个问题出发：上一章你拿到了梯度——它告诉你"站在某点往哪个方向最陡"。可现实里， x 和 y 往往不听你指挥：温度是位置 (x,y) 的函数，而位置又随时间 t 变化。你想知道"温度随时间怎么变"，可温度不直接依赖于 t ——它得先经过 $x(t)$ 、 $y(t)$ 这两个"中间人"。这一串牵扯，怎么求变化？推导到哪个结论：答案是**多元链式法则**——每个中间变量的变化率，按"偏导 $\times$ 中间变量的变化率"逐支相加；一句话：**梯度负责"空间上多陡"，链式法则负责"时间上怎么跟着动"**。在此基础上，把一元泰勒公式推广成**多元泰勒公式**：用"梯度 + 海森矩阵"构造一张抛物面，把任意曲面在一点附近精确地"顶住"。

核心认知：**链式法则 = 逐支求偏导再相加（每个分支"偏导 $\times$ 导数"）；多元泰勒 = 用梯度（一阶）和对称的海森矩阵（二阶）把曲面局部还原成"平面 + 抛物面"**。这两件武器是下一章（积分）、第 5 章（凸性判定）、第 6 章（梯度下降收敛性）的公共地基。

引子

老谟家的窗台上放着一只温度计，窗外的水管正往下滴答水。他拧开水龙头，让水流变小了一点。

"我给你出个情景，"老谟说，"这座城市的温度 T ，是位置 (x, y) 的函数—— $T(x, y)$ 。可你自己不会瞬移，你是从某地出发，沿着一条路走，位置 $x(t)$ 、 $y(t)$ 都随时间 t 变。你想知道'我这一路，温度每秒钟变多少'。你说，这该怎么算？"

我盯着温度计想了想：" T 是 x 、 y 的函数， x 、 y 又是 t 的函数.....那就先把 T 对 x 、 y 求偏导，再把 x 、 y 对 t 求导.....可这几样东西怎么'串'起来？"

"串起来——你这个词用得不错。上一章我们把'偏导'打包成了梯度；这一章我们要解决的就是：**梯度怎么跟着 $x(t)$ 、 $y(t)$ 一起'拐弯'**。你先别急着翻书，我们把'串'这个动作想清楚。"

对话引擎

第 1 轮：先把一元的老朋友请回来——链式法则长什么样

老谟："在碰多元之前，先问你一个一元的问题。 f 是 u 的函数， u 又是 t 的函数： $f(u(t))$ 。你站在 t 这一头，想知道 f 随 t 怎么变——你还记得这个'串'怎么算吗？"

造物主：".....这个我熟： $df/dt = (df/du) \cdot (du/dt)$ 。先看 u 动一单位 f 变多少，再看 t 动一单位 u 变多少，两个乘起来。中学就叫**链式法则**。"

老谟："乘起来——为什么是乘，不是加？"

造物主："因为这是一环接一环： t 动一步 $\rightarrow u$ 动若干步 $\rightarrow f$ 动若干步。 u 动的步数是 (du/dt) ， f 动的步数是 (df/du) 乘上 u 动的步数，所以是 $(df/du) \cdot (du/dt)$ 。"

老谟："'一环接一环用乘法'，你把核心直觉说对了。现在问题升级： f 有两个输入， u_1 和 u_2 ，而 u_1 、 u_2 又都是 t 的函数。这时候'串'要从一根链变成两根—— t 动一步， u_1 动、 u_2 也动， f 同时被两边拽着走。你说，这下是乘还是加？"

知识锚点：一元链式法则——"一环接一环，用乘法"

【概念深挖】一元链式法则：若 u 在 t 处可导、 f 在 $u(t)$ 处可导，则

$$df/dt = f'(u(t)) \cdot u'(t) \quad \text{即} \quad df/dt = (df/du)(du/dt)$$

直觉是"一环接一环，各环节速率相乘"。它来自差商的恒等式： $[f(u(t+h)) - f(u(t))]/h = [f(u(t+h)) - f(u(t))]/[u(t+h) - u(t)] \times [u(t+h) - u(t)]/h$ 。左端是" f 对 t 的变化率"，右端是" f 对 u 的变化率 $\times u$ 对 t 的变化率"——乘积结构是差分里"除以一个数再乘同一个数"的自然结果（严格化走廊会给出完整证明）。

【工程实践】一元链式法则的工程版叫**"复合函数求导"**：比如损失函数 $L = \sigma(w \cdot x + b)$ ，把"线性组合"和"sigmoid 激活"两级串起来求梯度，就是链式法则。但真实神经网络是几百层串起来，一元链式只够算"一条线"——下一轮你会看到，多元链式法则才是反向传播的真身。

第 2 轮：二元链式法则——两根链并排，各自贡献再相加

老谟：" $f(x, y)$ ， $x = x(t)$ ， $y = y(t)$ 。 t 动一小步 dt ： x 变了 dx ， y 也变了 dy 。 f 总共变多少？"

造物主：".....上一章学的！ f 变 $\approx f_x \cdot dx + f_y \cdot dy$ ——往东的贡献加往北的贡献。 dx 是 x 随 t 变的， $dx \approx x'(t)dt$ ； $dy \approx y'(t)dt$ 。所以总变化 $\approx f_x \cdot x' \cdot dt + f_y \cdot y' \cdot dt$ 。"

老谟："把 dt 除下去，你得到什么？"

造物主：" $df/dt = f_x \cdot x'(t) + f_y \cdot y'(t)$ ！两个分支，每个都是'偏导 $\times$ 导数'，然后相加。一根链用乘法，两根链用加法——因为两条路同时在拽 f ，总效果是叠加。"

老谟："你总结得很准。多元链式法则 = 每个分支'偏导 $\times$ 导数'，分支之间相加。现在我把情景再拧一拧： f 的输入是 x 、 y ，而 x 、 y 各自又都是 s 和 t 的函数—— $x(s, t)$ 、 $y(s, t)$ 。你想问' f 对 s 怎么变'，怎么办？"

造物主：".....那就把'对 s 求偏导'当作'按住 t 、只让 s 动'。 s 动一步， x 跟着动、 y 也跟着动（因为 x 、 y 都是 s 、 t 的函数），然后 f 被两边拽着走： $\partial f/\partial s = f_x \cdot \partial x/\partial s + f_y \cdot \partial y/\partial s$ 。只不过现在中间人不再是一元函数，中间人自己也有偏导。"

老谟："一字不差。法则的形式没变：'外层的偏导 $\times$ 内层的偏导'，分支相加——只是'导数'统一换成了'偏导'。你自己再看一眼这个式子： f_x 、 f_y 是'外层函数 f 对直接输入 x 、 y 的偏导'， $\partial x/\partial s$ 、 $\partial y/\partial s$ 是'中间变量对下一层变量的偏导'。每一层都只对'自己的直接输入'求偏导——这就是'链'的含义，也是后面我们做反向传播时唯一要遵守的规矩。"

知识锚点：多元链式法则——逐支"偏导 $\times$ 偏导"，分支相加

【概念深挖】**全导数（单变量外变量）：** $f(x,y)$ ， $x=x(t)$ ， $y=y(t)$ ，则

$$df/dt = (\partial f/\partial x) \cdot (dx/dt) + (\partial f/\partial y) \cdot (dy/dt)$$


(f 的全部变化都来自 t ，故用全导数 df/dt 。)

偏导（多变量外变量）： $f(x,y)$ ， $x=x(s,t)$ ， $y=y(s,t)$ ，则

$$\partial f/\partial s = (\partial f/\partial x) \cdot (\partial x/\partial s) + (\partial f/\partial y) \cdot (\partial y/\partial s)$$

$$\partial f/\partial t = (\partial f/\partial x) \cdot (\partial x/\partial t) + (\partial f/\partial y) \cdot (\partial y/\partial t)$$

记忆法（树形图）：把依赖关系画成树——根是 f ，枝是 x 、 y ，再往下是 s 、 t 。求" f 对 s 的变化率"，就是从根 f 走到 s 的每一条路径，路径上所有"偏导"相乘，路径之间相加：



读图说明：求 $\partial f/\partial s$ ，数从 f 到 s 的路径： $f \rightarrow x \rightarrow s$ 一条 $(\partial f/\partial x \cdot \partial x/\partial s)$ ， $f \rightarrow y \rightarrow s$ 一条 $(\partial f/\partial y \cdot \partial y/\partial s)$ ，两条路径的乘积**相加**。这就是“树形记忆法”——**每条路径乘起来，路径之间加起来**。这条规则对任意多层嵌套都成立，而且正是反向传播算法的骨架。

【工程实践】反向传播（backpropagation）就是链式法则的工程实现。神经网络里，损失 L 是“最后一层输出”的函数，而每一层输出又依赖前一层的权重。要求 L 对某个深层权重的梯度，你不能“直接求”，只能**从损失出发，沿着计算图一层层回推，每层应用链式法则把梯度传回去**——这叫“梯度反向传播”。你在框架里敲一行 `loss.backward()`，底层干的活就是本章这条“路径相乘、路径相加”的链式法则。这也是为什么“可微”（上一章的许可证）是深度学习的生命线：**只有可微，链式法则每一环的偏导才存在，梯度才传得动。**

【历史溯源】一元链式法则的思想可追溯到**莱布尼茨（Leibniz, 17 世纪）**——他发明的 dx/dy 记号天然适合表达“除法相乘”的链式结构。多元链式法则的雏形在**拉格朗日（Lagrange）1797 年《解析函数论》**中被处理（该书基于幂级数分析、偏导已有系统使用），而链式法则的矩阵化（雅可比矩阵）要到 19 世纪中叶由雅可比系统完成。**有趣的是：数学家花了上百年才把“多元链式”写干净，而今天它却是每个训练神经网络的人每天用到的底层引擎——一百年前的纯理论，今天是最热的工程。**

第 3 轮：链式法则还能干什么——雅可比矩阵与"向量版链式"

老谟："你把树形图数明白了。那我把问题再拧一圈：如果 f 不是只有一个输出，而是一组输出呢？比如你手里有个映射 $F = (F_1, F_2)$ ， F_1 和 F_2 都依赖 x, y 。你要对 s, t 求导——这一下会有多少个数？"

造物主："..... F_1 对 s 、 F_1 对 t 、 F_2 对 s 、 F_2 对 t ，一共 $2 \times 2 = 4$ 个数。而且每个数又是一串链式相加。这也太零碎了。"

老谟："零碎——但零碎的东西往往可以**装箱**。你把这 4 个数按'行是输出、列是输入'摆成一个 2×2 的表格，每一格填 $\partial F_i / \partial x_j$ 。这个表格，数学家管它叫**雅可比矩阵**。你猜猜，装了箱之后，链式法则会变成什么？"

造物主：".....装箱之后？两个映射的复合，求导就是把两个雅可比矩阵.....**乘起来**？"

老谟："你自己说出来就对了——**复合映射的雅可比矩阵 = 各层雅可比矩阵的乘积**。你看，'一环接一环用乘法'这条一元直觉，在向量世界里变成'一环接一环用矩阵乘法'——结构完全没变，只是数换成了表。**这就是为什么链式法则在工程里能被写得那么整齐：它本质上是矩阵乘法。**"

知识锚点：雅可比矩阵——链式法则的"装箱版"

【概念深挖】雅可比矩阵 (Jacobian matrix)：设 $F: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ， $F(x) = (F_1(x), \dots, F_m(x))$ ，其雅可比矩阵是 $m \times n$ 矩阵

$$J_F(x) = \begin{bmatrix} \partial F_1 / \partial x_1 & \partial F_1 / \partial x_2 & \dots & \partial F_1 / \partial x_n \\ \partial F_2 / \partial x_1 & \partial F_2 / \partial x_2 & \dots & \partial F_2 / \partial x_n \\ \vdots & \vdots & \ddots & \vdots \\ \partial F_m / \partial x_1 & \partial F_m / \partial x_2 & \dots & \partial F_m / \partial x_n \end{bmatrix} \quad (\text{第 } i \text{ 行第 } j \text{ 列} = F_i \text{ 对 } x_j \text{ 的偏导})$$

复合映射链式法则 (链式法则的矩阵形式)：若 $F: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 、 $G: \mathbb{R}^p \rightarrow \mathbb{R}^n$ ，则对 $H = F \circ G$ ：

$$J_H(x) = J_F(G(x)) \cdot J_G(x) \quad (\text{矩阵乘法})$$

行列对应关系： J_H 第 i 行第 j 列 $= \sum_k (\partial F_i / \partial y_k)(\partial y_k / \partial x_j)$ ——**中间变量 k 求和**，这正是"路径相乘、路径相加"的矩阵写法（矩阵乘法就是"行点乘列"）。

【工程实践】雅可比矩阵在工程里最重要的场合是坐标变换与数值稳定性：机器学习里"概率分布之间的变量替换"（如归一化流 Normalizing Flows）要算行列式 $|\det J|$ ；机器人的关节角→末端位置的速度映射就是雅可比矩阵，逆雅可比还用于机械臂控制。**一个表 + 一条乘法规则，把无数条零碎的链式求和全部收编。** 本章计算训练场里你会亲手填一个 2×2 雅可比并验证乘法规则。

第 4 轮：让梯度学会“拐弯”之后——为什么要泰勒公式

老谋：“链式法则让你能算‘复合函数怎么变’。现在换个方向问：**我只知道 f 在某一点附近的所有偏导信息（梯度、二阶偏导），能不能把 f 在这一点附近的样子‘重建’出来？** 一元函数里，我们靠泰勒公式——用多项式把函数在一点附近越贴越紧。多元函数怎么办？”

造物主：“.....把泰勒公式搬过来？一元是 $f(x) \approx f(a) + f'(a)(x-a) + \frac{1}{2}f''(a)(x-a)^2$ 。多元版是不是就变成‘梯度那项 + 二阶那项’？”

老谋：“你猜对了一半。**一元泰勒的二阶项是 $\frac{1}{2}f''(a)(x-a)^2$ ——就一个数。多元的二阶项，你猜要有多少个数？**”

造物主：“..... f 对 x 求两次、对 y 求两次、交叉求—— f_{xx} 、 f_{yy} 、 f_{xy} ，至少三个数？还得考虑怎么‘配上’ $(x-a)$ 、 $(y-b)$ 这些差量.....”

老谋：“对。而且这三个数（加上 f_{yx} ）摆在一起，正好又是一个**表**——叫**海森矩阵**。你猜猜，这张表乘上位移向量，怎么把二阶项写出来？提示：想想一元二阶项 ' $\frac{1}{2} \times \text{一个数} \times (\Delta x)^2$ ' 的样子。”

造物主：“.....‘一个数 $\times \Delta x^2$ ’？那多元就是 ' $\frac{1}{2} \times \text{表} \times \Delta \text{向量} \times \Delta \text{向量}$ '？这听着像.....**二次型**—— $\mathbf{h}^T \mathbf{H} \mathbf{h}$ ！一个行向量乘矩阵再乘列向量。”

老谋：“你连二次型都摸出来了。**多元泰勒的二阶项 = $\frac{1}{2} \cdot \mathbf{h}^T \cdot \mathbf{H} \cdot \mathbf{h}$** ，其中 $\mathbf{H}$ 是海森矩阵， $\mathbf{h}$ 是位移向量。这个二次型将来在第 5 章（凸性判定）会变成主角——你现在先认识它：海森矩阵把所有‘二阶信息’打包，二次型 $\mathbf{h}^T \mathbf{H} \mathbf{h}$ 告诉你在位移 $\mathbf{h}$ 方向上，曲面是凸是凹、弯得多厉害。”

知识锚点：海森矩阵与多元泰勒公式

【概念深挖】海森矩阵 (Hessian matrix)： $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的二阶偏导矩阵

$$\mathbf{H}_f(\mathbf{x}) = \left[\partial^2 f / \partial x_i \partial x_j \right] \quad (n \times n \text{ 对称矩阵, 若混合偏导连续})$$

对角线是 $f_{x_i x_i}$ （对同一变量求两次偏导），非对角线是混合偏导 $f_{x_i x_j}$ 。**若二阶偏导连续（克莱罗定理条件成立），则 $\mathbf{H}$ 是对称的： $f_{x_i x_j} = f_{x_j x_i}$ 。**

多元泰勒公式（二阶）： 设 f 在 $\mathbf{a}$ 附近有二阶连续偏导， $\mathbf{h} = \mathbf{x} - \mathbf{a}$ ，则

$$f(\mathbf{a} + \mathbf{h}) \approx f(\mathbf{a}) + \nabla f(\mathbf{a}) \cdot \mathbf{h} + \frac{1}{2} \cdot \mathbf{h}^T \cdot \mathbf{H}(\mathbf{a}) \cdot \mathbf{h}$$

- 零阶项 $f(\mathbf{a})$ ：常数——“地基高度”；
- 一阶项 $\nabla f \cdot \mathbf{h}$ ：梯度点乘位移——“倾斜平面”的贡献；
- 二阶项 $\frac{1}{2} \mathbf{h}^T \mathbf{H} \mathbf{h}$ ：海森二次型——“抛物面弯曲”的贡献。

直观理解：多元泰勒 = 用“平面（一阶）+ 抛物面（二阶）”把曲面在一点附近精确地顶住。一阶项描述“往哪个方向斜”，二阶项描述“往哪个方向弯、弯得多狠”。后面你会看到：**一阶项（梯度）决定“该往哪走”，二阶项（海森）决定“那个地方是不是坑、坑深不深”。**

【概念深挖】二阶项的展开（ $n=2$ 时）： $\frac{1}{2} h^T H h = \frac{1}{2} [f_{xx} \cdot h_1^2 + 2f_{xy} \cdot h_1 h_2 + f_{yy} \cdot h_2^2]$ 。注意交叉项系数是 **$2f_{xy}$** （因为 $h^T H h$ 展开时 $f_{xy} \cdot h_1 h_2$ 与 $f_{yx} \cdot h_2 h_1$ 各出现一次，对称时合并成 $2f_{xy}$ ）。**这个“交叉项带系数 2”的细节是手算多元泰勒时最容易错的地方，计算训练场会专门练。**

【历史溯源】**泰勒公式**由布鲁克·泰勒（Brook Taylor）1715 年提出，最初形式并不被当时学界看重，直到**欧拉（Euler）和拉格朗日（Lagrange）**重新发掘并严格化，才成为微积分的重器。多元泰勒的展开则由拉格朗日、柯西等人逐步完成。**海森矩阵**以德国数学家路德维希·奥托·黑塞（Ludwig Otto Hesse, 1811–1874）命名——他在 19 世纪处理多元函数的极值问题时系统使用了二阶偏导矩阵，西尔维斯特（Sylvester）等人后来以他的名字称呼这张矩阵。

【工程实践】多元泰勒的工程用途多得惊人：**牛顿法**（用二阶泰勒近似求极小点，一步跳到抛物面的顶点）、**局部线性化**（在操作点附近用一阶泰勒近似系统动力学）、**二阶优化器**（如利用海森信息的自然梯度/牛顿类方法）。一句话：**凡是“在一点附近用简单东西近似复杂东西”，背后都是泰勒公式。**下一章积分里，你还会看到泰勒“误差项”思想的近亲——用小块拼出整体。

第 5 轮：二阶偏导的次序——交叉项到底该用 f_{xy} 还是 f_{yx}

老谟：“海森矩阵非对角线上有两个位置： f_{xy} 和 f_{yx} 。我们刚说矩阵要对称，这两个数得相等——**凭什么？**你先拿个具体函数试试： $f(x, y) = x^2 y$ 。先对 x 求偏导再对 y 求偏导，和先对 y 求偏导再对 x 求偏导，得到的一样吗？”

造物主：“……我算算。 $f_x = 2xy$ ，再对 y 求： $f_{xy} = 2x$ 。 $f_y = x^2$ ，再对 x 求： $f_{yx} = 2x$ 。**一样！都是 $2x$ 。**”

老谟：“换个函数试试： $f(x, y) = e^x \sin y$ 。”

造物主：“ $f_x = e^x \sin y$ ，再对 y 求： $f_{xy} = e^x \cos y$ 。 $f_y = e^x \cos y$ ，再对 x 求： $f_{yx} = e^x \cos y$ 。**又一样。**难道……怎么求次序都无所谓？”

老谟：“大部分‘正经’函数都无所谓——这就是上一章的**克莱罗定理**。但你要小心：**‘无所谓’不是免费的，它要收门票——二阶混合偏导必须连续。**下一轮我给你看一个‘门票没交’的怪函数，它的 f_{xy} 和 f_{yx} 会不一样。你先记住：**海森矩阵能写成对称矩阵，靠的是克莱罗定理；而克莱罗定理有前提。**”

知识锚点：克莱罗定理与“不交门票”的反例

【概念深挖】**克莱罗定理 (Clairaut's theorem)**：若 f 在点 a 的某个邻域内二阶混合偏导 f_{xy} 、 f_{yx} 都存在且连续，则 $f_{xy}(a) = f_{yx}(a)$ 。**结论：混合偏导连续时，求导次序可以交换，海森矩阵对称。**

反例（门票没交，次序不可交换）：

$$f(x, y) = xy \cdot (x^2 - y^2) / (x^2 + y^2) \quad ((x, y) \neq (0, 0)) ; f(0, 0) = 0$$

这个函数在原点可以验证 $f_{xy}(0,0) = -1$ 而 $f_{yx}(0,0) = +1$ ——两个混合偏导在原点**不相等**！原因正是它在原点附近的混合偏导**不连续**，克莱罗定理的门票没交。这个函数很病态（在原点附近剧烈振荡），却完美地钉死了一件事：**海森矩阵的对称性不是白来的，它靠“二阶偏导连续”这一条。**

【工程实践】工程里绝大多数损失函数（多项式、指数、对数、sigmoid 组合）都满足二阶偏导连续，所以海森矩阵对称性几乎总是成立，二阶优化器放心用。**但遇到“分片函数”“带折角的函数”（如 ReLU 复合）时要留个心眼：分界处二阶偏导可能不连续，海森对称性的前提可能被踩破。**这也是为什么工程代码里检测到海森矩阵不对称时，往往会“人工对称化”（取 $(H + H^T)/2$ ）。

第 6 轮：多元泰勒的误差——近似到底准不准

老谟：“泰勒公式给你一个近似： $f(a+h) \approx f(a) + \nabla f \cdot h + \frac{1}{2}h^T H h$ 。可它是**近似**，不是**等于**。我问你：这个近似的误差有多大？什么时候可以放心用？”

造物主：“……一元泰勒有拉格朗日余项，误差是 $O(|h|^3)$ 或更高阶的小量。多元版应该也差不多？——好像误差会小到‘比位移的三次方还小’？”

老谟：“方向对了。**多元二阶泰勒的误差是 $o(|h|^2)$ ——也就是‘比 $|h|^2$ 还要高阶的小量’。**意思是： h 缩到一半，误差缩到原来的 $1/4$ 以下（因为误差按 $|h|^2$ 以上的阶收缩）。这个‘误差阶’的性质，比误差本身的价值还要重要——它保证了： **h 足够小的时候，抛物面近似几乎就是精确的。**以后第 6 章分析梯度下降收敛性、第 7 章判定鞍点，我们都会反复用‘二阶泰勒近似 + 误差是 $o(|h|^2)$ ’这套组合拳。你现在先把‘近似 + 误差阶’这个结构装好。”

知识锚点：泰勒公式的误差阶——“近似 + 余项”结构

【概念深挖】多元二阶泰勒的完整写法（含余项）： $f(a+h) = f(a) + \nabla f(a) \cdot h + \frac{1}{2} h^T H(a) h + o(|h|^2)$ ，当 $h \rightarrow 0$ 。

其中 $o(|h|^2)$ （读作“小 o 的 $|h|^2$ ”）表示**余项比 $|h|^2$ 更快趋于 0**： $\lim_{h \rightarrow 0} |\text{余项}|/|h|^2 = 0$ 。**一阶版本（省略二阶项）的误差是 $o(|h|)$ 。**

严格注记：误差阶 $o(|h|^2)$ 的成立条件是 f 在 a 附近有二阶连续偏导。若只有一阶信息，二阶项就没有保证。**"近似公式 + 误差阶"是配套出售的**——你写近似式时，必须同时声明它成立的前提（几阶可微）。

【工程实践】"误差阶"在数值方法里是生死线：**机器学习的优化器每次只迈很小一步（学习率小），正是为了待在'泰勒近似足够准'的区域里。**步长太大，误差 $o(|h|^2)$ 不再小，近似失效，训练发散——这就是"学习率太大导致损失爆炸"的数学根源。**误差阶思想贯穿全书：近似不可怕，可怕的是不知道近似在什么时候失效。**

第 7 轮：落点——"串"与"近似"两把钥匙

老谟："把窗台上那杯水端起来。你手里现在有两把钥匙，分别回答两个问题。第一把：'复合函数怎么求变化'——答案是什么？"

造物主："**链式法则：**每根分支'偏导 $\times$ 偏导'，分支之间相加；换成映射就是雅可比矩阵相乘。反向传播的底层就是它。"

老谟："第二把：'只知道局部的导数信息，怎么重建函数形状'——答案是什么？"

造物主："**多元泰勒：**用梯度（一阶）+ 海森矩阵（二阶）构造'平面 + 抛物面'，把曲面在一点附近顶住；误差是 $o(|h|^2)$ 。海森矩阵靠克莱罗定理保证对称。"

老谟："两把钥匙放一起，你会发现它们合起来能干一件大事：**第 5 章判定凸性、第 6 章证明梯度下降收敛、第 7 章区分鞍点和极小点，全都是'先链式求梯度/海森，再泰勒近似局部'的套路。**你先把这两把钥匙磨好——明天我们离开'点'，去解决'一块区域上的累积'：积分。"

严格化走廊

位置说明：本章对话负责"直觉"——为什么"串"是乘、为什么需要海森。本走廊负责"严谨"——把链式法则与多元泰勒写成精确的定理，并给出可复写的证明。**下面每一行，读者都能对着空白纸重写一遍。**

定义 1：复合函数 (composition)

设 $g: \mathbb{R} \rightarrow \mathbb{R}$ 、 $x: \mathbb{R} \rightarrow \mathbb{R}$ 、 $y: \mathbb{R} \rightarrow \mathbb{R}$ ，且 $x(t)$ 、 $y(t)$ 的取值落在 f 的定义域内。复合函数为 $F(t) = f(x(t), y(t))$ 。

定义 2：雅可比矩阵 (Jacobian matrix)

设 $F: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $F(x) = (F_1(x), \dots, F_m(x))$ 在 x 处所有偏导存在。**雅可比矩阵**为 $m \times n$ 矩阵

$$J_F(x) = [\partial F_i / \partial x_j(x)], \quad i = 1, \dots, m; \quad j = 1, \dots, n$$

定义 3：海森矩阵 (Hessian matrix)

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 x 处所有二阶偏导存在。**海森矩阵**为 $n \times n$ 矩阵

$$H_f(x) = [\partial^2 f / \partial x_i \partial x_j(x)]$$

若二阶偏导在 x 附近连续 (克莱罗定理条件), 则 $H_f(x)$ 对称。

定理 1 (一元链式法则)：若 u 在 t 处可导、 f 在 $u(t)$ 处可导, 则

$$(f \circ u)'(t) = f'(u(t)) \cdot u'(t)$$

证明 (可复写)：

- 记 $\Delta u = u(t+h) - u(t)$, $\Delta f = f(u(t+h)) - f(u(t))$ 。若 $\Delta u \neq 0$, 作恒等变形: $\Delta f/h = (\Delta f/\Delta u) \cdot (\Delta u/h)$ 。左端是差商 $[f(u(t+h)) - f(u(t))]/h$ 。
- 由 u 在 t 可导: $\Delta u/h \rightarrow u'(t)$ (当 $h \rightarrow 0$)。
- 由 f 在 $u(t)$ 可导: $\Delta f/\Delta u \rightarrow f'(u(t))$ (当 $\Delta u \rightarrow 0$; 而 $h \rightarrow 0$ 时 $\Delta u \rightarrow 0$, 因为 u 可导 $\Rightarrow u$ 连续)。
- 于是 $(f \circ u)'(t) = \lim \Delta f/h = \lim (\Delta f/\Delta u) \cdot (\Delta u/h) = f'(u(t)) \cdot u'(t)$ 。■

证明要点标注：第 1 步是**差商恒等变形** (除一个数再乘同一个数); 第 2、3 步分别用 **u 的可导性**与 **f 的可导性** (以及“可导 $\Rightarrow$ 连续”推出 $\Delta u \rightarrow 0$); 第 4 步是**极限的四则运算** (乘积的极限)。

定理 2 (多元链式法则)：设 f 在点 (x_0, y_0) 可微, $x(t)$ 、 $y(t)$ 在 t_0 可导且 $(x(t_0), y(t_0)) = (x_0, y_0)$, 则 $F(t) = f(x(t), y(t))$ 在 t_0 可导, 且

$$F'(t_0) = f_x(x_0, y_0) \cdot x'(t_0) + f_y(x_0, y_0) \cdot y'(t_0)$$

证明 (可复写)：

- 令 $\Delta t = h$, $\Delta x = x(t_0+h) - x(t_0)$, $\Delta y = y(t_0+h) - y(t_0)$ 。因 f 在 (x_0, y_0) 可微 (定义: 第 01 章定义 4), 全增量可写为: $F(t_0+h) - F(t_0) = f_x(x_0, y_0) \cdot \Delta x + f_y(x_0, y_0) \cdot \Delta y + \varepsilon_1 \cdot |(\Delta x, \Delta y)|$, 其中 ε_1

$\rightarrow 0$ (当 $(\Delta x, \Delta y) \rightarrow 0$)。

- 两边除以 h : $[F(t_0+h) - F(t_0)]/h = f_x \cdot (\Delta x/h) + f_y \cdot (\Delta y/h) + \varepsilon_1 \cdot (|\Delta x, \Delta y|/h)$ 。
- 因 x, y 在 t_0 可导: $\Delta x/h \rightarrow x'(t_0), \Delta y/h \rightarrow y'(t_0)$ 。
- 关键一项: $|\Delta x, \Delta y|/h = |h| \cdot |(\Delta x/h, \Delta y/h)| / h = (|h|/h) \cdot |(\Delta x/h, \Delta y/h)|$ 。因 $(\Delta x/h, \Delta y/h)$ 收敛于 (x', y') (有界), $|\Delta x, \Delta y|/h$ 有界; 又 $\varepsilon_1 \rightarrow 0$, 故 $\varepsilon_1 \cdot (|\Delta x, \Delta y|/h) \rightarrow 0$ 。
- 取极限: $F'(t_0) = f_x \cdot x'(t_0) + f_y \cdot y'(t_0)$ 。■

证明要点标注: 第 1 步用了**第 01 章定义 4 (可微的线性主部分解)**; 第 2 步是**代数整理**; 第 3 步用 x, y 的可导性; 第 4 步用**有界量 $\times$ 无穷小仍为无穷小** ($\varepsilon_1 \rightarrow 0$ 且 $|\Delta x, \Delta y|/h$ 有界); 第 5 步是**极限的四则运算**。

定理 3 (多元泰勒公式, 二阶): 设 f 在 a 附近有连续二阶偏导, 则当 $h \rightarrow 0$ 时

$$f(a+h) = f(a) + \nabla f(a) \cdot h + \frac{1}{2} h^T H(a) h + o(|h|^2)$$

证明 (思路, 可复写关键步骤): 以 $n=1$ 为热身, 二阶泰勒 $f(a+h) = f(a) + f'(a)h + \frac{1}{2}f''(a)h^2 + o(h^2)$, 这是**一元泰勒定理 (拉格朗日余项)**直接给出。对 $n=2$, 把 h 看成向量 (h_1, h_2) , 对一元函数 $\varphi(t) = f(a + t \cdot h)$ ($0 \leq t \leq 1$) 用一元二阶泰勒:

- $\varphi(1) = \varphi(0) + \varphi'(0) \cdot 1 + \frac{1}{2}\varphi''(0) \cdot 1^2 + o(1)$ 。
- 由定理 2 (多元链式法则): $\varphi'(0) = \nabla f(a) \cdot h$; $\varphi''(0) = h^T H(a) h$ (对 φ' 再求一次导数, 仍是链式法则; 交叉项 f_{xy}, f_{yx} 因克莱罗定理合并为 $2f_{xy} \cdot h_1 h_2$, 正好是二次型 $h^T H h$ 的展开)。
- 代入即得 $f(a+h) = f(a) + \nabla f(a) \cdot h + \frac{1}{2}h^T H(a) h + o(|h|^2)$ 。■

证明要点标注: 第 1 步是**"沿一条直线看"的降维技巧** (把多元函数限制在 a 到 $a+h$ 的线段上, 变成一元函数 $\varphi(t)$); 第 2 步用**定理 2 (多元链式法则) 连求两次导**; 第 3 步用**克莱罗定理**合并交叉项。

严格注记 (前提与证法的台阶差): 上述"沿直线降维 + 一元拉格朗日余项"的证法, 严格讲需要 f 在 a 附近有三阶连续偏导 (一元拉格朗日二阶余项的要求)。若只假设二阶连续偏导 (C^2), 结论 $f(a+h) = f(a) + \nabla f(a) \cdot h + \frac{1}{2}h^T H(a) h + o(|h|^2)$ **依然成立**, 但需改用 **Peano 余项**论证 (本质仍是"余项除以 $|h|^2$ 后趋于 0")。本教材以讲透思路为度, 不展开 Peano 余项的完整推导——你只需记住结论: C^2 下二阶泰勒的余项是 $o(|h|^2)$, 这一条在后面的凸性判定与鞍点分析中会被反复使用。

反例/边界

- **一元链式法则的边界**： f 在 $u(t)$ 不可导或 u 在 t 不可导时，定理不成立。如 $f(u) = |u|$ 在 $u = 0$ 不可导，则 $f(\sin t) = |\sin t|$ 在 $t = 0$ 处不可导（尽管 $\sin t$ 处处可导）——**外函数可导性缺一不可**。
- **多元链式的边界**：定理 2 要求 f 可微（不只是偏导存在）。上一章反例 $f = xy/(x^2+y^2)$ 在原点偏导存在但不可微，若 $x(t)$ 、 $y(t)$ 斜着穿过原点，链式法则会算错——**这就是为什么"可微是许可证"**。
- **克莱罗定理的边界**：混合偏导不连续时 $f_{xy} \neq f_{yx}$ 。反例 $f = xy(x^2-y^2)/(x^2+y^2)$ 在原点给出 $f_{xy} = -1$ 、 $f_{yx} = +1$ ，**海森矩阵不对称**，多元泰勒的二阶项写法失效。
- **泰勒近似的边界**：误差 $o(|h|^2)$ 只在 $h \rightarrow 0$ 时"小"。 h 大时近似可能很差（如 $f = e^x$ ，二阶泰勒在离原点远的地方严重失真）——**近似公式必须配合"h 小"的前提使用**。

知识点总结

知识点（本章推出的核心概念）

- **一元链式法则**： $df/dt = f'(u) \cdot u'(t)$ ——一环接一环，用乘法。差商恒等变形是其证明核心。
- **多元链式法则**： $df/dt = f_x \cdot x' + f_y \cdot y'$ ——每根分支"偏导 $\times$ 导数"，分支之间相加；多变量外变量时"导数"换成"偏导"。
- **树形记忆法**：从根到目标变量的每条路径，路径上偏导相乘，路径之间相加。
- **雅可比矩阵**： $J_F = [\partial F_i / \partial x_j]$ ；复合映射链式 = **雅可比矩阵相乘**（矩阵版本的"一环接一环"）。
- **海森矩阵**： $H = [\partial^2 f / \partial x_i \partial x_j]$ ，二阶偏导连续时**对称**（克莱罗定理）。
- **多元泰勒公式（二阶）**： $f(a+h) \approx f(a) + \nabla f \cdot h + \frac{1}{2} h^T H h + o(|h|^2)$ ——**平面 + 抛物面**顶住曲面；交叉项系数为 $2f_{xy}$ 。
- **误差阶**： $o(|h|^2)$ 表示余项比 $|h|^2$ 更快趋于 0；"近似公式 + 误差阶 + 可微前提"三者配套。

历史结论（本章涉及的史料）

- **莱布尼茨（17 世纪）**： dx/dy 记号天然适合表达链式结构，一元链式法则的思想源头。
- **拉格朗日（1797）**：《解析函数论》系统表述多元链式法则。
- **泰勒（1715）**：提出泰勒公式；欧拉、拉格朗日重新发掘并严格化。
- **黑塞（19 世纪）**：系统使用二阶偏导矩阵处理多元极值，海森矩阵以他命名；西尔维斯特等人推广了这一称呼。
- **克莱罗（18 世纪）**：混合偏导相等的定理（克莱罗定理）。

工程实践结论（本章知识在真实工程里怎么用）

- **反向传播 = 多元链式法则的工程实现**：loss.backward() 底层就是"路径相乘、路径相加"。
- **雅可比矩阵**：归一化流（行列式）、机械臂运动学（速度映射）、坐标变换。
- **牛顿法 = 多元泰勒的应用**：用二阶近似一步跳到抛物面顶点求极小点。
- **学习率必须小**：梯度下降每步待在"泰勒近似足够准"的区域，步长太大误差 $o(|h|^2)$ 失控导致发散。
- **海森对称性检查**：遇到分片/折角函数（ReLU 复合），二阶偏导可能不连续，代码里常做人工对称化 $(H+H^T)/2$ 。

计算训练场

位置说明：本章对话负责"为什么"，这里负责"怎么算"。请动笔完成每题后再对照解答。

题 1（易→中）：多元链式法则——全导数

题干：设 $f(x, y) = x^2y$ ，其中 $x(t) = t^2$ ， $y(t) = t^3$ 。(a) 用多元链式法则求 df/dt 。(b) 把 $x(t)$ 、 $y(t)$ 直接代入 f 得到一元函数 $f(t)$ ，直接求导，验证 (a) 的结果一致。(c) 求 df/dt 在 $t = 1$ 处的值。

完整分步解答：

(a) 链式法则：第 1 步：求外层偏导： $f_x = 2xy$ ， $f_y = x^2$ 。第 2 步：求内层导数： $x'(t) = 2t$ ， $y'(t) = 3t^2$ 。第 3 步：套公式 $df/dt = f_x \cdot x' + f_y \cdot y' = 2xy \cdot (2t) + x^2 \cdot (3t^2)$ 。第 4 步：代入 $x = t^2$ 、 $y = t^3$ ： $df/dt = 2 \cdot t^2 \cdot t^3 \cdot 2t + (t^2)^2 \cdot 3t^2 = 4t^6 + 3t^6 = 7t^6$ 。

(b) 直接代入验证：第 5 步： $f(t) = (t^2)^2 \cdot t^3 = t^4 \cdot t^3 = t^7$ 。第 6 步：直接求导： $f'(t) = 7t^6$ ✓ 与 (a) 一致。

(c) 数值：第 7 步： $t = 1$ ： $df/dt = 7 \cdot 1^6 = 7$ 。

答：(a) $df/dt = 7t^6$ ；(b) 与直接求导 $t^7 \rightarrow 7t^6$ 一致；(c) $t=1$ 处为 **7**。

常见错误：① 套公式时忘了"代入 x 、 y 的表达式"这最后一步，把 $2xy$ 留在答案里；② 把 $f_x = 2xy$ 误算成 $2x$ （把 y 当变量又当常数）；③ 直接代入时 $(t^2)^2$ 算成 t^4 是对的，但有人算成 t^6 。

题 2（中）：全链式法则——两个外变量，多层嵌套

题干：设 $f(x, y) = e^{(xy)}$ ，其中 $x = s^2 + t$ ， $y = st$ 。(a) 求 $\partial f/\partial s$ 与 $\partial f/\partial t$ （链式法则，表达式形式）。(b) 求 $\partial f/\partial s$ 与 $\partial f/\partial t$ 在点 $(s, t) = (1, 2)$ 的数值。(c) 直接代入化简 $f(s, t)$ ，重新求偏导，验证 (b)。

完整分步解答：

(a) 链式法则 (符号) : 第 1 步: 外层偏导: $f_x = y \cdot e^{(xy)}$, $f_y = x \cdot e^{(xy)}$ 。第 2 步: 内层偏导: $\partial x / \partial s = 2s$, $\partial x / \partial t = 1$; $\partial y / \partial s = t$, $\partial y / \partial t = s$ 。第 3 步: $\partial f / \partial s = f_x \cdot \partial x / \partial s + f_y \cdot \partial y / \partial s = y \cdot e^{(xy)} \cdot 2s + x \cdot e^{(xy)} \cdot t$ 。第 4 步: $\partial f / \partial t = f_x \cdot \partial x / \partial t + f_y \cdot \partial y / \partial t = y \cdot e^{(xy)} \cdot 1 + x \cdot e^{(xy)} \cdot s$ 。

(b) 数值: 第 5 步: 在 $(1, 2)$: $x = 1^2 + 2 = 3$, $y = 1 \cdot 2 = 2$, $xy = 6$, $e^6 \approx 403.4288$ 。第 6 步: $\partial f / \partial s = 2 \cdot e^6 \cdot (2 \cdot 1) + 3 \cdot e^6 \cdot 2 = 2e^6 \cdot 2 + 3e^6 \cdot 2 = 4e^6 + 6e^6 = 10e^6 \approx 4034.3$ 。第 7 步: $\partial f / \partial t = 2 \cdot e^6 \cdot 1 + 3 \cdot e^6 \cdot 1 = 5e^6 \approx 2017.1$ 。

(c) 直接代入验证: 第 8 步: $f(s, t) = e^{\{(s^2+t)(st)\}} = e^{\{s^3t + st^2\}}$ 。第 9 步: $\partial f / \partial s = e^{\{s^3t + st^2\}} \cdot (3s^2t + t^2)$ 。在 $(1, 2)$: $= e^6 \cdot (3 \cdot 1 \cdot 2 + 4) = e^6 \cdot 10 = 10e^6 \checkmark$ 。第 10 步: $\partial f / \partial t = e^{\{s^3t + st^2\}} \cdot (s^3 + 2st)$ 。在 $(1, 2)$: $= e^6 \cdot (1 + 4) = 5e^6 \checkmark$ 。

答: (a) $\partial f / \partial s = 2s \cdot y \cdot e^{(xy)} + t \cdot x \cdot e^{(xy)}$, $\partial f / \partial t = y \cdot e^{(xy)} + s \cdot x \cdot e^{(xy)}$; (b) $\partial f / \partial s = 10e^6 \approx 4034.3$, $\partial f / \partial t = 5e^6 \approx 2017.1$ ($e^6 \approx 403.4288$) ; (c) 验证一致 $\checkmark$ 。

常见错误: ① 算 $\partial f / \partial s$ 时把 $\partial y / \partial s$ 写成 1 (忘了 $y = st$ 对 s 求偏导是 t) ; ② $e^{(xy)}$ 链式求导时忘乘"内层对目标变量的偏导", 直接写 $e^{(xy)}$; ③ 交叉项漏项——两条路径 (经 x 、经 y) 缺一条。

题 3 (中→难) : 多元泰勒二阶展开——近似值与真实值对比

题干: 设 $f(x, y) = e^x \cos y$ 。(a) 求 ∇f 与海森矩阵 H 在 $(0, 0)$ 的值。(b) 写出 f 在 $(0, 0)$ 的二阶泰勒展开 (展开为 x 、 y 的多项式)。(c) 在点 $(0.1, 0.1)$, 比较"二阶泰勒近似值"与"真实值 $e^{0.1} \cos 0.1$ ", 计算相对误差。(d) 验证: 对二次多项式 $f(x, y) = x^2 + xy + y^2$, 在 $(1, 1)$ 的二阶泰勒展开精确等于原函数 (提示: 三阶及以上偏导为 0)。

完整分步解答:

(a) 梯度与海森: 第 1 步: $f_x = e^x \cos y$, $f_y = -e^x \sin y$ 。代入 $(0, 0)$: $\nabla f = (1, 0)$ 。第 2 步: 二阶偏导: $f_{xx} = e^x \cos y$, $f_{xy} = -e^x \sin y$, $f_{yy} = -e^x \cos y$ 。代入 $(0, 0)$: $f_{xx} = 1$, $f_{xy} = 0$, $f_{yy} = -1$ 。第 3 步: $H(0, 0) = [[1, 0], [0, -1]]$ 。

(b) 二阶泰勒展开: 第 4 步: $f(0, 0) = e^0 \cos 0 = 1$ 。第 5 步: 一阶项: $\nabla f \cdot (x, y) = 1 \cdot x + 0 \cdot y = x$ 。第 6 步: 二阶项: $\frac{1}{2} h^T H h = \frac{1}{2} (x^2 \cdot 1 + 2 \cdot 0 \cdot xy + y^2 \cdot (-1)) = \frac{1}{2} x^2 - \frac{1}{2} y^2$ 。第 7 步: **$f(x, y) \approx 1 + x + \frac{1}{2} x^2 - \frac{1}{2} y^2$** 。

(c) 数值比较: 第 8 步: 在 $(0.1, 0.1)$: 近似 $= 1 + 0.1 + \frac{1}{2}(0.01) - \frac{1}{2}(0.01) = 1.1$ 。第 9 步: 真实值 $= e^{0.1} \cdot \cos(0.1) = 1.1051709 \times 0.9950042 \approx 1.0996$ 。第 10 步: 相对误差 $= |1.1 - 1.0996| / 1.0996 \approx 0.0004 / 1.0996 \approx 0.036\%$ 。二阶近似在 $(0.1, 0.1)$ 已相当准。

(d) 精确性验证: 第 11 步: $f = x^2 + xy + y^2$ 。 $f(1, 1) = 3$; $\nabla f = (2x+y, x+2y)$, 在 $(1, 1)$ 为 $(3, 3)$; 海森 $H = [[2, 1], [1, 2]]$ (常数矩阵)。第 12 步: 令 $h_1 = x-1$, $h_2 = y-1$ 。泰勒展开: $3 + 3h_1 +$

$3h_2 + \frac{1}{2}(2h_1^2 + 2 \cdot 1 \cdot h_1 h_2 + 2h_2^2) = 3 + 3h_1 + 3h_2 + h_1^2 + h_1 h_2 + h_2^2$ 。第 13 步：展开原函数验证： $(1+h_1)^2 + (1+h_1)(1+h_2) + (1+h_2)^2 = 3 + 3h_1 + 3h_2 + h_1^2 + h_1 h_2 + h_2^2$ 。**逐项一致 ✓**——因为二次多项式的三阶及以上偏导全为 0，泰勒的"高阶尾巴"不存在，展开精确等于原函数。

答：(a) $\nabla f = (1, 0)$ ， $H = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ ；(b) $f \approx 1 + x + \frac{1}{2}x^2 - \frac{1}{2}y^2$ ；(c) 近似 1.1 vs 真实 ≈ 1.0996 ，相对误差 $\approx 0.036\%$ ；(d) 精确相等 ✓。

常见错误：① 二阶项的交叉项系数写错—— $h^T H h$ 展开后交叉项是 $2f_{xy} \cdot xy$ ，所以 $\frac{1}{2}$ 乘进去后是 $f_{xy} \cdot xy$ ；② 把 $f_{yy} = -e^x \cos y$ 算成 $+$ （ $\cos y$ 求两次导变 $-\cos y$ ）；③ 验证 (d) 时忘了"泰勒对多项式是精确的"——高阶项为 0 所以没有截断误差。

向导便签

这一章咱们干了什么：从"温度 $T(x, y)$ 沿着 $x(t)$ 、 $y(t)$ 这条路怎么变"这个问题出发，把一元链式法则升级成多元版——**每根分支"偏导×导数"，分支相加**；又用雅可比矩阵把"一堆零碎的链式求和"装进"矩阵乘法"这一个动作。接着把一元泰勒搬成多元版——**梯度（一阶）+ 海森矩阵（二阶）构造"平面 + 抛物面"把曲面顶住**，并记住误差是 $o(|h|^2)$ 。

钉死一句话：**链式法则 = 逐支乘、分支加（雅可比 = 矩阵乘）；多元泰勒 = $f + \nabla f \cdot h + \frac{1}{2}h^T H h$ ，误差 $o(|h|^2)$** 。前者让你会算"复合的导数"，后者让你会"局部重建函数"——这两招是全书后面所有"优化"章节的公共地基。

记住一个边界：**海森矩阵对称靠克莱罗定理（二阶偏导连续）**；遇到折角函数（ReLU）要留神，二阶信息可能失真。还有，**泰勒是近似不是等于**，步长一大误差就失控——这句第 6 章还会回来找你。

造物主手记

我曾踩的坑：

我一开始以为多元链式法则就是把一元的"乘"原样搬来——结果 f 有两个输入，我少算了一根分支，只沿 x 那条路算，忘了 y 那条路也要贡献，算出的导数差了一半。老谟让我画树形图：**从 f 到目标变量，每一条路径都不能漏**。另一个坑是多元泰勒的交叉项：我把 $\frac{1}{2}h^T H h$ 展开时，交叉项系数写成了 f_{xy} 而不是 $2f_{xy}$ ——差了一个因子 2，近似值和真实值对不上。**"交叉项带 2"这个细节，是手算多元泰勒最阴险的地方。**

顿悟时刻：

真正让我开窍的是雅可比矩阵那一步。老谟让我把四个偏导摆成 2×2 的表格，然后说"复合求导就是矩阵相乘"——那一刻我突然看清：**零碎的四条链式求和，装进一张表之后，只剩一个动作"乘"**。数学里

的"装箱" (向量、矩阵) 不是花架子, 它真的把计算简化了。从此我养成了一个习惯: **看到一堆零碎求和, 先想能不能装进一个矩阵。**

自测题

计算题须动笔完成, 附完整解答自核; 概念题用于检查理解。

题 A (计算, 易→中) : 链式法则求导

设 $f(x, y) = \sin(xy)$, $x(t) = 2t$, $y(t) = t^2$ 。(a) 用多元链式法则求 df/dt 。(b) 直接代入求 $f(t)$ 并求导, 验证一致。(c) 求 df/dt 在 $t = 1$ 的数值 (保留 3 位小数, $\cos 2 \approx -0.4161$)。

完整解答: (a) $f_x = y \cdot \cos(xy)$, $f_y = x \cdot \cos(xy)$; $x' = 2$, $y' = 2t$ 。 $df/dt = y \cdot \cos(xy) \cdot 2 + x \cdot \cos(xy) \cdot 2t = 2y \cdot \cos(xy) + 2tx \cdot \cos(xy)$ 。代入 $x = 2t$ 、 $y = t^2$: $df/dt = 2t^2 \cos(2t^3) + 2t \cdot (2t) \cos(2t^3) = 2t^2 \cos(2t^3) + 4t^2 \cos(2t^3) = 6t^2 \cdot \cos(2t^3)$ 。(b) $f(t) = \sin(2t \cdot t^2) = \sin(2t^3)$, $f'(t) = 6t^2 \cdot \cos(2t^3)$ ✓ 一致。(c) $t = 1$: $6 \cdot 1 \cdot \cos 2 = 6 \times (-0.4161) \approx -2.497$ 。

题 B (计算, 中→难) : 多元泰勒二阶展开

设 $f(x, y) = x^2y - y^3$ 。(a) 求 ∇f 与海森矩阵 H 在点 $(1, 1)$ 。(b) 写出 f 在 $(1, 1)$ 的二阶泰勒展开 (用 $h_1 = x-1$ 、 $h_2 = y-1$ 表示)。(c) 用展开式估计 f 在 $(0.9, 1.1)$ 的值, 并与真实值比较。

完整解答: (a) $f_x = 2xy$, $f_y = x^2 - 3y^2$ 。在 $(1,1)$: $f_x = 2$, $f_y = 1 - 3 = -2$ 。 $\nabla f = (2, -2)$ 。 $f_{xx} = 2y \rightarrow 2$; $f_{xy} = 2x \rightarrow 2$; $f_{yy} = -6y \rightarrow -6$ 。 $H = \begin{bmatrix} 2 & 2 \\ 2 & -6 \end{bmatrix}$ 。(b) $f(1,1) = 1 - 1 = 0$ 。展开: $f \approx 0 + 2h_1 + (-2)h_2 + \frac{1}{2}(2h_1^2 + 2 \cdot 2 \cdot h_1h_2 + (-6)h_2^2) = 2h_1 - 2h_2 + h_1^2 + 2h_1h_2 - 3h_2^2$ 。(c) $h_1 = 0.9 - 1 = -0.1$, $h_2 = 1.1 - 1 = 0.1$: 近似 $= 2(-0.1) - 2(0.1) + (-0.1)^2 + 2(-0.1)(0.1) - 3(0.1)^2 = -0.2 - 0.2 + 0.01 - 0.02 - 0.03 = -0.44$ 。真实值 $= x^2y - y^3 = (0.9)^2 \cdot 1.1 - (1.1)^3 = 0.81 \cdot 1.1 - 1.331 = 0.891 - 1.331 = -0.44$ 。完全相等 ✓ (因为 f 是三次多项式, 二阶泰勒恰好精确到"包括二次", 这里 h 方向的二次项完整保留, 巧合下精确——注意一般三次项会有截断, 本例只用了 $(0.9, 1.1)$ 恰好消掉)。

题 C (概念, 检查理解) : 链式法则与可微

老谟给造物主一个场景: $f(x,y)$ 在点 a 的两个偏导都存在, 但不可微; $x(t)$ 、 $y(t)$ 沿斜线穿过 a 。(1) 用多元链式法则求 df/dt 的公式, 在 a 点还可靠吗? 为什么?(2) 如果 f 可微但 x 、 y 中有一个在 a 不可导, 链式法则还成立吗?

完整解答: (1) 不可靠。定理 2 的证明第一步就用了" f 可微" (线性主部分解); f 只有偏导存在时, " f 变化 $\approx f_x \Delta x + f_y \Delta y$ " 这个线性主部不成立, 斜线方向上的行为不可控 (回想第 01 章反例 $xy/(x^2+y^2)$)。所以必须 f 可微。(2) 不成立。链式法则需要内层也可导—— x 或 y 在 a 处不可导, $\Delta x/h$ 不收敛, 差商极限不存在。链式法则要求"每一环都可导", 缺一环整个链断。

预告

你手里现在有两把钥匙：链式法则（复合函数怎么求变化）和多元泰勒（局部怎么重建曲面）。

可这两把钥匙，都还停留在"一个点"上。**下一章，我们要离开点，去面对"一整块区域"：二重积分。**一元积分是把曲线下的面积"切成薄条再累加"；多元积分是把曲面下的体积"切成小柱再累加"——可"切"的方向突然多了：先切 x 再切 y 、先切 y 再切 x 、用极坐标切.....**同样的体积，不同切法，结果会一样吗？** 那叫 Fubini 定理（富比尼定理），是下一章的主角。

而在那之前你最好记住本章最后一句话：**泰勒近似只在"步长小"时可信**——这个直觉马上会在"积分切块"里变成"块越小越准"。

第 03 章 · 多元积分——高维"面积"怎么加出来

本章从哪个问题出发：一元积分把曲线下的面积"切成薄条再累加"，得到的是一条线段上积累的总量。可一旦进入二维，你要算的不再是"一根线段下的面积"，而是"一张曲面底下一整块区域上的体积"——"切"的方向突然从"一条路"变成"一片地"，你往哪个方向切？不同的切法，加出来的东西还是同一个吗？推导到哪个结论：答案是**二重积分**——先把区域切成无数小块（小柱），每块的高度乘上小块的底面积，再全部加起来取极限；进而发现**累次积分**（先沿一个方向积、再沿另一个方向积）和"矩形域上的二重积分"是同一件事（**Fubini 定理**）；当区域是圆的、函数带旋转对称性时，**极坐标变换** $dA = r \cdot dr \cdot d\theta$ 能把"切"这件事做得又巧又快。

核心认知：**二重积分 = 把一块区域切成小柱、体积（高×底面积）求和取极限；它有三种"切法"——先 x 后 y、先 y 后 x、极坐标，在"好区域"上它们给出同一个数。**这一章是你从"点上的导数"走向"整块区域上的累积"的第一块跳板：它直接为册 06 的联合分布概率 $P((X,Y) \in D) = \iint_D f \, dx dy$ 铺好了路。

引子

老谟的厨房里横着一大块还没有切的红薯蛋糕，形状歪歪扭扭——不是规整的长方体，也不是圆柱，就是一刀下去随手切出来的、边角不齐的一块。

"我今天不爬山了，"我抄起刀，"我盯上这块蛋糕。老谟，我问你个实在的问题：**这块蛋糕占了多少体积？**你别跟我说秤——我要的是一个数，而且要用数学算出来。"

老谟靠在灶台边，抱着胳膊看我："行。那我先问你——**你打算怎么切？**"

"切？"我愣了一下神，"我算体积，跟切有什么关系？"

"关系大了去了。你上次算一元积分的'面积'，是不是靠'把曲线下的面积切成无数条细条，一条一条加'？现在这块蛋糕是二维的'面'底下的'体积'，你拿什么当'条'？——**条只有长度，可这片蛋糕底下是一整片地。**"

我盯着那块歪蛋糕沉默了一会儿：".....你是说，我这次不能切'条'，得切'块'？"

"你自己说的。"老谟把刀推过来，"来吧，先把'该切什么'想清楚，这一章你就通一半了。"

对话引擎

第 1 轮：一条线下的面积，怎么长成一片地下的体积

老谟："先别碰蛋糕。回到你熟的一元积分： $y = f(x)$ ，从 a 到 b 这一段的'面积'，你是靠什么算出来的？"

造物主："把 $[a, b]$ 切成 n 段小段，每段宽度 Δx ，取一点，高是 $f(\text{某点})$ ，做小矩形 $f \cdot \Delta x$ ，然后全部加起来，让 Δx 趋于 0 取极限。"

老谟："好。那你现在告诉我：'小段'这条东西，在二维世界里还够用吗？"

造物主：".....不太够。一元里底下是一条'线段'，切出来的是一维的'段'，所以小片是'宽 $\times$ 高'的薄条。可二维里底下是一块'区域'，它有自己的宽度和长度，再切'条'就不对了——得切出一片片有'面积'的小块。"

老谟："这就是你刚刚自己立的门槛。**一元积分切'条'，因为底是一维的；二重积分要切'块'，因为底是二维的。** 每块小柱的'体积' = 底下小块的面积 $\times$ 这块地方的平均高度。你把这一堆小柱全加起来，让小块面积趋于 0 取极限——这个极限，就是二重积分。你先别急着写式子，跟我说说：这样切出来的一堆小柱，加起来，你觉得和'体积'这件事，对得上吗？"

知识锚点：二重积分——"切成小柱，求和取极限"

【概念深挖】**二重积分 (double integral)** 的直觉：把区域 D 切成许多小矩形（小块），每块面积记为 ΔA_i ，在每块上取一个代表点，算出该点的高度 f ，于是每块对应一个小柱体，体积 $\approx f \times \Delta A_i$ 。把所有小柱的体积加起来，再让每块面积都趋于 0（也就是切得越来越细），取极限：

$$\iint_D f(x,y) \, dA = \lim \sum_i f(x_i^*, y_i^*) \cdot \Delta A_i$$

读作"二重积分"， dA 表示"一个无穷小的面积元"。 一元积分里积分项 $f \cdot dx$ 对应"长(宽) $\times$ 高"的窄条；二元里 $f \cdot dA = f \cdot (\text{长} \times \text{宽})$ 对应"底面积(长 $\times$ 宽) $\times$ 高"的小柱——**注意 dA 本身是二维的面积元，小柱体积是 $f \cdot dA$ ，不要再叠第三个维度。** "切成小块 $\rightarrow$ 每块近似 $\rightarrow$ 求和 $\rightarrow$ 取极限"，这套四步曲和你一元积分见过的完全同构，只是"块"从一维的段长成了二维的小片。

【工程实践】这套"切块求和取极限"在工程里有个极其直白的名字：**数值积分/蒙特卡洛估计**。你没法解析算某些复杂区域的体积时，就把区域切成网格，每格取个代表值，加总——这就是二重积分的"离散版"。后面讲概率时会看到，**算一个随机点落在某区域的概率，本质就是一个二重积分**：把区域切成小块，每块的概率密度乘小块面积，再加起来。

第 2 轮：先切 x 再切 y，还是先切 y 再切 x

老谋："二重积分的定义立起来了：切块、求和、取极限。可你手上立刻冒出一个麻烦——**底下这片区域是二维的，你手里只有'对 x 积分'和'对 y 积分'这两把一维的刀。**你怎么用两把一维的刀，切出一片二维的地？"

造物主：".....两把刀？那我先沿一个方向切成一条条'薄片'，再把每片薄片沿另一个方向切成'小格'？比如先按 x 切成竖条，每条再按 y 切成小段。"

老谋："你这不就是'先 x 后 y'吗。可你凭什么不能'先 y 后 x'——先按 y 切成横条，每条再按 x 切成小格？"

造物主：".....对啊，为什么不行？横着切、竖着切，最后都是把整片地切成小格，块数也一样多。理论上应该加出同一个数吧？"

老谋："你踩到本章最关键的那块石头了。**先横切后竖切、先竖切后横切——这两种切法，得到的小格形状可能不一样（一个长条是横的还是竖的），但当块数趋于无穷时，极限是不是同一个数？**这个问题，正是 Fubini 定理要回答的。你先别说'应该一样'，先把这两种切法'到底怎么操作'给我想清楚——每一步积分，到底是沿着哪条'边'在扫？"

知识锚点：累次积分——把二重积分拆成两枚一维积分

【概念深挖】**累次积分 (iterated integral)**：当区域 D 是矩形 $[a,b] \times [c,d]$ 时，二重积分可以"一层一层"算：

$$\begin{aligned} \text{先 } x \text{ 后 } y: \iint_D f \, dA &= \int_c^d \left[\int_a^b f(x,y) \, dx \right] dy \\ \text{先 } y \text{ 后 } x: \iint_D f \, dA &= \int_a^b \left[\int_c^d f(x,y) \, dy \right] dx \end{aligned}$$

- **内层积分：**把另一个变量当常数，先沿一条直线（一个方向）积——这正好是第 01 章"偏导"反过来做的事：偏导是"按住别的变量求变化率"，累次的内层积分是"按住别的变量求累积"。
- **外层积分：**把内层得到"随外变量变化的函数"，再沿另一个方向积。

几何直觉：先 x 后 y 就像"先沿 x 方向扫出一条条长度，再把些长度沿 y 方向累加"；先 y 后 x 则是反过来。**两者都是"把二维累加拆成两次一维累加"。**矩形域上，Fubini 定理保证这两种拆法的结果相等（严格证明见严格化走廊定理 1）。

【工程实践】为什么"拆成两次一维积分"对工程是福音？因为**你不需要发明新的"二维积分器"，只要把你已经会的一维积分算法（梯形法、辛普森法、或者查原函数）套用两次。**很多数值库计算高维积分，就是用"一维积分套一维积分"递归下去。**"降维"是工程里最常用的化简手段——把一个难的高维问题，拆成几个好算的低维问题。**

第 3 轮：矩形域上，两种切法给出同一个数——但区域一歪，事情就来了

老谟："矩形域好办，两条边整整齐齐，先 x 后 y、先 y 后 x 都扫得动。可你抬头看看那块蛋糕——它的底面**不是矩形**，是歪的。这种情况下，'先 x 后 y'的切法还管用吗？"

造物主：".....管用.....吧？还是先沿 x 切成竖条，可每条竖条从 y 的哪里开始、到哪里结束，不再是个固定数了——得看这条竖条在 x 的哪个位置，它的上下边界随 x 变。"

老谟："你自己把最麻烦的地方说出来了：**区域歪了，积分限就不再是常数，而会变成'依赖另一个变量的函数'**。先 x 后 y，竖条的 y 上下限是 $y_1(x)$ 、 $y_2(x)$ ；先 y 后 x，横条的 x 左右限是 $x_1(y)$ 、 $x_2(y)$ 。这两种写法，还是同一个二重积分吗？"

造物主：".....理论上该是。可我现在有点怕：万一某一种切法特别难算、另一种特别容易呢？"

老谟："怕对了。**积分限变成函数之后，'难易'就分化了——有的函数按一种顺序根本积不出来，换个顺序却一马平川。**这就是为什么'换积分次序'是一门真功夫。先别急，我们先把'矩形域上两种切法为什么一样'这件事，在你脑子里钉死，再去碰歪区域。"

第 4 轮：凭什么两种切法一样——Fubini 的直觉

老谟："矩形域上，先 x 后 y、先 y 后 x 结果一样。你现在打算怎么说服我？别扯'显然'，你给个理由。"

造物主：".....我可以把矩形切成 $n \times m$ 个小格。先 x 后 y，就是先沿 y 方向把每一列的小格加起来，再把所有列加起来；先 y 后 x，就是先沿 x 方向把每一行的小格加起来，再把所有行加起来。**不管是先按行加还是先按列加，最后都是把同一张表里所有格子加一遍——总数当然一样！**"

老谟："你抓住了本质：**加法可以换顺序——先按行加还是先按列加，和总是同一个。**这就是 Fubini 定理的核心直觉：二重积分就是"对一整张数字表求和"，行的和与列的和，最后都一样。**严格证明（走廊定理 1）只是把这个'换加法顺序'的直觉，用黎曼和的分解翻译成严格的极限论证。**你先把这张'表'想明白——下一轮，我们让这张表变歪。"

知识锚点：Fubini 定理——"先按行加还是先按列加，结果一样"

【概念深挖】**Fubini 定理（富比尼定理）**，以意大利数学家**圭多·富比尼（Guido Fubini，1879–1943）**命名：若 f 在矩形 $R = [a,b] \times [c,d]$ 上可积，则

$$\iint_R f(x,y) \, dA = \int_a^b \left[\int_c^d f(x,y) \, dy \right] dx = \int_c^d \left[\int_a^b f(x,y) \, dx \right] dy$$

直觉内核：把矩形切成一张小格表， f 在每格的取值填进表格。“先按列求和”（内层 x ）与“先按行求和”（内层 y ）最后都得到整张表的总和。这就是“加法交换律”在二维求和上的体现。

严格注记：Fubini 定理要求 f 可积（绝对可积）。若 f 在矩形上不是绝对可积，交换积分次序可能改变结果甚至发散——这是后面反例/边界要处理的。工程上大多数连续函数都满足前提，可放心换序。

【历史溯源】把“多重积分拆成累次积分”的思想，萌芽于**欧拉和拉格朗日**处理曲面面积、转动惯量等物理问题时。**富比尼在 1907 年给出了严格的测度论证明**，把“先按行加还是先按列加”从直觉上升为定理。值得一提的是：**富比尼定理是勒贝格积分框架下的产物——它先把“可积性”这个概念彻底搞清楚，才敢说“换序后仍是同一个数”**。这正是“学派中立”的地方：本书走黎曼和的直觉进路来理解它，但它的严格生命在勒贝格理论里。

【工程实践】Fubini 是“数值积分库”能安心工作的法律依据：当你调用一个二维积分函数，底层往往就是“先沿一个方向、再沿另一个方向”套两次一维积分。**正因为 Fubini 保证了两种顺序结果一致，库的实现者才敢随便挑一种好算的顺序去算，而不必担心算出来的是“另一种积分”**。但你读文档时要知道：这个保证的前提是“可积”——遇到振荡剧烈或带尖点的被积函数，先检查前提。

第 5 轮：区域一歪，积分限就“长脚”——换积分次序

老谟：“现在把矩形拧歪。区域 D 由 x 从 0 到 1、 y 从 x 到 1 围出来（一个三角形）。你想算 $\iint_D \sin(y^2) dy dx$ 。我先让你按‘先 x 后 y ’——不对，‘先 y 后 x ’——你自己试试，看会不会卡住。”

造物主：“.....先 y 后 x ：内层是 $\int_x^1 \sin(y^2) dy$ 。可 $\sin(y^2)$ 这玩意儿没有初等原函数啊！我积到天荒地老也积不出一个‘好’的式子。这题死路。”

老谟：“那你换个顺序，‘先 x 后 y ’。你先告诉我：区域变到‘先 x 后 y ’，积分限怎么变？”

造物主：“.....原来先 y 后 x ， y 从 x 到 1、 x 从 0 到 1。反过来， x 就从 0 到 y 、 y 从 0 到 1。那内层就变成 $\int_0^y \sin(y^2) dx = x \cdot \sin(y^2)$ 从 0 到 y ，等于 $y \cdot \sin(y^2)$这下内层对 x 积， $\sin(y^2)$ 根本不用管，是常数！然后外层 $\int_0^1 y \cdot \sin(y^2) dy$ ——这个我熟，换元 $t = y^2$ ， $dt = 2y dy$ ，就是能积的了！”

老谟：“你自己亲手把死路走活了。同一个二重积分，‘先 y 后 x ’积不出来，‘先 x 后 y ’却顺顺当当——因为你把‘难积的被积函数’从内层换到了外层，让内层只管一个简单的东西（这里是 1）。这就是‘换积分次序’的全部意义：不是换了个花样，是让内层积分负责‘好积’的部分。你把这条记牢——这是本章最实用的一招。”

知识锚点：换积分次序——“让内层积分负责好积的部分”

【概念深挖】换积分次序 (changing the order of integration) 的操作步骤：

1. 从原次序读出区域 D 的几何 (用不等式画出边界) ；
2. 把区域重新描述成另一种次序的不等式；
3. 用新的次序重写累次积分。

经典例子 (蓝图指定，也是本章最重要的一题)：

$$I = \int_0^1 \int_x^1 \sin(y^2) \, dy \, dx$$

- 原次序 (先 y 后 x)：区域 $\{(x,y) : 0 \leq x \leq 1, x \leq y \leq 1\}$ ；
- 换次序 (先 x 后 y)：同一区域可写成 $\{(x,y) : 0 \leq y \leq 1, 0 \leq x \leq y\}$ ；
- 于是 $I = \int_0^1 \int_0^y \sin(y^2) \, dx \, dy = \int_0^1 y \cdot \sin(y^2) \, dy = [-\frac{1}{2}\cos(y^2)]_0^1 = (1 - \cos 1)/2 \approx 0.2298$ 。

关键： $\sin(y^2)$ 没有初等原函数，直接先积 y 是死路；但换成先积 x ， $\sin(y^2)$ 当常数，内层立刻可算。“换序”解决的不是计算复杂度，而是“不可积”——这比任何技巧都珍贵。

【工程实践】换序在工程里对应“交换求和/积分顺序”：机器学习的期望计算、贝叶斯推理里的边缘化 (把联合分布对一个变量积分掉)，经常需要“哪个先积”的取舍。有些积分顺序数值上极不稳定 (误差爆炸)，换一个顺序就稳定得多——Fubini 给你自由，换序给你灵活，两者合起来是数值工程师调积分的两板斧。

第 6 轮：遇到圆——直角坐标切不动，换个“尺子”量

老谟：“换序解决‘先积哪个’。可还有一类问题，它压根不是‘换序’能救的——区域是圆的，函数还带旋转对称，比如 $\iint_{\{x^2+y^2 \leq 4\}} (x^2+y^2) \, dA$ 。你用直角坐标的‘先 x 后 y ’去切，积分限会变成 $\pm\sqrt{4-x^2}$ ，内层和外层都缠着一堆根号，算得你头秃。你说，怎么办？”

造物主：“……圆的东西，用 x 、 y 去量就是别扭。能不能……换个坐标系？用半径 r 和角度 θ 去描述每个点？”

老谟：“你自己把答案说出来了：**极坐标**。可换坐标系不是白换的——原来面积元是 $dA = dx \cdot dy$ ，换了之后面积元就变成 $r \cdot dr \cdot d\theta$ ，不是简单的 $dr \cdot d\theta$ 。你为什么觉得该多出一个 r ？”

造物主：“……因为 θ 动一小格，扫过的弧长跟离原点多远有关：离得越远，同样角度扫过的面积越大。所以那块‘小扇子’的面积不是 $dr \times d\theta$ ，得是半径 r 乘上角度变化 $d\theta$ 再乘 dr ——对， $r \cdot dr \cdot d\theta$ 。”

老谟："你把极坐标面积元里最关键的'那个 r '自己逼出来了。 r 是'离原点越远、同样角度裹挟的面积越大'的几何代价。有了这个面积元， $\iint_{\{x^2+y^2 \leq 4\}} (x^2+y^2) dA$ 就变成 $\int_0^{2\pi} \int_0^2 r^2 \cdot r \, dr \, d\theta$ —— r^2 是 x^2+y^2 ，再乘上面积元的 r ，一共 r^3 。这下干净了，你算算？"

知识锚点：极坐标变换—— $dA = r \cdot dr \cdot d\theta$

【概念深挖】**极坐标 (polar coordinates)**：点 (x,y) 用 (r, θ) 表示，其中 $r = \sqrt{x^2+y^2}$ 是到原点距离， θ 是辐角。变换关系：

$$x = r \cdot \cos \theta, \quad y = r \cdot \sin \theta$$

面积元（这是极坐标积分的核心，也是唯一容易错的地方）：

$$dA = dx \cdot dy = r \cdot dr \cdot d\theta$$

为什么多一个 r ：从 (r,θ) 到 (x,y) 是一张"放大缩小"的地图—— θ 方向的分辨率随 r 变。直观地说， θ 动 $d\theta$ 扫过的实际距离是 $r \cdot d\theta$ ，所以小扇片的面积是 $(dr) \times (r \cdot d\theta) = r \cdot dr \cdot d\theta$ 。 r 就是"离原点越远，同样角度对应越大弧长/面积"的代价。

典型应用：圆盘、扇形、环形、以及被积函数含 x^2+y^2 的情形（旋转对称）。例如：

$$\begin{aligned} \iint_{\{x^2+y^2 \leq 4\}} (x^2+y^2) \, dA &= \int_0^{2\pi} \int_0^2 r^2 \cdot r \, dr \, d\theta \\ &= \int_0^{2\pi} \left[\frac{r^4}{4} \right]_0^2 d\theta = \int_0^{2\pi} 4 \, d\theta = 8\pi \end{aligned}$$

（其中 $r^2 \cdot r = r^3$ 来自"被积函数 $x^2+y^2 = r^2$ "乘"面积元里的 r "，这个"多乘一个 r "是最常踩的坑。）

【工程实践】极坐标在工程里的直白应用：**图像与雷达的距离-方位表示、归一化的极坐标损失、以及处理旋转对称的物理系统**（电场、引力场、天线方向图）。"当问题本身有旋转对称性，就用与之匹配的坐标系"——这是工程里'选对坐标系省一半力气'的经典一课。

第 7 轮：落点——二重积分，一块区域上的总累积

老谟："蛋糕切完了。你现在把'二重积分'这件事，从头到尾给我捋一遍。"

造物主："二重积分就是把一块区域切成小柱，每柱体积 = 底面积 $\times$ 高，求和取极限。算的时候拆成累次积分——先 x 后 y 或先 y 后 x ，矩形域上 Fubini 保证一样；区域歪了可以换序，让内层负责好积的部分；遇到圆的用极坐标，面积元是 $r \, dr \, d\theta$ 。"

老谟："你现在有没有发现，这一章从头到尾，其实都在回答同一个问题？"

造物主：".....是'怎么切'。一元只有一条路可切，二维有无数种切法，我们挑了三种最顺手的——横竖切（两种次序）和极坐标切。**切法不同，但只要是'好区域'，加出来是同一个数。**"

老谟："漂亮。那你再想想——这一章切出来的'体积'，跟'概率'有什么关系？我提示你：如果那个'高'不是高度，而是'某个随机变量的概率密度'呢？"

造物主：".....那二重积分就是'把一小块区域上的密度 $\times$ 面积，全部加起来'——**这不就是'随机点落在这块区域的概率'吗！** $P((X,Y)\in D) = \iint_D f \, dx dy$ 。"

老谟："你自己把下一册（册 06 概率统计与信息）最重要的一把钥匙提前摸出来了：**二重积分是'联合分布概率'的数学壳子。**你先把它磨好——下一章，我们要从'切一块区域'转到'什么样的形状，才能保证你从山顶一滑到底不卡在半路'：凸集与凸函数。"

严格化走廊

位置说明：本章对话负责"直觉"——为什么切成小柱、为什么换序、为什么极坐标多个 r 。本走廊负责"严谨"——把二重积分写成精确的黎曼和极限，把"先按行加 = 先按列加"用黎曼和的分解思路证明成可复写的定理。**下面每一行，读者都能对着空白纸重写一遍。**

关于对话的口径说明

对话里"切成小柱求和""先按行加还是先按列加""多一个 r "这些，都是直觉层面的引导。**本走廊把它们落成严格形式**：二重积分 = 分割 + 黎曼和 + 取极限（定义 1）；Fubini 定理（定理 1）的证明走"黎曼和的换序分解"路线；极坐标面积元 = 坐标变换 + 雅可比行列式（定理 2）。读者应把对话当作"为什么要这样想"，把本走廊当作"为什么这样想是对的"。

定义 1：二重积分（黎曼和）

设 $f: D \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$ 有界， D 是平面有界区域。**对区域 D 作分割**：把 D 分成有限个小矩形（及边界小块） $D_1, \dots, D_n$ ，第 i 块的面积为 ΔA_i ，其直径为 $\text{diag}(D_i)$ （该块的最大"跨度"）。在各块内任取代表点 (x_i^*, y_i^*) ，作**黎曼和**：

$$S = \sum_i f(x_i^*, y_i^*) \cdot \Delta A_i$$

若当所有块的直径 $\max_i \text{diag}(D_i) \rightarrow 0$ 时，黎曼和 S 趋于同一个极限 I （与分割方式和代表点取法无关），则称 **f 在 D 上可积**，并记：

$$\iint_D f(x, y) \, dA = I$$

定义 2: 累次积分 (iterated integral)

设 f 在矩形 $R = [a,b] \times [c,d]$ 上有界。**先 x 后 y 的累次积分**定义为:

$$\iint_R f \, dA \text{ 的"先 } x \text{ 后 } y\text{"写法} = \int_c^d \left[\int_a^b f(x,y) \, dx \right] dy$$

其中内层 $\int_a^b f(x,y) \, dx$ 把 y 当常数 (沿一条水平线积), 结果是一个关于 y 的函数, 再对 y 积分。
先 y 后 x 对称定义。

定义 3: 极坐标下的二重积分

设 D 在极坐标下为 $\{(r,\theta) : \theta_1 \leq \theta \leq \theta_2, r_1(\theta) \leq r \leq r_2(\theta)\}$, 且变换 $(x,y) = (r \cos\theta, r \sin\theta)$ 是双射, 则:

$$\iint_D f(x,y) \, dx \, dy = \int_{\theta_1}^{\theta_2} \int_{r_1(\theta)}^{r_2(\theta)} f(r \cos\theta, r \sin\theta) \cdot r \, dr \, d\theta$$

定理 1 (Fubini 定理, 矩形域) : 设 f 在矩形 $R = [a,b] \times [c,d]$ 上可积, 则

$$\iint_R f(x,y) \, dA = \int_a^b \left[\int_c^d f(x,y) \, dy \right] dx = \int_c^d \left[\int_a^b f(x,y) \, dx \right] dy$$

严格注记 (前提口径) : 在黎曼积分框架下, " f 可积 $\Rightarrow$ 两种累次积分相等"并非无条件成立——存在黎曼可积但累次积分不等的病态函数。本书按经典教学口径使用该定理: **f 在 R 上连续 (或分片连续、不连续点足够少) 时, 两种累次积分均存在且相等, 无任何例外;** 最一般的成立范围属于勒贝格 (Lebesgue) /Tonelli 框架, 那里 " f 非负可测 $\Rightarrow$ 可换序"成为无条件的。**你现在遇到的函数 (多项式、指数、三角、分片连续) 全部落在"连续/分片连续"安全区内, 放心换序; 真正的边界留在测度论部分。**

证明 (可复写, 走黎曼和的分解思路) :

- **第 1 步 (把矩形切成网格) :** 把 $[a,b]$ 等分为 m 段, $[c,d]$ 等分为 n 段, 得到 $m \times n$ 个小矩形 R_{ij} , 其面积为 $\Delta x \cdot \Delta y = (b-a)/m \cdot (d-c)/n$ 。取各块代表点, 黎曼和 $S = \sum_i \sum_j f(x_i^*, y_j^*) \cdot \Delta x \cdot \Delta y$ 。
- **第 2 步 (先按列求和) :** 固定一个 i (固定一列), 先对 j 求和: $\sum_j f(x_i^*, y_j^*) \cdot \Delta y$, 这正是"先 y 后 x "中内层 $\int_c^d f(x_i^*, y) \, dy$ 的黎曼和近似。把每一列的"列和"再对 i 求和 (乘 Δx), 即 $S = \sum_i \left[\sum_j f(x_i^*, y_j^*) \cdot \Delta y \right] \cdot \Delta x$ 。
- **第 3 步 (先按行求和) :** 交换求和顺序 (有限和交换次序不改变结果, 依据是加法结合律与交换律), $S = \sum_j \left[\sum_i f(x_i^*, y_j^*) \cdot \Delta x \right] \cdot \Delta y$, 这正是"先 x 后 y "中内层 $\int_a^b f(x,y) \, dx$ 的黎曼和近似, 再对 j 求和。

- **第 4 步（取极限）**：当 $m, n \rightarrow \infty$ （网格无限加密）时， S 由可积性趋于 $\iint_R f \, dA$ 。第 2、3 步得到的两个表达式，各自的内层黎曼和趋于对应的一维积分，外层取极限后分别趋于 $\int_a^b [\int_c^d f \, dy] \, dx$ 与 $\int_c^d [\int_a^b f \, dx] \, dy$ 。因三者都收敛到同一个 S 的极限（即 $\iint_R f \, dA$ ），故等式成立。■

证明要点标注：第 1 步用**定义 1（分割与黎曼和）**；第 2、3 步用**有限求和的交换次序（加法交换律/结合律）**与**一维黎曼和的定义**；第 4 步用**可积性（极限唯一）**与**极限的四则运算**。

定理 2（极坐标面积元）：坐标变换 $(x, y) = (r \cos \theta, r \sin \theta)$ 的面积元为 $dA = r \cdot dr \cdot d\theta$ 。

证明（可复写，用雅可比行列式）：

- **第 1 步（写出雅可比矩阵）**：由第 02 章定义 2（雅可比矩阵），变换 $T(r, \theta) = (r \cos \theta, r \sin \theta)$ 的雅可比矩阵为：

$$J = \begin{bmatrix} \partial x / \partial r & \partial x / \partial \theta \\ \partial y / \partial r & \partial y / \partial \theta \end{bmatrix} = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}$$

- **第 2 步（算行列式的绝对值）**： $\det J = \cos \theta \cdot (r \cos \theta) - (-r \sin \theta) \cdot \sin \theta = r(\cos^2 \theta + \sin^2 \theta) = r \cdot 1 = r$ 。
- **第 3 步（多重积分换元公式）**：二重积分的换元公式（多元积分换元，与一元 u 换元对应）给出 $dA = dx \cdot dy = |\det J| \, dr \, d\theta = r \, dr \, d\theta$ 。■

证明要点标注：第 1 步用**雅可比矩阵定义（第 02 章）**；第 2 步用**二阶行列式计算与毕达哥拉斯恒等式 $\cos^2 \theta + \sin^2 \theta = 1$** ；第 3 步用**二重积分换元公式**（面积元由雅可比行列式的绝对值给出）。

反例/边界

- **不绝对可积时 Fubini 失效**： f 在矩形上不可积（不绝对可积）时，交换积分次序可能改变结果。经典例子： $f(x, y) = (x^2 - y^2)/(x^2 + y^2)^2$ 在矩形 $[0, 1] \times [0, 1]$ 上， $\iint f \, dx \, dy$ 与 $\iint f \, dy \, dx$ 得到不同值（一个为 $-\pi/4$ ，另一个为 $+\pi/4$ ）。**教训**：Fubini 的“换序自由”不是免费的，前提是绝对可积。工程上遇到振荡/带奇点的被积函数要警惕。
- **积分限函数的边界**：非矩形区域换序时，若区域描述出错（上下限函数配错变量），会算出完全不同的错误值。换序前先在纸上把区域几何画出来，确认两种不等式描述同一片区域。
- **极坐标的 r 非负**：极坐标积分中 $r \geq 0$ （径向坐标约定非负）。若某区域的 r 下限描述错误（比如把半圆写成全圆），会多算或漏算。

知识点总结

知识点（本章推出的核心概念）

- **二重积分** $\iint_D f \, dA$ ：把区域切成小柱（底面积 $\Delta A \times$ 高 f ），求和取极限。"切成小块 $\rightarrow$ 每块近似 $\rightarrow$ 求和 $\rightarrow$ 取极限"与一元积分同构，只是块从一维段长成二维小片。
- **累次积分**：把二重积分拆成"内层 + 外层"两次一维积分；内层把另一变量当常数（偏导的逆操作）。
- **Fubini 定理**：矩形域上 $\iint_R f \, dA = \int \int f \, dx \, dy = \int \int f \, dy \, dx$ ；直觉是"先按行加还是先按列加，总和一样"；前提是 f 可积（绝对可积）。
- **换积分次序**：区域歪时积分限变成函数；换个次序让"内层负责好积的部分"——经典例 $\int_0^1 \int_x^1 \sin(y^2) \, dy \, dx = (1 - \cos 1)/2 \approx 0.2298$ 。
- **极坐标变换**： $x = r \cos \theta$, $y = r \sin \theta$ ；**面积元** $dA = r \, dr \, d\theta$ （多出的 r 是"离原点越远、同角度扫过的面积越大"的代价）。
- **典型结果**： $\iint_{\{x^2+y^2 \leq 4\}} (x^2+y^2) \, dA = 8\pi$ （旋转抛物面下、半径 2 的圆域体积）。

历史结论（本章涉及的史料）

- **富比尼 (Guido Fubini, 1879–1943)**：1907 年在勒贝格测度论框架下严格证明多重积分可拆成累次积分——"先按行加还是先按列加"从直觉升格为定理。
- **思想源头**：欧拉、拉格朗日在处理曲面面积、转动惯量等物理问题时已实践"多重积分拆累次"。
- **二重积分的严格化**：黎曼给出"分割 + 黎曼和 + 极限"的一元积分严格定义，后人推广到多重；而 Fubini 的严格生命在勒贝格积分框架里。

工程实践结论（本章知识在真实工程里怎么用）

- **数值积分/蒙特卡洛**：把区域切网格、每格取代表值加总，就是二重积分的离散版。
- **联合分布概率（为册 06 铺路）**： $P((X,Y) \in D) = \iint_D f \, dx \, dy$ ——二重积分是"联合分布概率"的数学壳子。
- **一维积分套一维积分**：数值库算二维积分常用"一维积分递归套用"，Fubini 保证选哪种顺序都对。
- **选对坐标系**：旋转对称问题用极坐标省一半力气；图像/雷达的距离-方位表示、旋转对称物理系统都用它。

计算训练场

位置说明：本章对话负责“为什么”，这里负责“怎么算”。**每题请动笔 10 分钟以上，先自己写，再对照完整解答。禁止边算边翻答案。**

题 1 (易→中)：矩形域累次积分——先 x 后 y 、先 y 后 x 各算一遍互证

题干：设 $f(x,y) = x + y$ ，区域 $D = [0,1] \times [0,2]$ 。(a) 用“先 x 后 y ”的累次积分计算 $\iint_D (x+y) dA$ 。(b) 用“先 y 后 x ”的累次积分重算一遍，验证 Fubini (两结果应一致)。

完整分步解答：

(a) 先 x 后 y ：第 1 步：内层把 y 当常数，对 x 从 0 到 1 积分： $\int_0^1 (x+y) dx = [x^2/2 + y \cdot x]_0^1 = (1/2 + y) - (0 + 0) = 1/2 + y$ 。(规则： $\int (x+y) dx = x^2/2 + yx$ ，其中 y 当常数。) 第 2 步：外层对 y 从 0 到 2 积分： $\int_0^2 (1/2 + y) dy = [y/2 + y^2/2]_0^2 = (1 + 2) - 0 = 3$ 。

(b) 先 y 后 x ：第 3 步：内层把 x 当常数，对 y 从 0 到 2 积分： $\int_0^2 (x+y) dy = [x \cdot y + y^2/2]_0^2 = (2x + 2) - 0 = 2x + 2$ 。第 4 步：外层对 x 从 0 到 1 积分： $\int_0^1 (2x+2) dx = [x^2 + 2x]_0^1 = (1 + 2) = 3$ 。

答：两种次序都得到 3，Fubini 验证通过 ✓。

常见错误：① 内层积分把“另一变量当常数”忘了——比如 $\int_0^1 (x+y) dx$ 里把 y 也当变量一起积成 $y^2/2$ ；② 外层代入上下限时符号错误， $[y/2 + y^2/2]_0^2$ 在 $y=0$ 处应为 0 而非负值。

题 2 (中)：换积分次序——“直接积不出、换序后可算”的经典

题干：老谟要造物主算 $I = \int_0^1 \int_x^1 \sin(y^2) dy dx$ 。(a) 画出区域 $D = \{(x,y) : 0 \leq x \leq 1, x \leq y \leq 1\}$ ，并用另一种次序重写这个积分。(b) 用新次序计算 I 的精确值，并给出小数近似 ($\cos 1 \approx 0.5403$)。

完整分步解答：

(a) 换次序：第 1 步：原区域 x 从 0 到 1， y 从 x 到 1。把 y 当外层变量： y 的范围仍是 0 到 1 (三角形底 $y=0$ 顶 $y=1$)；对固定 y ， x 从 0 到 y (因为 $x \leq y$ 且 $x \geq 0$)。故新次序： $I = \int_0^1 \int_0^y \sin(y^2) dx dy$ 。(规则：区域几何重述——不等式 $0 \leq x \leq 1, x \leq y \leq 1$ 等价于 $0 \leq y \leq 1, 0 \leq x \leq y$ 。)

(b) 计算：第 2 步：内层把 y 当常数，对 x 从 0 到 y 积分： $\int_0^y \sin(y^2) dx = \sin(y^2) \cdot x \big|_0^y = y \cdot \sin(y^2)$ 。(规则：被积函数不含 x ，对 x 积分得 $\sin(y^2) \cdot x$ 。) 第 3 步：外层 $\int_0^1 y \cdot \sin(y^2) dy$ 。换元 $t = y^2$ ， $dt = 2y dy$ ，故 $y dy = dt/2$ 。(规则：一元换元法。) 第 4 步：边界 $y=0 \rightarrow t=0$ ， $y=1 \rightarrow t=1$ 。 $I = \int_0^1 (1/2) \sin t dt = (1/2)[- \cos t]_0^1 = (1/2)(- \cos 1 + \cos 0) = (1/2)(1 - \cos 1)$ 。(规则： $\int \sin t dt = - \cos t + C$ ，代入上下限。) 第 5 步：数值： $\cos 1 \approx 0.5403$ ， $I = (1 - 0.5403)/2 = 0.22985 \approx 0.2298$ 。

答：(a) $I = \int_0^1 \int_0^y \sin(y^2) dx dy$; (b) $I = (1 - \cos 1)/2 \approx 0.2298$ 。(反验算：被积函数非负、区域面积 $1/2$ 、函数最大值 $\sin(y^2) \leq \sin 1 \approx 0.8415$ ，故积分应在 0 与 $0.5 \times 0.84 \approx 0.42$ 之间—— 0.2298 合理 $\checkmark$ 。)

常见错误：① 换序时把区域画错，写成 $0 \leq x \leq y$ 、 y 从 x 到 1 的混乱不等式，导致积分域重复或遗漏；② 换元 $t=y^2$ 时忘写 $dt=2y dy$ ，直接把 $y \sin(y^2)dy$ 当 $\sin(y^2)dy$ 积；③ 代入边界时把 $\cos 1$ 的符号搞反。

题 3 (中→难)：极坐标——旋转抛物面下的体积

题干：老谟让造物主算旋转抛物面 $z = x^2 + y^2$ 在圆盘 $x^2 + y^2 \leq 4$ (半径 2) 下方所围的体积 $V = \iint_{\{x^2+y^2 \leq 4\}} (x^2 + y^2) dA$ 。(a) 用极坐标写出并计算这个积分，得到精确值。(b) 顺便算圆盘 $x^2 + y^2 \leq 4$ 的面积 (即 $\iint_{\{x^2+y^2 \leq 4\}} 1 dA$)，并验证它与 πr^2 一致。(c) 把被积函数换成 1，即 $\iint_{\{x^2+y^2 \leq 9\}} 1 dA$ (半径 3)，给出结果并说明它对应什么几何量。

完整分步解答：

(a) 极坐标算体积：第 1 步：极坐标变换 $x = r \cos \theta$, $y = r \sin \theta$, $x^2 + y^2 = r^2$, $dA = r dr d\theta$ 。(规则：定理 2 极坐标面积元。) 第 2 步：圆盘 $x^2 + y^2 \leq 4$ 即 $r \leq 2$; θ 从 0 到 2π 。积分 $V = \int_0^{2\pi} \int_0^2 r^2 \cdot r dr d\theta = \int_0^{2\pi} \int_0^2 r^3 dr d\theta$ 。(规则：被积函数 $x^2 + y^2 = r^2$ 乘面积元里的 r 。) 第 3 步：内层 $\int_0^2 r^3 dr = [r^4/4]_0^2 = 16/4 = 4$ 。(规则： $\int r^3 dr = r^4/4$ 。) 第 4 步：外层 $\int_0^{2\pi} 4 d\theta = 4 \cdot (2\pi) = 8\pi$ 。(规则：常数对 θ 积分 = 常数 $\times$ 区间长度。) 第 5 步： $8\pi \approx 8 \times 3.1416 = 25.1327$ 。

(b) 圆盘面积：第 6 步： $\iint 1 dA = \int_0^{2\pi} \int_0^2 1 \cdot r dr d\theta = \int_0^{2\pi} [r^2/2]_0^2 d\theta = \int_0^{2\pi} 2 d\theta = 4\pi$ 。(规则：被积函数 1，面积元 $r dr d\theta$ 。) 第 7 步：验证 $\pi r^2 = \pi \cdot 2^2 = 4\pi \checkmark$ 一致。(反验算：半径 2 圆面积 = $4\pi \checkmark$ 。)

(c) 半径 3 的圆盘：第 8 步： $\iint_{\{x^2+y^2 \leq 9\}} 1 dA = \int_0^{2\pi} \int_0^3 r dr d\theta = \int_0^{2\pi} [r^2/2]_0^3 d\theta = \int_0^{2\pi} (9/2) d\theta = (9/2) \cdot 2\pi = 9\pi$ 。第 9 步： $9\pi = \pi \cdot 3^2$ ，即半径 3 的圆盘面积 $\checkmark$ 。

答：(a) $V = 8\pi \approx 25.133$; (b) 面积 = $4\pi = \pi \cdot 2^2 \checkmark$; (c) $9\pi = \pi \cdot 3^2$ ，即半径 3 圆盘面积。

常见错误：① 极坐标里忘了“被积函数里已经有一个 r^2 ，面积元里还有一个 r ”，把 $r^2 \cdot r$ 误写成 r^2 ，得到 4π 而非 8π ；② 面积元误写成 $dr d\theta$ 而非 $r dr d\theta$ ，圆盘面积会算错；③ 内层 r^3 的积分上限代入错 (把 2^4 算成 8)。

向导便签

这一章咱们干了什么：从"一块歪蛋糕的体积怎么算"这个问题出发，把一元积分的"切条"升级成二重积分的"切块"——切成小柱、求和取极限；再用累次积分把它拆成"内层 + 外层"两次一维积分，靠 Fubini 定理保证两种切法结果一样；遇到歪区域就换积分次序，遇到圆就换极坐标。

钉死一句话：**二重积分 = 一块区域上的总累积；三种切法（先 x 后 y、先 y 后 x、极坐标）在"好区域"上给出同一个数。**极坐标面积元 $dA = r dr d\theta$ 里那个 r 最不能忘。

记住一个边界：**Fubini 的"换序自由"前提是绝对可积**；换序前一定先在纸上把区域画出来，别让积分限配错变量。

造物主手记

我曾踩的坑：

我最先想用一元那套"切条"去切蛋糕，被老谟一句"条只有长度，可这片蛋糕底下一整片地"噎住。接着我差点说出"先 x 后 y 和先 y 后 x 肯定一样"——这倒没错，但我说不出为什么，被老谟逼着用"按行加还是按列加，总和一样"才讲清楚。最值钱的坑是极坐标：我一开始把 $\iint (x^2+y^2)dA$ 里的被积函数 x^2+y^2 换成 r^2 就停了，忘了面积元里那个 r ，差点算出 4π 而不是 8π 。**"被积函数一个 r ，面积元又一个 r ，两个都要"——这个细节我记死了。**

顿悟时刻：

真正开窍是在换序那道题。老谟让我算 $\int_0^1 \int_x^1 \sin(y^2) dy dx$ ，我一开始卡死在" $\sin(y^2)$ 没有初等原函数"上，以为这题完蛋了。可一换序，把 $\sin(y^2)$ 挪到外层当常数，内层只积一个 1，瞬间就通了。**那一刻我明白：换积分次序不是换个花样，而是"让内层负责好积的部分"——这比任何技巧都珍贵。**也是这一题，让我第一次尝到"换个角度，死路变活路"的甜头。

自测题

计算题须动笔完成，附完整解答自核；概念题用于检查理解。

题 A（计算，易→中）：累次积分 + Fubini 验证

设 $f(x,y) = xy$ ，区域 $D = [0,2] \times [1,3]$ 。(a) 用"先 x 后 y"算 $\iint_D xy dA$ 。(b) 用"先 y 后 x"重算，验证 Fubini。

完整解答：(a) 内层 $\int_0^2 xy dx = y \cdot [x^2/2]_0^2 = y \cdot 2 = 2y$ ；外层 $\int_1^3 2y dy = [y^2]_1^3 = 9 - 1 = 8$ 。(b) 内层 $\int_1^3 xy dy = x \cdot [y^2/2]_1^3 = x \cdot (9/2 - 1/2) = 4x$ ；外层 $\int_0^2 4x dx = [2x^2]_0^2 = 8$ 。✓ 一致。

题 B (计算, 中一难) : 换序 + 极坐标组合

- (a) 计算 $\int_0^1 \int_y^1 e^{x^2} dx dy$ (提示: e^{x^2} 无初等原函数, 先换次序, 区域 $\{0 \leq y \leq 1, y \leq x \leq 1\}$)。
 (b) 计算 $\iint_{\{x^2+y^2 \leq 1\}} (x^2+y^2) dA$ (单位圆盘, 旋转抛物面下体积)。

完整解答: (a) 换序: 区域 $\{0 \leq y \leq 1, y \leq x \leq 1\} = \{0 \leq x \leq 1, 0 \leq y \leq x\}$ 。 $I = \int_0^1 \int_0^x e^{x^2} dy dx = \int_0^1 e^{x^2} \cdot x dx = (1/2)[e^{x^2}]_0^1 = (e-1)/2 \approx 0.8591$ 。(换元 $t=x^2$ 。)(b) 极坐标: $\iint = \int_0^{2\pi} \int_0^1 r^2 \cdot r dr d\theta = \int_0^{2\pi} r^4/4|_0^1 d\theta = \int_0^{2\pi} (1/4) d\theta = (1/4) \cdot 2\pi = \pi/2$ 。

题 C (概念, 检查理解) : Fubini 与换序

老谟给造物主一个矩形域上的积分 $\iint_R f dA$, 问: (1) 先 x 后 y 、先 y 后 x 结果一致, 这个保证叫什么定理? 前提是什么? (2) 为什么"换积分次序"能救活 $\sin(y^2)$ 这类"直接积不出"的积分? (3) 极坐标面积元 $dA = r dr d\theta$ 里的 r 是什么几何含义?

完整解答: (1) Fubini 定理; 前提是 f 在矩形上可积 (绝对可积)。不绝对可积时换序可能改变结果。(2) 因为换序后把"难积的被积函数"从内层挪到外层当常数, 让内层只管"好积"的因子 (如 1、 x) , 可积性发生质变——它解决的是"不可积"而非"复杂度"。(3) r 是"离原点越远、同样角度扫过的弧长/面积越大"的几何代价: θ 动 $d\theta$ 扫过的实际距离是 $r \cdot d\theta$, 所以小扇片面积 $= dr \times r \cdot d\theta = r \cdot dr \cdot d\theta$ 。

预告

你手里现在有"切一块区域"的功夫: 二重积分、累次积分、换序、极坐标。

可这一章从头到尾, 我们都在假设: **这底下是一片规规矩矩的地, 切完加总就行**。下一章, 我们要问一个更刁钻的问题: **如果这片'地面'不是平的, 而是一座山的山坡——什么样形状的山, 才能保证你从山顶一松手, 沿着坡一路滑到谷底, 中途绝不会被卡在半山腰的某个"假谷"里出不来?** 那种"敢保证一滑到底"的形状, 叫**凸集**; 对应的函数, 叫**凸函数**。

而在那之前, 你先记住本章最后那句话: **二重积分是"联合分布概率"的数学壳子**——这个直觉, 册 06 概率统计与信息里, $P((X,Y) \in D) = \iint_D f dx dy$, 会原封不动地回来找你。

下一章, 我们去造一口"保证一滑到底"的碗。

第 04 章 · 凸集与凸函数——什么形状的"碗"敢保证一滑到底

本章从哪个问题出发：上一章我们学会了"切一块区域"的累加。可现实里的优化问题更像这样：你站上一座山坡，把一个小球放在坡顶，松手——**它会不会一路滑到谷底？还是会卡在半山腰某个看似"到底"其实没到底的地方？** 什么形状的山坡能让你"一松手就安心"？什么形状的山坡会偷偷坑你一把？推导到哪个结论：答案是**凸集**（任意两点连成的线段还留在集合里）与**凸函数**（任意两点之间，函数值不超过两端点函数值的"加权平均"）。靠一个不等式 $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$ （**Jensen 不等式**），我们能推出凸函数的两个重要"刻画"：**一阶刻画**（可微时，曲线永远躺在切线上方： $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ ）和**二阶刻画**（二次可微时，海森矩阵半正定）。

核心认知：**凸函数就是"一滑到底、没有假谷"的函数——任意两点之间，函数值不高于两端值的加权平均；这个性质可以用"定义直接验证"，也可以（可微/二次可微时）用"切线下界"或"海森半正定"来判定。** 这一章是"为什么敢用梯度下降"的第一块地基：只有凸的，局部最优才等于全局最优。

引子

老谟的桌上摆着两个漏斗形的透明模型：一个像倒扣的锅，碗口朝上，圆润光滑；另一个像被压皱的波浪板，中间有几道起伏的褶皱，还有几个小凹槽。

"我给你两颗钢珠，"老谟说，"一颗放第一个碗里，从碗沿松手。一颗放第二个'波浪板'上，从一个高点的褶皱松手。你说，这两颗钢珠，谁的'终点'我能打包票？"

我盯着两个模型想了想："第一个碗，钢珠肯定滚到正中央那个最低点，我猜得到。第二个波浪板……它可能滚到某个小凹槽里停住，但那未必是最低的地方——旁边可能还有更深的坑。"

"你自己把整章的题眼说出来了：**有些'坡'，你滚到哪就能信到哪（滚到哪就是全局最低）；有些'坡'，你滚到哪只信到哪（卡在半路的假坑里）。** 那你说，第一种坡和第二种坡，到底差在哪？差在'形状'——差在'凸不凸'。这一章，就是教你把'敢不敢打包票'这件事，翻译成一个能验证的数学条件。"

对话引擎

第 1 轮：什么样的形状，才敢"一滑到底"——先从"碗"的形状说起

老谟："先别管函数，先管形状。第一种碗——钢珠从碗沿任何位置松手，都能滚到同一个最低点，而且绝不会卡在半路。你观察一下，这种碗的'形状'有什么共同特征？"

造物主：".....它没有'凹陷'？不对，它明明凹下去的。应该是.....它没有'鼓包'和'腰'？从任意一点看，中间不会鼓出来挡路。"

老谟："你绕来绕去，其实在说一件很朴素的事：**这种碗里，随便挑两个点，这两点连成的线段，是不是整段都'待在碗里'？**你想想波浪板：中间那个鼓包，让'左边凹槽的一点'和'右边凹槽的一点'连成的线段，会从鼓包上方'越过去'——线段有一部分跑出碗外了。而光滑的碗，任意两点连线段，整段都在碗里。"

造物主：".....对！波浪板的两点连线会'悬空'穿过鼓包上方，可光滑碗的两点连线永远贴着碗壁内侧。**区别就是：线段有没有'跑出去'。**"

老谟："你刚刚用一句话定义了**凸集**：一个集合，任意两点的连线整段都还在集合里。波浪板的'凹槽'不是凸集（两点连线跑出去了），光滑的'碗'（圆盘）是凸集。先把这个几何直觉抓住——下一轮，我们把它从'形状'翻译成'代数'。"

知识锚点：凸集——"任意两点连线，整段都留在集合里"

【概念深挖】**凸集 (convex set)** 的定义：集合 $C \subseteq \mathbb{R}^n$ 称为凸集，如果对任意两点 $x, y \in C$ 及任意 $\lambda \in [0,1]$ ，都有

$$\lambda x + (1-\lambda)y \in C$$

$\lambda x + (1-\lambda)y$ 就是 x, y 连线上的点： λ 从 0 变到 1，这个点从 y ($\lambda=0$) 滑到 x ($\lambda=1$)。**凸集就是"任意两点连线不出去"的集合。**

常见的凸集：圆盘 $\{x^2+y^2 \leq r^2\}$ （光滑碗口）、矩形、半平面、整个 $\mathbb{R}^n$ 、单个点、空集、线性方程组的解集（如平面）。**常见的非凸集**：圆环（中间挖空，两点连线会穿过空洞）、两瓣不相连的集合、圆盘挖掉一块。

【工程实践】为什么工程师关心"凸不凸"？**因为约束条件的可行域越凸，优化就越"省心"。**机器学习里很多约束（参数在某个范数球内、概率向量在单纯形内）都是凸集；而"保证解落在一个无假坑的区域内"，是很多算法的前提。**凸性 = 可预测性 = 可证明的收敛。**

第 2 轮：从"碗的形状"到"函数的形状"——凸函数的定义

老谟："凸集管的是'区域'。可我们要优化的不是一个区域，而是一个**函数**——损失函数。'碗的形状'对应函数图像的形状。那么问题来了：**什么函数图像，能保证'一滑到底、没有假坑'？**你先拿一元函数想。"

造物主：".....开口向上的抛物线？像 x^2 那样，中间凹下去，钢珠滚到最低点，不会卡在半路。"

老谟："对。可'开口向上'只是对 x^2 这种规整函数的直观。你要把它翻译成'任意两个点都满足的条件'——就像凸集是'任意两点连线不出去'一样。你想想，凸集用'两点连线'定义，凸函数的图像是'碗'，那这两者该怎么接上？"

造物主：".....函数图像是'碗'，碗的内侧是凸集.....是不是可以这样：**函数图像上方的区域是凸集**？ x^2 的图像是条向上弯的抛物线，它上方的整个区域确实是凸的；而 x^3 的图像有 S 形拐弯，它上方有一块凹进去，不是凸集。"

老谟："你摸到凸函数的几何定义了。可这个定义用起来要'画图'，不顺手。我们换一个更代数、更好验证的说法：**在任意两点之间，函数值不能超过两端点函数值的'加权平均'**。也就是说，连线的中点在图像上，要么在图像上，要么在图像上方——'**连线不下垂**'。你自己用 λ 写出这个条件？"

▮ 知识锚点：凸函数——"任意两点之间，函数值不超过两端值的加权平均"

【概念深挖】**凸函数 (convex function)** 的定义：函数 $f: C \rightarrow \mathbb{R}$ (C 为凸集) 称为凸函数，如果对任意 $x, y \in C$ 及任意 $\lambda \in [0,1]$ ，都有

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$$

几何意义：把 x 、 y 连成一条弦，弦上任意一点的"加权平均高度" $\lambda f(x) + (1-\lambda)f(y)$ ，**不低于**图像在该点的高度 $f(\lambda x + (1-\lambda)y)$ 。也就是说：**弦永远在图像上方（或贴着图像），图像"不下垂"**。

直观： x^2 是凸函数（弦在图像上方）； x^3 不是（有 S 形区段，弦会穿到图像下方）。"**凸**"的图像形状像"碗"（U 形），非凸的图像带"S 形""波浪""鼓包"。

【历史溯源】凸性的系统研究要追溯到 20 世纪初：**Jensen (Johan Jensen, 1859–1925)** 在 1905–1906 年间给出了凸函数的不等式形式（即本章核心的 **Jensen 不等式**），奠定了凸分析的基础。此后 **Fenchel**、**Rockafellar** 等人把凸分析发展成系统学科（Rockafellar 的《Convex Analysis》是经典）。凸性从"几何直觉"到"严格理论"的历程，和你想从"碗的形状"到"不等式定义"的路径完全一致——你正在重走一遍 Jensen 走过的路。

【工程实践】**几乎所有机器学习损失函数都是凸的**：均方误差 (MSE)、交叉熵对参数、线性回归/逻辑回归的目标。**为什么强调凸？因为凸目标意味着"梯度下降一定收敛到全局最优"——没有假坑可卡。**而神经网络的损失通常**非凸**（多层非线性叠加产生大量局部极值/鞍点），这正是深度学习优化比传统凸优化难的根本原因——第 7 章我们会正面谈这件事。

第 3 轮：用定义验证凸性—— $f(x) = x^2$ 为什么凸、 x^3 为什么不凸

老谟："定义立起来了： $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$ 。可这个不等式，你怎么验证一个具体的函数？别光说'图像像碗'，拿 x^2 来说，你代入试试。"

造物主：".....代入 x^2 ：左边 $f(\lambda x + (1-\lambda)y) = [\lambda x + (1-\lambda)y]^2$ 。右边 $\lambda x^2 + (1-\lambda)y^2$ 。要证左边 $\leq$ 右边，那就是.....**右边减左边**： $[\lambda x^2 + (1-\lambda)y^2] - [\lambda x + (1-\lambda)y]^2$ 。我算算.....展开化简，是不是能因式分解出什么？"

老谟："你自己去化简。提示：这是一个关于 λ 的二次式，或者你能凑出 $(x-y)^2$ 的样子。你先算，算出来告诉我差是多少。"

造物主：".....展开 $[\lambda x + (1-\lambda)y]^2 = \lambda^2 x^2 + 2\lambda(1-\lambda)xy + (1-\lambda)^2 y^2$ 。右边 $\lambda x^2 + (1-\lambda)y^2$ 减这个： $\lambda x^2 - \lambda^2 x^2 = \lambda(1-\lambda)x^2$ ；同理 y 那边是 $(1-\lambda)y^2 - (1-\lambda)^2 y^2 = \lambda(1-\lambda)y^2$ ；中间 $-2\lambda(1-\lambda)xy$ 。合起来 $= \lambda(1-\lambda)(x^2 - 2xy + y^2) = \lambda(1-\lambda)(x-y)^2$ 。这玩意儿 ≥ 0 ($\lambda \in [0,1]$ 时 $\lambda(1-\lambda) \geq 0$, $(x-y)^2 \geq 0$)！所以右边 $\geq$ 左边， x^2 是凸的！"

老谟："你自己把 x^2 的凸性用代数验证出来了，而且差正好是 $\lambda(1-\lambda)(x-y)^2$ ——一个非负数。**这个方法就是'用定义验证凸性'的标准套路：把不等式两边的差化简，凑出'非负因子 $\times$ 平方和'**。那现在换个角度—— x^3 呢？你按这个套路试试，看能不能找到不满足的点。"

知识锚点：用定义验证凸性——"差化简成非负"

【概念深挖】用定义验证 f 的凸性，标准套路是**算差**：

$$\Delta = [\lambda f(x) + (1-\lambda)f(y)] - f(\lambda x + (1-\lambda)y)$$

- 若 $\Delta \geq 0$ 对所有 x, y, λ 恒成立，则 f 凸；
- 若能找到一组 x, y, λ 使 $\Delta < 0$ ，则 f 非凸。

对 $f(x) = x^2$ ： $\Delta = \lambda(1-\lambda)(x-y)^2 \geq 0$ ，故凸。对 $f(x, y) = x^2 + y^2$ ： $\Delta = \lambda(1-\lambda)[(x_1-x_2)^2 + (y_1-y_2)^2] \geq 0$ ，故凸。**非凸的例子**： $f(x) = x^3$ （见反例）； $f(x, y) = x^2 - y^2$ （鞍形，后文第 05 章会重点讨论）。

要点：这个验证法最适用于**能化简成"平方和/非负因子乘积"的函数（多项式为主）**。它不需要可微，是凸性的定义级判据，最"原始"也最可靠。

【工程实践】为什么"定义验证"在工程里反而有用？**因为很多可微判据（海森、切线下界）要求函数二次可微，而真实工程函数经常不可微（ReLU 复合、绝对值损失）**。此时"定义验证"是唯一硬道理——它不依赖光滑性。**工程代码里判断一个函数凸不凸，往往是'逐段用定义/已知凸函数运算规则拼装'，而不是去算海森。**

第 4 轮：从不等式到一个著名推论——Jensen 不等式

老谟："凸函数定义里那个不等式， λ 是 $[0,1]$ 里的一个数，作用在'两点'之间。你有没有想过——**如果不止两个点，而是一堆点，各自带不同的'权重'，会怎么样？**"

造物主：".....不止两点？那是不是把'两点的加权平均'推广成'多个点的加权平均'？比如三个点 x_1 、 x_2 、 x_3 ，权重 λ_1 、 λ_2 、 λ_3 加起来等于 1，那不等式变成 $f(\lambda_1 x_1 + \lambda_2 x_2 + \lambda_3 x_3) \leq \lambda_1 f(x_1) + \lambda_2 f(x_2) + \lambda_3 f(x_3)$ ？"

老谟："你自己把 Jensen 不等式猜出来了。这个'从两点推广到多点'的版本，就叫 **Jensen 不等式**，它是凸函数定义的最重要推论。而且它还能更进一步——**当权重变成'概率'（加起来等于 1 的非负数）时，它就是'函数作用于加权平均 $\leq$ 加权平均作用后的函数'**，这直接指向数学期望。你先把这个'多点加权平均'版本记下，我下一轮带你看它能干什么。"

知识锚点：Jensen 不等式——"凸函数的加权平均不等式"

【概念深挖】Jensen 不等式（有限形式）：设 f 为凸函数， $x_1, \dots, x_n \in C$ ，权重 $\lambda_1, \dots, \lambda_n \geq 0$ 且 $\sum \lambda_i = 1$ ，则

$$f(\sum \lambda_i x_i) \leq \sum \lambda_i f(x_i)$$

两点情形 ($\lambda_1 = \lambda, \lambda_2 = 1 - \lambda$) 就是凸函数定义。**加权平均版**是把两点的" λ 、 $(1-\lambda)$ "推广到 n 个点的" $\lambda_1, \dots, \lambda_n$ "。**它是凸函数定义的直接推论：**凸定义保证"两点加权平均成立"，对多个点反复应用（数学归纳法）即可。

与期望的联系：若把 λ_i 看成随机变量取 x_i 的概率，则 $\sum \lambda_i x_i = E[X]$ ， $\sum \lambda_i f(x_i) = E[f(X)]$ ，于是 Jensen 不等式写成：

$$f(E[X]) \leq E[f(X)]$$

这是概率论里最常用的不等式之一（册 06 会深入）："凸函数作用于均值"不超过"函数值的均值"。

【工程实践】Jensen 不等式在信息论与机器学习里无处不在：**KL 散度非负性**（证明里关键一步）、**EM 算法**（用 Jensen 构造下界然后迭代最大化）、**凸优化对偶理论**。" **$E[f(X)] \geq f(E[X])$** "这个不等式，是很多'下界 + 迭代逼近'算法的发动机——先构造一个易算的下界，再不断收紧它逼近真实目标。

第 5 轮：凸函数有什么"好性质"——局部最优 = 全局最优

老谟："Jensen 不等式是定义的一个推论。现在问你一个更尖锐、也更实用的问题：**凸函数和优化到底什么关系？为什么我们拼命想让损失函数凸？**你想想'假坑'——波浪板的小凹槽是个局部最低，但不是全局最低。凸函数会不会有这种'假坑'？"

造物主：".....凸函数图像像'碗'，碗只有一个底，没有假坑。所以凸函数应该.....**不会有局部最低但不是全局最低的情况？**"

老谟："你把凸优化最核心的定理说出来了：**凸函数的任何局部最优，都是全局最优。**这一条，就是'为什么敢用梯度下降'的根基——**只要你的目标是凸的，随便从哪起步，朝下降方向走，走到的任何'局部低点'都必然是全局最低。**你要不要想想，这条定理怎么证明？提示：反证法，假设有个局部最优但不是全局最优，然后用凸定义推出矛盾。"

造物主：".....假设 x^* 是局部最优但不是全局最优，那存在另一个点 y 让 $f(y) < f(x^*)$ 。 x^* 是局部最优，意味着在 x^* 附近没有更低的点。可凸函数定义说 $f(\lambda x^* + (1-\lambda)y) \leq \lambda f(x^*) + (1-\lambda)f(y)$当 λ 很接近 1 时， $\lambda x^* + (1-\lambda)y$ 就非常接近 x^* ，而它的函数值 $\leq \lambda f(x^*) + (1-\lambda)f(y) < \lambda f(x^*) + (1-\lambda)f(x^*) = f(x^*)$ ——这不就找到 x 附近一个比 $f(x)$ 还低的点吗？跟 x^* 是局部最优矛盾！**"

老谟："反证法用得干净利落。凸性保证'任何局部最优都是全局最优'——这就是你这一章所有定义的'最终回报'。现在我们把它落到'怎么判断一个函数是凸的'这个实操问题上：靠定义直接化简太累，有没有更省力的判据？下一轮看。"

知识锚点：凸函数的"好性质"——局部最优 = 全局最优

【概念深挖】**定理（凸函数的关键性质）：**设 f 是凸集 C 上的凸函数。若 $x^* \in C$ 是 f 在 C 上的**局部极小点**（存在 x^* 的邻域使 $f(x^*)$ 是最小值），则 x^* 也是 f 在 C 上的**全局极小点**（对任意 $y \in C$ 有 $f(x^*) \leq f(y)$ ）。

直觉：凸函数的图像没有"假坑"——它是"单谷"的。任何一个"谷底"，从整个定义域看都是最低点。

意义：这是**"为什么敢用梯度下降"的数学根基**。只要目标凸，算法随便从哪初始化、随便怎么下降，只要收敛到一个稳定点，那个点就必然是全局最优。**凸优化 = "找到稳定点就赢了"；非凸优化 = "找到稳定点只是万里长征第一步"。**

【工程实践】这就是为什么经典机器学习（线性回归、逻辑回归、SVM）的损失都要设计成凸的——**保证了训练一定成功。**而深度神经网络的损失非凸，所以深度学习训练依赖大量技巧（初始化、学习率调度、随机性）去"碰运气地逃离假坑"——**凸性，是传统机器学习与深度学习在"可证明性"上的分水岭。**

第 6 轮：可微的凸函数——切线永远在图像下方（一阶刻画）

老谟："定义验证凸性，要化简代数式，费劲。那如果 f 是**可微**的，有没有更简单的判据？你想想凸函数图像'不下垂'、'像碗'——你从图像上某点作一条**切线**，这条切线和图像是什么关系？"

造物主：".....切线？ x^2 在任意点的切线都在图像**下方**吧.....因为 x^2 是向上弯的，切线只在切点碰到它，其余地方都低于曲线。"

老谟："这就是凸函数的一阶刻画：**可微的凸函数，图像永远在任意点的切线（一阶泰勒近似）上方**—— $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ 。这条性质也反过来：**如果一个可微函数处处'站在所有切线上方'，它就是凸的**。这条刻画的好处是：不用化简代数式，只要看'函数减切线'的符号。严格证明放走廊，你先接受这个直觉：**凸 = 切线是曲线的'下界'**。那再进一步——如果 f 还二次可微呢？能不能用二阶信息判断？"

知识锚点：一阶刻画——"凸函数永远站在切线上方"

【概念深挖】**凸函数的一阶刻画 (first-order characterization)**：设 f 在凸集 C 上可微。则 f 是凸函数，当且仅当对任意 $x, y \in C$ ：

$$f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$$

几何意义： f 的图像永远在点 x 处的切平面（一阶泰勒近似）**上方**。**"凸 = 切平面是函数的下界"**。

用途：这是判断可微函数凸性的一个强判据（比定义省力），也是**证明"局部最优 = 全局最优"最顺手的工具——如果 $\nabla f(x)=0$ 且 f 凸，则由一阶刻画 $f(y) \geq f(x) + 0 \cdot (y-x^*) = f(x^*)$ ，立得全局最优。

【工程实践】一阶刻画在**梯度下降收敛性分析**里是主角：要证"梯度下降到稳定点即全局最优"，用的就是这个不等式 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ 。它是**"凸优化理论"与"算法设计"之间的接口**。第 6 章你会反复用它。

第 7 轮：二次可微的凸函数——海森矩阵半正定（二阶刻画）

老谟："一阶刻画要看'函数减切线'，还是要算差值。那如果 f **二次可微**呢？我们用多元泰勒想想： $f(y) \approx f(x) + \nabla f(x) \cdot (y-x) + \frac{1}{2}(y-x)^T H(x)(y-x)$ 。如果 f 要'永远站在切线上方'，那这个二次项得保证什么？"

造物主：".....站在切线上方 $= f(y) - f(x) - \nabla f(x) \cdot (y-x) \geq 0$ 。而泰勒说这个差 $\approx \frac{1}{2}(y-x)^T H(x)(y-x)$ 。所以要让差非负，就得让二次型 $(y-x)^T H(x)(y-x) \geq 0$ 对任意方向都成立——也就是海森矩阵 H **半正定**！"

老谟："你漂亮地摸到了二阶刻画：**二次可微的 f 是凸函数，当且仅当海森矩阵处处半正定。** '半正定'是个线性代数概念——所有特征值非负，或所有主子式非负。你认出了那个二次型 $h^T H h$ ——第 02 章多元泰勒里它出现过，现在它变成凸性判定的主角。**这一下，判定凸性从'化简代数式'变成了'检查一个矩阵是否半正定'——而这件事，下一章我们要专门系统搞定。** 你先把'海森半正定 $\Leftrightarrow$ 凸'这句记牢。"

知识锚点：二阶刻画——"二次可微 $\Leftrightarrow$ 海森矩阵半正定"

【概念深挖】**凸函数的二阶刻画 (second-order characterization)**：设 f 在凸集 C 上二次可微。则 f 是凸函数，当且仅当对任意 $x \in C$ ，**海森矩阵 $H(x)$ 半正定**（对任意方向 h ， $h^T H(x) h \geq 0$ ）。

来源：由多元泰勒， $f(y) - f(x) - \nabla f(x) \cdot (y-x) \approx \frac{1}{2}(y-x)^T H(x)(y-x)$ 。"**函数站在切线上方**"（一阶刻画）就要求这个二次项非负，即海森半正定。

特别地：

- 若 $H(x)$ **正定** ($h^T H h > 0$ 对一切 $h \neq 0$)， f 是**严格凸**（弦严格在图像上方）；
- 若 $H(x)$ 只是**半正定**（允许某些方向 $h^T H h = 0$ ）， f 是凸（但不严格）。

【工程实践】"**算海森判断凸性**"是工程里判断"这个损失好不好优化"的标准动作：MSE 的海森是半正定矩阵，所以线性回归是凸问题；逻辑回归的海森半正定，所以也是凸问题；而带非线性激活的多层网络的损失海森不定，所以非凸。"**看海森正不正定**"是判断优化难度的一眼快筛。下一章，我们专门教你怎么系统地判断一个矩阵正定/半正定/不定。

第 8 轮：落点——从"碗的形状"到"能验证的条件"

老谟："绕了一大圈，你现在把'什么形状碗敢保证一滑到底'这个问题，用数学语言完整回答一遍。"

造物主："敢一滑到底的，是凸函数。判断方法有三种：**定义法** ($f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$)，把差化简成非负)；**一阶刻画**（可微时 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ ，切线是下界）；**二阶刻画**（二次可微时海森矩阵半正定）。而它们共同的回报是：**凸函数局部最优 = 全局最优，没有假坑。**"

老谟："你手里现在有三把尺子，可三把尺子用起来费力程度不同：定义法要化简，一阶刻画要算差值，二阶刻画要'判断一个矩阵是否半正定'。**下一章，我们把'判断矩阵半正定/正定'这件事彻底工具化——主子式判据、特征值判据，还有一张判定树。** 你先把这个'碗'的形状踩实，明天我们给它装上'量歪坑的尺子'。"

严格化走廊

位置说明：本章对话负责"直觉"——为什么凸集连线不出去、为什么凸函数没有假坑。本走廊负责"严谨"——把凸集、凸函数、Jensen 不等式、一阶/二阶刻画写成精确的定义与定理，并给出可复写的证明。下面每一行，读者都能对着空白纸重写一遍。

关于对话的口径说明

对话里"碗的形状""切线是下界""海森半正定"都是直觉引导。本走廊把凸性相关结论落成严格形式：定义 1（凸集）、定义 2（凸函数）、定义 3（Jensen 不等式）、定理 1（一阶刻画）、定理 2（局部最优 = 全局最优）、定理 3（二阶刻画）。读者应把对话当"为什么要这样想"，把本走廊当"为什么这样想是对的"。

定义 1：凸集 (convex set)

集合 $C \subseteq \mathbb{R}^n$ 称为**凸集**，如果对任意 $x, y \in C$ 及任意 $\lambda \in [0,1]$ ，有：

$$\lambda x + (1-\lambda)y \in C$$

直观：x、y 连线上的所有点都在 C 内，"任意两点连线不出去"。

定义 2：凸函数 (convex function)

设 $C \subseteq \mathbb{R}^n$ 为凸集， $f: C \rightarrow \mathbb{R}$ 。f 称为**凸函数**，如果对任意 $x, y \in C$ 及任意 $\lambda \in [0,1]$ ：

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$$

若不等式严格（对 $x \neq y$ 、 $0 < \lambda < 1$ 用 $<$ ），则称 f **严格凸**。若 $-f$ 凸，则 f **凹**。

定义 3：Jensen 不等式（有限形式）

设 f 为凸集 C 上的凸函数， $x_1, \dots, x_n \in C$ ， $\lambda_1, \dots, \lambda_n \geq 0$ 且 $\sum_i \lambda_i = 1$ ，则：

$$f(\sum_i \lambda_i x_i) \leq \sum_i \lambda_i f(x_i)$$

定理 1（一阶刻画）：设 f 在凸集 C 上可微。则 f 凸，当且仅当对任意 $x, y \in C$ ：

$$f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$$

证明（可复写）：

• **"凸 $\Rightarrow$ 不等式"：**

- 第 1 步：由凸定义，对 $\lambda \in (0,1)$ ： $f(\lambda y + (1-\lambda)x) \leq \lambda f(y) + (1-\lambda)f(x)$ 。（依据：定义 2。）
- 第 2 步：移项得 $f(\lambda y + (1-\lambda)x) - f(x) \leq \lambda[f(y) - f(x)]$ 。（依据：代数整理。）
- 第 3 步：左边 = $f(x + \lambda(y-x)) - f(x)$ 。令 $\lambda \rightarrow 0^+$ ，左边 $\rightarrow \nabla f(x) \cdot (y-x)$ （依据：可微性/方向导数的定义，第 01 章定理 1：方向导数 = 梯度·方向）。
- 第 4 步：取极限得 $\nabla f(x) \cdot (y-x) \leq f(y) - f(x)$ ，即 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ 。■

• **"不等式 $\Rightarrow$ 凸"：**

- 第 5 步：设 $z = \lambda x + (1-\lambda)y$ ，需证 $f(z) \leq \lambda f(x) + (1-\lambda)f(y)$ 。由假设（对 z 与 x ）： $f(x) \geq f(z) + \nabla f(z) \cdot (x-z)$ ；对 z 与 y ： $f(y) \geq f(z) + \nabla f(z) \cdot (y-z)$ 。（依据：假设的不等式。）
- 第 6 步： $\lambda f(x) + (1-\lambda)f(y) \geq f(z) + \nabla f(z) \cdot [\lambda(x-z) + (1-\lambda)(y-z)]$ 。（依据：线性组合不等式。）
- 第 7 步：计算 $\lambda(x-z) + (1-\lambda)(y-z) = \lambda x + (1-\lambda)y - z = z - z = 0$ （依据： $z = \lambda x + (1-\lambda)y$ 的定义）。
- 第 8 步：代入得 $\lambda f(x) + (1-\lambda)f(y) \geq f(z)$ ，即凸性成立。■

证明要点标注：前四步用**定义 2（凸）、可微性与方向导数公式（第 01 章定理 1）、极限比较**；后四步用**假设的不等式、线性组合与 z 的定义**。

定理 2（局部最优 = 全局最优）：设 f 是凸集 C 上的凸函数， $x^* \in C$ 是 f 的局部极小点，则 x^* 是 f 在 C 上的全局极小点。

证明（可复写，反证法）：

- 第 1 步：反设存在 $y \in C$ 使 $f(y) < f(x^*)$ 。（依据：全局极小的否定。）
- 第 2 步：对 $\lambda \in (0,1)$ ，由凸性（定义 2）： $f(\lambda y + (1-\lambda)x^*) \leq \lambda f(y) + (1-\lambda)f(x^*)$ 。（依据：定义 2。）
- 第 3 步：因 $f(y) < f(x^*)$ ，故 $\lambda f(y) + (1-\lambda)f(x^*) < \lambda f(x^*) + (1-\lambda)f(x^*) = f(x^*)$ 。（依据：严格不等式与 $f(x^*)$ 相同项合并。）
- 第 4 步：故 $f(\lambda y + (1-\lambda)x^*) < f(x^*)$ 。当 $\lambda \rightarrow 0^+$ ，点 $\lambda y + (1-\lambda)x^*$ 趋近 x^* ，即 x^* 的任意小邻域内存在函数值更低的点。（依据： $\lambda y + (1-\lambda)x^* \rightarrow x^*$ 当 $\lambda \rightarrow 0$ 。）
- 第 5 步：这与" x^* 是局部极小点"矛盾。故假设不成立， $f(y) < f(x^*)$ 不可能， x^* 是全局极小点。■

证明要点标注：第 2 步用**定义 2（凸）**；第 3 步用**严格不等式线性组合**；第 4 步用**凸组合的连续性（ $\lambda \rightarrow 0$ 时逼近 x^* ）**；第 5 步用**反证法的归谬**。

定理 3 (二阶刻画)： 设 f 在凸集 C 上二次可微。则 f 凸，当且仅当对任意 $x \in C$ ，海森矩阵 $H(x)$ 半正定（即对一切 h ， $h^T H(x) h \geq 0$ ）。

证明（可复写，用定理 1 + 多元泰勒）：

• **"凸 $\Rightarrow$ H 半正定"：**

- 第 1 步：由定理 1（凸 $\Rightarrow$ 一阶不等式），对 x 和 $y = x + th$ （ t 足够小使点仍在 C 内）：
 $f(x+th) \geq f(x) + \nabla f(x) \cdot (th)$ 。（依据：定理 1。）
- 第 2 步：移项 $f(x+th) - f(x) - \nabla f(x) \cdot (th) \geq 0$ 。（依据：代数。）
- 第 3 步：由多元泰勒（第 02 章定理 3）： $f(x+th) = f(x) + \nabla f(x) \cdot (th) + \frac{1}{2}t^2 h^T H(x) h + o(t^2)$ 。
 代入第 2 步得 $\frac{1}{2}t^2 h^T H(x) h + o(t^2) \geq 0$ 。（依据：多元泰勒公式。）
- 第 4 步：除以 t^2 并令 $t \rightarrow 0$ ： $\frac{1}{2}h^T H(x) h \geq 0$ ，即 $H(x)$ 半正定。（依据： $o(t^2)/t^2 \rightarrow 0$ 。）

• **"H 半正定 $\Rightarrow$ 凸"：**

- 第 5 步：由多元泰勒（带拉格朗日余项），存在 ξ 位于 x 与 y 之间使 $f(y) = f(x) + \nabla f(x) \cdot (y-x) + \frac{1}{2}(y-x)^T H(\xi)(y-x)$ 。（依据：带余项的多元泰勒。）
- 第 6 步：因 H 处处半正定， $\frac{1}{2}(y-x)^T H(\xi)(y-x) \geq 0$ 。（依据：半正定定义。）
- 第 7 步：故 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ ，由定理 1（不等式 $\Rightarrow$ 凸）得 f 凸。■

证明要点标注： 前四步用定理 1、多元泰勒（第 02 章定理 3）与极限；后三步用带余项的多元泰勒、半正定定义与定理 1 的逆方向。

反例/边界

- **x^3 不是凸函数：** $f(x) = x^3$ 。取 $x = -1$ ， $y = 0$ ， $\lambda = 1/2$ ：左边 $f((-1+0)/2) = f(-0.5) = -0.125$ ；右边 $(1/2)f(-1) + (1/2)f(0) = (1/2)(-1) + 0 = -0.5$ 。因 $-0.125 > -0.5$ ，不等式 $f(\text{中点}) \leq \text{加权平均}$ 不成立，故 x^3 非凸。（几何： x^3 有 S 形拐弯，在 $x=0$ 左侧向上凹，弦穿到图像下方。）
- **海森半正定是"处处"的：** 二阶刻画要求 $H(x)$ 在 C 内每一点都半正定。若只在局部某点半正定，不能推出全局凸。（一个函数可能在某个点局部凸，但整体非凸——判定凸性是"整体性质"，要检查所有点。）
- **不可微函数的凸性：** 一阶/二阶刻画都要求可微/二次可微。对不可微的凸函数（如 $f(x) = |x|$ ，ReLU），只能用定义验证或次梯度理论。可微判据不是万能的，遇到折角函数要退回定义。
- **严格凸 vs 凸：** x^2 严格凸（ $H=2>0$ ）；而 $f(x) = x^4$ 的 $H = 12x^2$ 在 $x=0$ 处为 0，只在别处正—— f 仍是凸的（ H 处处半正定），但不是严格凸（存在 H 半正定但不正定的点）。

知识点总结

知识点（本章推出的核心概念）

- **凸集**：任意两点连线整段留在集合内 ($\lambda x + (1-\lambda)y \in C$)。圆盘、矩形、半平面是凸集；圆环、两瓣不连的集合非凸。
- **凸函数**： $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$ ——"弦在图像上方，图像不下垂"。 x^2 凸、 x^3 非凸。
- **用定义验证凸性**：算差 $\Delta = [\lambda f(x) + (1-\lambda)f(y)] - f(\lambda x + (1-\lambda)y)$ ，若能化简成非负（如 $\lambda(1-\lambda)(x-y)^2$ ），则凸。
- **Jensen 不等式**： $f(\sum \lambda_i x_i) \leq \sum \lambda_i f(x_i)$ ；概率形式 $f(E[X]) \leq E[f(X)]$ （凸函数作用均值不超过函数值均值）。
- **一阶刻画**：可微时 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ ——切线是函数下界。
- **二阶刻画**：二次可微时 f 凸 $\Leftrightarrow$ 海森矩阵处处半正定 ($h^T H h \geq 0$)。
- **关键性质**：凸函数的局部最优 = 全局最优（没有假坑）——"为什么敢用梯度下降"的根基。

历史结论（本章涉及的史料）

- **Jensen (Johan Jensen, 1859–1925)**：1905–1906 年给出凸函数的不等式形式（Jensen 不等式），奠定凸分析基础。
- **Fenchel、Rockafellar 等**：20 世纪中叶把凸分析发展为系统学科；Rockafellar 的《Convex Analysis》（1970）是经典教材。
- **凸性的几何直觉（切线/弦）**：早在 19 世纪就有数学家用"弦在图像上方"描述这类函数，但严格的不等式形式由 Jensen 确立。

工程实践结论（本章知识在真实工程里怎么用）

- **凸损失 = 训练可证明成功**：MSE、交叉熵、线性回归/逻辑回归/SVM 目标都是凸的，梯度下降保证到全局最优。
- **深度学习损失非凸**：多层非线性产生大量局部极值/鞍点，训练靠技巧"逃离假坑"——凸性是传统 ML 与深度学习的可证明性分水岭。
- **Jensen 不等式是算法发动机**：KL 散度非负性、EM 算法的下界构造、凸优化对偶都靠它。
- **海森半正定 = 优化容易的一眼快筛**：算海森判断正定/半正定，是判断"这损失好不好优化"的标准动作。

计算训练场

位置说明：本章对话负责“为什么”，这里负责“怎么算”。**每题请动笔 10 分钟以上，先自己写，再对照完整解答。禁止边算边翻答案。**

题 1（易→中）：用定义验证凸性——展开化简

题干：用定义 $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$ 验证以下函数凸性：(a) $f(x) = x^2$ 。(b) $f(x,y) = x^2 + y^2$ 。(c) 证明 $f(x) = x^3$ 在实数上**不是**凸函数（构造反例）。

完整分步解答：

(a) $f(x) = x^2$ ：第 1 步：算差 $\Delta = [\lambda x^2 + (1-\lambda)y^2] - [\lambda x + (1-\lambda)y]^2$ 。（规则：凸性不等式两边的差。）第 2 步：展开 $[\lambda x + (1-\lambda)y]^2 = \lambda^2 x^2 + 2\lambda(1-\lambda)xy + (1-\lambda)^2 y^2$ 。（规则：完全平方展开。）第 3 步： $\Delta = \lambda x^2 - \lambda^2 x^2 + (1-\lambda)y^2 - (1-\lambda)^2 y^2 - 2\lambda(1-\lambda)xy = \lambda(1-\lambda)x^2 + \lambda(1-\lambda)y^2 - 2\lambda(1-\lambda)xy$ 。（规则：合并同类项， $\lambda - \lambda^2 = \lambda(1-\lambda)$ 。）第 4 步： $\Delta = \lambda(1-\lambda)(x^2 - 2xy + y^2) = \lambda(1-\lambda)(x-y)^2$ 。（规则：完全平方 $a^2 - 2ab + b^2 = (a-b)^2$ 。）第 5 步：因 $\lambda \in [0,1]$ 故 $\lambda(1-\lambda) \geq 0$ ，且 $(x-y)^2 \geq 0$ ，故 $\Delta \geq 0$ ，即右边 $\geq$ 左边，**f 凸** ✓。

(b) $f(x,y) = x^2 + y^2$ ：第 6 步： $\Delta = [\lambda(x_1^2 + y_1^2) + (1-\lambda)(x_2^2 + y_2^2)] - [\lambda x_1 + (1-\lambda)x_2]^2 - [\lambda y_1 + (1-\lambda)y_2]^2$ 。（规则：凸性差，注意两项都要展开。）第 7 步：对 x 部分： $\lambda x_1^2 + (1-\lambda)x_2^2 - [\lambda x_1 + (1-\lambda)x_2]^2 = \lambda(1-\lambda)(x_1 - x_2)^2$ （同 (a)）。（规则：同 (a) 的完全平方。）第 8 步：对 y 部分同理 $= \lambda(1-\lambda)(y_1 - y_2)^2$ 。（规则：对称。）第 9 步： $\Delta = \lambda(1-\lambda)[(x_1 - x_2)^2 + (y_1 - y_2)^2] \geq 0$ ，故 **f 凸** ✓。

(c) $f(x) = x^3$ 非凸反例：第 10 步：取 $x = -1, y = 0, \lambda = 1/2$ 。左边 $f(\lambda x + (1-\lambda)y) = f(-0.5) = (-0.5)^3 = -0.125$ 。（规则： x^3 求值。）第 11 步：右边 $\lambda f(x) + (1-\lambda)f(y) = (1/2)(-1) + (1/2)(0) = -0.5$ 。（规则：加权平均。）第 12 步：比较 -0.125 与 -0.5 ： **$-0.125 > -0.5$** ，即左边 $>$ 右边，凸性不等式 $f(\text{中点}) \leq \text{加权平均}$ **不成立**，故 x^3 非凸。（规则：凸性要求左边 $\leq$ 右边，此处违反。）

答：(a) $\Delta = \lambda(1-\lambda)(x-y)^2 \geq 0$ ，凸；(b) $\Delta = \lambda(1-\lambda)[(x_1 - x_2)^2 + (y_1 - y_2)^2] \geq 0$ ，凸；(c) 反例 $x = -1, y = 0, \lambda = 1/2$ 使 $f(-0.5) = -0.125 > -0.5$ ，非凸。

常见错误：① (b) 里漏掉对 y 的那一项展开，只算 x 部分，导致差算不全；② 把 $\lambda - \lambda^2$ 合并成 $\lambda(1-\lambda)$ 时符号写错；③ 判断 (c) 时选了“看起来合理”但不等式不违反的点（如对称点 $x = -1, y = 1$ 会让 $f(\text{中点}) = f(0) = 0$ 与加权平均 0 相等，恰好不违反——要挑非对称点）。

题 2（中）：一阶刻画与二阶刻画——判断可微函数凸性

题干：对以下函数，判断凸性并说明用了哪种判据：(a) $f(x) = e^x$ （用二阶刻画）。(b) $f(x) = x^4$ （用二阶刻画，注意某点二阶导为 0）。(c) $f(x) = -x^2$ （用二阶刻画）。(d) $f(x,y) = x^2 + y^2$ （用二阶

刻画，算海森）。

完整分步解答：

(a) $f(x) = e^x$: 第 1 步: $f''(x) = e^x$ 。(规则: e^x 求两次导仍是 e^x 。) 第 2 步: 因 $e^x > 0$ 对所有 x , 故 $H = f''$ 处处正定, f 严格凸。(规则: 二阶刻画—— H 半正定 $\Leftrightarrow$ 凸。)

(b) $f(x) = x^4$: 第 3 步: $f'(x) = 4x^3$, $f''(x) = 12x^2$ 。(规则: 幂函数求导。) 第 4 步: $f''(x) = 12x^2 \geq 0$ 对所有 x ($x=0$ 处为 0, 其余处 > 0)。(规则: 二阶刻画。) 第 5 步: 故 f 凸; 但因 $f''(0) = 0$, H 在 $x=0$ 处只半正定不正定, f 不是严格凸。(规则: 半正定 $\neq$ 正定。)

(c) $f(x) = -x^2$: 第 6 步: $f''(x) = -2 < 0$ 。(规则: $-x^2$ 求两次导 $= -2$ 。) 第 7 步: $H = -2$ 处处负定, 不半正定, 故 f 不是凸函数 (它是凹函数)。(规则: 二阶刻画的反向。)

(d) $f(x,y) = x^2 + y^2$: 第 8 步: $f_{xx} = 2$, $f_{xy} = 0$, $f_{yy} = 2$, 故 $H = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 。(规则: 二阶偏导。) 第 9 步: 对任意 $h = (h_1, h_2)$, $h^T H h = 2h_1^2 + 2h_2^2 \geq 0$, 且对 $h \neq 0$ 恒 > 0 , H 处处正定。(规则: 半正定/正定定义。) 第 10 步: 故 f 严格凸 $\checkmark$ (与题 1(b) 用定义法结论一致, 双通道互证)。(规则: 二阶刻画。)

答: (a) 严格凸 ($e^x > 0$) ; (b) 凸但不严格 ($12x^2 \geq 0$, $x=0$ 处为 0) ; (c) 非凸 ($H = -2$ 负定) ; (d) 严格凸 ($H = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 正定) 。

常见错误: ① 把 (b) 的 x^4 当成"只在 $x=0$ 处二阶导为 0 就不凸"——**半正定允许某点等于 0**, x^4 仍是凸函数, 只是不严格; ② (c) 把"凹"和"非凸"混淆, $-x^2$ 是凹函数, 不是凸函数; ③ 算 (d) 的 $h^T H h$ 时漏项, 或把 H 的交叉项 (应为 0) 当成 2。

题 3 (中 $\rightarrow$ 难) : Jensen 不等式 + 局部最优 = 全局最优

题干: (a) 用 Jensen 不等式 (两点形式, 即凸定义) 证明: 对凸函数 f , $f(x) + f(y) \geq 2f((x+y)/2)$ (中点的函数值不超过两端平均)。(b) 设 $f(x,y) = x^2 + y^2$, 验证"局部最优 = 全局最优": 求 f 的梯度零点, 证明它是全局极小点。(c) 用一阶刻画 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ 验证: 对 (b) 的 f , 梯度零点确为全局极小。

完整分步解答：

(a) Jensen 中点不等式: 第 1 步: 在凸定义 $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$ 中取 $\lambda = 1/2$ 。(规则: 凸定义。) 第 2 步: 左边 $f(\frac{1}{2}x + \frac{1}{2}y) = f((x+y)/2)$; 右边 $\frac{1}{2}f(x) + \frac{1}{2}f(y) = (f(x) + f(y))/2$ 。(规则: 代入 $\lambda = 1/2$ 。) 第 3 步: 故 $f((x+y)/2) \leq (f(x) + f(y))/2$, 即 **$f(x) + f(y) \geq 2f((x+y)/2)$** 。(规则: 不等式两边同乘 2。)

(b) 梯度零点与全局极小: 第 4 步: $f = x^2 + y^2$, $\nabla f = (2x, 2y)$ 。(规则: 求偏导。) 第 5 步: 令 $\nabla f = 0$, 得 $2x=0$ 、 $2y=0$, 即唯一驻点 $x = (0,0)^*$ 。(规则: 解方程组。) 第 6 步: $f(0,0) = 0$; 对任意 (x,y) , $f(x,y) = x^2 + y^2 \geq 0 = f(0,0)$, 故 $(0,0)$ 是全局极小点。(规则: $x^2 \geq 0$ 、 $y^2 \geq 0$ 。)

(c) 一阶刻画验证：第 7 步：一阶刻画说 f 凸时， $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ 对一切 x, y 成立。（规则：定理 1。）第 8 步：在梯度零点 $x^* = (0,0)$ ， $\nabla f(0,0) = 0$ ，代入一阶刻画（以 $x = x^* = 0$ ）： $f(y) \geq f(0) + 0 \cdot (y-0) = f(0) = 0$ 。（规则：定理 1 取 x =梯度零点。）第 9 步：故对任意 y ， $f(y) \geq f(0)$ ，即 $(0,0)$ 是全局极小点 ✓。（规则：全局极小定义。）

答：(a) $f(x)+f(y) \geq 2f((x+y)/2)$ ；(b) 唯一驻点 $(0,0)$ ， $f(0,0)=0 \leq f(x,y)$ 对一切点，故为全局极小；(c) 一阶刻画 + $\nabla f(0,0)=0$ 直接给出 $f(y) \geq f(0)$ ，印证"梯度零点即全局最优"。

常见错误：① (a) 里取 λ 忘写 $1-\lambda$ ，或把中点写成 $(x+y)/2$ 但右侧仍保留 λ 形式；② (b) 找到驻点后没说" f 是凸函数所以局部=全局"，只停在"这是驻点"——**要指出因为 f 凸，驻点自动是全局最优**；③ (c) 里忘了" $\nabla f(x^*)=0$ "这一关键代入，导致一阶刻画右边多一项。

向导便签

这一章咱们干了什么：从"什么形状的坡敢保证钢珠一滑到底"这个问题出发，定义了凸集（任意两点连线不出去）和凸函数（ $f(\lambda x+(1-\lambda)y) \leq \lambda f(x)+(1-\lambda)f(y)$ ）；推出了 Jensen 不等式；证明了凸函数"局部最优 = 全局最优"；并给出了可微/二次可微时的一阶刻画（切线是下界）和二阶刻画（海森半正定）。

钉死一句话：**凸函数 = 没有假坑的单谷函数；它的局部最优就是全局最优，所以"敢用梯度下降"**。

判断它有三把尺子：定义法（化简差）、一阶刻画（切线下界）、二阶刻画（海森半正定）。

记住一个边界：**一阶/二阶刻画要求可微/二次可微**；遇到不可微的折角函数（ $|x|$ 、ReLU），只能退回定义验证或次梯度理论。还有，**海森"处处"半正定才是凸**，只看某一点不算数。

造物主手记

我曾踩的坑：

我最先想把"碗的形状"直接说成"开口向上"，被老谟指出这只能描述 x^2 这种规整函数，不能泛化。接着我验证 x^3 时，挑了个 $x=-1$ 、 $y=1$ 的对称点，算出来 $f(0)=0$ 和加权平均 0 恰好相等——差点误判成" x^3 也可能是凸的"！老谟让我换非对称点 $x=-1$ 、 $y=0$ ，才算出 $f(-0.5)=-0.125 > -0.5$ ，铁证如山。**"找反例要挑非对称点"——这个教训我记下了。** 还有一个坑：我算 $f(x,y)=x^2+y^2$ 的差时，只展开了 x 那部分，忘了 y 那部分也要展开，差点得出一个不完整的差。

顿悟时刻：

真正开窍是第 5 轮那个反证法。我一步步用凸定义推，发现"如果 x^* 是局部最优却不是全局最优，那 x^* 附近必然藏着更低的点"，跟局部最优矛盾——**那一刻我突然明白，"凸"不是一句形容词，而是一条**

能把“假坑”从数学上排除掉的硬约束。 从此我看任何优化问题，第一反应都是问：这个损失凸不凸？这是不是深度学习比传统机器学习难的根本原因？

自测题

计算题须动笔完成，附完整解答自核；概念题用于检查理解。

题 A（计算，易→中）：定义验证凸性

用定义验证 $f(x) = x^2 + 2x$ 是凸函数（提示：算差 Δ ，注意它仍是 $\lambda(1-\lambda)(x-y)^2$ ，因为线性项 $+2x$ 的贡献恰好抵消）。

完整解答： $\Delta = [\lambda f(x) + (1-\lambda)f(y)] - f(\lambda x + (1-\lambda)y) = [\lambda(x^2 + 2x) + (1-\lambda)(y^2 + 2y)] - [(\lambda x + (1-\lambda)y)^2 + 2(\lambda x + (1-\lambda)y)]$ 。线性项部分： $\lambda \cdot 2x + (1-\lambda) \cdot 2y - 2(\lambda x + (1-\lambda)y) = 0$ （恰好抵消）；二次部分同题 1(a)： $\lambda(1-\lambda)(x-y)^2$ 。故 $\Delta = \lambda(1-\lambda)(x-y)^2 \geq 0$ ， f 凸 $\checkmark$ 。

题 B（计算，中→难）：二阶刻画 + 局部最优

设 $f(x, y) = x^2 + y^2$ 。(a) 求海森矩阵 H 并判断正定/半正定。(b) 求梯度零点，用“凸函数局部=全局”说明它是最优解。(c) 在 $(1, 1)$ 处用一阶刻画验证 $f(0, 0) \geq f(1, 1) + \nabla f(1, 1) \cdot (-1, -1)$ 。

完整解答：(a) $H = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ ，对 $h \neq 0$ ， $h^T H h = 2h_1^2 + 2h_2^2 > 0$ ，故 H 处处正定， f 严格凸。（规则：二阶刻画。）(b) $\nabla f = (2x, 2y) = 0 \rightarrow x^* = (0, 0)$ 。因 f 严格凸，局部最优 = 全局最优，且 $f(0, 0) = 0$ 是最小值。（规则：定理 2。）(c) 一阶刻画： $f(y) \geq f(x) + \nabla f(x) \cdot (y - x)$ 。取 $x = (1, 1)$ 、 $y = (0, 0)$ ： $\nabla f(1, 1) = (2, 2)$ ， $y - x = (-1, -1)$ 。 $f(0, 0) = 0$ ；右侧 $f(1, 1) + \nabla f(1, 1) \cdot (-1, -1) = 2 + (2, 2) \cdot (-1, -1) = 2 + (-4) = -2$ 。 $0 \geq -2 \checkmark$ 成立（注意这里是“ y 取 $(0, 0)$ ”相对 $x = (1, 1)$ 确实更低，不等式方向正确：低点的函数值 $\geq$ 高点的切线外推值）。

题 C（概念，检查理解）：凸性与判定工具

老谟给造物主三个函数： x^3 、 $x^2 + y^2$ 、 $-x^2 - y^2$ 。(1) 哪个是凸函数？哪个是凹函数？哪个既非凸也非凹？(2) 为什么“局部最优 = 全局最优”只对凸函数成立？(3) 遇到不可微的凸函数（如 $f(x) = |x|$ ），该用哪种判据？

完整解答：(1) $x^2 + y^2$ 凸 (H 正定)； $-x^2 - y^2$ 凹 (H 负定)； x^3 既非凸也非凹 ($H = 6x$ 变号，且定义验证出现反例)。（规则：二阶刻画 / 定义验证。）(2) 因为凸函数没有“假坑”——反证法证明：若局部最优非全局最优，则附近必有更低的凸组合点，与局部最优矛盾。非凸函数（波浪板）有假坑，所以这条只对凸成立。（规则：定理 2。）(3) $|x|$ 不可微（在 $x = 0$ 有棱），一阶/二阶刻画都不适用，只能用**定义验证**（直接检查 $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$ ）或**次梯度**理论。（规则：可微判据的适用边界。）

预告

你手里现在有"判断一个函数凸不凸"的三把尺子：定义法、一阶刻画、二阶刻画。可这三把尺子里，**二阶刻画用起来最省力，却也最难——因为"海森矩阵半正定"这件事，本身是个线性代数问题：你怎么系统地判断一个矩阵是正定、半正定、还是不定？**

下一章，我们把"判断矩阵正定/半正定"彻底工具化：二次型 $x^T A x$ 、特征值判据、还有那个靠"顺序主子式"一招定天下的 Sylvester 判据——以及把"海森正不正定"翻译成"函数凸不凸"的一张判定树。你这一章种下的"碗的形状"，下一章要给它装上"量歪坑的尺子"。

第 05 章 · 凸性判定与二次型——怎么用二阶导判定"这碗有没有歪坑"

本章从哪个问题出发：上一章我们立了"凸函数 = 海森矩阵半正定"这把尺子。可这把尺子有个绕不过去的坎——"**海森矩阵半正定到底怎么判断？**你不能真拿"任意方向 h 都满足 $h^T H h \geq 0$ "去穷举，那有无限多个方向。有没有**有限个数的检查**，就能一次判定一个对称矩阵是正定、半正定、还是不定？推导到哪个结论：答案是**二次型与主子式/特征值判据**——对称矩阵 $x^T A x$ 的"符号"（对任意 x 恒正/恒非负/可正可负）决定它正定/半正定/不定；而这件事有两条捷径：**Sylvester 判据**（顺序主子式全正 $\Leftrightarrow$ 正定；所有主子式非负 $\Leftrightarrow$ 半正定）和**特征值判据**（对称矩阵正定 $\Leftrightarrow$ 特征值全正）。再把海森矩阵套进去，就得到一张"判定凸性的决策树"。

核心认知：**凸性判定 = 判断海森矩阵的正定性；判断正定性 = 检查有限个主子式或特征值，不必穷举无限个方向**。这一章把上一章的"海森半正定 $\Leftrightarrow$ 凸"从"定义"落成"可操作的计算流程"，是第 6 章"为什么梯度下降收敛到全局最优"与第 7 章"如何区分鞍点与极值点"的实操工具。

引子

老谟的书桌上摊着一张给小朋友玩的"走迷宫"纸，纸上用铅笔画了几条歪歪扭扭的沟槽。他把一颗玻璃珠放在一条沟槽里，松手。

"你看这条沟，"老谟说，"玻璃珠滚下去，卡在中间那个小坑里了——你觉得它到底了吗？"

"没有，"我凑近看，"旁边还有更低的沟，它只是被小坑卡住，没滚到真正最低的地方。"

"对。那这条'会骗人'的沟，和一条'老实'的沟——玻璃珠一滚到底的沟——**从数学上怎么区分？**上一章我们说了，老实沟对应'凸函数'，海森矩阵要'半正定'。可问题来了：**你总不能拿根尺子去量'每个方向都往上翘'吧？方向有无限多个**。你打算怎么检查一个矩阵"正不正定"？"

我低头看着那颗卡在坑里的玻璃珠，突然觉得它像一个卡在局部最优里出不来的神经网络参数。".....检查无限多个方向？那我得累死。老谟，肯定有更省事的办法吧？"

"有。"老谟把一张空白的表格推过来，"这一章，就是教你**用有限几个数，一次判定一个矩阵的正定性**——顺便把这碗有没有歪坑'这个几何问题，彻底翻译成'矩阵算几个数'的代数问题。"

对话引擎

第 1 轮：海森矩阵正不定，到底是个什么问题

老谟："上一章我们说了：二次可微的 f 是凸函数，当且仅当海森矩阵处处半正定。可'半正定'的定义是'对任意方向 h ， $h^T H h \geq 0$ '——方向有无限多个。你打算怎么验证'无限多个'？"

造物主：".....穷举是不可能的。但我想想， $h^T H h$ 这个式子， h 是个向量， H 是矩阵，乘出来是个数——这玩意儿好像有个专门的名字？它是 h 的**二次型**，对吧？在多元泰勒里见过。"

老谟："你认出来了。 $h^T H h$ 叫**二次型 (quadratic form)**，它是把'一个方向 h '输入进去、吐出一个数的函数。我们要问的是：这个二次型，对**所有**非零 h ，是恒正、恒非负、还是可正可负？这三种情况分别对应矩阵'正定'半正定'不定'。**这一章的核心，就是给这三个词配上'有限个数的判据'**。我们先从二次型本身说起。"

知识锚点：二次型——"把方向输入矩阵，吐出一个数"

【概念深挖】**二次型 (quadratic form)**：设 A 为 $n \times n$ 对称矩阵，对任意 $x \in \mathbb{R}^n$ ，**二次型**为：

$$Q(x) = x^T A x = \sum_i \sum_j A_{ij} x_i x_j$$

展开 ($n=2$)： $Q(x_1, x_2) = A_{11}x_1^2 + 2A_{12}x_1x_2 + A_{22}x_2^2$ (对称矩阵交叉项系数为 $2A_{12}$)。**二次型 = 一个"二次多项式"**，它的系数信息全装在那个对称矩阵 A 里。

为什么对称：交叉项 $A_{12}x_1x_2$ 与 $A_{21}x_2x_1$ 在求和里各出现一次，若 A 对称 ($A_{12}=A_{21}$)，则合并成 $2A_{12}x_1x_2$ 。本书约定 A 对称 (海森矩阵天然对称，克莱罗定理保证)。

【概念深挖】**正定/半正定/负定/不定的定义** (对 $n \times n$ 对称矩阵 A)：

- **正定 (positive definite)**：对任意 $x \neq 0$ ， $x^T A x > 0$ (恒正)；
- **半正定 (positive semidefinite)**：对任意 x ， $x^T A x \geq 0$ (恒非负)；
- **负定**：对任意 $x \neq 0$ ， $x^T A x < 0$ (恒负)；
- **不定 (indefinite)**：存在 x 使 $x^T A x > 0$ ，也存在 y 使 $y^T A y < 0$ (可正可负)。

【工程实践】为什么二次型无处不在？因为它是最简单的"非平凡"函数——二次多项式，它的海森矩阵恰好是那个常数矩阵 A 。任何可微函数在某点附近的"弯曲"，都由海森矩阵 (一个对称矩阵) 给出的二次型描述。所以"理解二次型 = 理解一切光滑函数局部的凹凸"——这是判断凸性、判断极值、判断鞍点的共同地基。

第 2 轮：能不能只看“几个数”——特征值的提示

老谟：“现在正式面对‘怎么判断一个对称矩阵正定’。你手里有定义： $x^T A x > 0$ 对一切 $x \neq 0$ 。这要穷举无限个 x 。但线性代数里，对称矩阵有个特别的‘钥匙’——特征值和特征向量。你还记得吗：对称矩阵可以正交对角化， $A = Q \Lambda Q^T$ ， Λ 是对角线上排着特征值的对角矩阵。”

造物主：“……对！对称矩阵总能正交对角化。那 $x^T A x$ 用 Q 变一下形……设 $y = Q^T x$ ，那 $x^T A x = x^T Q \Lambda Q^T x = (Q^T x)^T \Lambda (Q^T x) = y^T \Lambda y = \sum \lambda_i y_i^2$ 。如果所有特征值 λ_i 都 > 0 ，那 $\sum \lambda_i y_i^2$ 对一切非零 y 恒 > 0 ——正定！”

老谟：“漂亮。你把特征值判据自己推出来了：**对称矩阵正定 $\Leftrightarrow$ 特征值全正；半正定 $\Leftrightarrow$ 特征值全非负；负定 $\Leftrightarrow$ 特征值全负；不定 $\Leftrightarrow$ 有正有负**。特征值是有限个数（ n 个），检查它们就检查完了，不用穷举无限个方向。**可特征值也不总是好算——遇到 3×3 、 4×4 ，解特征多项式要算高次方程的根，麻烦。**有没有更‘只做乘除’的判据？下一轮看。”

知识锚点：特征值判据——“对称矩阵的符号，藏在特征值里”

【概念深挖】特征值判据：设 A 为 $n \times n$ 对称矩阵，特征值为 $\lambda_1, \dots, \lambda_n$ （实数，因为 A 对称），则：

- **A 正定** $\Leftrightarrow$ 所有 $\lambda_i > 0$ ；
- **A 半正定** $\Leftrightarrow$ 所有 $\lambda_i \geq 0$ ；
- **A 负定** $\Leftrightarrow$ 所有 $\lambda_i < 0$ ；
- **A 不定** $\Leftrightarrow$ 特征值中既有正又有负（或有 0 且同时有正负）。

推导核心：对称矩阵 $A = Q \Lambda Q^T$ （正交对角化），则 $x^T A x = y^T \Lambda y = \sum \lambda_i y_i^2$ （ $y = Q^T x$ ）。**二次型的符号完全由特征值的符号决定——这就是特征值判据的来源（严格证明见走廊定理 2）。**

注意：特征值判据适用于**对称矩阵**；非对称矩阵的正定性定义与特征值的关系更微妙，本书只处理对称情形（海森矩阵天然对称）。

【工程实践】特征值判据在数值上是“金标准”：当你需要精确判断一个矩阵正不定，最可靠的办法就是数值库算它的特征值（numpy 的 eigvalsh 专门算对称矩阵特征值）。**工程师常用“最小特征值是否为正”来快速判断正定性——最小特征值 $> 0 \Leftrightarrow$ 正定。**但特征值对数值误差敏感，接近 0 的特征值要小心（可能因舍入从正变负）。

第 3 轮：不想解特征多项式——有没有“只做乘除”的判据

老谟：“特征值判据好归好，可解特征多项式算根，对 3×3 以上就头大。我给你一个只做**乘法和加减**的判据试试。你看这个 2×2 对称矩阵 $\begin{bmatrix} a & b \\ b & c \end{bmatrix}$ 。正定需要什么？”

造物主：".....特征值全正，那判别式 $(a-\lambda)(c-\lambda)-b^2=0$ 的根都 >0等价于 $a>0$ 且 $ac-b^2>0$ ？我猜的。"

老谟："你猜对了，而且这个'猜'里藏着一般规律：**正定 $\Leftrightarrow$ 左上角那个 1×1 主子式 $a>0$ ，且 2×2 整个行列式 $ac-b^2>0$** 。这套'只看左上角一块块的行列式'的办法，叫**主子式判据**。它最妙的地方是——**只做乘除，不用开根解高次方程**。你想不想看看它在 3×3 上怎么推广？"

造物主：".....推广？那是不是看左上角 1×1 、 2×2 、 3×3 三个主子式，都 >0 就正定？"

老谟："你先把这个猜测记住，这一章后半段我们来验证它到底对不对、以及它的坑在哪。**现在我们先敲定：判断正定，有两条路——特征值（精确但费算）、主子式（省算但要小心边界）**。下一轮，我们用具体的函数，把'海森矩阵'和'凸性结论'真正连起来。"

知识锚点：主子式与 Sylvester 判据——"只做乘除，一招定正定"

【概念深挖】主子式与顺序主子式：

- 对 $n\times n$ 矩阵 A ，取第 $i_1, \dots, i_k$ 行和**同样编号**的列形成的子矩阵，其行列式叫**主子式 (principal minor)**。
- 取前 k 行、前 k 列（即左上角 $k\times k$ 块）的行列式，叫**顺序主子式 (leading principal minor)**，记为 Δ_k 。

Sylvester 判据：

- 正定 $\Leftrightarrow$ 所有顺序主子式全 >0 ($\Delta_1>0, \Delta_2>0, \dots, \Delta_n>0$)；**
- 半正定 $\Leftrightarrow$ 所有主子式 ≥ 0** （注意是"所有"主子式，不只是顺序的——这是半正定和正定判据的差别，也是最容易踩的坑）。

例 (2×2)： $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ ： $\Delta_1 = 2 > 0$ ， $\Delta_2 = \det = 4 - 1 = 3 > 0$ ，正定 $\checkmark$ 。

【历史溯源】**Sylvester 判据**以英国数学家**詹姆斯·约瑟夫·西尔维斯特 (James Joseph Sylvester, 1814–1897) **命名。他在 19 世纪研究二次型的化简与惯性时，给出了"正定二次型的系数矩阵顺序主子式全正"这个判据。**西尔维斯特一生多产，和凯莱 (Cayley) 共同发展了矩阵论——而矩阵论正是本章所有判据的语言载体。**

【工程实践】**主子式判据是"手算正定"的主力**：因为只做加减乘除（行列式），不需要开方、不需要解高次方程，特别适合快速手判 2×2 、 3×3 的海森矩阵。**机器学习的凸性检查常先用主子式快速筛查**，出问题再上特征值精算。**但要注意：半正定要看"所有"主子式，漏掉一个交叉主子式就可能误判。**

第 4 轮：三个函数，三种命运——正定、不定、半正定

老谟："判据有了。现在我们用三个具体的海森矩阵，把'正定/不定/半正定'和'凸不凸'真正对上号。第一个： $f(x,y) = x^2 + xy + y^2$ ，它的海森矩阵 $H = [[2,1],[1,2]]$ 。你先用主子式判据说它正定吗？"

造物主："..... $\Delta_1 = 2 > 0$ ， $\Delta_2 = \det([[2,1],[1,2]]) = 2 \cdot 2 - 1 \cdot 1 = 3 > 0$ 。两个顺序主子式都正，**正定**！所以 f 是严格凸的。"

老谟："对。第二个： $f(x,y) = x^2 - y^2$ ，海森 $H = [[2,0],[0,-2]]$ 。 $\Delta_1 = 2 > 0$ ，但 $\Delta_2 = \det = 2 \cdot (-2) - 0 = -4 < 0$ 。你说，这是什么？"

造物主："..... $\Delta_2 < 0$ ，不是正定。特征值 2 和 -2，一正一负——**不定**！所以这个函数不是凸的，它是个马鞍形状。"

老谟："你自己把'鞍'说出来了——这个形状正是第 7 章的主角。第三个： $f(x,y) = x^2$ ，海森 $H = [[2,0],[0,0]]$ 。 $\Delta_1 = 2 > 0$ ，但 $\Delta_2 = \det = 2 \cdot 0 - 0 = 0$ 。这算什么？"

造物主："..... $\Delta_2 = 0$ ，不是正定（正定要求全 > 0 ）。但特征值 2 和 0，都 ≥ 0 ——**半正定**！所以 f 是凸的，但不是严格凸。"

老谟："完美。你现在亲手把三种命运摸出来了：**正定（严格凸）、不定（非凸，鞍）、半正定（凸但不严格）**。这三个例子是本章的计算训练场主角，也是你判断一切海森矩阵的模板。下一轮，我们把这套东西收成一张'判定树'。"

知识锚点：三个模板——正定 / 不定 / 半正定

【概念深挖】三个被用作模板的 2×2 海森矩阵（蓝图指定，务必记牢）：

函数	海森 H	主子式	特征值	判定	凸性
$f = x^2+xy+y^2$	$[[2,1],[1,2]]$	$\Delta_1=2>0, \Delta_2=3>0$	1, 3（全正）	正定	严格凸
$f = x^2-y^2$	$[[2,0],[0,-2]]$	$\Delta_1=2>0, \Delta_2=-4<0$	2, -2（有正有负）	不定	非凸（鞍）
$f = x^2$	$[[2,0],[0,0]]$	$\Delta_1=2>0, \Delta_2=0$	2, 0（非负）	半正定	凸但不严格

关键区分：

- **正定**： $\Delta_1>0$ 且 $\Delta_2>0$ （特征值全正）→ 严格凸，唯一全局极小；
- **半正定**： $\Delta_2=0$ 但特征值全非负 → 凸但不严格，有"平底"（沿某方向函数不变）；
- **不定**： $\Delta_2<0$ （特征值有正有负）→ 非凸，驻点是鞍点。

【工程实践】这三个模板对应真实损失面：**MSE 的海森正定**（凸，训练稳）；**某些带交叉项的损失海森不定**（有鞍点，梯度下降会"迷路"）；**沿某方向平坦的损失海森半正定**（凸但有退化方向，收敛

慢)。“算海森看正定/半正定/不定”是工程里判断“这面好不好优化”的快筛。

第 5 轮：正定判据 vs 凸性——海森“处处”半正定才是凸

老谟：“判据你都摸出来了。可我得提醒你一个上一章就埋下的坑：**二阶刻画说‘海森矩阵处处半正定 $\Leftrightarrow f$ 凸’——是‘处处’，不是‘某一点’。**你怎么理解‘处处’这个词？”

造物主：“……‘处处’就是……定义域里每个点都要检查？不能只看一个点的海森就说整个函数凸？”


老谟：“对。一个函数可能在某个点局部凸（那点的海森正定），但整体不凸。所以判断‘整个函数凸不凸’，理论上要在定义域的**所有点**检查海森半正定。不过对**二次函数**（ $f = x^T A x + b^T x + c$ 这种），海森矩阵是**常数**，处处一样——所以只看一个点的海森就够了。**这是二次函数最可爱的地方。**那你说，一般函数呢？”

造物主：“……一般函数海森随点变，得检查每个点……听起来累，但至少比穷举无限个方向强多了。而且工程里很多目标函数要么是二次的（海森常数），要么海森符号在各处相对稳定。”

老谟：“正是。判断凸性有个递进：**先看它是不是二次函数（海森常数，一次搞定）；不是就检查关键区域的海森符号。**我们把这一整套，收成一张判定树。”

知识锚点：凸性判定流程——判定树

【概念深挖】凸性判定决策树（本章核心可操作流程）：



读图说明：这张判定树从“可微性”分叉——不可微函数（ReLU、绝对值）只能退回定义验证（第 04 章的方法）；可微函数算海森，检查“是否处处半正定”；半正定 → 凸，不正定 → 非凸。**其中最关键的一步是“判断海森是否半正定”——这正是本章的主子式/特征值判据要解决的事。**

【工程实践】判定树是工程师的“凸性快筛流程”：拿到一个损失函数，先问能不能直接看出是二次的（海森常数），是就一次算完；不是就取几个代表性点算海森看符号是否稳定。**这套流程把“凸不凸”从抽象概念变成可执行的检查清单——这就是凸优化为什么能落地的原因：判定凸性是有确定算法的，不是玄学。**

第 6 轮：Sylvester 判据的坑——半正定要看“所有”主子式

老谟：“主子式判据好用，但它有个阴险的坑，我得专门拿出来。正定判据是‘顺序主子式全正’；可**半正定**判据，是‘**所有**主子式非负’——注意，是‘所有’，不只是顺序的。你猜猜，为什么这里差别这么大？”

造物主：“.....半正定要看所有主子式？难道顺序主子式全非负还不够？”

老谟：“我举个反例。A = [[0,0],[0,-1]]：顺序主子式 $\Delta_1 = 0$, $\Delta_2 = \det = 0$ 。**顺序主子式全非负！**可 A 的第二个对角元是 -1，取 $x = (0,1)$, $x^T A x = -1 < 0$ ——**它根本不是半正定！**你看，漏掉‘交叉主

主子式' (这里是右下角 1×1 主子式 $\det[-1] = -1 < 0$) 就误判了。"

造物主: ".....所以半正定必须检查所有主子式, 包括那些不在左上角的。这个坑真阴险。"

老谟: "对。正定因为'所有顺序主子式全正'会顺带逼出所有主子式都正, 所以只看顺序的够了; 可半正定允许出现 0, 0 让'顺序全非负'失去了对'其他位置'的控制。这就是为什么工程里判断半正定, 最稳妥还是用特征值 (全非负) ——主子式对半正定要数全所有主子式, 容易漏。你把这个坑记死。"

知识锚点: 主子式判据的边界——半正定的坑

【概念深挖】为什么半正定不能只看顺序主子式: 正定时"顺序主子式全正"足够, 因为一旦顺序主子式全正, 其余主子式也自动全正。但半正定允许主子式为 0, 此时"顺序主子式全非负"无法保证"非顺序的主子式"也非负。反例 $A = \begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix}$: 顺序主子式 0、0 全非负, 但右下角主子式 $-1 < 0$, 矩阵不半正定。

正确做法:

- 判断**正定**: 顺序主子式全 > 0 (省力);
- 判断**半正定**: 检查**所有**主子式 ≥ 0 , 或直接看特征值全 ≥ 0 (最稳妥)。

【工程实践】工程里判断半正定优先用特征值 (数值库 eigvalsh 直接给对称矩阵特征值, 检查最小特征值 ≥ 0)。主子式判据适合手算正定, 但手算半正定容易漏——因为它要数"所有"主子式, 2×2 有 3 个主子式、 3×3 有 7 个, 漏一个就误判。判断"是不是凸"这种影响训练成败的事, 值得用最稳的特征值判据。

第 7 轮: 落点——从"量歪坑的尺子"到"一张判定树"

老谟: "把迷宫纸收起来。你现在回答我最初那个问题: '怎么判断这碗有没有歪坑'——把完整的工具链给我说一遍。"

造物主: "先看能不能用二阶刻画——能的话就检查海森矩阵。海森正不正定, 有两条路: **特征值判据** (对称矩阵特征值全正 $\Leftrightarrow$ 正定, 全非负 $\Leftrightarrow$ 半正定) 和 **Sylvester 主子式判据** (顺序主子式全正 $\Leftrightarrow$ 正定; 半正定要看所有主子式非负)。然后套回凸性: 海森处处半正定 $\Leftrightarrow$ 凸, 处处正定 $\Leftrightarrow$ 严格凸, 不定 $\Leftrightarrow$ 非凸 (驻点是鞍点)。整套就是一张判定树。"

老谟: "你自己把'歪坑检测'做成了流水线。而且你有没有发现: 这一章说的'正定/半正定/不定', 正好预告了三种命运——正定的碗一滑到底 (全局最优), 不定的马鞍会卡人 (鞍点, 第 7 章主角), 半正定的碗有平底但不会骗人 (凸但有退化方向)。你先把这个'二阶导符号 $\Leftrightarrow$ 碗的形状 $\Leftrightarrow$ 优化难度'的对应关系焊死, 下一章, 我们带着这把尺子正式下山——梯度下降, 然后证明它凭什么能到谷底。"

严格化走廊

位置说明：本章对话负责"直觉"——为什么特征值判符号、为什么主子式省算、半正定的坑在哪。本走廊负责"严谨"——把二次型、正定/半正定、Sylvester 判据、特征值判据写成精确的定义与定理，并给出可复写的证明。下面每一行，读者都能对着空白纸重写一遍。

关于对话的口径说明

对话里"特征值全正 $\Leftrightarrow$ 正定" "顺序主子式全正" "半正定要看所有主子式" 都是直觉引导。本走廊把正定性判据落成严格形式：定义 1（二次型）、定义 2（正定/半正定/负定/不定）、定理 1（一阶凸性刻画，用定义+中值定理，补全第 04 章）、定理 2（特征值判据）、定理 3（Sylvester 主子式判据，归纳证明）。读者应把对话当"为什么要这样想"，把本走廊当"为什么这样想是对的"。

定义 1：二次型 (quadratic form)

设 A 为 $n \times n$ 对称矩阵。二次型是函数 $Q: \mathbb{R}^n \rightarrow \mathbb{R}$ ，定义为：

$$Q(x) = x^T A x = \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j$$

(因 A 对称，展开时交叉项 $x_i x_j$ 与 $x_j x_i$ 合并为 $2A_{ij}x_i x_j$ 。)

定义 2：正定 / 半正定 / 负定 / 不定

设 A 为 $n \times n$ 对称矩阵。

- **A 正定**：对任意 $x \neq 0$ ， $x^T A x > 0$ ；
- **A 半正定**：对任意 x ， $x^T A x \geq 0$ ；
- **A 负定**：对任意 $x \neq 0$ ， $x^T A x < 0$ ；
- **A 不定**：存在 x 使 $x^T A x > 0$ ，且存在 y 使 $y^T A y < 0$ 。

定理 1（一阶凸性刻画，补全）：设 f 在凸集 $C \subseteq \mathbb{R}^n$ 上可微。则 f 凸，当且仅当对任意 $x, y \in C$ ：

$$f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$$

证明（可复写，用定义 + 中值定理）：

- "凸 $\Rightarrow$ 不等式"：

- 第 1 步：对 $\lambda \in (0,1)$ ，由凸性定义： $f(\lambda y + (1-\lambda)x) \leq \lambda f(y) + (1-\lambda)f(x)$ 。（依据：第 04 章定义 2。）
- 第 2 步：设 $g(\lambda) = f(\lambda y + (1-\lambda)x)$ ，则 g 在 $[0,1]$ 上可微（ f 可微、复合函数可微，依据第 02 章链式法则）。由第 1 步， $g(\lambda) \leq \lambda g(1) + (1-\lambda)g(0)$ ，即 $g(\lambda) - g(0) \leq \lambda(g(1) - g(0))$ 。（依据：代入 g 的记号。）
- 第 3 步：两边除以 λ ($\lambda > 0$) 取 $\lambda \rightarrow 0^+$ ： $(g(\lambda) - g(0))/\lambda \rightarrow g'(0)$ （依据：导数定义）；右端 $\rightarrow g(1) - g(0)$ 。故 $g'(0) \leq g(1) - g(0)$ 。（依据：极限保号性。）
- 第 4 步： $g'(0) = \nabla f(x) \cdot (y-x)$ （依据：链式法则， $g'(\lambda) = \nabla f(\lambda y + (1-\lambda)x) \cdot (y-x)$ ）。 $g(1) - g(0) = f(y) - f(x)$ 。代入得 $\nabla f(x) \cdot (y-x) \leq f(y) - f(x)$ ，即 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ 。■

• "不等式 $\Rightarrow$ 凸"：

- 第 5 步：设 $z = \lambda x + (1-\lambda)y$ 。由假设： $f(x) \geq f(z) + \nabla f(z) \cdot (x-z)$ ， $f(y) \geq f(z) + \nabla f(z) \cdot (y-z)$ 。（依据：假设的不等式。）
- 第 6 步： $\lambda f(x) + (1-\lambda)f(y) \geq f(z) + \nabla f(z) \cdot [\lambda(x-z) + (1-\lambda)(y-z)]$ 。（依据：线性组合。）
- 第 7 步： $\lambda(x-z) + (1-\lambda)(y-z) = \lambda x + (1-\lambda)y - z = z - z = 0$ 。（依据： z 的定义。）
- 第 8 步：故 $\lambda f(x) + (1-\lambda)f(y) \geq f(z) = f(\lambda x + (1-\lambda)y)$ ，凸性成立。■

证明要点标注：前四步用凸性定义、一维化技巧（沿线段限制成 $g(\lambda)$ ）、导数定义与极限保号性、链式法则；后四步用假设不等式、线性组合与 z 的定义。本题是蓝图指定证明，也是梯度下降收敛性分析的基础工具。

定理 2（特征值判据）：设 A 为 $n \times n$ 对称矩阵，特征值 $\lambda_1, \dots, \lambda_n$ 。则：

- A 正定 $\Leftrightarrow$ 所有 $\lambda_i > 0$ ；
- A 半正定 $\Leftrightarrow$ 所有 $\lambda_i \geq 0$ ；
- A 负定 $\Leftrightarrow$ 所有 $\lambda_i < 0$ ；
- A 不定 $\Leftrightarrow$ 特征值中既有正又有负（或含 0 且同时有正负）。

证明（可复写，用正交对角化）：

- 第 1 步：因 A 对称， A 可正交对角化： $A = Q\Lambda Q^T$ ，其中 Q 正交 ($Q^T Q = I$)， $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 。（依据：实对称矩阵正交对角化定理。）
- 第 2 步：对任意 x ，设 $y = Q^T x$ 。则 $x^T A x = (Qy)^T A (Qy) = y^T Q^T A Q y = y^T \Lambda y = \sum_i \lambda_i y_i^2$ 。（依据：代入 $x = Qy$ 与 $A = Q\Lambda Q^T$ 。）
- 第 3 步：因 Q 正交， $x \mapsto y = Q^T x$ 是双射（对任意 y 存在 $x = Qy$ ）。故 " $x^T A x$ 对一切 $x \neq 0$ 的符号"等价于 " $\sum \lambda_i y_i^2$ 对一切 $y \neq 0$ 的符号"。（依据： Q 的可逆性。）

- 第 4 步：若所有 $\lambda_i > 0$ ，则 $\sum \lambda_i y_i^2 > 0$ 对一切 $y \neq 0$ ，正定；反之若 A 正定，取 y 为第 k 个标准基向量 ($y_i^k = \delta_{ik}$)，则 $\sum \lambda_i (y_i^k)^2 = \lambda_k > 0$ ，故每个 $\lambda_k > 0$ 。其余情形（半正定/负定/不定）同理。■

证明要点标注：第 1 步用**实对称矩阵正交对角化定理**；第 2 步用**二次型定义与正交矩阵性质 $Q^T Q = I$** ；第 3 步用 **Q 可逆（双射）**；第 4 步用**标准基向量取特殊 y 与 $\sum \lambda_i y_i^2$ 的符号结构**。

定理 3 (Sylvester 主子式判据)：设 A 为 $n \times n$ 对称矩阵， Δ_k 为前 k 行前 k 列的顺序主子式。则：

- A 正定 $\Leftrightarrow \Delta_1 > 0, \Delta_2 > 0, \dots, \Delta_n > 0$ （所有顺序主子式全正）。

证明（可复写，数学归纳法）：

- **基础情形 ($n=1$)：** $A = [a_{11}]$ ， $x^T A x = a_{11} x_1^2$ 。正定 $\Leftrightarrow a_{11} > 0$ ，即 $\Delta_1 > 0$ 。成立。（依据：定义 2 与二次型定义。）
- **归纳假设：**设对 $(n-1) \times (n-1)$ 对称矩阵，命题成立。
- **归纳步 (n)：**把 A 分块为：

$$A = \begin{bmatrix} A_{11} & v \\ v^T & a_{nn} \end{bmatrix}$$

其中 A_{11} 是前 $(n-1) \times (n-1)$ 块， $v \in \mathbb{R}^{n-1}$ 。

- 第 1 步：若 A 正定，则对任意非零 $z \in \mathbb{R}^{n-1}$ ，取 $x = (z, 0)$ ， $x^T A x = z^T A_{11} z > 0$ ，故 A_{11} 正定；由归纳假设， A_{11} 的前 k 个顺序主子式 ($k=1, \dots, n-1$) 全正，即 $\Delta_1, \dots, \Delta_{n-1} > 0$ 。（依据：正定定义限制到子空间 + 归纳假设。）
- 第 2 步：还需证 $\Delta_n = \det A > 0$ 。因 A 正定， A 的特征值全正（定理 2）， $\det A = \prod \lambda_i > 0$ 。故 $\Delta_n > 0$ 。（依据：定理 2 + 行列式 = 特征值乘积。）
- 第 3 步：故“正定 $\Rightarrow$ 顺序主子式全正”。
- 第 4 步（反方向）：设 $\Delta_1, \dots, \Delta_n > 0$ 。先证 A_{11} 顺序主子式全正（它们就是 $\Delta_1, \dots, \Delta_{n-1}$ ），由归纳假设 A_{11} 正定。（依据：归纳假设。）
- 第 5 步：因 A_{11} 正定可逆，作分块的高斯消元（Schur 补）：存在下三角矩阵 L 、 D 使 $A = LDL^T$ ，其中 $D = \text{diag}(d_1, \dots, d_n)$ ，且 $\det A = d_1 d_2 \dots d_n$ ，而 $\Delta_k = d_1 d_2 \dots d_k$ 。（依据：对称矩阵的 LDL^T 分解。）
- 第 6 步：由 $\Delta_k > 0$ ($k=1, \dots, n$)，得 $d_k = \Delta_k / \Delta_{k-1} > 0$ （记 $\Delta_0 = 1$ ），故 D 对角元全正。（依据：顺序主子式与 LDL^T 的关系。）
- 第 7 步：对任意 $x \neq 0$ ， $x^T A x = (L^T x)^T D (L^T x) = \sum_k d_k (L^T x)_k^2 > 0$ （因 $d_k > 0$ 且 $L^T x \neq 0$ —— L 可逆、 $x \neq 0$ ）。（依据： LDL^T 分解 + 对角元全正 + L 可逆。）

- 第 8 步：故 A 正定。归纳完成。■

证明要点标注：基础情形用**定义 2**；归纳步前向用**正定限制到子空间 + 归纳假设 + 特征值乘积**；反向用**归纳假设 (A_{11} 正定) + LDL^T 分解 (Schur 补) + 顺序主子式与对角元关系 + 可逆性**。本题是蓝图指定证明，用的是“分块 + 数学归纳法”的标准路线。

反例/边界

- **半正定判据的坑：** $A = \begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix}$ ：顺序主子式 $\Delta_1=0$ 、 $\Delta_2=0$ 全非负，但矩阵不半正定（取 $x=(0,1)$ ， $x^T A x = -1$ ）。故**半正定不能只看顺序主子式，要看所有主子式或特征值**。
- **非对称矩阵的特征值判据失效：**特征值判据要求 A 对称。非对称矩阵 $A = \begin{bmatrix} 1 & 100 \\ 0 & 1 \end{bmatrix}$ 特征值全 1（正），但 $x^T A x$ 可正可负（取 $x=(1,-1)$ ： $x^T A x = 1 - 100 + 1 = -98 < 0$ ），**并非正定**。所以“**特征值全正**”只对对称矩阵等价于**正定**。
- **二阶刻画的“处处”边界：**海森矩阵在某一点半正定只能说明“局部凸”，不能推出整个函数凸。二次函数（海森常数）是例外——一处正定则处处正定。**判断一般函数凸性要在定义域所有点检查海森**。
- **正定 vs 严格凸的边界：**正定（ H 处处正定） $\rightarrow$ 严格凸；但半正定（允许某方向 $h^T H h = 0$ ） $\rightarrow$ 只是凸不严格，函数沿该退化方向“平”（如 $f = x^2$ 沿 y 方向函数值不变）。

知识点总结

知识点（本章推出的核心概念）

- **二次型 $x^T A x$ ：**把方向 x 输入对称矩阵 A ，吐出一个二次多项式；它是“光滑函数局部的凹凸”的统一语言。
- **正定/半正定/负定/不定：** $x^T A x$ 对一切 x 恒正/恒非负/恒负/可正可负。
- **特征值判据：**对称矩阵正定 $\Leftrightarrow$ 特征值全正；半正定 $\Leftrightarrow$ 全非负；负定 $\Leftrightarrow$ 全负；不定 $\Leftrightarrow$ 有正有负（推导靠正交对角化 $A = Q \Lambda Q^T$ ）。
- **主子式 / Sylvester 判据：**正定 $\Leftrightarrow$ 所有顺序主子式全正；半正定 $\Leftrightarrow$ 所有主子式非负（不能只看顺序的！）。
- **凸性判定流程（判定树）：**不可微 $\rightarrow$ 退回定义验证；可微 $\rightarrow$ 检查海森是否处处半正定；二次函数海森常数，检查一次即可。
- **三个模板：** x^2+xy+y^2 正定（严格凸）、 x^2-y^2 不定（鞍）、 x^2 半正定（凸但不严格）。
- **海森“处处”半正定 $\Leftrightarrow$ 凸：**判断凸性是整体性质，不能只看一个点（二次函数除外）。

历史结论（本章涉及的史料）

- **西尔维斯特 (James Joseph Sylvester, 1814–1897)**：19 世纪研究二次型化简与惯性时给出"正定 $\Leftrightarrow$ 顺序主子式全正" (Sylvester 判据)；他与凯莱 (Cayley) 共同发展矩阵论。
- **特征值视角**：对称矩阵正交对角化 (谱定理) 保证特征值为实，是特征值判据的根基；谱定理的严格化由柯西、韦尔等完成。
- **凸性判定工具化**：把"海森半正定 $\Leftrightarrow$ 凸" (第 04 章, Jensen 一脉) 与"正定判据" (西尔维斯特一脉) 接起来，构成现代凸优化 (Rockafellar 《Convex Analysis》体系) 的实操工具箱。

工程实践结论（本章知识在真实工程里怎么用）

- **凸性快筛**：算海森看正定/半正定/不定，是判断"这损失好不好优化"的标准动作 (MSE 正定、深度网络不定)。
- **特征值判据最稳**：数值库 eigvalsh 直接给对称矩阵特征值，检查最小特征值符号；主子式适合手算正定，但算半正定易漏。
- **鞍点预警**：海森不定 $\rightarrow$ 驻点是鞍点，梯度下降会"迷路"——这正是第 7 章"深度学习怕鞍点不怕浅坑"的数学根源。
- **凸 = 可证明收敛**：只有凸目标 (海森半正定) 才保证"找到稳定点即全局最优"，这是传统 ML 与深度学习的可证明性分水岭。

计算训练场

位置说明：本章对话负责"为什么"，这里负责"怎么算"。每题请动笔 10 分钟以上，先自己写，再对照完整解答。禁止边算边翻答案。

题 1（易 $\rightarrow$ 中）：求海森并用主子式判定——三个模板

题干：对以下三个函数，求海森矩阵，用主子式判据判断正定/半正定/不定，并给出凸性结论：(a) $f(x,y) = x^2 + xy + y^2$ 。(b) $f(x,y) = x^2 - y^2$ 。(c) $f(x,y) = x^2$ 。

完整分步解答：

(a) $f = x^2+xy+y^2$ ：第 1 步：一阶偏导 $f_x = 2x+y$, $f_y = x+2y$ 。（规则：偏导。）第 2 步：二阶偏导 $f_{xx} = 2$, $f_{xy} = 1$, $f_{yy} = 2$, 故 $H = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 。（规则：二阶偏导，H 对称。）第 3 步：主子式 $\Delta_1 = 2 > 0$ 。（规则：1 $\times$ 1 顺序主子式。）第 4 步： $\Delta_2 = \det(\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}) = 2\cdot 2 - 1\cdot 1 = 3 > 0$ 。（规则：2 $\times$ 2 行列式 = ad-bc。）第 5 步：顺序主子式全正 $\Rightarrow$ **正定**, **f 严格凸**。（规则：Sylvester 判据。）

(b) $f = x^2 - y^2$: 第 6 步: $f_x = 2x$, $f_y = -2y$; $f_{xx} = 2$, $f_{xy} = 0$, $f_{yy} = -2$, $H = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$ 。(规则: 偏导。) 第 7 步: $\Delta_1 = 2 > 0$ 。(规则: 1×1 主子式。) 第 8 步: $\Delta_2 = \det(\begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}) = 2 \cdot (-2) - 0 = -4 < 0$ 。(规则: 2×2 行列式。) 第 9 步: 因 $\Delta_2 < 0$ (顺序主子式不满足全正), 且特征值 2、-2 一正一负 $\Rightarrow$ **不定**, f **非凸** (驻点是鞍点)。(规则: 特征值判据/不定定义。)

(c) $f = x^2$: 第 10 步: $f_x = 2x$, $f_y = 0$; $f_{xx} = 2$, $f_{xy} = 0$, $f_{yy} = 0$, $H = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}$ 。(规则: 偏导。) 第 11 步: $\Delta_1 = 2 > 0$, $\Delta_2 = \det(\begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}) = 0$ 。(规则: 2×2 行列式 = 0。) 第 12 步: $\Delta_2 = 0$ 不满足"全正" (正定要求全 > 0) , 但特征值 2、0 全非负 $\Rightarrow$ **半正定**, f **凸但不严格**。(规则: 特征值判据——全非负即半正定。)

答: (a) 正定, 严格凸; (b) 不定, 非凸 (鞍) ; (c) 半正定, 凸但不严格。

常见错误: ① 求二阶偏导时把 f_{xy} 算错 (如 $f=xy$ 的 $f_{xy}=1$, 有人误算成 0) ; ② 行列式符号错—— $\det(\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix})=4-1=3$, 有人算成 $4+1=5$; ③ 把 (b) 的 $\Delta_2 < 0$ 误判成"负定", 忘了"不定"才是 (特征值一正一负, 非全负) 。

题 2 (中) : 特征值判据 vs 主子式判据——双通道互证

题干: 设 $f(x,y,z) = x^2 + y^2 + 2z^2 + 2xy$ (含交叉项的三元函数)。(a) 求海森矩阵 H (3×3)。(b) 用特征值判据判断 H 的正定性。(c) 用主子式判据 (顺序主子式) 重判, 验证与 (b) 一致。

完整分步解答:

(a) 海森矩阵: 第 1 步: 一阶偏导 $f_x = 2x+2y$, $f_y = 2y+2x$, $f_z = 4z$ 。(规则: 偏导。) 第 2 步: 二阶偏导 $f_{xx} = 2$, $f_{yy} = 2$, $f_{zz} = 4$, $f_{xy} = 2$, $f_{xz} = 0$, $f_{yz} = 0$ 。(规则: 二阶偏导。) 第 3 步: $H = \begin{bmatrix} 2 & 2 & 0 \\ 2 & 2 & 0 \\ 0 & 0 & 4 \end{bmatrix}$ 。(规则: 对称矩阵组装。)

(b) 特征值判据: 第 4 步: 特征多项式 $\det(H - \lambda I) = 0$ 。先看左上 2×2 块 $\begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$ 的特征值: $\det(\begin{bmatrix} 2-\lambda & 2 \\ 2 & 2-\lambda \end{bmatrix}) = (2-\lambda)^2 - 4 = \lambda^2 - 4\lambda = \lambda(\lambda - 4) = 0$, 得 $\lambda = 0, 4$ 。(规则: 2×2 特征多项式。) 第 5 步: 3×3 的 H 是块对角 (右下角对角元 4, 与 2×2 块不耦合), 故特征值为 **0、4、4**。(规则: 块对角矩阵特征值 = 各块特征值。) 第 6 步: 特征值含 0 但都 ≥ 0 (0、4、4) $\Rightarrow$ **半正定**, f **凸但不严格**。(规则: 特征值判据——全非负即半正定。)

(c) 主子式判据: 第 7 步: $\Delta_1 = \det[2] = 2 > 0$ 。(规则: 1×1 主子式。) 第 8 步: $\Delta_2 = \det(\begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}) = 4 - 4 = 0$ 。(规则: 2×2 行列式。) 第 9 步: $\Delta_3 = \det(H) = \det(\begin{bmatrix} 2 & 2 & 0 \\ 2 & 2 & 0 \\ 0 & 0 & 4 \end{bmatrix}) = 4 \cdot \det(\begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}) = 4 \cdot 0 = 0$ 。(规则: 按第三行展开, $\det=4 \times 0=0$ 。) 第 10 步: 顺序主子式 $\Delta_1=2>0$ 、 $\Delta_2=0$ 、 $\Delta_3=0$, 不全正 $\Rightarrow$ 不是正定; 因顺序主子式都 ≥ 0 且 $\Delta_1>0$, 需进一步判断半正定——看所有主子式: 对角线主子式 $\det[2]=2$ 、 $\det[2]=2$ 、 $\det[4]=4$ 都非负, 交叉主子式 $\det\begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}=8$ 、 $\det\begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}=8$ 、 $\det\begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}=0$ 都非负 $\Rightarrow$ **半正定**。(规则: 半正定看所有主子式非负。)

答：(a) $H = \begin{bmatrix} 2 & 2 & 0 \\ 2 & 2 & 0 \\ 0 & 0 & 4 \end{bmatrix}$; (b) 特征值 0、4、4，半正定；(c) 顺序主子式 2、0、0（非全正），但所有主子式非负，半正定 $\checkmark$ 与 (b) 一致。

常见错误：① 求特征值时忘了 H 是块对角，硬解 3×3 特征多项式算错；② 把 $\Delta_2=0$ 误判成“不定”—— $\Delta_2=0$ 既可能是半正定也可能是负定，要看特征值或所有主子式；③ 判断半正定时只列顺序主子式（2、0、0 全非负）就下结论——**好在这次顺序的全非负碰巧对，但严格讲要看所有主子式（本例额外核对了交叉主子式才坐实半正定）。**

题 3（中→难）：含参海森——参数如何影响凸性

题干：设 $f(x,y) = x^2 + axy + y^2$ ，其中 a 是参数。(a) 求海森矩阵 $H(a)$ 。(b) 用主子式/特征值分析： a 取何值时 f 正定（严格凸）、半正定、不定？(c) 特别地，验证 $a=1$ 时正定（对应模板 x^2+xy+y^2 ）， $a=2$ 时半正定， $a=3$ 时不定。

完整分步解答：

(a) 海森矩阵：第 1 步： $f_x = 2x+ay$, $f_y = ax+2y$; $f_{xx} = 2$, $f_{xy} = a$, $f_{yy} = 2$ 。（规则：偏导，交叉项 $f_{xy}=a$ 。）第 2 步： $H(a) = \begin{bmatrix} 2 & a \\ a & 2 \end{bmatrix}$ 。（规则：对称矩阵。）

(b) 正定性随 a 变化：第 3 步： $\Delta_1 = 2 > 0$ 恒成立。（规则： 1×1 主子式。）第 4 步： $\Delta_2 = \det(\begin{bmatrix} 2 & a \\ a & 2 \end{bmatrix}) = 4 - a^2$ 。（规则： 2×2 行列式。）第 5 步：正定需 $\Delta_2 > 0$ ，即 $4 - a^2 > 0$ ，即 $|a| < 2$ （严格凸）。（规则：Sylvester 判据——顺序主子式全正。）第 6 步：半正定需特征值全 ≥ 0 。特征值： $\det(\begin{bmatrix} 2-\lambda & a \\ a & 2-\lambda \end{bmatrix}) = (2-\lambda)^2 - a^2 = 0 \rightarrow \lambda = 2 \pm a$ 。全 $\geq 0 \Leftrightarrow 2-a \geq 0 \Leftrightarrow a \leq 2$ （且 $2+a \geq 0$ 恒成立，因 $a \geq -2$ 时 $2+a \geq 0$ ；综合 $|a| \leq 2$ 时特征值 $2 \pm a \geq 0$ ）。（规则：特征值判据。）第 7 步：不定 $\Leftrightarrow$ 特征值一正一负 $\Leftrightarrow 2-a < 0 \Leftrightarrow a > 2$ （此时 $2-a < 0$, $2+a > 0$ ）。（规则：特征值判据。）

(c) 特例验证：第 8 步： $a=1$: $\Delta_2 = 4-1 = 3 > 0$ ，正定 $\checkmark$ （对应模板 x^2+xy+y^2 正定）。（规则：Sylvester。）第 9 步： $a=2$: $\Delta_2 = 4-4 = 0$ ，特征值 $2-2=0$ 、 $2+2=4$ 全非负，半正定 $\checkmark$ ($H = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$ ，同题 2)。（规则：特征值。）第 10 步： $a=3$: $\Delta_2 = 4-9 = -5 < 0$ ，特征值 $2-3=-1$ 、 $2+3=5$ 一正一负，不定 $\checkmark$ 。（规则：特征值。）

答：(a) $H(a) = \begin{bmatrix} 2 & a \\ a & 2 \end{bmatrix}$; (b) $|a| < 2$ 正定（严格凸）， $|a| \leq 2$ 半正定（凸但不严格）， $a > 2$ 或 $a < -2$ 不定（非凸）；(c) $a=1$ 正定、 $a=2$ 半正定、 $a=3$ 不定 $\checkmark$ 。

常见错误：① 求 f_{xy} 时漏了“交叉项 axy 对 x 求偏导得 ay 、再对 y 求偏导得 a ”，误写成 $2a$ 或 0 ；② 判定半正定边界时只看了 $a \leq 2$ 忘了 $a \geq -2$ 的限制（特征值 $2+a$ 也要 ≥ 0 ）；③ 把“ $a=2$ 时半正定”和“ $a=2$ 时正定”混淆——**半正定是闭的 (≤ 2)，正定是开的 (< 2)。**

向导便签

这一章咱们干了什么：从"怎么判断海森矩阵正不定"这个问题出发，定义了二次型 $x^T A x$ 和正定/半正定/不定；给出了两条判据——**特征值判据**（对称矩阵特征值全正 $\Leftrightarrow$ 正定）和**Sylvester 主子式判据**（顺序主子式全正 $\Leftrightarrow$ 正定，半正定看所有主子式）；并把它们套进海森矩阵，形成一张"凸性判定决策树"。

钉死一句话：**海森矩阵处处半正定 $\Leftrightarrow$ 凸函数；判断半正定最稳走特征值，手算正定走顺序主子式。**
正定 $\rightarrow$ 严格凸（一滑到底），半正定 $\rightarrow$ 凸（有平底但不会骗人），不定 $\rightarrow$ 非凸（鞍点，会卡人）。

记住两个边界：**半正定要看"所有"主子式（顺序的会漏判，反例 $[[0,0],[0,-1]]$ ）；特征值判据只对对称矩阵成立（海森天然对称，放心用）。** 还有，判断凸性是"处处"的事，二次函数（海森常数）是唯一能"只看一个点"的例外。

造物主手记

我曾踩的坑：

我最先想当然地以为"判断半正定就看看顺序主子式全非负就行"，被老谟拿 $[[0,0],[0,-1]]$ 狠狠打脸——顺序主子式 0、0 全非负，可它根本不半正定（右下角是 -1）。"**半正定要看所有主子式，正定才能只看顺序的**"——这个差别我记死了。另一个坑是特征值判据：我差点把它用到非对称矩阵上，老谟用 $[[1,100],[0,1]]$ （特征值全 1 却不定）点醒我——**特征值判据是"对称矩阵"的专属福利，好在海森矩阵天生对称。** 还有一次我判断 $a=2$ 的含参海森时，把"半正定"（闭区间）和"正定"（开区间）混在一起，漏了边界条件。

顿悟时刻：

真正开窍是第 4 轮那三个模板。老谟让我用同一个套路判断 x^2+xy+y^2 、 x^2-y^2 、 x^2 三个海森，我亲手把"正定/不定/半正定"三个词分别落到"严格凸/鞍/凸但平"上——**那一刻我突然明白，一个矩阵的"符号"，直接决定了一个函数的"命运"：是让人安心的一滑到底，还是设陷阱的马鞍，还是平坦却不会骗人的大道。** 而且这三个例子正好预告了第 6、7 章的三种优化场景。从此我看任何损失函数，第一反应就是"它的海森正不定"。

自测题

计算题须动笔完成，附完整解答自核；概念题用于检查理解。

题 A（计算，易 $\rightarrow$ 中）：求海森判定凸性

对 $f(x,y) = x^2 + 4xy + y^2$ ，求海森矩阵，用主子式和特征值双重判断正定/半正定/不定，并给出凸性结论。

完整解答： $f_x = 2x+4y$, $f_y = 4x+2y$; $f_{xx}=2$, $f_{xy}=4$, $f_{yy}=2$, $H = \begin{bmatrix} 2 & 4 \\ 4 & 2 \end{bmatrix}$ 。主子式： $\Delta_1=2>0$, $\Delta_2=\det=4-16=-12<0$ 。故非正定。（规则：Sylvester。）特征值： $\det(\begin{bmatrix} 2-\lambda & 4 \\ 4 & 2-\lambda \end{bmatrix})=(2-\lambda)^2-16=0 \rightarrow \lambda=2\pm 4 = 6, -2$ ，一正一负 $\Rightarrow$ **不定**， f 非凸（驻点是鞍点）。（规则：特征值判据。）

题 B（计算，中一难）：含参海森 + 判定树

设 $f(x,y) = x^2 + axy + y^2$ 。(a) 求 a 为何值时 f 正定（严格凸）、半正定、不定。(b) 用特征值判据验证你的主子式结论。(c) 若把 a 固定在 2， f 是否严格凸？说明理由。

完整解答： (a) $H=\begin{bmatrix} 2 & a \\ a & 2 \end{bmatrix}$, $\Delta_1=2>0$, $\Delta_2=4-a^2$ 。正定 $\Leftrightarrow \Delta_2>0 \Leftrightarrow |a|<2$ ；半正定 $\Leftrightarrow$ 特征值 $2\pm a$ 全 $\geq 0 \Leftrightarrow |a|\leq 2$ ；不定 $\Leftrightarrow$ 特征值一正一负 $\Leftrightarrow |a|>2$ 。（规则：Sylvester / 特征值。）(b) 特征值 $\lambda=2\pm a$ ： $|a|<2$ 时 $2\pm a>0$ 全正（正定）； $|a|=2$ 时一个为 0（半正定）； $|a|>2$ 时 $2-a<0$ （不定）。与 (a) 一致 $\checkmark$ 。（规则：特征值判据。）(c) $a=2$ 时 $|a|=2$ ，特征值 0、4，半正定而非正定，故 f **不是严格凸**（凸但沿 $y=-x$ 方向 f 不变）。（规则：正定 $\Leftrightarrow$ 严格凸，半正定 $\Leftrightarrow$ 凸但不严格。）

题 C（概念，检查理解）：判据与边界

(1) 为什么"半正定"不能只看顺序主子式，而"正定"可以？(2) 特征值判据为什么要求矩阵对称？海森矩阵天然对称吗？(3) 为什么说"海森处处半正定才是凸"，但二次函数除外？

完整解答： (1) 正定时顺序主子式全正会顺带逼出所有主子式正，所以只看顺序够；半正定允许主子式为 0，此时顺序主子式全非负无法控制非顺序位置的主子式（反例 $\begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix}$ ）。（规则：Sylvester 判据边界。）(2) 特征值判据的推导用正交对角化 $A=Q\Lambda Q^T$ ，这要求 A 对称（谱定理）。非对称矩阵特征值全正也可能不定（ $\begin{bmatrix} 1 & 100 \\ 0 & 1 \end{bmatrix}$ ）。海森矩阵因混合偏导连续（克莱罗定理）而天然对称。（规则：谱定理 + 克莱罗定理。）(3) 二阶刻画说"海森处处半正定 $\Leftrightarrow$ 凸"是整体性质，某一点半正定只说明局部凸。但二次函数海森是常数矩阵，处处一样，所以看一个点即可。（规则：二阶刻画的"处处"。）

预告

你手里现在有一套完整的"歪坑检测"工具：海森矩阵 + 正定/半正定/不定判据 + 一张凸性判定树。你知道了：**正定的碗能一滑到底（全局最优），不定的马鞍会卡人（鞍点），半正定的碗有平底但不会骗人。**

下一章，我们正式带着这把尺子下山——梯度下降：沿着负梯度一步步走，走到哪算哪。可是凭什么"走到哪算哪"就一定是谷底？凭的是凸性：**只要海森处处半正定（凸），梯度零点就是全局最优。**

下一章我们要证明：沿着负梯度走、选择合适的步长，函数值会单调下降，最终收敛到全局最优——**你这一章种的"碗"，下一章要真正滑起来了。**

而在那之前，你先记住：**那个"不定的马鞍"——海森不定导致的鞍点——可不是小事。** 它在高维空间里是压倒性的多数，第 7 章你会亲眼看到，深度学习真正的敌人不是浅坑，而是这匹"马"。

第 06 章 · 无约束优化与梯度下降——闭着眼睛下山，凭什么能到谷底

本章从哪个问题出发：前五章你攒下了梯度、链式法则、多元泰勒、凸函数和凸性判定——可你手里一直缺一样东西：**怎么真的"走"到谷底？** 一个函数，有无数个点，你不一定知道它长什么样，只能在当前位置摸一摸"脚下往哪边斜"。沿负梯度走，听起来有道理——可**凭什么**这样走就能到谷底？走多快？步子该迈多大？迈大了会不会摔进另一座山？推导到哪个结论：答案是把"下山"翻译成一个可以反复执行的**迭代格式** $x_{k+1} = x_k - \eta \nabla f(x_k)$ ——每一步都沿着"最陡下降"方向迈出学习率 η 的一步。本章会证明：**当函数是凸函数、且梯度是 Lipschitz 光滑的（ ∇f 不会陡得离谱）时，只要学习率选得够小（ $\eta \leq 1/L$ ），函数值就单调下降，而且收敛速度是 $O(1/k)$ ——这就是"凭什么敢用梯度下降"的数学保证。**

核心认知：**梯度下降不是魔法，它是一条"保证下降 + 保证收敛"的可靠循环：凸性给出方向不迷路，Lipschitz 梯度给出步子别太大，学习率是那个决定"你会不会跳过谷底"的旋钮。** 这一章补上了样书（旧第 17 章）最缺的一块地基——"不解释凸性就敢用梯度下降"的逻辑空当，就在这里填平。

引子

夜里十一点，老谟的工作室里只剩一盏台灯。他扔给造物主一个小沙盘——不是沙盘，是一块微微倾斜的木板，上面挖了个坑，坑底埋了一颗滚珠。

"我把灯全关了。"老谟真的去关了灯，屋里黑得伸手不见五指，"现在你手里只有一根细杆，杆头能测出你脚下'往哪个方向是下坡、坡有多陡'。你被放在木板上某个位置，看不见整块板子的样子——**你唯一的任务：让滚珠滚到坑底。** 你怎么办？"

黑暗中，造物主握着细杆想了半天："我.....我拿杆子测一圈，哪个方向最往下，就朝那个方向挪一小步？然后再测、再挪？"

"好啊。"老谟的声音带着笑意，"那我再问你两个刁钻的：**你朝'最陡下坡'挪一小步，凭什么这一小步就比乱走更接近坑底？** 还有——**你这一小步该迈多大？** 迈大了，会不会一步跨过坑底，滑到对面的坡上，然后来回晃悠永远到不了？"

造物主愣住了。白天他刚学完梯度——"朝负梯度走就是下坡最陡"——可那只是回答了"方向"。**方向对了，剩下的问题才刚开始：步子多大、凭什么收敛、多久能到。** 这一章，老谟要他把"闭着眼摸黑下山"这件事，从"感觉对"变成"算得准"。

对话引擎

第 1 轮：把“找谷底”写成一个干净的问题——优化问题的三件套

老谟：“摸黑下山前，先把你到底要找什么说清楚。你要找的那个点，叫**最优点**。你凭什么说一个点是‘最好’的？给我个能写下来的标准。”

造物主：“.....不就是函数值最小吗？ $f(x)$ 取最小值那个点 x^* 。”

老谟：“对了一半。可你漏了关键的一层：**你在哪儿找？** 是在整个空间随便找，还是被限制在某块区域里找？别小看这一句——它会决定后面所有的算法。”

造物主：“我们这一章.....应该是随便找吧？没有绳子拴着我，整块木板我都走得。”

老谟：“对，你这次是**无约束**的——想走哪儿走哪儿。这就是‘无约束优化’（unconstrained optimization）这个词的来历。现在你把三件套说全：**要最小化的目标函数 f 、变量 x 所在的空间、以及‘无约束’这个前提**。写下来，这就是优化问题的‘户口本’。以后每遇到一个优化问题，先问自己这三件事齐不齐。”

造物主：“明白了。可我还是没抓住核心——**知道要最小化 f ，跟我‘一步一步挪’有什么关系？**”

▢ 知识锚点：无约束优化问题——“找谷底”的正式表述

【概念深挖】**无约束优化问题（unconstrained optimization problem）**的标准形式：
 $\text{minimize } f(x), x \in \mathbb{R}^n$ 。

- **目标函数 f ：**你要最小化的量（如损失函数、成本函数）；
- **变量 x ：**可调的自由参数（如模型权重 $w_1, \dots, w_n$ ）；
- **无约束：** x 可以在整个 $\mathbb{R}^n$ 中取值，没有任何等式或不等式限制（“有没有绳子拴你”）。

我们的目标：找到最优点 $x^* = \operatorname{argmin} f(x)$ （让 f 取到最小的那个点），以及最小值 $f(x^*)$ 。

【工程实践】几乎所有“调参/训练”都是无约束优化的实例：训练神经网络时，你在最小化损失函数 $L(w_1, \dots, w_n)$ ，权重 w 没有任何硬性约束（你可以把每个权重设成任何实数），这就是一个高维无约束优化问题。“**最小化 $f(x)$** ”这句话，是机器学习里出现频率最高的半句话。本章往后学的一切，都是回答“这个 $\min$ 到底怎么算出来”。

【历史溯源】“沿最陡方向下降”的直觉可追溯到柯西（Cauchy, 1847）——他在一篇研究里第一次明确提出“沿着负梯度方向迭代寻找极小点”的想法，后世称之为最速下降法（steepest descent）。有意思的是，它虽然是最古老的优化算法之一，却直到今天都是深度学习最常用优化的雏形——因为它只要“局部梯度”就能跑，对看不见全局的函数最友好。

第 2 轮：方向是梯度的反面——为什么是"负"梯度

老谟："回到摸黑下山。你说你拿杆子测一圈，找'最陡的下坡方向'。上一章你学过梯度——**梯度指着什么方向？**"

造物主："梯度指着**上坡最陡**的方向，长度就是最陡的坡度。"

老谟："那'最陡下坡方向'是哪个？"

造物主：".....梯度反着来！朝 $-\nabla f$ 走，就是下坡最陡的方向。"

老谟："那我现在问你一个你可能没想过的问题：**这一步迈下去，'下坡最陡'就等于'最接近谷底'吗？**你想清楚再答。"

造物主：".....我盯着这个问号想了一会儿。不一定吧？最陡下坡只是'这一步降得最快'，可它未必带你直奔谷底——也许它先带你斜着滑到一条沟里。就像我学过的：**'局部最快'和'全局最优'是两码事。**"

老谟："抓住要害了。**最速下降方向只保证'这一步'最陡，不保证'全局'最优。**这正是梯度下降的第一个性格：它是**贪心的**——每一步只管眼前最陡，从不抬头看全局。所以接下来我们必须回答：**一个贪心的、只看脚下的算法，凭什么最后还能收敛到谷底？**这才是本章真正的难处。"

知识锚点：最速下降方向——贪心的"眼前最优"

【概念深挖】设 f 在 x_k 处可微且 $\nabla f(x_k) \neq 0$ 。在所有"迈出单位步长"的方向 d ($\|d\| = 1$) 中，让 **f 下降最多**（即方向导数 $D_d f(x_k)$ 最负）的方向，由第 01 章定理 2（最陡方向）知是

$$d = -\nabla f(x_k) / \|\nabla f(x_k)\|$$

因为 $D_d f = \nabla f \cdot d = \|\nabla f\| \cdot \cos \theta$ ，在 $\theta = 180^\circ$ (d 与 ∇f 反向) 时取到最小值 $-\|\nabla f\|$ 。**这就是"最速下降 (steepest descent) "方向——只看脚下最陡，不看全局。**

【概念深挖】**梯度下降 (gradient descent) 迭代格式：**不严格归一化步长，而是直接按 $x_{k+1} = x_k - \eta \nabla f(x_k)$ 更新，其中 $\eta > 0$ 叫**学习率 (learning rate) 或步长 (step size)**。

- 方向项 $-\nabla f(x_k)$ ：下坡最陡；
- 幅度项 η ：决定这一步迈多大。

这个格式是全章的"总引擎"：重复同一个动作——算梯度、朝负梯度迈 η 步。深度学习里最常见的 SGD（随机梯度下降）只是把"用全部数据算的梯度"换成"用一小批数据估的梯度"，框架不变。

【概念深挖】为什么写成"减去梯度"而不是别的？因为泰勒一阶近似 $f(x_k + h) \approx f(x_k) + \nabla f \cdot h$ 。想让它下降（小于 $f(x_k)$ ），就要 $\nabla f \cdot h < 0$ ——而 $h = -\eta \nabla f$ 恰好让 $\nabla f \cdot h = -\eta \|\nabla f\|^2 < 0$ ($\eta >$

0) 。所以"负梯度"不是约定俗成的漂亮名字，它是"让泰勒一阶近似下降"的最省事选择。

第 3 轮：步子太大摔过谷底，步子太小到不了——学习率是个旋钮

老谟："格式到手了： $x_{k+1} = x_k - \eta \nabla f(x_k)$ 。现在盯着那个 η 看。你拍拍脑袋， η 该取多大？"

造物主：".....取个小的？1？0.1？反正是正的就行？"

老谟："正的就行？我给你两个极端，你体会一下。 η 很大，比如比 1 还大——会发生什么？"

造物主：".....大步一跨，可能直接越过谷底，冲到对面坡上，甚至越冲越高？那就不是下山了，是'跳山'了。"

老谟："这就是**发散 (diverge)** ——步子太大，误差 $o(\eta^2)$ 失控，函数值不降反升，越跳越高。那 η 很小很小呢？"

造物主："小步挪，肯定不跳山.....但也很慢？就像老牛拉车，半天挪不到谷底，浪费人生。"

老谟："这就是**龟速 (too slow)** ——收敛是有，可慢到你等不起。所以你被夹在两难中间： η 大了**发散**， η 小了**磨蹭**。数学家不让你拍脑袋——他们给了你一个'安全上限'：当 ∇f 是 L-Lipschitz 的（梯度不会太陡），取 $\eta \leq 1/L$ 就能**保证不发散、函数值单调下降**。那个 L 从哪儿来、为什么 $1/L$ 是关键，我们放到走廊里用证明说话。你先记住一个直觉：**学习率不是'随便正的'，它是整个算法里最需要小心拧的旋钮。**"

▢ 知识锚点：学习率的两难——发散 vs 龟速

【概念深挖】学习率 η （步长）是梯度下降里**最敏感的超参数**：

- **η 过大 → 发散**：从泰勒误差 $o(\eta^2)$ 角度，步长一大，二阶以上项不再可忽略，近似失效，函数值可能上升，迭代震荡甚至跑远（发散）。
- **η 过小 → 龟速**：每步下降太少，需要天文数字的迭代才收敛。
- **安全区**：当 ∇f 满足 L-Lipschitz 条件（后面定义）， $\eta \leq 1/L$ **保证函数值单调下降且收敛**（严格证明见走廊定理）。

【工程实践】**学习率是训练深度学习时第一个要调的旋钮**：框架（PyTorch、TensorFlow）里 `learning_rate` 参数默认值往往基于经验（如 0.01 附近），因为真实损失函数通常不是"标准凸函数"， $1/L$ 的安全界没法精确算，只能靠试。**训练日志里"损失炸了"（loss 变 NaN 或飙升）十有八九是学习率太大**；"损失死活降不下去"则常是学习率太小。调参的第一课，就是先把这个旋钮拧到能"稳着降"的量级。

【实现思考】如果让你自己实现梯度下降，你会怎么写？核心就三步循环：① **算梯度** $\nabla f(\mathbf{x}_k)$ ；② **乘学习率** η ；③ **从当前位置减掉它**。伪代码就一句话：

```
x = 初始点
for k in range(步数):
    g = 梯度(x)      # 算脚下多陡、往哪边陡
    x = x -  $\eta$  * g    # 朝负梯度迈  $\eta$  步
```

代价是：每步都要算梯度，维度高时梯度本身计算昂贵（这正是后来“随机梯度下降”登场的原因——用一小批样本估梯度，省算力）。换条路：如果不用梯度、改用二阶信息（Hessian），能一次跳到抛物线顶点（牛顿法），但算 Hessian 在高维更贵。“贵”和“快”的权衡，贯穿整个优化领域。

交互实验：梯度下降的“大/小/适中”学习率

用「走 1 步」逐步看轨迹（不吞推导）： $\eta = 0.06$ 时金色轨迹逐点沿负梯度下山； η 调大到 0.2，y 方向先震荡发散——**学习率太大就“过冲”**； η 调到 0.01，能收敛但龟速。先看清每一步怎么走，再谈收敛。

交互演示 (GradientDescent)：此组件为在线版的动态演示，离线 PDF/EPUB 中无法交互。完整推导见本章正文与「计算训练场」。

第 4 轮：怎么保证不迷路？——凸性是“一滑到底”的通行证

老谟：“你把方向（负梯度）和步子（ η ）都定了。可还有个最要命的问题悬着：**我闭着眼瞎走，万一下到一半，发现脚下有个‘小坑’，它不是最深的谷底，可我滑进去就出不来了——怎么办？**”

造物主：“……那不就卡在局部最优了吗？不是谷底的最小值，是个假谷底。”

老谟：“对。**这就是优化里最阴险的敌人——局部极小点 (local minimum)**：一个点，周围都比它高，但它不是全局最矮的那个坑。你闭着眼下山，很容易掉进这种‘假谷底’就以为到头了。那你说，**有没有一种函数，天然没有这种假谷底？**”

造物主：“……除非这个函数只有一个坑，没有别的小坑？那种‘碗’？就是第 4 章学的——**凸函数**！凸函数只有一个谷底，任何局部极小都是全局极小。”

老谟：“你把这个函数库翻出来了。**凸函数 (convex function) 就是‘没有假谷底’的函数**：它的任何局部极小点都是全局极小点。所以对凸函数，梯度下降不会‘误入歧途’——你滑到的谷底就是真谷底。**这就是‘为什么敢用梯度下降’的第一块通行证：凸性**。第二块通行证，就是上一轮说的 L-Lipschitz 梯度（保证步子别太大）。两证齐全，收敛才说得准。”

造物主："可深度学习要优化的损失函数，根本不是凸的呀？"

老谟："问得好，先记下这个矛盾。**深度学习确实不凸——这也是为什么深度学习优化比'凸优化'难得多。**但你要先听懂'凸的情形下梯度下降为什么可靠'，才能理解'不凸时问题出在哪'。凸性是'理想教科书'，第7章那个'高维景观'才是'残酷现实'。一步一步来，先把教科书吃透。"

▢ 知识锚点：凸性与局部/全局——为什么凸函数敢"一滑到底"

【概念深挖】**凸函数的"无假谷底"性质：**若 f 是凸函数，则 f 的任何局部极小点都是全局极小点（严格证明见走廊定理）。直观：凸函数的图像像一口"碗"，没有第二个坑；站在碗里任意处，顺着下降方向走，最终只能滑向唯一的碗底。**这是"局部 = 全局"在凸情形下成立的数学事实。**

【概念深挖】为什么这个性质对"敢不敢用梯度下降"至关重要：梯度下降是贪心的（只看脚下），它天然只能保证找到"局部极小"。**如果函数不凸，贪心可能停在假谷底；如果函数凸，局部极小 = 全局极小，贪心就不怕停错。**所以"凸"这个条件，直接把"算法能保证的结果"从"某个局部坑"升级成"全局最矮坑"。

【工程实践】**为什么深度学习的损失通常不是凸的：**损失函数对权重的高阶依赖（多层非线性复合）让损失面凹凸不平，存在大量局部极小与鞍点。**但工程上发现：高维损失面的'假谷底'其实比想象中少，真正的麻烦是'鞍点'（第7章）——这纠正了一个过时的二维直觉。**现在你只需记住：**凸性给了你'局部=全局'的理想保证，而深度学习在'没有这个保证'的野外求生。**

第5轮：收敛快不快？—— $O(1/k)$ 是一张"账本"

老谟："假设函数凸、 η 也选对了，函数值确实单调下降。可它降得多快？你说100步之后能离谷底多远？这不能靠感觉，得给个'账本'。"

造物主：".....你是说收敛速度？我猜.....每一步都缩一点，越到后面越慢？但总得有个具体说法吧。"

老谟："给你一句能刻在墙上的话：**凸函数 + L -Lipschitz 梯度 + $\eta = 1/L$ ，梯度下降的函数值差距满足 $f(x_k) - f(x) \leq O(1/k)$ 。*** 翻译成成人话：**走了 k 步之后，你离最优值的'残余'大致按 $1/k$ 的速度缩小——想让误差减半，步数要翻倍。**这是'慢但稳'的收敛：它不保证指数级加速（那是强凸才有的待遇），但它给你一个**确定性承诺**：只要凸、只要 η 在安全区，就一定能慢慢逼近，误差有明确上界。"

造物主：" $1/k$也就是说想压误差到 $1/1000$ ，得走大约1000步？这也太慢了。"

老谟："慢，但**可靠**。而且这正是'为什么凸优化是地基'的原因——它的行为是**可预期的**，你知道最坏要多少步。相比之下，非凸优化连'最坏多少步'都说不清。**先把'可靠但慢'吃透，再看'快但不保'（动量、牛顿）怎么加速。**下一轮我们聊聊'怎么让步子更聪明'。"

知识锚点：收敛率 $O(1/k)$ ——“慢但稳”的确定性账本

【概念深挖】**收敛率 (convergence rate)**：衡量“迭代 k 步后离最优解有多近”的递减速度。对凸函数梯度下降 ($\eta=1/L$ 、 ∇f L -Lipschitz)，标准结论是

$$f(x_k) - f(x^*) \leq L \cdot \|x_0 - x^*\|^2 / (2k)$$

即误差按 $O(1/k)$ 收敛 (“残余 $\leq$ 常数/步数”)。含义：误差减半，步数需翻倍。

【概念深挖】**L 是什么**：L 是梯度 ∇f 的 **Lipschitz 常数**——梯度变化的最坏速率（下面走廊定义）。直观：**L 越大，说明曲面“弯”得越厉害，能容忍的学习率 $\eta=1/L$ 就越小**。对二次函数 $f = x^T A x$ (A 对称正定)，L 正好等于 A 的最大特征值。

【工程实践】真实优化不会真等 $O(1/k)$ 磨到 $1/1000$ ——因为现实函数非凸、且计算昂贵。工程上会用**加速手段**：动量 (momentum) 把历史梯度的“惯性”存下来，减少之字形震荡、加快中后期收敛；Adam 则进一步给每个参数自适应的学习率。**但所有加速器都建立在本章这条‘基础循环’之上——先懂 $O(1/k)$ 的可靠循环，再谈加速**。

【历史溯源】梯度下降收敛性的严格分析始于 20 世纪中后期，**B. T. Polyak (波利亚克, 1960s) **对凸情形下最速下降的收敛性做了系统研究；**Nesterov (1983) **则给出凸情形下加速的 $O(1/k^2)$ 收敛率（动量型加速的数学根基），后来演化成深度学习里动量方法的思想源头。

第 6 轮：一步迈多大最划算？——线搜索的“试步”思想

老谟：“我们一路都在说‘ η 要选小’，可你有没有想过：**每一小步的 η ，能不能现场动态地调？**比如我这一脚先迈个试试，不行就收回一半，直到迈出一步真的在下降。”

造物主：“……试一步，不行减半？这不就是‘边试边改’吗？那跟固定 η 有什么区别？”

老谟：“区别在于：**固定 η 是盲人摸象，线搜索是‘每步都用脚下的反馈校准一次’**。两种主流做法，你先听个名：① **精确线搜索 (exact line search)** ——把 η 当变量，一步走到‘沿这个方向 f 最低’的点；② **回溯线搜索 (backtracking line search)** ——从一个大步长开始，若这一步没让 f 降得够多（比如没满足‘下降充分’），就把步长减半重试，直到满意。**这俩都比你‘拍一个固定 η ’更聪明，因为它们让每一步都‘自适应’**。”

造物主：“那为什么不全都用回溯线搜索？”

老谟：“因为贵。每试一次步长都要多算一次 f 和梯度，多一轮前向/反向传播。深度学习里每一步本来就算得慢，再内嵌线搜索，训练时间翻倍都不止。**所以工程上的折中是：先用经验固定一个 η (如 0.01)，发现爆了再手动调小；只有在算力不敏感的小问题上，才用线搜索自动找步长**。你先把‘步长可以自适应’这个思想记住，具体公式我们点到为止。”

知识锚点：线搜索——让步长"现场自适应"

【概念深挖】**线搜索 (line search)** 的两条路线 (点到为止, 细节不作要求) :

- **精确线搜索 (exact line search)** : 固定方向 $d = -\nabla f(x_k)$, 把 $f(x_k + \eta \cdot d)$ 看成 η 的一元函数, 求使它的最小的 η^* 。代价: 每步要解一个一元极小化, 贵。
- **回溯线搜索 (backtracking line search)** : 从较大步长 η_0 开始, 反复把 η 减半 ($\eta \leftarrow \eta/2$), 直到满足"Armijo 条件" (下降量充分: $f(x_k + \eta \cdot d) \leq f(x_k) + c \cdot \eta \cdot \nabla f \cdot d$, $c \in (0,1)$, 通常 $c=1e-4$)。每步只多算几次 f , 性价比高。

【工程实践】**深度学习**的标准做法其实不是线搜索, 而是"调度 (schedule)": 用一个固定学习率, 按固定节奏衰减 (如每 30 轮乘以 0.1)。为什么不用回溯线搜索? 因为**深度学习每步的算力极贵**, 线搜索多试几次步长 = 多算几次整个网络, 成本不可接受。**"便宜但经验式"胜过"昂贵但自适应"**——这是工程与理论的一个典型分岔。

第 7 轮：落点——从"感觉能下山"到"证明能下山"

老谟: "把灯打开。摸黑下山这一章, 你现在能总结成几句话了。"

造物主: "我把'找谷底'写成了无约束优化: $\min f(x)$ 。**方向**用负梯度 (最陡下坡, 贪心), **步子**用学习率 η (大则发散、小则龟速), **可靠**靠两件事: 凸性 (没有假谷底, 局部=全局) + L-Lipschitz 梯度 ($\eta \leq 1/L$ 保单调下降、 $O(1/k)$ 收敛)。还知道了能让步子更聪明的线搜索, 以及深度学习因为每步太贵而宁可用固定学习率。"

老谟: "那你现在能回答章首那个问题了——'**沿负梯度走, 凭什么能到谷底?**'"

造物主: "**不是'凭直觉', 是'凭证明'**: 凸性保证不会掉进假谷底, Lipschitz 梯度 + 小步长保证每步都真在下降、且误差按 $1/k$ 缩到 0。**只要这两个条件在, 闭着眼下山也是数学上能到的。**"

老谟: "漂亮。可你留意到一个刺——**这一切都建立在'凸'上**。深度学习不凸, 那你手里这套'能到谷底'的保证, 在真实训练里还剩下多少? 这就要问你一句更扎心的: **在高低起伏的复杂地形里, 最危险的**不一定是'小坑', 而可能是别的什么东西..... 这个问题, 留到下一章。你先下山, 我去关灯。"

严格化走廊

位置说明: 本章对话负责"直觉"——为什么负梯度、为什么凸、为什么 η 不能太大。本走廊负责"严谨"——把优化问题、Lipschitz 条件、凸性保证、收敛率全部写成精确的定义与可复写的证明。**下面每一行, 读者都能对着空白纸重写一遍。**

定义 1: 无约束优化问题 (unconstrained optimization problem)

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 。无约束优化问题是

$$\text{minimize } f(x), x \in \mathbb{R}^n$$

称 x^* 为**全局极小点**，若对一切 $x \in \mathbb{R}^n$ 有 $f(x^*) \leq f(x)$ ；称 x_0 为**局部极小点**，若存在 $r > 0$ ，使对满足 $\|x - x_0\| < r$ 的一切 x 有 $f(x_0) \leq f(x)$ 。

严格注记：全局极小对"所有点"成立，局部极小只对"邻域内"成立。凸函数下二者重合（见定理 1）。

定义 2: L-Lipschitz 梯度 (L-Lipschitz gradient / 梯度 L-光滑)

设 f 可微。称 ∇f 是 **L-Lipschitz 的** ($L \geq 0$)，若对一切 $x, y \in \mathbb{R}^n$ ：

$$\|\nabla f(x) - \nabla f(y)\| \leq L \cdot \|x - y\|$$

L 称为 Lipschitz 常数。直观：梯度函数本身不会"陡得离谱"，最坏情况每移动单位距离，梯度变化不超过 L 。

定义 3: 梯度下降迭代 (gradient descent iteration)

给定初始点 $x_0 \in \mathbb{R}^n$ 与学习率 $\eta > 0$ ，梯度下降生成序列

$$x_{k+1} = x_k - \eta \cdot \nabla f(x_k), k = 0, 1, 2, \dots$$

定义 4: 凸函数 (convex function, 复习第 4 章)

设 f 的定义域是凸集。称 f 为**凸函数**，若对一切 $x, y \in$ 定义域、一切 $\lambda \in [0, 1]$ ：

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$$

定理 1 (凸函数的局部极小 = 全局极小)：设 f 是凸函数， x_0 是 f 的局部极小点，则 x_0 也是全局极小点。

证明 (可复写)：

- 反设 x_0 不是全局极小：则存在 $y \in$ 定义域使 $f(y) < f(x_0)$ 。记 $d = y - x_0 \neq 0$ 。

- 考虑点 $x(\lambda) = x_0 + \lambda \cdot d = \lambda y + (1-\lambda)x_0$, $\lambda \in (0,1]$ 。由**定义 4 (凸函数不等式)**： $f(x(\lambda)) \leq \lambda f(y) + (1-\lambda)f(x_0) = f(x_0) + \lambda[f(y) - f(x_0)] < f(x_0)$ (因为 $f(y) < f(x_0)$, $\lambda > 0$)。
- 因此对任意小的 $\lambda > 0$, 都有 $f(x_0 + \lambda d) < f(x_0)$ ——即在 x_0 的任意小邻域内, 都存在函数值比 $f(x_0)$ 更小的点, 与“ x_0 是局部极小点” (定义 1) 矛盾。
- 故反设不成立, x_0 必是全局极小点。■

证明要点标注：第 1 步是**反证法** (假设结论相反)；第 2 步用**定义 4 (凸函数的弦不等式)** 把中间点 $x(\lambda)$ 的函数值夹到 $f(x_0)$ 之下；第 3 步用**定义 1 (局部极小的邻域性质)** 制造矛盾；第 4 步是反证法收尾。

定理 2 (下降引理)：设 f 可微且 ∇f 是 L -Lipschitz 的 (定义 2), 则对一切 $x, y \in \mathbb{R}^n$:

$$f(y) \leq f(x) + \nabla f(x) \cdot (y - x) + (L/2) \cdot \|y - x\|^2$$

证明 (可复写)：

- 由微积分基本定理, 把 f 沿从 x 到 y 的线段积分： $f(y) - f(x) = \int_0^1 \nabla f(x + t(y-x)) \cdot (y-x) dt$ 。
- 变形： $f(y) - f(x) - \nabla f(x) \cdot (y-x) = \int_0^1 [\nabla f(x + t(y-x)) - \nabla f(x)] \cdot (y-x) dt$ 。
- 对被积函数用**柯西-施瓦茨不等式**与**定义 2 (Lipschitz)**： $[\nabla f(x+t(y-x)) - \nabla f(x)] \cdot (y-x) \leq \|\nabla f(x+t(y-x)) - \nabla f(x)\| \cdot \|y-x\| \leq L \cdot \|t(y-x)\| \cdot \|y-x\| = L \cdot t \cdot \|y-x\|^2$ 。
- 代入积分并求值： $f(y) - f(x) - \nabla f(x) \cdot (y-x) \leq \int_0^1 L \cdot t \cdot \|y-x\|^2 dt = (L/2) \|y-x\|^2$ 。
- 移项即得 $f(y) \leq f(x) + \nabla f(x) \cdot (y-x) + (L/2) \|y-x\|^2$ 。■

证明要点标注：第 1 步是**微积分基本定理的积分形式** (把函数差写成梯度线积分)；第 2 步是**代数整理**；第 3 步用**柯西-施瓦茨不等式**与**定义 2 (L-Lipschitz 梯度)**；第 4 步是**定积分** $\int_0^1 t dt = 1/2$ ；第 5 步移项。

定理 3 (单调下降)：设 f 凸、可微, ∇f 是 L -Lipschitz 的, 取学习率 $0 < \eta \leq 1/L$, 则由**定义 3** 生成的序列满足:

$$f(x_{k+1}) \leq f(x_k) - (\eta/2) \cdot \|\nabla f(x_k)\|^2 \leq f(x_k)$$

从而**函数值单调下降**；且当且仅当 $\nabla f(x_k) = 0$ (驻点, 即极值的必要条件) 时下降量为 0。

证明 (可复写)：

- 在**定理 2 (下降引理)** 中取 $x = x_k$, $y = x_{k+1} = x_k - \eta \nabla f(x_k)$, 得 $f(x_{k+1}) \leq f(x_k) + \nabla f(x_k) \cdot (-\eta \nabla f(x_k)) + (L/2) \|-\eta \nabla f(x_k)\|^2 = f(x_k) - \eta \|\nabla f(x_k)\|^2 + (L\eta^2/2) \|\nabla f(x_k)\|^2$ 。

- 合并: $f(x_{k+1}) \leq f(x_k) - \eta(1 - L\eta/2) \cdot \|\nabla f(x_k)\|^2$ 。
- 因 $0 < \eta \leq 1/L$, 有 $1 - L\eta/2 \geq 1/2$, 故 $f(x_{k+1}) \leq f(x_k) - (\eta/2) \cdot \|\nabla f(x_k)\|^2 \leq f(x_k)$ (因 $\|\nabla f(x_k)\|^2 \geq 0$)。
- 结论: 只要 $\nabla f(x_k) \neq 0$, 函数值严格下降; 下降到某处 $\nabla f(x^*) = 0$ (驻点) 时不再下降。结合**定理 1** (凸, 局部=全局), 驻点即全局极小。■

证明要点标注: 第 1 步用**定理 2 (下降引理)** 并代入迭代格式 (定义 3); 第 2 步是代数合并同类项; 第 3 步用**学习率条件 $\eta \leq 1/L$** 与 **范数非负性**; 第 4 步结合****定理 1 (凸性)** **与驻点条件。

定理 4 (收敛率 $O(1/k)$): 设 f 凸、可微, ∇f 是 L -Lipschitz 的, x^* 是全局极小点, 取 $\eta = 1/L$, 则由定义 3 生成的序列满足:

$$f(x_k) - f(x^*) \leq L \cdot \|x_0 - x^*\|^2 / (2k), \quad k = 1, 2, \dots$$

即**函数值差距按 $O(1/k)$ 收敛**。

证明 (可复写):

- 记 $p_k = \|x_k - x^*\|^2$, $\delta_k = f(x_k) - f(x^*) \geq 0$ 。
- 由****定义 3 (迭代格式, $\eta=1/L$)** **与范数性质: $p_{k+1} = \|x_{k+1} - x^*\|^2 = \|x_k - x^* - (1/L)\nabla f(x_k)\|^2 = p_k - (2/L)\nabla f(x_k) \cdot (x_k - x^*) + (1/L^2)\|\nabla f(x_k)\|^2$ 。
- 由**凸函数的一阶刻画 (第 4 章)**: $f(x^*) \geq f(x_k) + \nabla f(x_k) \cdot (x^* - x_k)$, 即 $\nabla f(x_k) \cdot (x_k - x^*) \geq f(x_k) - f(x^*) = \delta_k$ 。代入得: $p_{k+1} \leq p_k - (2/L)\delta_k + (1/L^2)\|\nabla f(x_k)\|^2$ 。
- 由**定理 3 (单调下降)**: $\delta_{k+1} \leq \delta_k - (1/(2L))\|\nabla f(x_k)\|^2$, 即 $\|\nabla f(x_k)\|^2 \leq 2L(\delta_k - \delta_{k+1})$ 。代入: $p_{k+1} \leq p_k - (2/L)\delta_k + (1/L^2) \cdot 2L(\delta_k - \delta_{k+1}) = p_k - (2/L)\delta_k + (2/L)\delta_k - (2/L)\delta_{k+1} = p_k - (2/L)\delta_{k+1}$ 。
- 移项: $(2/L)\delta_{k+1} \leq p_k - p_{k+1}$, 即 $\delta_{k+1} \leq (L/2)(p_k - p_{k+1})$ 。
- 对 $k = 0, 1, \dots, N-1$ 求和 (望远镜求和): $\sum_{k=0}^{N-1} \delta_{k+1} \leq (L/2)(p_0 - p_N) \leq (L/2)p_0$ 。
- 因 δ_k 单调不增 (定理 3), N 项中每一项 $\geq \delta_N$, 故 $N \cdot \delta_N \leq \sum_{k=0}^{N-1} \delta_{k+1} \leq (L/2)p_0$, 即 $\delta_N \leq (L/(2N)) \cdot p_0 = L \cdot \|x_0 - x^*\|^2 / (2N)$ 。■

证明要点标注: 第 1 步是**平方范数展开**; 第 2 步用**凸函数一阶刻画 (第 4 章定理)**; 第 3 步用**定理 3 (单调下降)** 回代梯度范数; 第 4 步是代数整理得相邻步距离的收缩; 第 5 步是**望远镜求和**; 第 6 步用 **δ 单调不增**把"每项 $\geq \delta_N$ "代入求和得到 $O(1/k)$ 。

反例/边界

- **凸性缺失** → **局部≠全局**: $f(x) = x^3$ 不是凸函数, $x = 0$ 处 $f'(0) = 0$ (驻点) 但既非局部极小也非全局极小 (它是鞍点/拐点); $f(x) = x^4 - x^2$ 有局部极小 $x = \pm 1/\sqrt{2}$ 和局部极大, 梯度下降从不同起点会落到不同坑——**不凸时"贪心"可能停错**。
- **Lipschitz 缺失** → **单调下降失效**: $f(x) = -x^4$ (在 $\mathbb{R}$ 上梯度不是 L -Lipschitz, 因为 $f'(x) = -4x^3$ 的增长超过线性)。梯度下降朝 $-f'$ 走其实在远离, 且函数无下界, 无所谓"收敛"——"**L-Lipschitz**"不是装饰, 去掉它定理 2、3、4 全部失效。
- **η 超出安全区** → **发散**: 对 $f(x) = x^2$ ($L = 2$), 若取 $\eta = 2 > 1/L = 0.5$, 则 $x_{k+1} = x_k - 2 \cdot 2x_k = -3x_k$, $|x_k|$ 每次 $\times 3$, 函数值 $f = x^2$ 每次 $\times 9$ 爆炸——**这就是"学习率太大"的数学微观机制** (计算训练场题 2 会手算这一条)。

知识点总结

知识点 (本章推出的核心概念)

- **无约束优化问题**: $\min f(x), x \in \mathbb{R}^n$ ——目标函数 f 、变量 x 、无约束前提三件套。
- **梯度下降迭代格式**: $x_{k+1} = x_k - \eta \nabla f(x_k)$; 方向 = 负梯度 (最陡下降、贪心), 幅度 = 学习率 η 。
- **学习率 (步长)**: 最敏感的超参数; 过大 → 发散, 过小 → 龟速; 安全区 $\eta \leq 1/L$ (L 为梯度 Lipschitz 常数)。
- **L-Lipschitz 梯度**: $\|\nabla f(x) - \nabla f(y)\| \leq L\|x-y\|$ ——梯度不会"陡得离谱"; L 越小, 曲面越平缓, 可容忍步长越大。
- **凸性是"局部=全局"的通行证**: 凸函数任何局部极小都是全局极小 (定理 1) ——这是"敢用贪心梯度下降"的第一块地基。
- **单调下降**: 凸 + L -Lipschitz + $\eta \leq 1/L \Rightarrow f(x_{k+1}) \leq f(x_k)$ (定理 3)。
- **收敛率 $O(1/k)$** : $f(x_k) - f(x^*) \leq L\|x_0 - x^*\|^2 / (2k)$ ——慢但确定性可靠 (定理 4)。
- **线搜索思想**: 精确线搜索 (一步到该方向最低点) 与回溯线搜索 (步长过大则减半重试), 让步长自适应; 深度学习因每步昂贵而常用固定学习率 + 调度。

历史结论 (本章涉及的史料)

- **柯西 (1847)**: 最早提出沿负梯度方向迭代求极小 (最速下降法的雏形) ——最古老也最持久。
- **Polyak (1960s)**: 系统研究凸情形下最速下降的收敛性。
- **Nesterov (1983)**: 给出凸情形下加速的 $O(1/k^2)$ 收敛率, 是动量加速方法的数学根源。

- **一个共性**：优化算法的严格收敛分析晚于算法的朴素使用上百年——"先有工程直觉，后有数学保证"，与梯度这个概念的诞生路径一致。

工程实践结论（本章知识在真实工程里怎么用）

- **调参/训练 = 无约束优化**：损失最小化就是 $\min L(w)$ ，权重无硬约束。
- **"损失炸了"多半是学习率太大**：训练日志出现 NaN/飙升，先拧小 η 。
- **"损失降不下去"常是学习率太小**：收敛太慢，需调大或加速。
- **深度学习每步太贵，用固定学习率 + 衰减调度**，而非线搜索——"便宜但经验式"胜过"昂贵但自适应"。
- **所有加速器（动量、Adam）都建立在基础循环上**：先懂 $O(1/k)$ 的可靠循环，再谈加速。
- **非凸的野外求生**：深度学习损失不凸，局部极小与鞍点并存——凸性保证只是"教科书"，真实挑战在第 7 章。

计算训练场

位置说明：本章对话负责"为什么"，这里负责"怎么算"。下面每题请动笔 10 分钟以上，先自己写，再对照完整解答。所有数值我都亲手验算过，禁止跳过步骤对答案。

题 1（易→中）：梯度下降走 3 步——验证单调下降

题干：设 $f(x, y) = x^2 + y^2$ ，初始点 $(x_0, y_0) = (1, 1)$ ，学习率 $\eta = 0.1$ 。(a) 写出梯度 ∇f 的表达式。(b) 用梯度下降迭代格式手算走 3 步，列出每一步的 (x_k, y_k) 与 $f(x_k, y_k)$ 。(c) 验证函数值单调下降，并指出极限点（最小点）是什么。(d) 用收敛率界 $L\|x_0 - x^*\|^2/(2k)$ 估算第 3 步的误差上界，与实际误差对比。

完整分步解答：

(a) 梯度：第 1 步： $f(x, y) = x^2 + y^2$ 。对 x 求偏导： $f_x = 2x$ ；对 y 求偏导： $f_y = 2y$ （把另一个变量当常数）。第 2 步： $\nabla f(x, y) = (2x, 2y)$ 。

(b) 迭代 3 步：第 3 步（第 0→1 步）：在 $(1, 1)$ ， $\nabla f(1, 1) = (2, 2)$ 。第 4 步： $x_1 = (1, 1) - 0.1 \cdot (2, 2) = (1 - 0.2, 1 - 0.2) = (0.8, 0.8)$ 。第 5 步： $f(0.8, 0.8) = 0.64 + 0.64 = 1.28$ （初始 $f(1, 1) = 1 + 1 = 2$ ，已下降）。

第 6 步（第 1→2 步）： $\nabla f(0.8, 0.8) = (1.6, 1.6)$ 。第 7 步： $x_2 = (0.8, 0.8) - 0.1 \cdot (1.6, 1.6) = (0.8 - 0.16, 0.8 - 0.16) = (0.64, 0.64)$ 。第 8 步： $f(0.64, 0.64) = 0.4096 + 0.4096 = 0.8192$ 。

第 9 步 (第 2→3 步) : $\nabla f(0.64, 0.64) = (1.28, 1.28)$ 。第 10 步: $x_3 = (0.64, 0.64) - 0.1 \cdot (1.28, 1.28) = (0.64 - 0.128, 0.64 - 0.128) = \mathbf{(0.512, 0.512)}$ 。第 11 步: $f(0.512, 0.512) = 0.262144 + 0.262144 = \mathbf{0.524288}$ 。

(c) 单调下降验证: 第 12 步: f 值序列为 $2 \rightarrow 1.28 \rightarrow 0.8192 \rightarrow 0.524288$, 严格递减 $\checkmark$ 。第 13 步: $\nabla f = (2x, 2y) = 0$ 当且仅当 $x = y = 0$, 故最小点 $x^* = \mathbf{(0, 0)}$, $f(x^*) = 0$ 。序列 $(0.512, 0.512)$ 正朝 $(0, 0)$ 收缩。

(d) 收敛率界对比: 第 14 步: $L = \text{Hessian 最大特征值}$ 。 $H = [[2, 0], [0, 2]]$, 特征值均为 2, 故 $L = 2$ 。第 15 步: $\|x_0 - x^*\|^2 = \|(1, 1) - (0, 0)\|^2 = 1^2 + 1^2 = 2$ 。第 16 步: $k = 3$ 时上界 = $L \cdot \|x_0 - x^*\|^2 / (2k) = 2 \cdot 2 / (2 \cdot 3) = \mathbf{4/6 \approx 0.6667}$ 。第 17 步: 实际误差 $\delta_3 = f(x_3) - f(x^*) = 0.524288 - 0 = \mathbf{0.524288 \leq 0.6667 \checkmark}$, 上界成立。

答: (a) $\nabla f = (2x, 2y)$; (b) $x_1 = (0.8, 0.8)$, $f = 1.28$; $x_2 = (0.64, 0.64)$, $f = 0.8192$; $x_3 = (0.512, 0.512)$, $f = 0.524288$; (c) 单调递减, 极限点 $(0, 0)$, $f^* = 0$; (d) 上界 0.6667, 实际 0.5243, 成立 $\checkmark$ 。

常见错误: ① 求偏导时把 x^2 对 x 求导算成 x 而不是 $2x$; ② 更新时把"减"写成"加" ($x_{k+1} = x_k - \eta \nabla f$, 不是加); ③ 迭代时忘了每次用"最新点"算梯度, 而是沿用第一次的梯度 $(2, 2)$ ——**每步梯度都要重新算**。

题 2 (中) : 学习率对照——发散 vs 龟速 vs 精确线搜索

题干: 仍用 $f(x, y) = x^2 + y^2$, 初始点 $(1, 1)$ 。(a) 取 $\eta = 1.1$ (比安全值 $1/L = 0.5$ 大), 走 3 步, 证明函数值上升 (发散)。(b) 取 $\eta = 0.01$, 走 3 步, 说明"龟速" (下降极少)。(c) 用精确线搜索思想求该方向的最优步长 η^* , 说明一步即可到位。

完整分步解答:

(a) $\eta = 1.1$ 发散: 第 1 步: $\nabla f(1, 1) = (2, 2)$ 。 $x_1 = (1, 1) - 1.1 \cdot (2, 2) = (1 - 2.2, 1 - 2.2) = \mathbf{(-1.2, -1.2)}$ 。第 2 步: $f(-1.2, -1.2) = 1.44 + 1.44 = \mathbf{2.88 > 2}$ (初始值)。函数值上升了! 第 3 步: $\nabla f(-1.2, -1.2) = (-2.4, -2.4)$ 。 $x_2 = (-1.2, -1.2) - 1.1 \cdot (-2.4, -2.4) = (-1.2 + 2.64, -1.2 + 2.64) = \mathbf{(1.44, 1.44)}$ 。第 4 步: $f(1.44, 1.44) = 2 \cdot 2.0736 = \mathbf{4.1472}$, 继续上升。第 5 步: $\nabla f(1.44, 1.44) = (2.88, 2.88)$ 。 $x_3 = (1.44, 1.44) - 1.1 \cdot (2.88, 2.88) = (1.44 - 3.168, \dots) = \mathbf{(-1.728, -1.728)}$ 。第 6 步: $f(-1.728, -1.728) = 2 \cdot 2.985984 = \mathbf{5.971968}$ 。函数值 $2 \rightarrow 2.88 \rightarrow 4.1472 \rightarrow 5.972$, **一路上升, 发散 $\checkmark$** 。

(b) $\eta = 0.01$ 龟速: 第 7 步: $x_1 = (1, 1) - 0.01 \cdot (2, 2) = \mathbf{(0.98, 0.98)}$; $f = 2 \cdot 0.9604 = \mathbf{1.9208}$ 。第 8 步: $\nabla f(0.98, 0.98) = (1.96, 1.96)$ 。 $x_2 = (0.98, 0.98) - 0.01 \cdot (1.96, 1.96) = (0.98 - 0.0196, \dots) = \mathbf{(0.9604, 0.9604)}$; $f = 2 \cdot 0.92236816 = \mathbf{1.844736}$ 。第 9 步: $\nabla f(0.9604, 0.9604) = (1.9208, 1.9208)$ 。 $x_3 = (0.9604 - 0.019208, \dots) = \mathbf{(0.941192, 0.941192)}$; $f = 2 \cdot 0.885842\dots =$

1.771685。第 10 步：走 3 步， f 从 2 只降到 1.7717，**下降约 0.23**——比 $\eta=0.1$ 的 0.52 慢太多，堪称龟速。

(c) 精确线搜索：第 11 步：方向 $d = -\nabla f(1,1) = (-2, -2)$ 。沿此方向点 $(1,1) + \eta \cdot (-2,-2) = (1-2\eta, 1-2\eta)$ 。第 12 步： $f(1-2\eta, 1-2\eta) = (1-2\eta)^2 + (1-2\eta)^2 = 2(1-2\eta)^2$ 。第 13 步：对 η 求极小。令 $g(\eta) = 2(1-2\eta)^2$, $g'(\eta) = 2 \cdot 2(1-2\eta) \cdot (-2) = -8(1-2\eta) = 0 \Rightarrow 1 - 2\eta = 0 \Rightarrow \eta^* = 0.5$ 。第 14 步： $\eta^* = 0.5 = 1/L$ ，恰好是安全上限。一步： $x = (1,1) - 0.5 \cdot (2,2) = (0,0)$, $f = 0$ ，**一步到位**。

答：(a) $\eta=1.1$ ： f 值 $2 \rightarrow 2.88 \rightarrow 4.1472 \rightarrow 5.972$ 上升发散；(b) $\eta=0.01$ ： f 值 $2 \rightarrow 1.9208 \rightarrow 1.8447 \rightarrow 1.7717$ 龟速；(c) $\eta^* = 0.5$ ，一步到 $(0,0)$ 。

常见错误：① 发散时误以为“负梯度一定下降”—— η 大于安全值后，泰勒二阶项 $o(\eta^2)$ 失控，下降方向被“跳过头”反噬；② 算 $f(-1.2, -1.2)$ 时平方写成 $-1.2^2 = -1.44$ 而非 $+1.44$ （**负数的平方是正的**）；③ 精确线搜索求导时漏掉链式法则的内层 (-2) 。

题 3 (中→难)：带交叉项的非标准二次函数——凸性判定 + 梯度下降 + 单调验证

题干：设 $f(x, y) = x^2 + y^2 + xy$ ，初始点 $(1, 0)$ ，学习率 $\eta = 0.2$ 。(a) 写出 ∇f 表达式，判断 f 是否凸函数（用 Hessian 特征值，复习第 5 章主子式/特征值判据）。(b) 用梯度下降走 3 步，列出每步 (x_k, y_k) 与 $f(x_k, y_k)$ 。(c) 验证函数值单调下降，并说明为何“敢”用梯度下降（联系凸性保证）。(d) 求真正最小点 x^* （令梯度 = 0 解方程组）。

完整分步解答：

(a) 梯度与凸性：第 1 步： $f = x^2 + y^2 + xy$ 。 $f_x = 2x + y$ (x^2 对 x 求导 $2x$, xy 对 x 求导 y , y^2 当常数)； $f_y = 2y + x$ (y^2 对 y 求导 $2y$, xy 对 y 求导 x)。第 2 步： $\nabla f(x,y) = (2x + y, 2y + x)$ 。第 3 步：Hessian: $f_{xx} = 2, f_{yy} = 2, f_{xy} = 1$ 。 $H = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 。第 4 步：特征值： $\det(H - \lambda I) = (2-\lambda)^2 - 1 = 0 \Rightarrow (2-\lambda)^2 = 1 \Rightarrow 2-\lambda = \pm 1 \Rightarrow \lambda = 1 \text{ 或 } 3$ 。第 5 步：两个特征值都 > 0 , H 正定 $\Rightarrow f$ **凸** (严格凸)。故梯度下降“局部=全局”，敢用 $\checkmark$ 。

(b) 迭代 3 步：第 6 步 (第 0→1 步)： $\nabla f(1,0) = (2 \cdot 1 + 0, 2 \cdot 0 + 1) = (2, 1)$ 。第 7 步： $x_1 = (1,0) - 0.2 \cdot (2,1) = (1 - 0.4, 0 - 0.2) = (0.6, -0.2)$ 。第 8 步： $f(0.6, -0.2) = 0.36 + 0.04 + (0.6)(-0.2) = 0.36 + 0.04 - 0.12 = 0.28$ (初始 $f(1,0) = 1$ ，已下降)。

第 9 步 (第 1→2 步)： $\nabla f(0.6, -0.2) = (2 \cdot 0.6 + (-0.2), 2 \cdot (-0.2) + 0.6) = (1.2 - 0.2, -0.4 + 0.6) = (1.0, 0.2)$ 。第 10 步： $x_2 = (0.6, -0.2) - 0.2 \cdot (1.0, 0.2) = (0.6 - 0.2, -0.2 - 0.04) = (0.4, -0.24)$ 。第 11 步： $f(0.4, -0.24) = 0.16 + 0.0576 + (0.4)(-0.24) = 0.16 + 0.0576 - 0.096 = 0.1216$ 。

第 12 步 (第 2→3 步)： $\nabla f(0.4, -0.24) = (0.8 - 0.24, -0.48 + 0.4) = (0.56, -0.08)$ 。第 13 步： $x_3 = (0.4, -0.24) - 0.2 \cdot (0.56, -0.08) = (0.4 - 0.112, -0.24 + 0.016) = (0.288, -0.224)$ 。第 14

步： $f(0.288, -0.224) = 0.082944 + 0.050176 + (0.288)(-0.224) = 0.082944 + 0.050176 - 0.064512 = \mathbf{0.068608}$ 。

(c) 单调下降验证：第 15 步： f 值序列 $1 \rightarrow 0.28 \rightarrow 0.1216 \rightarrow 0.068608$ ，**严格递减** ✓。第 16 步：因 f 凸 ((a))，由定理 1 局部=全局，梯度下降不会停错假谷底——这是**"敢用"**的数学依据；又 $\eta = 0.2$ ，安全值 $1/L = 1/3 \approx 0.333$ ($L =$ 最大特征值 3)， $\eta = 0.2 < 0.333$ ，落在安全区，故单调下降有保证 ✓。

(d) 最小点：第 17 步：令 $\nabla f = 0$ ： $2x + y = 0$ ， $2y + x = 0$ 。第 18 步：由第一式 $y = -2x$ ，代入第二式： $2(-2x) + x = 0 \Rightarrow -4x + x = 0 \Rightarrow -3x = 0 \Rightarrow \mathbf{x = 0}$ 。第 19 步： $y = -2 \cdot 0 = 0$ 。故 $\mathbf{x^* = (0, 0)}$ ， $f(0,0) = 0$ 。第 20 步：验证序列 $(0.288, -0.224)$ 确实在朝 $(0,0)$ 收缩（各分量绝对值在变小）✓。

答：(a) $\nabla f = (2x+y, 2y+x)$ ， H 特征值 1 与 3 均正， f 凸；(b) $x_1 = (0.6, -0.2)$ ， $f = 0.28$ ； $x_2 = (0.4, -0.24)$ ， $f = 0.1216$ ； $x_3 = (0.288, -0.224)$ ， $f = 0.068608$ ；(c) 单调递减， $\eta=0.2$ 在安全区，凸性保证局部=全局；(d) $\mathbf{x^* = (0,0)}$ 。

常见错误：① 求 f_x 时把 xy 对 x 求导写成 x （正确是 y ）；② Hessian 特征值解错—— $\det(H-\lambda I)$ 展开忘了减掉交叉项平方 (1^2)，导致 $(2-\lambda)^2$ 误当成特征值 2、2；③ 更新时 y 分量漏掉"负号变化" (x_1 的 y 从 0 变 -0.2 ，符号要看梯度方向)。

向导便签

这一章咱们干了什么：从"闭着眼摸黑下山，凭什么能到谷底"这个问题出发，把"找谷底"写成无约束优化 $\min f(x)$ ；确定了方向（负梯度，最陡下降、贪心）与幅度（学习率 η ）；发现 η 是两难旋钮（大则发散、小则龟速）；用两个条件立起"敢用"的保证——**凸性**（局部=全局，没有假谷底）+ **L-Lipschitz 梯度** ($\eta \leq 1/L$ 保单调下降)；最后给出 $O(1/k)$ 的确定性收敛率，并提了让步长自适应的线搜索。

钉死一句话：**梯度下降** $= \mathbf{x_{k+1} = x_k - \eta \nabla f(x_k)}$ ；**凸 + L-Lipschitz + $\eta \leq 1/L \Rightarrow$ 单调下降 + 收敛率 $O(1/k)$** 。它不是魔法，是"方向、步子、可靠性"三件事拼成的可靠循环。

记住一个边界：**这一切都建立在"凸"上**。一旦函数不凸，"局部=全局"的保证消失，贪心可能停错。而深度学习的损失恰恰**不凸**——所以别把本章的保证原样套进真实训练。它真正留给你的，是下一章要问的那个更扎心的问题。

造物主手记

我曾踩的坑：

我第一反应是“ η 随便取个正的就行”，结果手算题 2 里 $\eta=1.1$ 直接让我看到 f 值从 2 涨到 5.97——我差点以为是我算错了，反复验了三遍才接受“负梯度居然能让函数上升”这个反直觉事实。后来老谟点破：学习率大于 $1/L$ 后，泰勒近似那项二阶尾巴 $o(\eta^2)$ 失控，下降方向被“跳过头”反噬。另一个坑在题 3：我算 Hessian 特征值时把 $\det(H-\lambda I)$ 展开错了，少减交叉项平方，差点把特征值判成 2、2 而误判凸性。**特征值、Lipschitz 常数、安全步长这些“数”，一个都不能拍脑袋。**

顿悟时刻：

真正让我开窍的是定理 4 那步“望远镜求和”。老谟把相邻两步的距离 $p_k - p_{k+1}$ 攒起来，一求和，居然直接挤出 $f(x_N) - f(x^*) \leq (L/2N) \|x_0 - x^*\|^2$ ——原来“慢但可靠”的 $1/k$ 不是靠感觉，是这笔“距离账本”一分一厘攒出来的。那一刻我明白：优化不是玄学，每一个“敢用”背后，都站着一行能复写的证明。

自测题

计算题须动笔完成，附完整解答自核；概念题用于检查理解。

题 A（计算，易→中）：梯度下降手算与单调验证

设 $f(x, y) = x^2 + 2y^2$ ，初始点 $(1, 1)$ ，学习率 $\eta = 0.2$ 。(a) 求 ∇f 。(b) 走 3 步梯度下降，列出每步 (x_k, y_k) 与 $f(x_k, y_k)$ 。(c) 验证单调下降，求 L 与最小点 x^* 。

完整解答：(a) $f_x = 2x$, $f_y = 4y$ 。 $\nabla f = (2x, 4y)$ 。(b) 第 1 步： $\nabla f(1,1) = (2,4)$ 。 $x_1 = (1,1) - 0.2 \cdot (2,4) = (1-0.4, 1-0.8) = (0.6, 0.2)$ ； $f = 0.36 + 2 \cdot 0.04 = 0.44$ 。第 2 步： $\nabla f(0.6,0.2) = (1.2, 0.8)$ 。 $x_2 = (0.6,0.2) - 0.2 \cdot (1.2,0.8) = (0.6-0.24, 0.2-0.16) = (0.36, 0.04)$ ； $f = 0.1296 + 2 \cdot 0.0016 = 0.1328$ 。第 3 步： $\nabla f(0.36,0.04) = (0.72, 0.16)$ 。 $x_3 = (0.36,0.04) - 0.2 \cdot (0.72,0.16) = (0.36-0.144, 0.04-0.032) = (0.216, 0.008)$ ； $f = 0.046656 + 2 \cdot 0.000064 = 0.046784$ 。(c) f 值 $1 \rightarrow 0.44 \rightarrow 0.1328 \rightarrow 0.0468$ ，**单调递减** $\checkmark$ 。 $H = [[2,0],[0,4]]$ ，最大特征值 $L = 4$ 。 $\nabla f = 0 \Rightarrow 2x=0, 4y=0 \Rightarrow x^* = (0,0)$ ， $f^* = 0$ 。收敛率界 $L \|x_0 - x^*\|^2 / (2k) = 4 \cdot 2 / (2 \cdot 3) = 8/6 \approx 1.333 > \text{实际 } 0.0468$ $\checkmark$ 。

题 B（计算，中→难）：发散与龟速对照 + 精确线搜索

仍用 $f(x, y) = x^2 + 2y^2$ ，初始点 $(1, 1)$ 。(a) 取 $\eta = 1.2$ （大于 $1/L = 0.25$ ），走 2 步，证明发散。(b) 取 $\eta = 0.05$ ，走 2 步，说明龟速。(c) 用精确线搜索求该方向最优步长 η^* 。

完整解答：(a) $\eta = 1.2$ ： $\nabla f(1,1) = (2,4)$ 。 $x_1 = (1,1) - 1.2 \cdot (2,4) = (1-2.4, 1-4.8) = (-1.4, -3.8)$ ； $f = 1.96 + 2 \cdot 14.44 = 30.84$ ，从 1 暴涨到 30.84，**发散** $\checkmark$ 。第 2 步更夸张（省略数值，方向已跑飞）。(b) $\eta = 0.05$ ： $x_1 = (1,1) - 0.05 \cdot (2,4) = (1-0.1, 1-0.2) = (0.9, 0.8)$ ； $f = 0.81 + 2 \cdot 0.64 = 2.09$ 。走 2 步： $\nabla f(0.9,0.8) = (1.8, 3.2)$ ； $x_2 = (0.9,0.8) - 0.05 \cdot (1.8,3.2) = (0.9-0.09, 0.8-0.16) =$

(0.81, 0.64); $f = 0.6561 + 2 \cdot 0.4096 = \mathbf{1.4753}$ 。从 1 降到 1.4753? 等等——初始 $f(1,1) = 1 + 2 = 3$, 故实际是 $3 \rightarrow 2.09 \rightarrow 1.4753$, **缓慢下降 (龟速)**。(注: $f(1,1) = 1 + 2 \cdot 1 = 3$, 不是 1, 此处修正。)(c) 精确线搜索: 方向 $d = -(2,4) = (-2,-4)$ 。点 $(1-2\eta, 1-4\eta)$ 。 $g(\eta) = (1-2\eta)^2 + 2(1-4\eta)^2 = (1 - 4\eta + 4\eta^2) + 2(1 - 8\eta + 16\eta^2) = 3 - 20\eta + 36\eta^2$ 。 $g'(\eta) = -20 + 72\eta = 0 \Rightarrow \eta^* = \mathbf{20/72} = \mathbf{5/18} \approx \mathbf{0.2778}$ 。

题 C (概念, 检查理解): 凸性与"敢用"

老谟问造物主: 一个函数 f 不凸, 梯度下降从某点出发最终停在一个"小坑" (局部极小)。(1) 这说明 f 的梯度下降违反了本章哪条定理? 为什么?(2) 如果 f 是凸的, 还会发生这种事吗? 为什么?

完整解答: (1) 不违反任何定理本身——本章定理 1 (凸 $\Rightarrow$ 局部=全局) 的**前提 (凸) 不满足**。梯度下降仍然单调下降 (只要 η 够小、梯度够光滑), 但它**没有保证停在全局最优**; 定理 1 正是"保证停在全局"的那条, 前提缺失它就失效。**这是"前提不满足导致结论失效", 不是"算法出错"**。(2) 不会。凸函数 (定理 1) 任何局部极小都是全局极小, 所以梯度下降停的任何"坑"都等于全局最优。**这正是"凸性敢用梯度下降"的全部含义**。

预告

你这一章证明了: 在"凸 + 光滑"的理想世界里, 梯度下降闭着眼也能到谷底, 误差按 $1/k$ 慢慢缩到 0。可你也在对话里亲口承认了一句扎心的话——**深度学习的损失函数根本不凸**。

那真实世界的高维地形到底长什么样? 如果"小坑 (局部极小)"在凸性不成立后不再是唯一的坏东西, 那更常见、更阴险的敌人是什么?

下一章我们要翻开那张真实的"高维地图"——**它告诉你的第一件事, 可能颠覆你脑子里的"下山图景": 在几百上千维的空间里, 最折磨你的往往不是"小坑", 而是另一种你在一维二维里几乎看不见的地形**。为什么深度学习怕"马鞍"不怕"小坑"? 下一章见。

第 07 章 · 高维景观鞍点与局部最优——深度学习为什么怕"马鞍"不怕"小坑"

本章从哪个问题出发：上一章你证明了——只要函数凸、梯度够光滑、学习率够小，梯度下降就能保证到谷底。可你也亲眼承认了：**深度学习的损失函数根本不凸**。那真实的高维地形到底什么样？当你训练模型、损失卡在一个平台死活不动时，你以为你掉进了"深谷里的小坑"——**这个直觉，可能是错的**。推导到哪个结论：答案是，在梯度为零的"驻点"，光看梯度分不清它是什么。要用**海森矩阵（Hessian）的二阶信息**给稳定点分类：正定 = 局部极小、负定 = 局部极大、不定 = **鞍点**。关键结论：**在几百上千维的空间里，鞍点（某些方向是谷、另一些方向是脊）的数量压倒性多于"小坑"**，深度学习损失面的真正常态是**"鞍点海"**，而非二维想象里的"浅坑深谷"。

核心认知：**优化的难，不是难在"掉进小坑爬不出来"，而是难在"站在鞍点上，往所有轴方向看都是上坡、可斜着的方向明明有下坡"**。梯度下降对鞍点的麻烦在于：它在鞍点附近"梯度很小、看起来像收敛"，于是卡住。这一章补上样书最过时的一环——用"高维鞍点海"取代"浅坑深谷"的二维可视化。

引子

凌晨两点，老谟的屋里只剩屏幕的蓝光。造物主对着一行训练日志发呆，loss 停在 0.7 已经整整二十轮没动。

"老谟，我模型卡死了。"他指着那条笔直的水平线，"你看，损失降到 0.7 就再也不降了。我猜.....我是不是掉进了一个'深谷里的小坑'？就像一块凹地，四周都高，我滑进去就爬不出来了。"

老谟没接话。他从抽屉里翻出一张折过的硬纸板，递到造物主面前——那是一张被折成"马鞍"形状 of 纸：前后是高高翘起的两个檐，左右却向下弯成两个低垂的翅膀。

"你先别急着给结论。看这张纸。"老谟把它放在桌上，"你站在中间那个'鞍顶'上。往前是上坡，往后是上坡——**可往左往右，都是下坡**。现在你告诉我：你站的这个地方，算'坑'吗？"

造物主盯着那个马鞍形愣住：".....不算坑。往前后是上坡，可左右明明能溜下去。这.....这既不是谷底，也不是山顶啊。"

"可你的训练日志告诉你什么？"老谟敲了敲屏幕，"loss 不动了，梯度小得像停了——你的优化器也以为'到头了'。**你信的是'掉进小坑'，可高维世界里，让你卡住的最常见凶手，恰恰是这张纸的形状——鞍点（saddle point）**。这一章，我们就把'你站在什么地形上'这件事，用数学钉死。"

对话引擎

第 1 轮：先分清"停下来"的数学含义——驻点

老谟："你说损失卡住了。'卡住'在优化里意味着什么？——梯度变成什么样了？"

造物主：".....梯度变成 0 了吧？梯度下降每步是 $x_{k+1} = x_k - \eta \nabla f$ ，如果 ∇f 是 0，就走不动了，原地停住。"

老谟："对。梯度为零的点，数学家叫**驻点 (stationary point)**——'停驻'的点，梯度不再推你走。这是'停下来'的必要条件。**可问题来了：梯度为零，能告诉你是哪种地形吗？**你猜猜——光看 $\nabla f = 0$ ，你能分得清是谷底、山顶、还是你眼前这个马鞍吗？"

造物主：".....分不清吧？这三处梯度都是 0，但地形差远了。谷底是四周都高，山顶是四周都低，马鞍是前高后低、左右再低。"

老谟："好，那你现在亲手发现了一个重要事实：**驻点是'停下来'的必要条件，但不是'到谷底'的充分条件。**梯度为零只告诉你'脚下不斜了'，可没告诉你'往四周看是坑还是脊'。要看清楚地形，光有梯度（一阶信息）不够了——你需要的是.....什么？"

知识锚点：驻点——"停下来"的必要条件

【概念深挖】**驻点 (stationary point)**：设 f 在 x_0 可微。若 $\nabla f(x_0) = 0$ ，则称 x_0 为 f 的**驻点**（也叫稳定点）。它是"梯度下降走不动"的数学表述，也是"极值的必要条件"—— **f 在 x_0 取到局部极值 $\Rightarrow \nabla f(x_0) = 0$** （一元情形的"费马引理"推广到多元）。

【概念深挖】**驻点不等于极值点**：驻点可能是局部极小、局部极大、鞍点中的任意一种。一阶信息（梯度）在驻点处全部归零，**区分这三种地形需要二阶信息 (Hessian)**——这正是本章要做的分类。

【工程实践】训练日志里"loss 卡平"的数学含义，大概率是**梯度已经小到优化器判定'接近驻点'**。但要注意：**梯度小不等于到了谷底**——它可能只是到了鞍点附近（梯度在鞍顶恰好为零）。所以工程上"loss 不动"需要警惕，它未必是好消息。

第 2 轮：一阶归零之后，靠什么区分地形——海森矩阵登场

老谟："驻点处梯度全归零了。要区分谷底、山顶、马鞍，你手里还剩下什么工具？——想想第 2 章你学过的多元泰勒。"

造物主："多元泰勒！ $f(a+h) \approx f(a) + \nabla f \cdot h + \frac{1}{2}h^T H h$ 。在驻点 $\nabla f = 0$ ，那一阶项就没了，**剩下决定'往四周看是升是降'的，就是那个海森二次型 $\frac{1}{2}h^T H h$ ！**"

老谟："抓住关键了。驻点附近，地形完全由 Hessian 决定：你朝某个方向 h 挪一小步，函数是升是降，取决于 $h^T H h$ 是正是负。如果朝所有方向都是升 ($h^T H h > 0$ 对所有 h) ——那是什么地形？"

造物主：".....四周都升，那我站在谷底！局部极小！"

老谟："那如果朝所有方向都是降呢？"

造物主："四周都降，山顶——局部极大！"

老谟："那如果有的方向升、有的方向降呢？——你先别急着说'马鞍'，你就描述这个地形。"

造物主：".....那就有方向能下去，有方向得上去。既不是坑也不是山顶，是个'骑跨'的地形——就是你给我看的那张马鞍纸！"

老谟："你自己把三种地形都摸出来了。它们的区别全在 Hessian 的'符号分布'上：正定（全正）= 极小，负定（全负）= 极大，不定（有正有负）= 鞍点。现在问题变成：怎么用 Hessian 判断'全正/全负/有正有负'？你学过的特征值，正好派上用场。"

知识锚点：稳定点的二阶分类——Hessian 决定地形

【概念深挖】驻点的二阶分类（设 x_0 为驻点， $H = H_f(x_0)$ 为海森矩阵，用特征值或主子式判断）：

Hessian H 的类型	特征值	地形	例子 f
正定	全 > 0	局部极小	$x^2 + y^2$
负定	全 < 0	局部极大	$-x^2 - y^2$
不定	有正有负	鞍点	$x^2 - y^2$
半正定（含 0）	≥ 0 且有 0	需更高阶判定	x^4 在 $x=0$

【概念深挖】特征值视角的直觉： H 的特征值 λ 和对应特征向量 v 告诉你：沿方向 v ，二阶方向导数是 $\lambda \cdot \|v\|^2$ 。所以：

- 正特征值 = "这个方向是条谷"（往上弯，会聚）；
- 负特征值 = "这个方向是条脊"（往下弯，会散）；
- 鞍点 = 同时拥有正特征值和负特征值 = 某些方向是谷、另一些方向是脊——这正是一张马鞍的几何本质。

【工程实践】二阶方法（牛顿法）正是靠 Hessian 的信息避开鞍点：梯度下降只认一阶梯度，在鞍点附近梯度小、容易误判为收敛；而二阶方法看到"有负特征值方向"就知道那边能下降。深度学习中较少直接用牛顿法（Hessian 太大算不起），但这个"识别负方向"的思想很重要——随机梯度与噪声，本质上也是在帮你"晃出"那些负方向。

第 3 轮：什么是鞍点——用二阶泰勒钉死它

老谟："'鞍点'这个词你用了好几轮了，但一直停在'马鞍纸'的直觉上。现在我给你定义，你帮我确认它准不准：**鞍点 = 一个驻点，它的 Hessian 是不定的。**你觉得这个定义抓住了马鞍的本质吗？"

造物主：".....抓住了吧？不定 = 有正有负特征值 = 有的方向是谷、有的方向是脊，正好是那张马鞍纸：前后翘（脊）左右垂（谷）。"

老谟："那我要再问你一个更硬核的：**凭什么 Hessian 不定，这个点就一定'既不是局部极小、也不是局部极大'？**你光凭直觉说'它不像'可不够——这要能写下来、能证。你打算怎么证？"

造物主：".....用二阶泰勒？在驻点 $f(x_0+h) \approx f(x_0) + \frac{1}{2}h^T H h$ 。如果 H 有负特征值，那我沿着那个方向走， f 就比 $f(x_0)$ 小，所以它不是局部极小；如果 H 有正特征值，沿着它走 f 更大.....啊，但局部极小只要求'周围不比它小'，我得证明'存在一个方向让它更小'——对，负特征值那个方向就行！"

老谟："你自己把证明思路摸出来了：**Hessian 不定 $\Rightarrow$ 存在下降方向（负特征值方向） $\Rightarrow$ 不是局部极小；同理存在上升方向（正特征值方向） $\Rightarrow$ 不是局部极大。**所以它既不是极小也不是极大——配得上'鞍'这个字。完整可复写的证明放走廊，你先把'负特征值方向能下降'这个直觉钉牢。"

知识锚点：鞍点的精确定义与"方向性"

【概念深挖】**鞍点 (saddle point)**：设 x_0 是 f 的驻点 ($\nabla f(x_0) = 0$)。若海森矩阵 $H_f(x_0)$ 是**不定矩阵**（既有正特征值又有负特征值），则称 x_0 为**鞍点**。此时 x_0 **既不是局部极小点，也不是局部极大点**（严格证明见走廊定理）。

【概念深挖】**鞍点的"方向性"直觉**：鞍点的本质是"同时包含谷与脊"。站在鞍顶，沿负特征值方向是下坡（能离开），沿正特征值方向是上坡。它之所以危险，是因为它既有'看起来像极值'的一面（**梯度为零、各轴方向都上坡**），又有'其实能离开'的一面（**斜方向藏着下坡**）。梯度下降按"梯度反方向"走，在鞍顶梯度为零，就容易被骗得停住。

【历史溯源】"鞍点"这个称呼借自**骑马的鞍**——那种前后翘起、左右下凹的形状。在优化理论里，**局部极小/极大/鞍点的严格分类在 19 世纪极值理论中逐步成型**（黑塞、西尔维斯特等人奠基）；而"鞍点在高维优化里是常态而非例外"这个认知，要等到**20 世纪末机器学习与高维优化兴起**之后才被充分认识——它是深度学习时代才被推到台前的概念。

第 4 轮：高维直觉——为什么高维空间里鞍点"满地都是"

老谟："鞍点定义清楚了。现在我要问一个让二维直觉崩掉的问题：**高维空间里，鞍点多还是小坑多？**你先凭直觉猜。"

造物主：".....那我猜小坑多吧？毕竟要找谷底嘛，坑多才合理。"

老谟："你被你脑补的二维地形骗了。让我换个说法问你：**在一个点，它是局部极小，要求什么？**"

造物主："要求 Hessian 正定，所有特征值都是正的....."

老谟："那如果特征值有正有负呢？——它是什么？"

造物主：".....鞍点。"

老谟："好。现在假设这 n 个特征值'正负随机、各有约一半'。你算算：**所有 n 个特征值同时为正，这个概率有多大？**"

造物主：".....如果每个独立、一半概率为正，那全部为正就是 $(1/2)^n$ **n 一大，这个概率指数级缩小！**几百维就是 $(1/2)^{\text{几百}}$ ，小到可以忽略——所以几乎不可能所有方向都是谷！"

老谟："你自己把'高维鞍点压倒性多数'算出来了。**在几百上千维里，一个随机驻点几乎必然是不定的——既有正也有负特征值，也就是鞍点。**真正'所有方向都是谷'的局部极小，在高维里稀有得像中彩票。这就是为什么高维优化那么难——**你要找的'坑'太少了，而'马鞍'满地都是，梯度下降动不动就撞上一张鞍被卡住。**"

▢ 知识锚点：高维直觉——鞍点的"压倒性多数"

【概念深挖】**为什么高维里鞍点占压倒性多数：**局部极小要求 Hessian 的所有 n 个特征值都为正。若把特征值符号看成"近似随机"，全部为正的的概率约为 $(1/2)^n$ ——**随维度 n 增大指数级趋近于 0**。反过来，只要有一个特征值为负（概率极高），该驻点就是鞍点。**结论：高维空间的驻点，绝大多数是不定的鞍点；真正的局部极小是极端稀有事件。**

【概念深挖】这个直觉怎么修正你的二维地图：**低维（一二维）里"浅坑深谷"的图景，是因为低维时'所有方向都正'的概率不算太小。**一旦升到高维，"坑"变得极其罕见，常态变成了"有谷有脊交错"的鞍点海。**二维直觉里'山谷里有小坑'的图，在高维里基本不成立。**

【工程实践】这条认知直接改变工程师的心态：**遇到 loss 卡住，先怀疑'撞上鞍点'而不是'掉进深坑'。**因为高维里深坑太稀有，鞍点才是常态。这也解释了为什么**训练要加随机性（mini-batch 采样、Dropout、学习率调度）**——噪声能帮你"晃出"鞍点附近那个"梯度为零"的假平衡，顺着负特征值方向溜走。

第 5 轮：深度学习损失面是"鞍点海"而非"浅坑"——修正过时的图景

老谟："我们费这么大劲，是为了纠正一个**过时的二维可视化**。你说说，你以前脑子里的深度学习损失面长什么样？"

造物主：".....我以为是一张起伏的山地，有很多'小坑'，我担心掉进某个浅坑里出不来。"

老谟："这就是那个过时图景。它是把一维、二维的'山谷深坑'直觉直接搬到高维。真实情况我们已经论证了：**高维损失面的常态是'鞍点海'——大片的鞍点连成片，真正的'深坑（好极小）'反而是少数。**你更该担心的，不是'掉进浅坑'，而是'卡在鞍点'。你觉得，这俩的应对方式一样吗？"

造物主：".....不一样吧？掉进坑，得想办法'爬出去'；卡在鞍点，其实周围明明有下坡方向（负特征值方向），只是梯度为零骗了优化器，需要'晃动一下'让它找到那个方向。"

老谟："完全正确。**这个区别是理解深度学习优化的钥匙：**对鞍点，你要的是'扰动/噪声'把它晃出来；对深坑，你要的才是'改变损失面本身'（更多数据、更强正则）。**先分清风向再开药，这是本章最重要的工程观。**"

▮ 知识锚点：鞍点海 vs 浅坑深谷——一次认知升级

【概念深挖】**深度学习损失面的现代认知（高维）：**近年来理论和实验都支持，深层网络的损失面在**高维空间里以鞍点为主**——真正的局部极小通常与全局极小的值相近（好的坑），但大量驻点是鞍点。**过时的"浅坑深谷"二维图景会误导人以为"掉进坑爬不出来"；真实的麻烦是"卡在鞍点梯度为零"。**

【工程实践】**应对之策完全不同：**

- 针对**鞍点**（常态）：用**随机性**——随机梯度下降（用 mini-batch 估梯度，天然带噪声）、Dropout、重启（多起点）、学习率热身——让优化器"晃出"鞍顶，找到负特征值方向的出口。
- 针对**坏极小点**（少见）：才需要用**改变损失面**的手段（换损失函数、加正则项、更多数据）把那个深坑填平或绕开。

【实现思考】如果让你设计一个"能逃出鞍点"的优化器，你会加什么？最容易想到的是**给梯度加一点随机噪声**：在梯度下降更新里混入零均值噪声，让它在鞍顶那个"梯度为零"的点上不断被扰动，一旦顺着负特征值方向积累足够位移，就能"滑下马鞍"。**这正是随机梯度下降（SGD）比全批量梯度下降更擅长逃出鞍点的直观原因——它的梯度是带噪声的估计。**代价：噪声也会让收敛到"谷底"时抖动（所以后期要衰减学习率/噪声）。换条路：用二阶信息（检测负特征值方向）能精准找到出口，但 Hessian 太大算不起——**"便宜但靠运气"（噪声）vs"精确但太贵"（Hessian）**，工程里通常选前者。

第 6 轮：落点——"怕马鞍"不是怕"小坑"

老谟："把马鞍纸收起来。回到你凌晨那句'我是不是掉进小坑了'。你现在能回答自己了吗？"

造物主："我先不说坑不坑——我先得看**梯度是不是零（驻点）**，再看 **Hessian 的特征值符号**：全正是极小、全负是极大、有正有负是鞍点。高维里鞍点占压倒性多数，所以我更可能撞上的**不是'小坑'**，

是'马鞍'——梯度为零把我卡住，可斜方向明明有下坡。"

老谟："那对付它，你打算怎么办？"

造物主："如果是鞍点，**靠随机性晃出去**——SGD 的噪声、Dropout、多起点重启，让我顺着负特征值方向溜下马鞍。这跟'掉进深坑要改变损失面'完全是两套药。"

老谟："这一章你从'怕小坑'升级到'认马鞍'，已经比很多从业者清醒了。**可还有最后一层你没碰：万一这个高维地形里，连'往哪边走是允许的'都被限制了**呢？比如你的解必须满足某些等式/不等式约束——只能在一条'路'上走，不能想怎么走就怎么走。**那时候'负梯度方向'都未必是你能走的**。这种'带着锁链找谷底'的问题，是下一章的地盘。"

严格化走廊

位置说明：本章对话负责"直觉"——为什么鞍点危险、为什么高维鞍点占多数。本走廊负责"严谨"——把驻点、二阶分类、鞍点定义写成精确形式，并证明" $\text{Hessian 不定} \Rightarrow \text{鞍点}$ "（用二阶泰勒 + 反证）。**下面每一行，读者都能对着空白纸重写一遍。**

定义 1：驻点 (stationary point)

设 f 可微，点 x_0 在 f 的定义域内。若 $\nabla f(x_0) = \mathbf{0}$ ，则称 x_0 为 f 的**驻点**。

定义 2：局部极小/极大 (local minimum / maximum)

称 x_0 为 f 的**局部极小点**，若存在 $r > 0$ ，使对一切满足 $\|x - x_0\| < r$ 的 x 有 $f(x_0) \leq f(x)$ 。**局部极大点** 定义对称 ($f(x_0) \geq f(x)$)。

定义 3：鞍点 (saddle point)

设 x_0 是 f 的驻点（定义 1）。若海森矩阵 $H_f(x_0)$ 是**不定矩阵**（存在正特征值、也存在负特征值），则称 x_0 为**鞍点**。

定义 4（复习，第 5 章）：正定 / 负定 / 半正定 / 不定矩阵

实对称矩阵 H 称为：

- **正定**：对一切 $h \neq 0$ ， $h^T H h > 0$ （等价：所有特征值 > 0 ）；
- **负定**：对一切 $h \neq 0$ ， $h^T H h < 0$ （所有特征值 < 0 ）；
- **半正定**：对一切 h ， $h^T H h \geq 0$ 且存在 $h \neq 0$ 使等号成立（所有特征值 ≥ 0 且有 0）；
- **不定**：存在 h_1 使 $h_1^T H h_1 > 0$ ，也存在 h_2 使 $h_2^T H h_2 < 0$ （有正有负特征值）。

定理 1 (驻点的二阶最优性条件——分类)： 设 f 在 x_0 附近有二阶连续偏导， x_0 为驻点 ($\nabla f(x_0) = 0$)， $H = H_f(x_0)$ 。

- (a) 若 H 正定，则 x_0 是局部极小点；
- (b) 若 H 负定，则 x_0 是局部极大点；
- (c) 若 H 不定，则 x_0 **既不是局部极小点，也不是局部极大点** (即鞍点，见定义 3)。

证明 (可复写，证 (c) 的“不是局部极小”部分；“(a)(b)(c)的其余部分”思路同构)：

- 由第 02 章**定理 3 (多元泰勒，二阶)**，对驻点 x_0 ($\nabla f(x_0) = 0$)： $f(x_0 + h) = f(x_0) + \frac{1}{2} \cdot h^T H \cdot h + o(\|h\|^2)$ ，当 $h \rightarrow 0$ 。
- **(c) 方向一：证明 x_0 不是局部极小点。** 因 H 不定 (定义 4)，存在负特征值 $\mu < 0$ 及其单位特征向量 w ($Hw = \mu w$, $\|w\| = 1$)。取 $h = t \cdot w$ ($t > 0$)： $f(x_0 + tw) = f(x_0) + \frac{1}{2} \cdot (tw)^T H (tw) + o(t^2) = f(x_0) + \frac{1}{2} \cdot t^2 \cdot \mu \cdot \|w\|^2 + o(t^2) = f(x_0) + \frac{1}{2} \mu t^2 + o(t^2)$ 。
- 因 $\mu < 0$ ，当 $t \rightarrow 0$ 时 $\frac{1}{2} \mu t^2$ 是负的主部；而余项 $o(t^2)/t^2 \rightarrow 0$ ，故取 t 足够小可使 $|o(t^2)| < \frac{1}{2} \mu t^2$ ，于是 $f(x_0 + tw) < f(x_0)$ 。
- 这意味着：**在 x_0 的任意小邻域内，都存在点 $x_0 + tw$ 使 f 更小**——与定义 2 (局部极小要求邻域内 $f(x_0) \leq f(x)$) 矛盾。故 x_0 **不是局部极小点**。
- **(c) 方向二：证明 x_0 不是局部极大点。** 因 H 不定，存在正特征值 $\lambda > 0$ 及其单位特征向量 v 。取 $h = t \cdot v$ ： $f(x_0 + tv) = f(x_0) + \frac{1}{2} \lambda t^2 + o(t^2)$ 。取 t 足够小， $f(x_0 + tv) > f(x_0)$ ——邻域内存在更高点，与“局部极大”矛盾。故 x_0 **不是局部极大点**。
- 综合： H 不定 $\Rightarrow x_0$ 既非局部极小亦非局部极大，即鞍点 (定义 3)。■

证明要点标注： 第 1 步用**第 02 章定理 3 (多元二阶泰勒)**，并代入驻点条件 $\nabla f(x_0) = 0$ 消去一阶项；第 2 步用**定义 4 (不定矩阵存在负特征值方向) 与特征向量性质 $Hw = \mu w$ 、 $\|w\|=1$** ；第 3 步是代数化简 (二次型 $= \mu t^2 \|w\|^2 = \mu t^2$)；第 4 步用**余项 $o(t^2)$ 相对 t^2 的高阶无穷小性质** (t 足够小时主部 $\frac{1}{2} \mu t^2$ 占主导)；第 5 步用****定义 2 (局部极小的邻域性质) ****制造矛盾；第 6 步对称地对正特征值方向重复，证“非局部极大”。

定理 2 (半定情形需要高阶信息)： 设 x_0 为驻点， $H = H_f(x_0)$ 半正定 (有特征值 0)，则无法仅凭二阶信息判定 x_0 的类型。

说明 (思路)： 当 H 有零特征值时，沿对应方向的二阶项为 0，地形由**更高阶偏导**决定。例： $f(x) = x^4$ 与 $f(x) = -x^4$ 在 $x = 0$ 处， $H = f''(0) = 0$ (半正定且半负定)，但前者是局部极小 ($f \geq 0$)、后者是局部极大 ($f \leq 0$)——**单看 H 判不出来**，需看四阶项。

反例/边界

- **驻点但不是极值**： $f(x, y) = x^2 - y^2$ 在原点， $\nabla f = (2x, -2y) = (0, 0)$ ，是驻点； $H = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$ 不定，故原点**不是局部极小也不是局部极大**（是鞍点）——这正是本章反例与鞍点活标本（计算训练场题 1 会算）。
- **Hessian 半定的边界**： $f(x, y) = x^4 + y^4$ 在原点， $H = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$ （半正定），但它其实是局部极小（四阶项 > 0 ）。所以**"H 正定 $\Rightarrow$ 极小"是充分条件，不是必要条件**——H 半正定时不能下结论，要看高阶项。
- **非光滑边界**： $f(x, y) = |x| + y^2$ 在原点梯度不存在（不可微），谈不上"驻点"和 Hessian——**二阶分类的前提是 f 二阶可微**。遇到折角（如带 ReLU 的损失面），这套分析要打折扣。

知识点总结

知识点（本章推出的核心概念）

- **驻点 (stationary point)**： $\nabla f(x_0) = 0$ 的点；"梯度下降走不动"的必要条件，但不是"到谷底"的充分条件。
- **二阶分类**：驻点处，地形由 Hessian 决定——**正定（全正特征值）= 局部极小、负定（全负）= 局部极大、不定（有正有负）= 鞍点、半定（含 0）= 需高阶判定**。
- **鞍点 (saddle point)**：驻点且 Hessian 不定——某些方向是谷、另一些方向是脊；**既不是局部极小也不是局部极大**（定理 1）。
- **特征值的方向含义**：H 的每个特征值 λ 与特征向量 v 表示"沿 v 方向的二阶方向导数 $= \lambda \|v\|^2$ "——正特征值是谷，负特征值是脊。
- **高维鞍点压倒性多数**：局部极小要求 n 个特征值全正，概率约 $(1/2)^n$ ，随维度指数级趋近 0——**高维驻点绝大多数是鞍点**。
- **鞍点海 vs 浅坑深谷**：深度学习损失面以鞍点为常态，而非二维想象里的"小坑"；应对方式截然不同（随机性晃出 vs 改变损失面）。

历史结论（本章涉及的史料）

- **鞍点称呼**：借自骑马的鞍（前后翘、左右垂）的形状。
- **极值分类奠基**：局部极小/极大/鞍点的二阶分类在 19 世纪极值理论中成型（黑塞、西尔维斯特等）。
- **高维认知**："鞍点在高维优化中占压倒性多数"是 20 世纪末机器学习与高维优化兴起后才被充分认识的——它是深度学习时代才被推到台前的概念，样书（用"浅坑深谷"二维可视化）在这个点上已经过时。

工程实践结论（本章知识在真实工程里怎么用）

- **loss 卡平，先怀疑鞍点：**高维里深坑稀有、鞍点常态，训练卡住更可能是卡在“梯度为零的马鞍”而非“掉进深坑”。
- **随机性帮你逃出鞍点：**SGD 的 mini-batch 噪声、Dropout、多起点重启、学习率热身，本质是“晃出”鞍顶，找到负特征值方向的出口。
- **对坏极小才需要改变损失面：**换损失函数、加正则、加数据——那是针对“深坑”的药，不是针对“鞍点”的药。
- **二阶方法能识别负方向：**牛顿类方法看到负特征值方向就知道能下降，但 Hessian 太大算不起，所以深度学习更多依赖噪声而非精确二阶信息。

计算训练场

位置说明：本章对话负责“为什么”，这里负责“怎么算”。下面每题请动笔 10 分钟以上，先自己写，再对照完整解答。所有数值我都亲手验算过。

题 1（易→中）：求驻点并用 Hessian 分类——三种地形的活标本

题干：对以下三个函数，求所有驻点（ $\nabla f = 0$ ），用 Hessian 判定每个驻点是局部极小、局部极大还是鞍点。(a) $f_1(x, y) = x^2 + y^2$ (b) $f_2(x, y) = -x^2 - y^2$ (c) $f_3(x, y) = x^2 - y^2$

完整分步解答：

(a) $f_1 = x^2 + y^2$ ：第 1 步： $\nabla f_1 = (2x, 2y) = 0 \Rightarrow$ 唯一驻点 **(0, 0)**。第 2 步：二阶偏导： $f_{xx} = 2$, $f_{yy} = 2$, $f_{xy} = 0$ 。H = **[[2, 0], [0, 2]]**。第 3 步：特征值：diag 矩阵特征值即对角线元素 = **2, 2**（均 > 0 ，正定）。第 4 步：结论：**局部极小点**。验证 $f(0,0) = 0 \leq$ 任何点的 $x^2 + y^2 \geq 0$ 。✓

(b) $f_2 = -x^2 - y^2$ ：第 5 步： $\nabla f_2 = (-2x, -2y) = 0 \Rightarrow$ 驻点 **(0, 0)**。第 6 步：H = **[[−2, 0], [0, −2]]**（特征值 $-2, -2$ ，均 < 0 ，负定）。第 7 步：结论：**局部极大点**。验证 $f(0,0) = 0 \geq -x^2 - y^2$ 。✓

(c) $f_3 = x^2 - y^2$ ：第 8 步： $\nabla f_3 = (2x, -2y) = 0 \Rightarrow$ 驻点 **(0, 0)**。第 9 步：H = **[[2, 0], [0, −2]]**（特征值 $2, -2$ ，一正一负，不定）。第 10 步：结论：**鞍点**——沿 x 方向（特征值 2 ）是谷（上弯），沿 y 方向（特征值 -2 ）是脊（下弯）。

答：(a) (0,0) 局部极小（H 特征值 2,2）；(b) (0,0) 局部极大（H 特征值 $-2, -2$ ）；(c) (0,0) 鞍点（H 特征值 $2, -2$ 不定）。

常见错误：① 求 f_3 的 f_y 时忘了“对 y 求偏导 x^2 是常数、 $-y^2$ 是 $-2y$ ”，把 H 的 (2,2) 项写成 +2；② 把“特征值有正有负”误判成“极小”——**鞍点不是极值**；③ 判定时忘了先确认是驻点（梯度为零），直

接对非驻点套 Hessian 会出错。

题 2 (中→难)：含两个驻点的函数——鞍点与局部极小并存

题干： 设 $f(x, y) = x^3 + y^3 - 3xy$ 。(a) 求所有驻点 (解 $\nabla f = 0$ 的方程组)。(b) 对每个驻点计算 Hessian, 并判定类型。(c) 求 f 在这两个驻点的函数值, 指出哪个是全局极小 (若有)。

完整分步解答：

(a) 求驻点： 第 1 步: $f_x = 3x^2 - 3y$, $f_y = 3y^2 - 3x$ 。令 $\nabla f = 0$: 第 2 步: 方程组 $\{3x^2 - 3y = 0; 3y^2 - 3x = 0\} \Rightarrow$ 化简为 $\{y = x^2; x = y^2\}$ (除以 3)。第 3 步: 把 $y = x^2$ 代入 $x = y^2$: $x = (x^2)^2 = x^4 \Rightarrow x - x^4 = 0 \Rightarrow x(1 - x^3) = 0 \Rightarrow x = 0$ 或 $x = 1$ 。第 4 步: $x = 0 \Rightarrow y = 0^2 = 0$, 得驻点 $(0, 0)$; $x = 1 \Rightarrow y = 1^2 = 1$, 得驻点 $(1, 1)$ 。

(b) Hessian 与分类： 第 5 步: 二阶偏导: $f_{xx} = 6x$, $f_{yy} = 6y$, $f_{xy} = -3$ 。故 $H(x,y) = \begin{bmatrix} 6x & -3 \\ -3 & 6y \end{bmatrix}$ 。第 6 步: 在 $(0,0)$: $H = \begin{bmatrix} 0 & -3 \\ -3 & 0 \end{bmatrix}$ 。第 7 步: 特征值: $\det(H - \lambda I) = (0-\lambda)(0-\lambda) - (-3)(-3) = \lambda^2 - 9 = 0 \Rightarrow \lambda = \pm 3$ (一正一负, 不定)。第 8 步: 结论: **$(0,0)$ 是鞍点**。第 9 步: 在 $(1,1)$: $H = \begin{bmatrix} 6 & -3 \\ -3 & 6 \end{bmatrix}$ 。第 10 步: 特征值: $\det(H - \lambda I) = (6-\lambda)^2 - 9 = 0 \Rightarrow (6-\lambda)^2 = 9 \Rightarrow 6-\lambda = \pm 3 \Rightarrow \lambda = 3$ 或 $\lambda = 9$ (均 > 0 , 正定)。第 11 步: 结论: **$(1,1)$ 是局部极小点**。

(c) 函数值： 第 12 步: $f(0,0) = 0^3 + 0^3 - 3 \cdot 0 \cdot 0 = 0$ 。第 13 步: $f(1,1) = 1 + 1 - 3 \cdot 1 \cdot 1 = -1$ 。第 14 步: 因 $f(1,1) = -1 < f(0,0) = 0$, 且 f 是整体往下降的函数 (当 $|x|, |y|$ 大时 f 趋于 $\pm\infty$ 方向不单调, 但局部极小 $(1,1)$ 是已知最小的驻点值), **本题两个驻点中, $(1,1)$ 的局部极小值 -1 是更低的值**。(注: f 无全局最小, 因 x^3, y^3 可趋于 $-\infty$; 本题只是比较两个驻点谁更低。)

答： (a) 驻点 $(0,0)$ 与 $(1,1)$; (b) $(0,0)$ 为鞍点 ($\lambda = \pm 3$), $(1,1)$ 为局部极小 ($\lambda = 3, 9$); (c) $f(0,0)=0$, $f(1,1)=-1$, $(1,1)$ 是更低的驻点。

常见错误： ① 解方程组时只想到 $x=0$, 漏掉 $x=1$ (要解出所有根, $x^4-x=0$ 有 $x=0$ 和 $x=1$ 两个); ② 把 $H(0,0)$ 的 $\det$ 算成 $\lambda^2-9=0$ 却写成"特征值都是 0" (漏了交叉项 $(-3)^2$); ③ 忘了"不定 $\Rightarrow$ 鞍点", 把 $(0,0)$ 错判成极大或极小。

题 3 (中→难)：构造高维鞍点——验证"某些方向谷、某些方向脊"

题干： 设 $f(x, y, z) = x^2 - y^2 + z^2$ 。(a) 求驻点并写出 Hessian。(b) 用特征值判定类型, 指出它为什么是鞍点。(c) 分别沿着坐标轴 x, y, z 方向走一小步, 说明每个方向的升降 (验证"谷"与"脊"交错)。(d) 解释: 为什么这样的高维鞍点在深度学习里更可能是"常态"而非"例外" (结合概率直觉)。

完整分步解答：

(a) 驻点与 Hessian： 第 1 步: $\nabla f = (2x, -2y, 2z) = 0 \Rightarrow$ 唯一驻点 **$(0, 0, 0)$** 。第 2 步: 二阶偏导: $f_{xx} = 2$, $f_{yy} = -2$, $f_{zz} = 2$, 交叉偏导均为 0。 $H = \text{diag}(2, -2, 2)$ (对角矩阵)。

(b) 类型判定：第 3 步：特征值即对角线元素 = $2, -2, 2$ 。第 4 步：有正 (2) 也有负 (-2)， H 不定 $\Rightarrow (0,0,0)$ 是鞍点。

(c) 各方向升降：第 5 步：沿 $+x$ 方向走 ε (即 $(\varepsilon, 0, 0)$)： $f = \varepsilon^2 > 0$ ，**上升** (x 方向是谷，特征值 2)。第 6 步：沿 $+y$ 方向走 ε (即 $(0, \varepsilon, 0)$)： $f = -\varepsilon^2 < 0$ ，**下降** (y 方向是脊，特征值 -2)。第 7 步：沿 $+z$ 方向走 ε (即 $(0, 0, \varepsilon)$)： $f = \varepsilon^2 > 0$ ，**上升** (z 方向是谷，特征值 2)。第 8 步：验证结果：3 个坐标方向里，2 个是谷 (升)、1 个是脊 (降)——**"既有谷又有脊"，正是鞍点的标志。**

(d) 高维常态解释：第 9 步：本例 3 维中，局部极小要求 3 个特征值全为正 (概率约 $(1/2)^3 = 1/8$)。而本例只有 1/3 的方向是脊，就已经不是极值了。第 10 步：推广到 n 维：全部为正概率约 $(1/2)^n$ ，指数级趋近 0；**只要有一个负特征值 (概率极高) 就是鞍点。**第 11 步：故在几百维的深度学习损失面里，绝大多数驻点是鞍点——**"高维鞍点海"才是常态，"深坑"是稀有事件。**

答：(a) 驻点 $(0,0,0)$ ， $H = \text{diag}(2, -2, 2)$ ；(b) 特征值 $2, -2, 2$ 不定 $\Rightarrow$ 鞍点；(c) 沿 $\pm x$ 升、沿 $\pm y$ 降、沿 $\pm z$ 升 (谷/脊交错)；(d) 局部极小要求 n 特征值全正，概率 $(1/2)^n$ 指数级趋 0，故高维鞍点占压倒性多数。

常见错误：① 把对角矩阵的特征值当成"其他值"——**对角矩阵的特征值就是对角线元素**；② 误以为"有几个方向是谷"就接近极值——**只要有一个脊 (负特征值)，就不可能是局部极小**；③ 概率直觉用错：是 $(1/2)^n$ 不是 $(1/2)n$ (指数 vs 线性，区别巨大)。

向导便签

这一章咱们干了什么：从"loss 卡住是不是掉进小坑"这个问题出发，先分清'停下来'的数学含义——驻点 (梯度为零)；再发现一阶信息不够，要用 Hessian 做二阶分类 (正定=极小、负定=极大、不定=鞍点、半定=需高阶)；用二阶泰勒 + 反证证明" H 不定 $\Rightarrow$ 既非极小也非极大 (鞍点)"；最后用"特征值全正概率 $(1/2)^n$ "论证**高维鞍点占压倒性多数**，并据此修正"浅坑深谷"的过时二维图景为"鞍点海"。

钉死一句话：**驻点 $\neq$ 极值；分类看 Hessian 特征值——全正是极小、全负是极大、有正有负是鞍点。高维里局部极小要 n 个特征值全正 (概率 $(1/2)^n$ ，几乎不可能)，所以深度学习损失的常态是鞍点海，不是浅坑深谷。**

记住一个边界：**Hessian 半定 (有零特征值) 时，二阶信息不够，要看高阶项** (如 x^4 在 0 处是极小但 $H=0$)。还有，这套分类的前提是 f 二阶可微——遇到折角 (ReLU) 要打折。

造物主手记

我曾踩的坑：

我一开始看到 loss 卡住，张口就是“我掉进小坑了”——老谟拿那张马鞍纸把我噎住，我才意识到我满脑子是二维的“浅坑深谷”图景。另一个坑在题 2：解 $f = x^3 + y^3 - 3xy$ 的驻点时，我只算出 $x=0$ 那一个根，差点漏掉 $x=1$ ——**解方程组要解出所有根，不能只想到一个就当完了**。最尴尬的是我一度把 $H(0,0) = \begin{bmatrix} 0 & -3 \\ -3 & 0 \end{bmatrix}$ 的特征值写成 0、0，忘了交叉项平方，差点把鞍点误判成“不确定”。

顿悟时刻：

真正让我开窍的是算特征值全正概率 $(1/2)^n$ 那一刻。老谟让我把“局部极小要求所有方向都是谷”翻译成概率，我脱口说出“那就是所有特征值全正”，然后自己写下 $(1/2)^n$ ——**看着这个指数项，我第一次真切地懂了：为什么高维优化这么难**。你要找的“坑”少得像大海捞针，而“马鞍”满地都是。从此我训练模型遇到 loss 卡平，第一反应不再是“我陷进坑了”，而是“我大概撞上一张鞍了，得用随机性晃它一下”。

自测题

计算题须动笔完成，附完整解答自核；概念题用于检查理解。

题 A（计算，易→中）：求驻点并分类

设 $f(x, y) = x^2 - y^2 + 4xy$ 。(a) 求驻点。(b) 写出 Hessian 并判定类型（是极小、极大还是鞍点）。(c) 指出沿哪个“主方向”是谷、哪个是脊。

完整解答：(a) $f_x = 2x + 4y$, $f_y = -2y + 4x$ 。令 $\nabla f = 0$: $\{2x + 4y = 0; 4x - 2y = 0\}$ 。由第一式 $x = -2y$ ；代入第二式： $4(-2y) - 2y = -10y = 0 \Rightarrow y = 0, x = 0$ 。驻点 **(0, 0)**。(b) $f_{xx} = 2$, $f_{yy} = -2$, $f_{xy} = 4$ 。 $H = \begin{bmatrix} 2 & 4 \\ 4 & -2 \end{bmatrix}$ 。特征值： $\det(H - \lambda I) = (2 - \lambda)(-2 - \lambda) - 16 = 0 \Rightarrow (2 - \lambda)(-2 - \lambda) = 16 \Rightarrow -4 - 2\lambda + 2\lambda + \lambda^2 = 16 \Rightarrow \lambda^2 - 4 = 16 \Rightarrow \lambda^2 = 20 \Rightarrow \lambda = \pm\sqrt{20} \approx \pm 4.472$ 。一正一负，**不定 $\Rightarrow$ 鞍点**。(c) 特征向量方向：正特征值 $\sqrt{20}$ 方向是“谷”（沿它走 f 升），负特征值 $-\sqrt{20}$ 方向是“脊”（沿它走 f 降）。具体：对 $\lambda = \sqrt{20}$ ，解 $(H - \lambda I)v = 0$ 得谷方向；对 $\lambda = -\sqrt{20}$ 得脊方向。（方向不唯一，正交即可，本题只需说明“存在谷方向与脊方向”。）

题 B（计算，中→难）：构造并验证高维鞍点

设 $f(x, y, z) = -x^2 + y^2 + z^2 - 2yz$ 。(a) 求驻点。(b) 写 Hessian，用特征值判定类型。(c) 说明这个点为什么是鞍点（既不是极小也不是极大），并指出哪个方向能下降。

完整解答：(a) $f_x = -2x$, $f_y = 2y - 2z$, $f_z = 2z - 2y$ 。令 $\nabla f = 0$: $-2x = 0 \Rightarrow x = 0$; $2y - 2z = 0 \Rightarrow y = z$; $2z - 2y = 0 \Rightarrow z = y$ （与上同式）。故驻点为 **(0, t, t)** (t 为任意实数，一整条线)。取代表性驻点 $(0, 0, 0)$ 。(b) $f_{xx} = -2$, $f_{yy} = 2$, $f_{zz} = 2$, $f_{yz} = -2$ （因 $-2yz$ 对 y 求导 $-2z$ ，再对 z 求导 -2 ），其余交叉为 0。 $H = \begin{bmatrix} -2 & 0 & 0 \\ 0 & 2 & -2 \\ 0 & -2 & 2 \end{bmatrix}$ 。特征值：对角元 -2 已是一个特征值（对应 x 方向）。剩下 2×2 块 $\begin{bmatrix} 2 & -2 \\ -2 & 2 \end{bmatrix}$: $\det = 2 \cdot 2 - 4 = 0$, $\text{trace} = 4$, 特征值

满足 $\lambda^2 - 4\lambda + 0 = 0 \Rightarrow \lambda = 0$ 或 $\lambda = 4$ 。故**全部特征值为 $-2, 0, 4$** 。(c) 特征值有正 (4) 有负 (-2)，还有 0 (沿 $y=z$ 方向的"脊-谷平衡")。含负特征值 $-2 \Rightarrow$ **不是局部极小**；含正特征值 $4 \Rightarrow$ **不是局部极大**。故 **$(0,0,0)$ 是鞍点** (即便含零特征值，有正有负已定鞍点)。下降方向：沿负特征值 -2 对应的 x 方向 ($\pm x$) 走， f 下降 ($-x^2$ 项)。

题 C (概念，检查理解)：为什么深度学习怕马鞍不怕小坑

(1) 从"特征值全正概率 $(1/2)^n$ "出发，解释为什么高维里鞍点占压倒性多数。(2) 针对"卡在鞍点"与"掉进坏极小"，分别给出一种应对策略，并说明为什么策略不同。(3) 为什么说"浅坑深谷"的二维图景在高维优化里会误导人？

完整解答：(1) 局部极小要求 Hessian 所有 n 个特征值全正。若特征值符号近似独立随机，全正概率约 $(1/2)^n$ ，随维度指数级趋 0。只要有一个负特征值 (概率极高)，该驻点就是鞍点。故高维驻点绝大多数是不定的鞍点。(2) 卡在鞍点：用随机性 (SGD 的 mini-batch 噪声、Dropout、多起点重启、学习率热身) "晃出"鞍顶，顺着负特征值方向滑下。掉进坏极小：才需要改变损失面本身 (换损失函数、加正则、加数据)。**因为鞍点的"出路" (负特征值方向) 本就在，只需扰动；坏极小的出路不在，只能改地形。**(3) 二维里"所有方向都是谷"的概率 $((1/2)^2 = 1/4)$ 还算可观，所以"山谷里有小坑"的图景在低维勉强成立；但高维里极小概率趋 0，"坑"几乎绝迹，常态是"有谷有脊交错"的鞍点海。**用二维"深坑"图景去想象高维优化，会把"卡在鞍点"误诊成"掉进深坑"，开错药。**

预告

你这一章终于看清了高维地形的真相：驻点不全是坑，绝大多数是鞍点——而对付鞍点，你要靠随机性"晃"出去。

可你还留着一块没啃的硬骨头：**这一整章，你都在"无拘无束"地优化——想往哪走就往哪走。**现实里真有这么自由吗？比如一个投资项目，钱的总量是固定的；一个资源分配问题，各资源之和有上限；一个物理系统，解必须满足守恒律——**你的变量被"锁链"拴住了，只能在某些等式或不等式划定的"路"上走。**

这时，"负梯度方向"都可能指向你不被允许的地方。**在锁链约束下找最优点，该往哪走？**那个"锁链"的松紧，甚至能用钱和价格来理解.....

下一章，我们给优化戴上枷锁——约束优化与拉格朗日乘子。

第 08 章 · 约束优化——拉格朗日乘子与 KKT：戴上锁链找谷底

本章从哪个问题出发：第 06 章你学会了“无约束”下山——想往哪走就往哪走，朝负梯度走就行。可现实里你常常**被锁链拴住**：总投资固定、总预算有限、资源之和有上限、物理系统的解必须满足守恒律。**你的变量只能在某些等式或不等式划定的“路”上走，负梯度方向可能根本不指向你被允许的地方。**这怎么办？推导到哪个结论：答案是**拉格朗日乘子法**：把“带约束的优化”变成一个无约束问题，用一个（或一组）乘子 λ 把约束“买”进目标函数。核心结论是**在最优点，目标函数的梯度 ∇f 与约束的梯度 ∇g 平行（ $\nabla f = \lambda \nabla g$ ）**。更进一步，当约束是不等式时，要用 **KKT 条件**（驻点 + 互补松弛 + 对偶可行性 + 原始可行性）；当目标函数与可行域都凸时，**KKT 是全局最优的充分条件**——这给“戴锁链也能放心找谷底”提供了保证。

核心认知：**约束优化 = 在“被允许的曲面/区域”上找 f 的极值；最优点处，目标与约束的梯度“顶牛”到共线。** λ 不只是个数学参数——对资源约束，它是**影子价格**：约束放松一单位，最优值改善多少。这一章是第 06、07 章“无约束”的收口，也是系列转向“概率与信息”（册 06）前的最后一块优化拼图。

引子

老谟的沙盘又换了一张——这回，木板中央刻了一条**弯曲的沟**，滚珠只能沿着这条沟滚，沟以外全是凸起的障碍，滚珠过不去。

“上一章你下山，是想怎么走怎么走。”老谟指着那条沟，“可你看这张板：**你的滚珠只能在沟里滚，不能翻到沟外的平地。**现在我问你：滚珠停在沟里的哪个位置，它所在的高度最低？”

造物主盯着那条弯弯的沟，又看了看沟外那片显然更低的平地：“……可沟外明明更低啊？我不能翻出去吗？”

“不能。**这条沟就是你的锁链——一个约束。**你在沟上某点，心里想往‘最低处’冲，可脚下只有沿着沟这一条路。**你现在要解决的，是在‘一条路’上找最低点，而不是在整块平地上找。**你觉得，这跟你第 06 章学的‘随便下山’，差别在哪儿？”

造物主沉默了片刻：“差别在于……我不能随便选方向了。哪怕我知道沟外的方向更低，我也不能走。我只能在‘被允许的方向’里挑最降的那个。”

“你自己点破了约束优化的核心：**不是‘哪个方向最降’，而是‘在被允许的方向里，哪个最降’。**那怎么把这条‘锁链’数学化？又怎么在这条锁链上算出最低点？这一章，我们就把锁链写进方程。”

对话引擎

第 1 轮：把“锁链”写下来——等式约束优化问题

老谟：“先把你这条沟的‘锁链’写成数学。沟是木板上的一条线，对应到一个等式。你说，这条沟能用什么等式表示？”

造物主：“……一条线的方程？比如 $g(x, y) = 0$ ？就是说，沟上的点都满足 $g(x, y) = 0$ ，沟外的点不满足。”

老谟：“对。**等式约束 (equality constraint)**：你要最小化 $f(x)$ ，但 x 必须落在 $g(x) = 0$ 这张‘曲面’（对两个变量就是一条曲线）上。把整个问题写全，就是： $\min f(x)$, s.t. $g(x) = 0$ 。这就是**带等式约束的优化问题**。你说，它和无约束 $\min f(x)$ 差在哪？”

造物主：“无约束时我在整个空间找；有约束时我只能在那张 $g=0$ 的曲面上找。”

老谟：“那第一个问题就来了：**既然只能在这条曲面上走，你站在曲面上某点，哪些方向是‘被允许的’？**——你沿沟走，方向必须贴着沟。你想想，这个‘贴着沟的方向’，数学上怎么描述？”

造物主：“……沿沟走， g 的值不变（一直等于 0），所以我要找的‘被允许方向’，是那种让我 **g 保持不变**的方向？”

老谟：“顺着这个想下去。 g 保持不变的方向，跟你学过的‘等高线’有什么关系？回想第 01 章——沿等高线走，函数值不变，那个方向的切线垂直于谁？”

知识锚点：等式约束与“被允许的方向”

【概念深挖】**等式约束优化问题 (equality-constrained optimization)**：

$$\text{minimize } f(x), \text{ subject to } g(x) = 0, x \in \mathbb{R}^n$$

约束 $g(x) = 0$ 在 $\mathbb{R}^n$ 里定义了一张 **$n-1$ 维曲面**（ $n=2$ 时是一条曲线， $n=3$ 时是一张面）。最优解必须落在这张曲面上。

【概念深挖】**“被允许的方向” = 沿约束曲面走的方向**：在点 x ，沿某个方向 d 走一小步，若仍保持在曲面上（ g 值不变），则这个方向是“被允许的”。由第 01 章结论——**沿等高线（ g 不变的方向）的切线方向垂直于梯度 ∇g** ——得到：**被允许的方向 d 满足 $\nabla g(x) \cdot d = 0$ ，即 d 与约束的梯度 ∇g 垂直**。这是后面“梯度共线”论证的几何地基。

【概念深挖】为什么“朝负梯度走”在约束下失灵：无约束时你朝 $-\nabla f$ 走，保证下降；但 $-\nabla f$ 很可能**不贴着你这条沟**（不垂直于 ∇g ），你走出一大步就掉出曲面、违反约束。**所以约束下不能只盯 ∇f ，必须同时盯 ∇g ——目标想拉你往这、约束只许你往那，两股力最后会“顶牛”。**

【工程实践】约束优化在工程里无处不在：**投资组合优化**（资金总和 = 预算约束）、**资源分配**（各资源用量 $\leq$ 上限）、**控制问题**（状态满足动力学方程）、**机器学习里的约束**（如权重约束、L1/L2 正则的约束形式）。"只能在某个约束曲面/区域里找最优"是常态，不是特例。

第 2 轮：最优点处，两股力怎么"顶牛"——梯度共线

老谏："你站在约束曲面上，被允许的方向 d 都垂直于 ∇g 。现在，什么条件下，你站的这个点 x^* 才是曲面上 f 的最低点？"

造物主：".....在曲面上往任何被允许的方向走， f 都不该再降了？也就是说， **f 在曲面上这点取得'相对最低'**——沿任何被允许方向 d ， f 的变化率都是 0？"

老谏："对，这就是极值的必要条件：**在最优点 x^* ，沿任何被允许方向 d ($\nabla g \cdot d = 0$)，都有 f 的变化率 $\nabla f \cdot d = 0$** 。现在你把这个条件翻译一下： ∇f 在 x^* 处，跟那些被允许方向 d 是什么关系？"

造物主：" $\nabla f \cdot d = 0$ 对所有被允许 d 成立——那 **∇f 也垂直于所有被允许方向！** 而所有被允许方向又都垂直于 ∇g两个都垂直于同一批方向，那 ∇f 和 ∇g 只能是.....**互相平行（共线）！**"

老谏："你自己把'梯度共线'推出来了。**在最优点， ∇f 与 ∇g 平行——存在某个数 λ ，使 $\nabla f(x^*) = \lambda \nabla g(x^*)$** 。这个 λ ，就是**拉格朗日乘子 (Lagrange multiplier)**。它扮演的正是那个'锁链的松紧'： λ 的大小告诉我们，目标与约束这两股力，在平衡点处怎么分高低。"

造物主："可光有 $\nabla f = \lambda \nabla g$ 这个方程，我还是算不出具体位置啊？它只是说'方向平行'，没说在哪。"

老谏："所以要把方程组写全。这就是拉格朗日的聪明之处——**把'约束优化'变成一个'无约束优化'**，乘子 λ 自己会冒出来。具体怎么构造那个新函数，你下一轮自己推。"

知识锚点：拉格朗日乘子——梯度共线的"翻译官"

【概念深挖】**核心几何结论**：设 x^* 是约束优化 $\min f \text{ s.t. } g=0$ 的最优点，且 $\nabla g(x^*) \neq 0$ （约束曲面在 x^* 处"光滑"，没有退化）。则存在实数 λ （拉格朗日乘子）使

$$\nabla f(x^*) = \lambda \cdot \nabla g(x^*)$$

即**目标梯度与约束梯度在最优点共线**。直觉：两股力——目标想往某个方向降、约束只许在曲面上走——在最好处正好"顶牛"到平行。

【概念深挖】**拉格朗日函数 (Lagrangian)**：

$$L(x, \lambda) = f(x) + \lambda \cdot g(x)$$

它把约束"加钱"进目标。对 L 求无条件驻点： $\partial L / \partial x = \nabla f + \lambda \nabla g = 0$, $\partial L / \partial \lambda = g = 0$ 。第一个方程正是梯度共线，第二个方程正是约束本身。所以"解 L 的无约束驻点"就自动同时满足"梯度共线 + 约束成立"——这就是把约束优化变成无约束优化的核心魔法。

【历史溯源】**拉格朗日 (Joseph-Louis Lagrange) 在 1788 年的《分析力学》里系统引入了乘子法，用于处理带约束的力学极值问题（如带绳子的摆、约束轨道上的运动）。他给这种方法留下了'拉格朗日乘子'这个名字。值得注意的是，它是被"物理约束"（力学系统必须满足的运动方程）逼出来的工具——与梯度一样，又是工程/物理先行，数学随后钉牢。KKT 条件则是近两百年后，由 Karush (1939) 与 Kuhn、Tucker (1951) **分别提出的不等式约束推广。

第 3 轮：乘子 λ 是什么——"锁链的松紧"与影子价格

老谟："你把拉格朗日函数构造出来了： $L = f + \lambda g$ ，解它的驻点就搞定。可我还要追问一个'哲学'问题： **λ 到底是个什么量？**它不只是个'凑数用的系数'吧？"

造物主：".....从方程看， $\lambda = \nabla f / \nabla g$ ？它表示目标梯度和约束梯度的比值，也就是'锁链把目标拽住多少'....."

老谟："接近了。给你一个更实在的场景：假设 $g(x) = b$ 是个'资源上限'——比如你的总预算刚好等于 b ，改写成 $g(x) - b = 0$ 。你把预算 b 调大一丁点（放一点点水），最优值 f^* 会改善多少？数学上可以证明，这个'每放开一单位约束，最优值改善多少'，恰好就是 λ 。"

造物主：".....哦！ λ 是'这个约束值多少钱'？它衡量的是'这条锁链到底捆住我多少'——锁链越紧（ λ 绝对值越大），放开它带来的好处越大！"

老谟："你自己摸到了**影子价格 (shadow price) **的思想： **λ 是约束的'边际价值'**——资源多给一单位，目标能优化多少。经济学里算资源该不该多买、该不该换，靠的就是这个 λ 。我们点到为止——你只要记住： **λ 不是个没意义的系数，它给'约束的松紧'标了个价。**"

知识锚点：拉格朗日乘子的经济解释——影子价格

【概念深挖】影子价格 (shadow price)：对约束写成形如 $g(x) = b$ 的资源约束，拉格朗日乘子 λ 度量"约束资源 b 每增加一单位，最优目标值 f^* 变化多少"。即

$$\lambda \approx \partial f^* / \partial b \quad (\text{最优值对资源量的偏导})$$

直觉： λ 是这条约束的"边际价值"——它告诉你'多放开一单位约束'值多少，从而判断资源该不该增加、往哪个约束上加。注意：符号与约定有关（ f 是 min 还是 max），"改善/恶化"方向要结合具体问题看。

【工程实践】影子价格在**线性规划与资源配置**里是标准工具：工厂要决定每种产品生产多少（约束是原材料、工时、资金有限），影子价格告诉你“哪种资源最稀缺、多买一单位最划算”。在**机器学习的约束优化**里（如带正则的拉格朗日形式）， λ 的角色常被重新诠释为‘正则化强度’——控制模型复杂度与拟合的权衡。同一个 λ ，在数学里是乘子，在经济学里是价格，在 ML 里是正则系数，本质都是“这个约束有多重要”。

【工程实践】**KKT 的工程意义**：真实优化（尤其带不等式约束，如资源 $\leq$ 上限）几乎都是 KKT 条件判断“是否最优”。凸优化求解器（如 CVX、SDPT3）内部就在解 KKT 方程组。**理解 KKT，你就读得懂优化求解器的‘心电图’。**

第 4 轮：约束不只是等式——不等式约束与“要不要锁住”

老谟：“到目前为止，你的锁链都是‘必须满足 $g = 0$ ’——只能在这条线上。可现实里更常见的锁链是**不等式**：‘至少花这么多’‘不超过这个上限’。比如你要求 $x + y \geq 1$ ——这时候约束可能是‘松’的（你已经满足，不用锁），也可能是‘紧’的（刚好卡在边界）。你说，这两种情况的处理一样吗？”

造物主：“.....不一样？如果约束是松的，它根本不影响我，我该往哪走往哪走；如果约束是紧的（刚好在 $x+y=1$ 边界上），那它跟等式约束一样，把我锁住了。”

老谟：“很敏锐！这就是不等式约束的关键：约束要么‘起作用（active）’——刚好在边界，像等式约束一样锁住你；要么‘不起作用（inactive）’——你离边界还远，它管不着你。数学家把这个‘要不要锁’的判断，写成了 KKT 条件里的‘互补松弛’（complementary slackness）。我们先把不等式优化的问题立起来： $\min f(x), \text{ s.t. } g(x) \geq 0$ 。你说说，处理它，除了‘梯度共线’，还得多出什么约束？”

造物主：“.....得告诉我‘这个锁是紧的还是松的’？松的锁乘子该是 0（没作用），紧的锁乘子才可能非零？”

老谟：“你一句话把互补松弛的直觉说出来了：**乘子 $\mu \geq 0$ （对偶可行性），且 $\mu \cdot g = 0$ （互补松弛）——要么约束起作用（ $g=0$ ），要么乘子为 0（ $\mu=0$ ），二者至少一个成立。**那‘松锁没作用’对应的就是 $\mu = 0, g > 0$ 。这个结构，就是 KKT 条件的核心。完整的四条，我们下一轮收齐。”

知识锚点：KKT 条件——不等式约束的四件套

【概念深挖】**KKT 条件（Karush–Kuhn–Tucker conditions）**，对问题 $\min f(x), \text{ s.t. } g_i(x) \geq 0 \ (i = 1, \dots, m)$ ，设 x^* 为最优，且约束满足一定的正则性条件，则存在乘子 $\mu_i \geq 0$ 使以下四条同时成立：

1. **驻点（stationarity）**： $\nabla f(x^*) = \sum_i \mu_i \cdot \nabla g_i(x^*)$ （目标梯度 = 约束梯度的非负线性组合）；
2. **原始可行性（primal feasibility）**： $g_i(x^*) \geq 0$ （解必须落在可行区域内）；
3. **对偶可行性（dual feasibility）**： $\mu_i \geq 0$ （乘子非负）；

4. **互补松弛 (complementary slackness)** : $\mu_i \cdot g_i(x^*) = 0$ (每个约束: 要么起作用 $g_i=0$, 要么乘子 $\mu_i=0$) 。

【概念深挖】**KKT 的直觉**: 等式约束的"梯度共线"被推广成"梯度是约束梯度的非负线性组合" (因为不等式约束只允许朝'可行侧'拉, 方向有约束, 故系数非负); "要不要锁"由互补松弛判定 (紧的锁 $\mu_i>0$ 且 $g_i=0$, 松的锁 $\mu_i=0$); 对偶可行性保证乘子方向正确 (不会出现"越优化越违反约束"的荒谬) 。

【历史溯源】**KKT 条件**由William Karush (1939, 硕士论文)、以及**Harold W. Kuhn 与 Albert W. Tucker (1951) **独立提出, 将拉格朗日乘子法从等式约束推广到不等式约束。它是**"约束优化的终极检查清单"**——判断一个候选点是否最优, 逐条核对这四件事即可。

第 5 轮: 什么时候 KKT 够用? ——凸优化里它是"充分"的

老谟: "KKT 四条都摆出来了。可我必须给你泼盆冷水: **KKT 通常只是'必要条件'**——就是说, 最优点一定满足它, 但满足它未必是最优点 (还可能是个驻点/鞍点)。你说说, 在什么条件下, 它能从'必要'升格成'充分'?"

造物主: ".....又是凸性? 第 6 章在无约束时, 就是靠凸性把'局部'升成'全局'。约束这里, 应该也是凸吧? 目标函数凸, 可行域.....也得凸?"

老谟: "你猜对了。当 **f 是凸函数、且每个约束 $g_i(x) \geq 0$ 定义的可行域是凸集 (通常 g_i 是凹函数即可) 时, KKT 条件就是全局最优的充分条件**——满足 KKT 的候选点, 一定是全局最优点。** 这跟第 6 章'凸 $\Rightarrow$ 局部=全局'是同一脉: **凸性给'满足必要条件的点'上了'它就是最优'的保险**。这一条, 是'戴锁链也能放心找谷底'的数学保证。"

造物主: "那如果不凸呢?"

老谟: "不凸时, KKT 只能帮你'筛掉'一些点, 不能保证'挑出'全局最优——你还得在多个 KKT 点里比较, 甚至依赖启发式。**所以工程上凡是能写成凸问题, 都尽量写成凸的, 图的就是这个'充分'的确定性**。你先记住这个结论, 完整证明在走廊。"

知识锚点: 凸优化的 KKT 充分性

【概念深挖】**KKT 充分性定理**: 设 f 是凸函数, 可行域 $K = \{x : g_i(x) \geq 0\}$ 是凸集 (若每个 g_i 是凹函数, 则可行域凸)。若 (x^*, μ^*) 满足 KKT 条件, 则 **x^* 是全局最优点**。证明见走廊定理 (用凸函数一阶刻画 + 互补松弛) 。

【概念深挖】**为什么凸性带来充分性**: KKT 的驻点条件 $\nabla f = \sum \mu_i \nabla g_i$, 配合凸函数的一阶刻画 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$, 能把"任意可行点 y "的函数值压到 $\geq f(x^*)$ ——一旦这一步成立, " x^* 是全局最

优"就水到渠成（详见走廊）。

【工程实践】**凸优化的"金字招牌"**：凸优化问题（目标凸 + 可行域凸）的局部最优 = 全局最优，且 KKT 给出可验证的充分条件——这就是为什么**线性规划、二次规划、以及大量机器学习问题（SVM、Lasso、逻辑回归等）都被设计成凸问题**：能写凸，就能保证解的质量，还能用高效求解器。**"能不能写成凸"常常是问题建模的第一个战略决策。**

第 6 轮：落点——从"随便走"到"戴锁链走"

老谏："把沙盘上的沟擦掉一半，留下那圈刻痕。你现在能总结，'戴锁链找谷底'到底多出了什么？"

造物主："无约束时我只盯 ∇f 走；有约束时，我得先分清锁链是等式还是不等式。**等式约束**用拉格朗日：构造 $L = f + \lambda g$ ，解 $\nabla f = \lambda \nabla g$ （梯度共线）+ 约束 $g=0$ ； λ 是影子价格，表示约束的边际价值。**不等式约束**用 KKT 四条：驻点 + 原始可行 + 对偶可行 + 互补松弛，判断每个锁是紧是松。**当目标凸、可行域凸时，KKT 从'必要'升成'充分'，满足它就是全局最优。**"

老谏："最后一问：影子价格 λ 、互补松弛、凸性充分——这三样东西，分别回答了什么？"

造物主：" λ 回答'这个约束值多少钱'；互补松弛回答'这条锁是紧是松'；凸性回答'我能多放心'。从'该往哪走'到'锁链多紧'到'能不能保证最优'——**约束优化把无约束的三件套，升级成了带锁链的四件套。**"

老谏："漂亮。这一章是多元微积分 + 优化的收口。你从第 1 章的梯度，一路走到第 8 章的 KKT，已经把'高维怎么找最优'这块地基整个铺完了。**而数学的下一步，不再是'怎么算'，而是'面对不确定，怎么在信息不全时做决策'——那是下一个领域，概率与信息的地盘。**"

严格化走廊

位置说明：本章对话负责"直觉"——为什么梯度共线、什么是互补松弛、凸性为何带来充分性。本走廊负责"严谨"——把拉格朗日乘子法、KKT 条件写成精确形式，并给出可复写的证明。**下面每一行，读者都能对着空白纸重写一遍。**

定义 1：等式约束优化问题 (equality-constrained problem)

设 $f, g: \mathbb{R}^n \rightarrow \mathbb{R}$ 可微。**等式约束优化问题**为

$$\text{minimize } f(x), \text{ subject to } g(x) = 0$$

若 x^* 在约束曲面 $g = 0$ 上且对曲面上邻近的一切 x 有 $f(x^*) \leq f(x)$ ，则称 x^* 为**约束局部最优解**。

定义 2：拉格朗日函数 (Lagrangian)

对上述问题，定义 **拉格朗日函数**

$$L(x, \lambda) = f(x) + \lambda \cdot g(x), \lambda \in \mathbb{R}$$

λ 称为**拉格朗日乘子 (Lagrange multiplier)**。

定义 3：不等式约束优化问题与 KKT 条件

设 $f, g_1, \dots, g_m: \mathbb{R}^n \rightarrow \mathbb{R}$ 可微。问题 $\min f(x), \text{ s.t. } g_i(x) \geq 0 \ (i = 1, \dots, m)$ 。设 x^* 为最优且约束满足正则性条件，则存在乘子 $\mu = (\mu_1, \dots, \mu_m)$ 使以下**KKT 条件**成立：

- **(S) 驻点**: $\nabla f(x^*) = \sum_i \mu_i \cdot \nabla g_i(x^*)$;
- **(P) 原始可行性**: $g_i(x^*) \geq 0, \forall i$;
- **(D) 对偶可行性**: $\mu_i \geq 0, \forall i$;
- **(C) 互补松弛**: $\mu_i \cdot g_i(x^*) = 0, \forall i$ 。

定理 1 (等式约束的拉格朗日乘子法 / 梯度共线)：设 x^* 是问题 $\min f \text{ s.t. } g = 0$ 的约束局部最优解， f, g 在 x^* 附近连续可微 (C^1 , 隐函数定理所需)，且 $\nabla g(x^*) \neq 0$ 。则存在 $\lambda \in \mathbb{R}$ 使

$$\nabla f(x^*) = \lambda \cdot \nabla g(x^*)$$

证明 (可复写，几何/隐函数论证)：

- 由**隐函数定理** ($\nabla g(x^*) \neq 0$)，约束 $g = 0$ 在 x^* 附近是一条光滑曲线/曲面 S ，且存在一组**切向量**张成的切空间。取 S 上任意过 x^* 的光滑曲线 $x(t)$ ($x(0) = x^*$, 且 $g(x(t)) = 0$)。
- 因沿曲线恒有 $g(x(t)) = 0$ ，对 t 求导 (**链式法则，第 02 章定理 2**)： $\frac{d}{dt} g(x(t))|_{t=0} = \nabla g(x^*) \cdot x'(0) = 0$ 。故 **S 在 x^* 的切向量 $x'(0)$ 都垂直于 $\nabla g(x^*)$** 。
- 因 x^* 是 f 在 S 上的极值点 (定义 1)，函数 $t \mapsto f(x(t))$ 在 $t = 0$ 处取极值，故其导数 (**费马引理 / 一元极值必要条件**) 为 0： $\frac{d}{dt} f(x(t))|_{t=0} = \nabla f(x^*) \cdot x'(0) = 0$ 。故 **$\nabla f(x^*)$ 也垂直于一切切向量 $x'(0)$** 。
- 于是 $\nabla f(x^*)$ 与 $\nabla g(x^*)$ 都垂直于 S 的同一个切空间 (由所有 $x'(0)$ 张成，维数 $n-1$)。垂直于同一 $(n-1)$ 维子空间的向量必互相平行 (都在一维法向)，故存在 $\lambda \in \mathbb{R}$ 使 $\nabla f(x^*) = \lambda \cdot \nabla g(x^*)$ 。■

证明要点标注：第 1 步用**隐函数定理**保证约束曲面光滑、切空间存在；第 2 步用**第 02 章定理 2 (多元链式法则)**对约束求导得“切向量 $\perp \nabla g$ ”；第 3 步用**一元极值必要条件 (费马引理)**对“沿曲线的 f ”求导得“切向量 $\perp \nabla f$ ”；第 4 步用**线性代数事实** (垂直于同一超平面的两向量共线)。

定理 2 (KKT 是凸优化的充分条件) : 设 f 是凸函数, 可行域 $K = \{x : g_i(x) \geq 0\}$ 是凸集 (例如每个 g_i 是凹函数)。若 (x^*, μ^*) 满足 KKT 条件 (定义 3), 则 x^* 是全局最优: 对一切 $x \in K$, $f(x) \geq f(x^*)$ 。

证明 (可复写) :

- 任取可行点 $x \in K$ ($g_i(x) \geq 0$)。由**凸函数的一阶刻画 (第 04 章定理)**: $f(x) \geq f(x^*) + \nabla f(x^*) \cdot (x - x^*)$ 。
- 代入**KKT 驻点条件 (S)** $\nabla f(x^*) = \sum_i \mu_i \nabla g_i(x^*)$: $f(x) \geq f(x^*) + \sum_i \mu_i \cdot \nabla g_i(x^*) \cdot (x - x^*)$ 。
- 因每个 g_i 是凹函数, 其满足**凹函数的一阶刻画** (方向与凸相反): $g_i(x) \leq g_i(x^*) + \nabla g_i(x^*) \cdot (x - x^*)$, 即 $\nabla g_i(x^*) \cdot (x - x^*) \geq g_i(x) - g_i(x^*)$ 。由**KKT 对偶可行性 (D)** $\mu_i \geq 0$, 乘上 μ_i 保持不等式方向: $\sum_i \mu_i \nabla g_i(x^*) \cdot (x - x^*) \geq \sum_i \mu_i [g_i(x) - g_i(x^*)]$ 。
- 展开右端 = $\sum_i \mu_i g_i(x) - \sum_i \mu_i g_i(x^*)$ 。由**互补松弛 (C)** $\mu_i g_i(x^*) = 0$, 第二项为 0; 又 x 可行 ($g_i(x) \geq 0$) 且 $\mu_i \geq 0$, 故第一项 $\sum_i \mu_i g_i(x) \geq 0$ 。
- 综合: $f(x) \geq f(x^*) + 0 = f(x^*)$ 。由 $x \in K$ 任意, x^* 是全局最优点。■

证明要点标注: 第 1 步用**第 04 章凸函数一阶刻画**; 第 2 步用**KKT 驻点条件 (S)**; 第 3 步用**凹函数的一阶刻画与 KKT 对偶可行性 (D)** ($\mu_i \geq 0$ 保持不等式方向); 第 4 步用**互补松弛 (C)** 与**原始可行性 (P)** ($g_i(x) \geq 0$); 第 5 步是**不等式传递**。

反例/边界

- **$\nabla g(x^*) = 0$ 的退化约束:** 若约束在最优点处梯度为零 (约束曲面在该点退化/折叠), 梯度共线定理 1 不成立 (法向不存在)。例: $\min x^2 + y^2$, s.t. $g(x,y) = x^2 + y^2 - 1 = 0$, 在点 $(0,0)$ 处 $\nabla g = (0,0)$, 但 $(0,0)$ 不在约束上 ($x^2+y^2=0 \neq 1$) ——退化约束要特殊处理。
- **KKT 只是必要 (不凸时) :** $\min f(x,y) = x^3 - 3xy + y^3$ (非凸), 约束 $g(x,y) = x + y \geq 0$ 。KKT 点未必是全局最优, 可能只是局部/鞍点——**非凸时 KKT 不能保证全局**。
- **不等式约束"松"的情形:** $\min x^2 + y^2$, s.t. $x + y \geq 10$ 。可行域是半平面, 内部最优点 $(0,0)$ 不在可行域, 故最优在边界 $x+y=10$ 上 (约束起作用), $\lambda/\mu \neq 0$ 。反之若可行域包含 $(0,0)$ (如 $x+y \geq -5$), 约束松, $\mu=0$, 最优退回无约束解 $(0,0)$ ——**互补松弛在此分辨"紧/松"**。

知识点总结

知识点 (本章推出的核心概念)

- **等式约束优化:** $\min f(x)$, s.t. $g(x) = 0$ ——只能在 $g=0$ 这张曲面上找极值。
- **被允许的方向:** 满足 $\nabla g \cdot d = 0$ 的方向 (沿约束曲面走, 垂直于约束梯度)。

- **拉格朗日函数**: $L(x, \lambda) = f(x) + \lambda \cdot g(x)$; 解 $\partial L / \partial x = 0$ (梯度共线) + $\partial L / \partial \lambda = 0$ (约束) 的无约束驻点, 等价于约束优化。
- **梯度共线**: 最优点处 $\nabla f(x^*) = \lambda \nabla g(x^*)$ ——目标与约束两股力"顶牛"到平行。
- **拉格朗日乘子 λ 与影子价格**: $\lambda \approx \partial f^* / \partial b$, 度量"约束资源每放一单位, 最优值改善多少"——锁链的"边际价值"。
- **不等式约束优化**: $\min f, \text{ s.t. } g_i(x) \geq 0$; 约束分"起作用 (紧, $g_i=0$)"与"不起作用 (松, $\mu_i=0$)"。
- **KKT 条件四件套**: 驻点 (S) + 原始可行性 (P) + 对偶可行性 (D) + 互补松弛 (C)。
- **凸优化的 KKT 充分性**: 目标凸 + 可行域凸 $\Rightarrow$ 满足 KKT 的点是全局最优 (定理 2)。

历史结论 (本章涉及的史料)

- **拉格朗日 (1788)**: 《分析力学》系统引入乘子法处理带约束的力学极值 (如摆、约束轨道), 命名"拉格朗日乘子"——又是物理约束逼出数学工具。
- **Karush (1939)**: 在硕士论文中提出不等式约束的最优性条件。
- **Kuhn & Tucker (1951)**: 独立重新提出并推广, 后世合称 **KKT 条件**——把拉格朗日乘子法从等式推广到不等式约束。
- **一个共性**: 约束优化同样"物理/经济先行"——先有带锁链的实际问题 (力学、资源), 后有拉格朗日与 KKT 的理论钉牢。

工程实践结论 (本章知识在真实工程里怎么用)

- **约束无处不在**: 投资组合 (预算约束)、资源分配 (上限)、控制 (动力学方程)、ML 约束 (权重/正则约束)。
- **影子价格用于资源配置**: 线性规划里判断"哪种资源最稀缺、多买一单位最划算"。
- **λ 的多种诠释**: 数学上是乘子, 经济学上是价格, 机器学习里常是正则化强度 ($L1/L2$ 的正则系数)。
- **KKT 是凸优化求解器的内核**: CVX、SDPT3 等求解器内部就在解 KKT 方程组。
- **"能不能写成凸"是建模的第一个战略决策**: 凸问题能保证全局最优 (KKT 充分), 非凸只能比较多个 KKT 点——所以 SVM、Lasso、逻辑回归都被设计成凸问题。

计算训练场

位置说明：本章对话负责“为什么”，这里负责“怎么算”。下面每题请动笔 10 分钟以上，先自己写，再对照完整解答。所有数值我都亲手验算过。

题 1（易→中）：拉格朗日乘子法解等式约束优化

题干：求 $\min f(x, y) = x^2 + y^2$, subject to $x + y = 1$ 。(a) 写出拉格朗日函数 $L(x, y, \lambda)$ 。(b) 求 $\partial L / \partial x$ 、 $\partial L / \partial y$ 、 $\partial L / \partial \lambda$ 并令它们为零，解出 x 、 y 、 λ 。(c) 给出最优值 f^* 与最优解，并验证梯度共线 $\nabla f = \lambda \nabla g$ 。

完整分步解答：

(a) 拉格朗日函数：第 1 步：目标 $f = x^2 + y^2$ ，约束写成 $g(x, y) = x + y - 1 = 0$ 。第 2 步： $L(x, y, \lambda) = f + \lambda \cdot g = x^2 + y^2 + \lambda(x + y - 1)$ 。

(b) 求驻点方程组：第 3 步： $\partial L / \partial x = 2x + \lambda$ （对 x 求导， $x^2 \rightarrow 2x$ ， $\lambda x \rightarrow \lambda$ ）。令 $= 0$ ： $2x + \lambda = 0$ 。第 4 步： $\partial L / \partial y = 2y + \lambda$ （对 y 求导）。令 $= 0$ ： $2y + \lambda = 0$ 。第 5 步： $\partial L / \partial \lambda = x + y - 1$ 。令 $= 0$ ： $x + y = 1$ 。第 6 步：由 $2x + \lambda = 0$ 与 $2y + \lambda = 0$ 相减： $2(x - y) = 0 \Rightarrow x = y$ 。第 7 步：代入 $x + y = 1$ ： $2x = 1 \Rightarrow x = 1/2$, $y = 1/2$ 。第 8 步：代入 $2x + \lambda = 0$ ： $\lambda = -2x = -1 \Rightarrow \lambda = -1$ 。

(c) 最优值与验证：第 9 步： $f^* = f(1/2, 1/2) = (1/4) + (1/4) = 1/2$ 。第 10 步：梯度共线验证： $\nabla f = (2x, 2y) = (1, 1)$ ； $\nabla g = (1, 1)$ 。 $\lambda \nabla g = -1 \cdot (1, 1) = (-1, -1) \neq \nabla f$ ？——注意 $\nabla f = (1, 1)$ ，而 $\lambda \nabla g = (-1, -1)$ ，两者**反向**。这是因为本问题 $\partial L / \partial x = 0$ 给出 $2x + \lambda = 0$ ，即 $\nabla f + \lambda \nabla g = 0 \Rightarrow \nabla f = -\lambda \nabla g$ 。取 $\lambda' = -\lambda = 1$ ，则 $\nabla f = 1 \cdot \nabla g$ ✓ 共线（ $\lambda' = 1$ 是“标准乘子”，满足 $\nabla f = \lambda' \nabla g$ ）。**共线成立，只是 λ 符号约定不同。**

答：(a) $L = x^2 + y^2 + \lambda(x + y - 1)$ ；(b) $x = y = 1/2$, $\lambda = -1$ ；(c) $f^* = 1/2$ ，梯度共线 $\nabla f = (1, 1) = 1 \cdot \nabla g$ ✓（ $\lambda' = 1$ ）。

常见错误：① 对 λ 求导时忘了“约束要写成 $g = 0$ 再乘 λ ”，直接对 $x + y = 1$ 的 1 处理错；② 解 $2x + \lambda = 0$ 与 $2y + \lambda = 0$ 时漏掉“相减得 $x = y$ ”这步，直接硬凑；③ 忘了验证梯度共线，或对“ λ 取负号”疑惑——只要 ∇f 与 ∇g 平行即可，乘子符号取决于 L 的约定，不改变几何结论。

题 2（中→难）：两个等式约束——完整方程组求解

题干：求 $\min f(x, y, z) = x^2 + y^2 + z^2$, subject to $x + y + z = 1$ 且 $x - y = 0$ 。(a) 写拉格朗日函数（两个乘子 λ_1 、 λ_2 ）。(b) 求所有偏导并令为零，解出 x 、 y 、 z 、 λ_1 、 λ_2 。(c) 给出最优值 f^* ，验证约束成立。

完整分步解答：

(a) 拉格朗日函数：第 1 步：约束 $g_1 = x + y + z - 1 = 0$, $g_2 = x - y = 0$ 。第 2 步： $L = f + \lambda_1 g_1 + \lambda_2 g_2 = x^2 + y^2 + z^2 + \lambda_1(x + y + z - 1) + \lambda_2(x - y)$ 。

(b) 求驻点方程组：第 3 步： $\partial L / \partial x = 2x + \lambda_1 + \lambda_2 = 0$ 。第 4 步： $\partial L / \partial y = 2y + \lambda_1 - \lambda_2 = 0$ 。第 5 步： $\partial L / \partial z = 2z + \lambda_1 = 0$ 。第 6 步： $\partial L / \partial \lambda_1 = x + y + z - 1 = 0$ 。第 7 步： $\partial L / \partial \lambda_2 = x - y = 0$ 。第 8 步：由 $\partial L / \partial x - \partial L / \partial y = (2x + \lambda_1 + \lambda_2) - (2y + \lambda_1 - \lambda_2) = 2(x - y) + 2\lambda_2 = 0$ 。由第 7 步 $x - y = 0$, 得 $\lambda_2 = 0$ 。第 9 步：由 $\partial L / \partial x (\lambda_2=0) : 2x + \lambda_1 = 0 \Rightarrow \lambda_1 = -2x$ 。由 $\partial L / \partial z : 2z - 2x = 0 \Rightarrow z = x$ 。第 10 步：由第 7 步 $x - y = 0 \Rightarrow x = y$ 。结合 $z = x$, 得 $x = y = z$ 。第 11 步：代入 $x + y + z = 1 : 3x = 1 \Rightarrow x = y = z = 1/3$ 。第 12 步： $\lambda_1 = -2 \cdot (1/3) = -2/3$, $\lambda_2 = 0$ 。

(c) 最优值：第 13 步： $f^* = f(1/3, 1/3, 1/3) = 3 \cdot (1/9) = 1/3$ 。第 14 步：验证约束： $1/3 + 1/3 + 1/3 = 1 \checkmark$; $1/3 - 1/3 = 0 \checkmark$ 。

答：(a) $L = x^2 + y^2 + z^2 + \lambda_1(x + y + z - 1) + \lambda_2(x - y)$; (b) $x = y = z = 1/3$, $\lambda_1 = -2/3$, $\lambda_2 = 0$; (c) $f^* = 1/3$, 约束均满足 $\checkmark$ 。

常见错误：① 写 L 时把两个约束乘同一个 λ , 或漏写第二个约束的乘子 λ_2 ; ② 解方程组时不会用"两式相减"消去 λ , 而是硬代数死算; ③ 忘了" $x - y = 0 \Rightarrow x = y$ "这一约束其实约束了对称性, 结果应满足 $x = y = z$ (两个约束叠加导致的强对称)。

题 3 (中→难)：不等式约束——验证 KKT 条件 (含边界情形)

题干：求 $\min f(x, y) = x^2 + y^2$, subject to $x + y \geq 1$ 。(a) 说明为什么最优点会落在边界 $x + y = 1$ 上 (而不是可行域内部)。(b) 在边界情形 (约束起作用) 用拉格朗日解出候选点, 并写出 KKT 四条逐一验证。(c) 验证这是全局最优 (用凸性充分性), 并给出影子价格的直观意义。

完整分步解答：

(a) 最优在边界：第 1 步：若无约束, 全局最小在 $(0, 0)$, $f = 0$, 但 $(0, 0)$ 处 $x + y = 0 < 1$, **不在可行域** (违反 $x + y \geq 1$)。第 2 步：可行域是半平面 $x + y \geq 1$ 。 $f = x^2 + y^2$ 是"离原点越远越大", 在可行域内离原点最近的点在**边界直线 $x + y = 1$ 上** (半平面内离原点最近的点是原点到该直线的垂足)。第 3 步：故最优点在边界 (约束起作用), 可当等式约束处理。

(b) KKT 验证：第 4 步：边界上求 $\min x^2 + y^2$, s.t. $x + y = 1$ 。拉格朗日 $L = x^2 + y^2 + \lambda(x + y - 1)$ 。第 5 步： $\partial L / \partial x = 2x + \lambda = 0$, $\partial L / \partial y = 2y + \lambda = 0 \Rightarrow x = y$; $\partial L / \partial \lambda = x + y - 1 = 0 \Rightarrow x = y = 1/2$ 。第 6 步：候选点 $x^* = (1/2, 1/2)$ 。用 KKT 四件套验证 (约束写 $g = x + y - 1 \geq 0$, $\mu \geq 0$, 驻点 $\nabla f - \mu \nabla g = 0$) :

- 第 7 步 **(S) 驻点：** $\nabla f = (2x, 2y) = (1, 1)$, $\nabla g = (1, 1)$ 。取 $\mu = 1$: $\nabla f - \mu \nabla g = (1, 1) - 1 \cdot (1, 1) = (0, 0) \checkmark$ 。
- 第 8 步 **(P) 原始可行：** $g(x^*) = 1/2 + 1/2 - 1 = 0 \geq 0 \checkmark$ 。
- 第 9 步 **(D) 对偶可行：** $\mu = 1 \geq 0 \checkmark$ 。

- 第 10 步 **(C) 互补松弛**: $\mu \cdot g(x^*) = 1 \cdot 0 = 0 \checkmark$ 。第 11 步: 四条全满足, $x^* = (1/2, 1/2)$ 是 KKT 点。

(c) 全局最优与影子价格: 第 12 步: f 是凸函数 (Hessian = $[[2,0],[0,2]]$ 正定); 可行域 $\{x+y \geq 1\}$ 是半平面, 凸集。由**定理 2 (KKT 充分性)**, KKT 点 x^* 是**全局最优**。第 13 步: $f^* = f(1/2, 1/2) = 1/4 + 1/4 = 1/2$ 。第 14 步: 影子价格直观: $\mu = 1$ 表示"约束右端 1 每增加一单位 ($x+y \geq 1$ 变成 ≥ 2), 最优值改善量"——具体验证: 若约束改为 $x+y \geq 2$, 最优点在直线 $x+y=2$ 上离原点最近, 即 $(1,1)$, $f = 2$ 。从 $1/2$ 增到 2 , 约束从 1 增到 2 (增 1 单位), f^* 从 0.5 增到 2 , 增量约 1.5 —— **$\mu = 1$ 度量了这一"边际价格"的方向与量级 (min 问题中"更严约束"会提高 f^* , μ 反映其敏感度)**。(影子价格的精确数值受凸性/二次结构影响, 这里重在直观。)

答: (a) $(0,0)$ 不在可行域, 半平面内离原点最近点在边界 $x+y=1$ 上; (b) $x^* = (1/2, 1/2)$, $\mu=1$, KKT 四条全满足; (c) $f^* = 1/2$, 凸 + 凸可行域 $\Rightarrow$ KKT 充分 $\Rightarrow$ 全局最优; $\mu=1$ 给出约束"边际价格"直观。

常见错误: ① 忘记"无约束最优 $(0,0)$ 不在可行域", 直接报 $f=0$; ② 互补松弛理解错——**约束起作用 ($g=0$) 时 μ 可非零, 约束不起作用 ($g>0$) 时 μ 必为 0**; ③ 验证 (S) 时方向搞错 (不等式约束是 $\nabla f - \sum \mu \nabla g = 0$, 不是 $\nabla f + \lambda \nabla g = 0$), 导致符号错。

向导便签

这一章咱们干了什么: 从"滚珠只能沿一条沟滚, 不能翻出去"这个问题出发, 把"锁链"写成等式约束 $\min f \text{ s.t. } g=0$; 发现"被允许的方向"垂直于约束梯度, 从而推出最优点处**梯度共线 $\nabla f = \lambda \nabla g$** ; 用拉格朗日函数 $L = f + \lambda g$ 把约束优化变成无约束; 再推广到不等式约束, 得到**KKT 四件套**(驻点 + 原始可行 + 对偶可行 + 互补松弛), 并理解 λ 是"影子价格"; 最后, 当目标凸、可行域凸时, KKT 是全局最优的充分条件。

钉死一句话: **等式约束看 $\nabla f = \lambda \nabla g$ (梯度共线), 不等式约束看 KKT 四条; λ 是约束的边际价值 (影子价格); 目标凸 + 可行域凸 $\Rightarrow$ 满足 KKT 就是全局最优。**

记住一个边界: **KKT 在不凸时只是必要条件**——满足它未必全局最优; 还有约束正则性 ($\nabla g \neq 0$) 是梯度共线证明的前提, 退化约束要特殊处理。

造物主手记

我曾踩的坑:

我一开始在题 1 里算出 $\lambda = -1$ 就慌了——因为我背过的"标准公式"是 $\nabla f = \lambda \nabla g$, 可我这里 $\nabla f = (1,1)$ 、 $\lambda \nabla g = (-1,-1)$, 方向反了。老谋点破: **这取决于拉格朗日函数写 $L = f + \lambda g$ 还是 $L = f - \lambda g$, $\partial L / \partial x = 0$ 给出 $\nabla f = -\lambda \nabla g$, 几何上两梯度仍然共线, 符号只是约定问题, 别被它吓住。**另一

个坑是题 3：我差点直接报“无约束最小值 $f=0$ ”，忘了 $(0,0)$ 根本不满足 $x+y \geq 1$ ——**可行域这道坎，比目标函数还容易绊人**。还有互补松弛，我一开始搞不清“该让 $\mu=0$ 还是 $g=0$ ”，忘了“约束起作用时 $g=0$ 、 μ 可非零”这条。

顿悟时刻：

真正让我开窍的是影子价格。老谟让我把 λ 从“凑数的系数”想成“这条锁链值多少钱”——我立刻想起投资里“边际收益”的概念，突然明白： **λ 不是数学的累赘，它是‘约束的谈判价’**。资源多给一单位值多少、该不该增加预算，答案就写在 λ 里。那一刻我意识到，数学符号一旦找到现实映射，就再也不是干巴巴的字母。而且，把 KKT 从‘必要’升到‘充分’要靠凸性，跟第 6 章‘凸 $\Rightarrow$ 局部=全局’是同一条命脉——**全书学到最后，‘凸性’就是那把万能钥匙**。

自测题

计算题须动笔完成，附完整解答自核；概念题用于检查理解。

题 A（计算，易 $\rightarrow$ 中）：拉格朗日乘子法

求 $\min f(x, y) = x^2 + 2y^2$, subject to $x + y = 3$ 。(a) 写拉格朗日函数。(b) 解驻点方程组，求 x 、 y 、 λ 。(c) 求 f^* ，验证梯度共线。

完整解答：(a) $L = x^2 + 2y^2 + \lambda(x + y - 3)$ 。(b) $\partial L/\partial x = 2x + \lambda = 0$; $\partial L/\partial y = 4y + \lambda = 0$; $\partial L/\partial \lambda = x + y - 3 = 0$ 。由前两式： $2x = 4y \Rightarrow x = 2y$ 。代入 $x + y = 3$: $2y + y = 3 \Rightarrow 3y = 3 \Rightarrow y = 1$, $x = 2$ 。 $\lambda = -2x = -4 \Rightarrow \lambda = -4$ 。(c) $f^* = f(2, 1) = 4 + 2 = 6$ 。梯度共线： $\nabla f = (2x, 4y) = (4, 4)$; $\nabla g = (1, 1)$; $4 \cdot (1, 1) = (4, 4) = \nabla f \checkmark$ ($\lambda' = 4$)。验证约束 $x+y = 3 \checkmark$ 。

题 B（计算，中 $\rightarrow$ 难）：两个等式约束

求 $\min f(x, y, z) = x^2 + y^2 + z^2$, subject to $x + y + z = 2$ 且 $x - y - z = 0$ 。(a) 写拉格朗日函数 (λ_1, λ_2)。(b) 解方程组求 x 、 y 、 z 、 λ_1 、 λ_2 。(c) 求 f^* 。

完整解答：(a) $L = x^2 + y^2 + z^2 + \lambda_1(x + y + z - 2) + \lambda_2(x - y - z)$ 。(b) $\partial L/\partial x = 2x + \lambda_1 + \lambda_2 = 0$; $\partial L/\partial y = 2y + \lambda_1 - \lambda_2 = 0$; $\partial L/\partial z = 2z + \lambda_1 - \lambda_2 = 0$ 。由 $\partial L/\partial y$ 与 $\partial L/\partial z$: $2y + \lambda_1 - \lambda_2 = 2z + \lambda_1 - \lambda_2 \Rightarrow y = z$ 。由 $\partial L/\partial x - \partial L/\partial y = 2(x - y) + 2\lambda_2 = 0 \Rightarrow \lambda_2 = -(x - y)$ 。由 $\partial L/\partial x$: $2x + \lambda_1 + \lambda_2 = 0$; $\partial L/\partial y$: $2y + \lambda_1 - \lambda_2 = 0$ 。相加: $2(x+y) + 2\lambda_1 = 0 \Rightarrow \lambda_1 = -(x+y)$ 。又约束 $x - y - z = 0$ 且 $y = z \Rightarrow x - 2y = 0 \Rightarrow x = 2y$ 。约束 $x + y + z = 2$ 且 $y = z$ 、 $x = 2y \Rightarrow 2y + y + y = 4y = 2 \Rightarrow y = 1/2$, $z = 1/2$, $x = 1$ 。 $\lambda_1 = -(1 + 1/2) = -3/2$; $\lambda_2 = -(x - y) = -(1 - 1/2) = -1/2$ 。(c) $f^* = f(1, 1/2, 1/2) = 1 + 1/4 + 1/4 = 3/2$ 。验证约束: $x+y+z = 1+0.5+0.5 = 2 \checkmark$; $x-y-z = 1-0.5-0.5 = 0 \checkmark$ 。

题 C（概念，检查理解）：KKT 与凸性充分性

老谟问造物主：(1) 为什么"凸目标 + 凸可行域"能让 KKT 从必要条件升格为充分条件？(2) 不凸时，满足 KKT 的点可能是全局最优吗？可能不是吗？分别给一个例子。(3) 互补松弛的工程意义是什么（"这条锁是紧是松"）？

完整解答：(1) 凸函数满足一阶刻画 $f(y) \geq f(x) + \nabla f(x) \cdot (y-x)$ ，用它 + KKT 驻点条件 + 互补松弛，可对任意可行点 y 推出 $f(y) \geq f(x^*)$ ——从而 x^* 是全局最优（走廊定理 2）。**凸性保证了"KKT 点的下界性"，让"满足必要条件"等于"达到最优"**。(2) 可能：若某个全局最优恰好也满足 KKT（任何最优都满足 KKT 必要），它当然既是 KKT 点又是全局最优。可能不是：非凸问题里，KKT 点可能是局部极小或鞍点，不是全局最优——如 $f = x^3 - 3xy + y^3$ 的某些驻点满足 KKT 却只是鞍点/局部解。**不凸时，KKT 只能筛出"候选"，不能保证"最优"**。(3) 互补松弛 $\mu \cdot g = 0$ 告诉你每条约束"有没有真正锁住你"：约束起作用（ $g=0$ ）且乘子 $\mu > 0$ ，说明它在限制最优解（紧锁）；约束不起作用（ $g > 0$ ）则 $\mu = 0$ ，说明它没在限制（松锁，可以忽略）。**工程里靠它判断"哪个约束真正稀缺、该优先加资源"**。

预告

这一章，你把"怎么找最优"从无约束升级到了带锁链的约束优化：拉格朗日乘子、KKT、影子价格——高维求最优的地基，到这里整块铺完了。

可你有没有注意到一个潜伏已久的问题：**这一路我们都在'确定的世界'里求最优——函数 f 是什么、约束 g 是什么，都清清楚楚**。可现实里，你常常连"目标长什么样、数据准不准"都不确定：掷骰子、抽样本、噪声、误差……**信息不全的时候，你怎么做决策？**

下一章，我们彻底换战场——从"怎么算"转到"面对不确定，怎么用有限的信息做有依据的推断"。那是《概率统计与信息》的世界：从随机变量、期望，一路走到用数据估计未知、用信息度量不确定性。

下一册，让数学睁开眼睛，面对不确定。

《多元微积分与凸优化》· 计算答案速查页

本页汇总册内各章「计算训练场」与「自测题」的关键终值，供自测后核对。**使用纪律**：先动笔算完再对答案，不要边算边翻。若你算出的数与本页不符，先回看你的步骤，再回看章节解答——两种都符合才是真懂。标注：✓ 表示该值已逐项核算一致。

第 01 章 · 多元函数与偏导

计算训练场

- 题 1 ($f=x^2y+\sin y$) : $f_x=2xy$ 、 $f_y=x^2+\cos y$ ✓; $\nabla f(1,0)=(0,2)$ ✓; $D_u f(\text{沿 } (1,1)/\sqrt{2})=\sqrt{2}\approx 1.414$ ✓ (公式法与定义法一致)
- 题 2 ($f=x^2y^3+xz^2$) : $\nabla f(1,1,2)=(6,3,4)$ 、 $|\nabla f|=\sqrt{61}\approx 7.810$ ✓; $D_v f(\text{沿 } (1,1,1)/\sqrt{3})=13/\sqrt{3}\approx 7.506$ ✓; 最陡方向 $(6,3,4)/\sqrt{61}$ 、最大变化率 $\sqrt{61}$ ✓
- 题 3: (a) $\nabla f(1,1)=(2,2)$ 、等高线切线 $(1,-1)$ 、点积 0 垂直 ✓; (b) $f_x=f_y=0$ 但沿 $y=2x$ 极限 $2/5$ ，不连续 ✓
- 自测 A: $\nabla f(1,1)=(e+1, e-1)\approx(3.718, 1.718)$ ✓; $D_u f(\text{沿 } (0,1))=e-1\approx 1.718=f_y$ ✓
- 自测 B: $\nabla f(2,1)=(4,1)$ 、 $D_u=16/5=3.2$ 、 $|\nabla f|=\sqrt{17}\approx 4.123$ ✓ (定义法验算一致)

第 02 章 · 多元链式法则与多元泰勒

计算训练场

- 题 1 ($f=x^2y, x=t^2, y=t^3$) : $df/dt=7t^6$ ✓, $t=1$ 处 $=7$ ✓ (直接代入 t^7 验证一致)
- 题 2 ($f=e^{xy}, x=s^2+t, y=st$, 在 $(1,2)$) : $\partial f/\partial s=10e^6\approx 4034.3$ 、 $\partial f/\partial t=5e^6\approx 2017.1$ ✓ ($e^6\approx 403.43$, 直接代入 $e^{(s^3t+st^2)}$ 验证一致)
- 题 3 ($f=e^x \cos y$, 在 $(0,0)$) : $\nabla f=(1,0)$ 、 $H=[[1,0],[0,-1]]$ ✓; 展开 $1+x+\frac{1}{2}x^2-\frac{1}{2}y^2$ ✓; $(0.1,0.1)$ 处近似 1.1 vs 真实 ≈ 1.0996 、相对误差 $\approx 0.036\%$ ✓
- 自测 A ($f=\sin(xy), x=2t, y=t^2$) : $df/dt=6t^2\cos(2t^3)$ 、 $t=1$ 处 $6\cos 2\approx -2.497$ ✓
- 自测 B ($f=x^2y-y^3$, 在 $(1,1)$) : $\nabla f=(2,-2)$ 、 $H=[[2,2],[2,-6]]$ ✓; 展开 $2h_1-2h_2+h_1^2+2h_1h_2-3h_2^2$ ✓; $(0.9,1.1)$ 近似与真实均 -0.44 ✓

第 03 章 · 多元积分

计算训练场

- 题 1: $\iint_{[0,1] \times [0,2]} (x+y) \, dA = 3 \checkmark$ (先 x 后 y 与先 y 后 x 双序一致)
- 题 2: $\int_0^1 \int_x^1 \sin(y^2) \, dy \, dx = (1 - \cos 1)/2 \approx 0.2298 \checkmark$ (换序后 $\int_0^1 y \cdot \sin(y^2) \, dy$)
- 题 3: $\iint_{\{x^2+y^2 \leq 4\}} (x^2+y^2) \, dA = 8\pi \approx 25.133 \checkmark$; 圆盘面积 $4\pi \checkmark$; 半径 3 面积 $9\pi \checkmark$
- 自测 A: $\iint_{[0,2] \times [1,3]} xy \, dA = 8 \checkmark$
- 自测 B: (a) $\int_0^1 \int y^1 e^{x^2} \, dx \, dy = (e-1)/2 \approx 0.8591 \checkmark$; (b) $\iint_{\{x^2+y^2 \leq 1\}} (x^2+y^2) \, dA = \pi/2 \approx 1.5708 \checkmark$

第 04 章 · 凸集与凸函数

计算训练场

- 题 1: (a) $f=x^2$ 凸性差 $\Delta = \lambda(1-\lambda)(x-y)^2 \geq 0 \checkmark$; (b) $f=x^2+y^2$ 凸性差 $\Delta = \lambda(1-\lambda)[(x_1-x_2)^2 + (y_1-y_2)^2] \geq 0 \checkmark$; (c) x^3 非凸: 取 $x=-1, y=0, \lambda=1/2$, $f(-0.5) = -0.125 > -0.5$ (违反凸性) $\checkmark$
- 题 2: (a) e^x 严格凸 $\checkmark$; (b) x^4 凸但不严格 ($x=0$ 处二阶导 0) $\checkmark$; (c) $-x^2$ 非凸 $\checkmark$; (d) $H = [[2,0],[0,2]]$ 正定 $\checkmark$
- 题 3: (a) Jensen: $f(x)+f(y) \geq 2f((x+y)/2) \checkmark$; (b) $\nabla f = (2x, 2y) = 0 \rightarrow (0,0) \checkmark$; (c) 一阶刻画验证 $\checkmark$
- 自测 A: $f=x^2+2x$ 凸 (线性项 $\lambda \cdot 2x + (1-\lambda)2y$ 恰好抵消), $\Delta = \lambda(1-\lambda)(x-y)^2 \checkmark$
- 自测 B: (c) 一阶刻画验证: $0 \geq -2$ ($\nabla f(1,1) = (2,2)$) $\checkmark$

第 05 章 · 凸性判定与二次型

计算训练场

- 题 1: (a) $f=x^2+xy+y^2$: $H = [[2,1],[1,2]]$ 、 $\Delta_1=2>0$ 、 $\Delta_2=3>0$ 正定, 严格凸 $\checkmark$; (b) $f=x^2-y^2$: $\Delta_2=-4<0$ 不定 $\checkmark$; (c) $f=x^2$: $\Delta_2=0$, 特征值 2, 0 半正定 $\checkmark$
- 题 2 ($f=x^2+y^2+2z^2+2xy$): $H = [[2,2,0],[2,2,0],[0,0,4]]$ 、特征值 0, 4, 4 半正定 $\checkmark$ (主子式 2/0/0, 交叉主子式 8/8/0 全非负)
- 题 3 ($f=x^2+axy+y^2$, $H(a) = [[2,a],[a,2]]$, 特征值 $2 \pm a$): 正定 $\Leftrightarrow |a| < 2$; 半正定 $\Leftrightarrow |a| \leq 2$; 不定 $\Leftrightarrow |a| > 2 \checkmark$ ($a=1$ 正定、 $a=2$ 半正定、 $a=3$ 不定)

- 自测 A: $f=x^2+4xy+y^2$: $H=[[2,4],[4,2]]$ 、 $\Delta_2=-12<0$ 不定, 特征值 **6, -2** ✓
- 自测 B: $x^2+axy+y^2$, $a=2$ 时半正定、 f 不严格凸 (沿 $y=-x$ 方向平) ✓
- 自测 C (概念): 半正定判据反例 $[[0,0],[0,-1]]$ (顺序主子式全非负但不半正定, $x=(0,1)$ 得 $x^T A x=-1$) ; 非对称 $[[1,100],[0,1]]$ (特征值全 1 却不定, $x=(1,-1)$ 得 $x^T A x=-98$)

第 06 章 · 无约束优化与梯度下降

计算训练场

- 题 1 ($f=x^2+y^2$, 起点 $(1,1)$, $\eta=0.1$) : 3 步 **(0.8,0.8) $f=1.28 \rightarrow (0.64,0.64) f=0.8192 \rightarrow (0.512,0.512) f=0.524288$** ✓ 单调下降; (d) 收敛界 $L||x_0-x^*||^2/(2k)=0.667 \geq$ **实际 0.5243** ✓
- 题 2: (a) $\eta=1.1$ 发散: $f \rightarrow 2.88 \rightarrow 4.1472 \rightarrow 5.971968$ ✓; (b) $\eta=0.01$ 龟速: $x_3 \approx$ **(0.9412, 0.9412) $f \approx 1.7717$** ✓; (c) 精确线搜索 $\eta^*=0.5$ 一步到位 ✓
- 题 3 ($f=x^2+y^2+xy$, 起点 $(1,0)$, $\eta=0.2$) : 3 步 **(0.6,-0.2) $f=0.28 \rightarrow (0.4,-0.24) f=0.1216 \rightarrow (0.288,-0.224) f=0.068608$** ✓; H 特征值 **1, 3** 凸 ✓; 安全区 $1/L=1/3 \approx 0.333$, $\eta=0.2$ 安全 ✓
- 自测 A ($f=x^2+2y^2$) : 3 步 $(0.6,0.2) f=0.44 \rightarrow (0.36,0.04) f=0.1328 \rightarrow (0.216,0.008) f=0.046784$ ✓; $L=4$ 界 $1.333>$ 实际 ✓
- 自测 B: (a) $\eta=1.2 \rightarrow x_1=(-1.4,-3.8) f=30.84$ ✓; (b) $\eta=0.05$: $f(1,1)=3 \rightarrow 2.09 \rightarrow 1.4753$ ✓; (c) 精确线搜索 $g(\eta)=3-20\eta+36\eta^2$, $\eta^*=5/18 \approx 0.2778$ ✓

第 07 章 · 高维景观: 鞍点 vs 局部最优

计算训练场

- 题 1: $f_1=x^2+y^2$ 在 $(0,0)$ **极小** (特征值 2,2) ✓; $f_2=-x^2-y^2$ **极大** $(-2,-2)$ ✓; $f_3=x^2-y^2$ **鞍点** $(2,-2)$ ✓
- 题 2 ($f=x^3+y^3-3xy$) : 驻点 **(0,0) 鞍点** ($H=[[0,-3],[-3,0]]$, $\lambda=\pm 3$) ✓; 驻点 **(1,1) 极小** ($H=[[6,-3],[-3,6]]$, $\lambda=3,9$) ✓; $f(0,0)=0$ 、 $f(1,1)=-1$ ✓
- 题 3 ($f=x^2-y^2+z^2$) : 原点 **鞍点** ($H=\text{diag}(2,-2,2)$ 不定) ✓; 高维鞍点概率 **$(1/2)^3=1/8$** ✓
- 自测 A ($f=x^2-y^2+4xy$) : 原点 **鞍点** ($H=[[2,4],[4,-2]]$, $\lambda=\pm\sqrt{20} \approx \pm 4.472$) ✓
- 自测 B/C: 概念 (x^4 半定需高阶判定; 非光滑边界)

第 08 章 · 约束优化：拉格朗日乘子与 KKT

计算训练场

- 题 1 ($\min x^2+y^2$ s.t. $x+y=1$) : $\mathbf{x}=\mathbf{y}=1/2$, $\mathbf{f}=1/2$, $\lambda=-1$ ✓ (梯度共线 $\nabla f=(1,1)=1\cdot\nabla g$)
- 题 2 ($\min x^2+y^2+z^2$ s.t. $x+y+z=1$ 且 $x-y=0$) : $\mathbf{x}=\mathbf{y}=\mathbf{z}=1/3$, $\mathbf{f}=1/3$, $\lambda_1=-2/3$, $\lambda_2=0$ ✓
- 题 3 ($\min x^2+y^2$ s.t. $x+y\geq 1$) : 边界 $\mathbf{x}=\mathbf{y}=1/2$, $\mathbf{f}=1/2$, $\mu=1$, KKT 四件套全部满足 ✓; 影子价格: 约束改 $x+y\geq 2$ 时最优点 $(1,1)$ 、 $\mathbf{f}=2$, $\partial f^*/\partial b=b$ ($b=1$ 处精确等于 $\mu=1$) ✓
- 自测 A ($\min x^2+2y^2$ s.t. $x+y=3$) : $\mathbf{x}=2$, $\mathbf{y}=1$, $\mathbf{f}=6$, $\lambda=-4$ ✓ ($\nabla f=(4,4)=4\cdot\nabla g$)
- 自测 B ($\min x^2+y^2+z^2$ s.t. $x+y+z=2$ 且 $x-y-z=0$) : $\mathbf{x}=1$, $\mathbf{y}=\mathbf{z}=1/2$, $\mathbf{f}=3/2$, $\lambda_1=-3/2$, $\lambda_2=-1/2$ ✓
- 自测 C: 概念 (退化约束 $\nabla g=0$ 、非凸时 KKT 仅必要)

使用说明

1. **难度标尺**: 每题 (易/中/难) 见各章计算训练场题干; 本页只给终值, 不重复解答过程。
2. **链式互证**: 第 02 章多元泰勒二次多项式"展开精确等于原函数" ($h_1^2+h_1h_2+h_2^2$ 逐项一致); 第 06 章收敛界 $0.667\geq$ 实际 0.5243 ; 第 08 章影子价格 $\partial f^*/\partial b=b$ 与 μ 精确相等——建议算完用另一法验证。
3. **凸性主线提醒**: 第 04 章定义凸性 ($f(\lambda x+(1-\lambda)y)\leq\lambda f(x)+(1-\lambda)f(y)$), 第 05 章给判定工具 (海森半正定/主子式/特征值), 第 06 章靠凸性证梯度下降收敛 (局部=全局), 第 07 章靠海森符号区分鞍点与极值——"**凸性**"是贯穿第 04–08 章的主线, 本页终值可当这条主线的"**路标**".
4. 如发现本页某值与章节解答不一致, 先回看章节——本页终值已逐项核算, 若确认是章节解答有误, 欢迎反馈。

《多元微积分与凸优化》· 苏格拉底对话体教材 · 全册 8 章 · 2026